

Enunciado

Proyecto Integrador: Regresión

Predicción de una respuesta continua

Propósito

Definir desde cero un problema de **predicción de una respuesta continua** en Ingeniería Industrial y construir un sistema reproducible que integre las tres unidades del curso: los **fundamentos** (decisión, población, incertidumbre e inferencia), la **regularización** (lineal, ridge, lasso, elastic-net, splines/GAM y validación cruzada) y los **ensembles** (árbol, Random Forest, boosting y combinación).

Dinámica del curso. El curso contempla dos casos de estudio. El **Caso 1 (Regresión)** es común a todos los equipos. En el **Caso 2**, cada equipo recibe aleatoriamente una variante: **clasificación supervisada** o **clasificación no supervisada**. Este documento corresponde a el **Caso 1: Regresión**.

1. Problema y dataset

Cada equipo selecciona un problema realista de Ingeniería Industrial (demanda, consumo energético, tiempos de proceso, costos, calidad dimensional, productividad, degradación o mermas) y busca un dataset externo. Antes de modelar, entrega una propuesta de una página con: contexto, usuario y decisión apoyada; unidad de análisis (entidad y momento), respuesta continua, instante de predicción, horizonte y población objetivo; fuente, enlace, licencia y responsable; tamaño, variables, período y criterios de inclusión; y riesgos iniciales (leakage, sesgo, dependencia, calidad). Mínimo sugerido: 1.000 observaciones utilizables y al menos ocho variables informativas. No se permiten datasets usados en clases.

2. Métodos mínimos

1. baseline (media, valor previo o promedio por grupo)
2. regresión lineal (OLS) con diagnóstico de residuos y multicolinealidad
3. ridge, lasso y elastic-net
4. modelo flexible: splines o GAM

5. árbol de regresión y Random Forest
6. Gradient Boosting o XGBoost
7. combinación de modelos (averaging o stacking)

Cada exclusión debe justificarse con evidencia (error fuera de muestra, estabilidad o interpretabilidad).

3. Pregunta de decisión

¿Qué modelo predice mejor la respuesta continua fuera de muestra, con qué error e incertidumbre, y qué complejidad se justifica frente a un baseline?

4. Protocolo

- Diseñar una partición coherente con el uso futuro (temporal, por grupos o aleatoria).
- Estimar al menos una relación con intervalo de confianza y distinguir significancia de relevancia.
- Seleccionar hiperparámetros (λ , α , nudos, mtry, profundidad, shrinkage) por validación cruzada.
- Ajustar imputación, codificación, escalamiento y selección dentro de cada fold; fijar semillas.
- Comparar siempre frente a un baseline o solución de referencia, con incertidumbre.
- Congelar el sistema antes de abrir el test y evaluar al menos un subgrupo relevante.

Integridad

El uso anticipado del test, el preprocesamiento global o la selección con test invalidan la evaluación de generalización. Una buena métrica no compensa fuga de información ni la ausencia de baseline.

5. Equipo

Trabajo en equipo. No se asignan roles fijos: todos los integrantes deben participar en la presentación y poder defender cualquier parte (datos, código, método y decisiones).

6. Entregables y formato

```
equipo_regresion/
|-- presentacion.pdf    (o .pptx)    <- producto principal
|-- codigo/             (script reproducible en R)    <- producto principal
|-- informe.pdf         (respaldo, maximo 5 paginas)
'-- datos/ o enlace_descarga.txt
```

El **producto evaluado es la presentación y el script**; el informe es un respaldo (máximo 5 páginas, sin contar portada ni referencias). La presentación tiene **10 diapositivas, 10 minutos de exposición y 10 minutos de**

preguntas. El script debe ejecutarse desde una sesión limpia y reproducir los resultados. Un diccionario de variables se incluye como anexo del informe.

7. Evaluación

La evaluación se concentra en el **producto**: la calidad de la presentación (diseño y oratoria) y del script. El informe respalda las afirmaciones, pero no es el foco. La mayor ponderación recae en la **oratoria y dominio conceptual** y en la **calidad de la presentación**. Se califica con **dos notas independientes**: **cátedra** (presentación, oratoria, rigor e informe de respaldo) y **laboratorio** (el script). La ponderación detallada está en la rúbrica. Existe además una **co-evaluación** entre pares que puede reducir las notas individuales (ver rúbrica).

8. Tabla obligatoria (validación)

Modelo	Familia	RMSE	MAE	R^2	RMSE subgrupo	vs baseline
Baseline	—					
OLS	Lineal					
Ridge / Lasso / EN	Regularizado					
Splines / GAM	Flexible					
Random Forest	Ensemble					
Boosting	Ensemble					
Stacking / averaging	Ensemble					

El resultado final de test se presenta por separado, sólo para el sistema seleccionado, frente al baseline. Indique “n/a” donde una métrica no aplique.

9. Hitos

- **Semana 1:** propuesta aprobada; datos, auditoría, partición y baseline.
- **Semana 2:** modelos, validación y comparación preliminar.
- **Semana 3:** test, presentación, script e informe de respaldo.