

Enunciado

Proyecto Integrador: Clasificación Supervisada

Predicción de una respuesta categórica

Propósito

Definir desde cero un problema de **clasificación** (respuesta categórica) en Ingeniería Industrial y construir un sistema reproducible que compare modelos lineales, locales, de margen y de árboles, valide, calibre y convierta probabilidades en una **política operacional** compatible con costos y capacidad.

Dinámica del curso. El curso contempla dos casos de estudio. El **Caso 1 (Regresión)** es común a todos los equipos. En el **Caso 2**, cada equipo recibe aleatoriamente una variante: **clasificación supervisada** o **clasificación no supervisada**. Este documento corresponde a la variante **Clasificación supervisada** del **Caso 2**.

1. Problema y dataset

Cada equipo selecciona un problema realista de Ingeniería Industrial (mantenimiento, calidad, fraude, crédito, abandono, seguridad, cumplimiento o riesgo operacional) y busca un dataset externo. Antes de modelar, entrega una propuesta de una página con: contexto, usuario y decisión apoyada; unidad de observación, clases, clase positiva, instante de predicción, horizonte y población objetivo; fuente, enlace, licencia y responsable; tamaño, variables, período y criterios de inclusión; y riesgos iniciales (leakage, sesgo, dependencia, calidad). Mínimo sugerido: 1.000 observaciones utilizables y al menos ocho variables informativas. No se permiten datasets usados en clases.

2. Métodos mínimos

1. baseline (prevalencia, clase mayoritaria o regla vigente)
2. regresión logística
3. KNN
4. SVM lineal y SVM con kernel

5. árbol de clasificación
6. Random Forest
7. Gradient Boosting o XGBoost

Cada exclusión debe justificarse con evidencia (error fuera de muestra, estabilidad o interpretabilidad).

3. Pregunta de decisión

¿Qué modelo responde mejor al problema, con qué desempeño fuera de muestra y mediante qué umbral o política de priorización debería utilizarse?

4. Protocolo

- Diseñar una partición coherente con el uso futuro (temporal, por grupos o aleatoria).
- Aplicar el tratamiento del desbalance (pesos, SMOTE) sólo dentro de los folds de entrenamiento.
- Seleccionar el umbral o la política top- k por costos y capacidad, sin consultar el test.
- Ajustar imputación, codificación, escalamiento y selección dentro de cada fold; fijar semillas.
- Comparar siempre frente a un baseline o solución de referencia, con incertidumbre.
- Congelar el sistema antes de abrir el test y evaluar al menos un subgrupo relevante.

Integridad

El uso anticipado del test, el preprocesamiento global o la selección con test invalidan la evaluación de generalización. Una buena métrica no compensa fuga de información ni la ausencia de baseline.

5. Equipo

Trabajo en equipo. No se asignan roles fijos: todos los integrantes deben participar en la presentación y poder defender cualquier parte (datos, código, método y decisiones).

6. Entregables y formato

```
equipo_clasificacion/  
|-- presentacion.pdf    (o .pptx)    <- producto principal  
|-- codigo/             (script reproducible en R)    <- producto principal  
|-- informe.pdf         (respaldo, maximo 5 paginas)  
'-- datos/ o enlace_descarga.txt
```

El **producto evaluado es la presentación y el script**; el informe es un respaldo (máximo 5 páginas, sin contar portada ni referencias). La presentación tiene **10 diapositivas, 10 minutos de exposición y 10 minutos de**

preguntas. El script debe ejecutarse desde una sesión limpia y reproducir los resultados. Un diccionario de variables se incluye como anexo del informe.

7. Evaluación

La evaluación se concentra en el **producto**: la calidad de la presentación (diseño y oratoria) y del script. El informe respalda las afirmaciones, pero no es el foco. La mayor ponderación recae en la **oratoria y dominio conceptual** y en la **calidad de la presentación**. Se califica con **dos notas independientes**: **cátedra** (presentación, oratoria, rigor e informe de respaldo) y **laboratorio** (el script). La ponderación detallada está en la rúbrica. Existe además una **co-evaluación** entre pares que puede reducir las notas individuales (ver rúbrica).

8. Tabla obligatoria (validación)

Modelo	ROC-AUC	PR-AUC	Log-loss	Precision	Recall	F1	Costo
Baseline							
Logística							
KNN							
SVM lineal / kernel							
Árbol							
Random Forest							
Boosting							

El resultado final de test se presenta por separado, sólo para el sistema seleccionado, frente al baseline. Indique “n/a” donde una métrica no aplique.

9. Hitos

- **Semana 1:** propuesta aprobada; datos, auditoría, partición y baseline.
- **Semana 2:** modelos, validación y comparación preliminar.
- **Semana 3:** test, presentación, script e informe de respaldo.