

Enunciado

Proyecto Integrador: Clasificación No Supervisada

Descubrimiento de estructura mediante clustering

Propósito

Definir desde cero un problema de **segmentación** sin etiquetas en Ingeniería Industrial y construir un sistema reproducible que primero pregunte si existe estructura (test de Hopkins) y luego compare **hard clustering** (K-means, PAM, DBSCAN, HDBSCAN), **soft clustering** (GMM) y **clustering jerárquico**, validando, evaluando estabilidad e interpretando los grupos.

Dinámica del curso. El curso contempla dos casos de estudio. El **Caso 1 (Regresión)** es común a todos los equipos. En el **Caso 2**, cada equipo recibe aleatoriamente una variante: **clasificación supervisada** o **clasificación no supervisada**. Este documento corresponde a la variante **Clasificación no supervisada** del **Caso 2**.

1. Problema y dataset

Cada equipo selecciona un problema realista de Ingeniería Industrial (segmentación de clientes o productos, perfiles de operación o demanda, regímenes de proceso, agrupamiento de sensores o zonas de riesgo) y busca un dataset externo. Antes de modelar, entrega una propuesta de una página con: contexto, usuario y decisión apoyada; unidad de observación, variables y tipos, escala y población objetivo (sin etiqueta objetivo); fuente, enlace, licencia y responsable; tamaño, variables, período y criterios de inclusión; y riesgos iniciales (leakage, sesgo, dependencia, calidad). Mínimo sugerido: 1.000 observaciones utilizables y al menos ocho variables informativas. No se permiten datasets usados en clases.

2. Métodos mínimos

1. distancia justificada y test de Hopkins (tendencia al agrupamiento)
2. K-means y PAM / K-medoids
3. DBSCAN y HDBSCAN

4. Gaussian Mixture Models (EM, selección por BIC/ICL)
5. clustering jerárquico con al menos dos linkages
6. solución de referencia (aleatoria) para contrastar la validación

Cada exclusión debe justificarse con evidencia (error fuera de muestra, estabilidad o interpretabilidad).

3. Pregunta de decisión

¿Existe estructura en los datos y, de existir, qué método y cuántos grupos entregan una segmentación estable, interpretable y útil para la decisión?

4. Protocolo

- Diseñar una partición coherente con el uso futuro (temporal, por grupos o aleatoria).
- Usar la **misma** distancia en Hopkins, en el algoritmo y en la validación interna.
- Evaluar estabilidad al variar semilla, submuestra o distancia (Rand/ARI, NMI, VI).
- Ajustar imputación, codificación, escalamiento y selección dentro de cada fold; fijar semillas.
- Comparar siempre frente a un baseline o solución de referencia, con incertidumbre.
- Congelar el sistema antes de abrir el test y evaluar al menos un subgrupo relevante.

Integridad

El uso anticipado del test, el preprocesamiento global o la selección con test invalidan la evaluación de generalización. Una buena métrica no compensa fuga de información ni la ausencia de baseline.

5. Equipo

Trabajo en equipo. No se asignan roles fijos: todos los integrantes deben participar en la presentación y poder defender cualquier parte (datos, código, método y decisiones).

6. Entregables y formato

```
equipo_clustering/
|-- presentacion.pdf    (o .pptx)    <- producto principal
|-- codigo/             (script reproducible en R)    <- producto principal
|-- informe.pdf         (respaldo, maximo 5 paginas)
'-- datos/ o enlace_descarga.txt
```

El **producto evaluado es la presentación y el script**; el informe es un respaldo (máximo 5 páginas, sin contar portada ni referencias). La presentación tiene **10 diapositivas, 10 minutos de exposición y 10 minutos de**

preguntas. El script debe ejecutarse desde una sesión limpia y reproducir los resultados. Un diccionario de variables se incluye como anexo del informe.

7. Evaluación

La evaluación se concentra en el **producto**: la calidad de la presentación (diseño y oratoria) y del script. El informe respalda las afirmaciones, pero no es el foco. La mayor ponderación recae en la **oratoria y dominio conceptual** y en la **calidad de la presentación**. Se califica con **dos notas independientes**: **cátedra** (presentación, oratoria, rigor e informe de respaldo) y **laboratorio** (el script). La ponderación detallada está en la rúbrica. Existe además una **co-evaluación** entre pares que puede reducir las notas individuales (ver rúbrica).

8. Tabla obligatoria (validación)

Método	Familia	Distancia	K/estructura	Silhouette	CH / DB	Estabilidad (ARI)
Referencia (aleatoria)	—					
K-means / PAM	Hard					
DBSCAN / HDBSCAN	Densidad					
GMM	Soft					
Jerárquico (Ward)	Jerárquico					
Jerárquico (average)	Jerárquico					

El resultado final de test se presenta por separado, sólo para el sistema seleccionado, frente al baseline. Indique “n/a” donde una métrica no aplique.

9. Hitos

- **Semana 1:** propuesta aprobada; datos, auditoría, partición y baseline.
- **Semana 2:** modelos, validación y comparación preliminar.
- **Semana 3:** test, presentación, script e informe de respaldo.