

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Ejercicios de las Slides

Enunciados y soluciones

Unidad 1: Regularización, validación cruzada y modelos flexibles

Luis Rojo-González, Ph.D.

Profesor Asistente

Departamento de Ingeniería Industrial

Universidad de Santiago de Chile

Versión: 1.0

Fecha: Julio 2026


Orientaciones de uso

Este documento desarrolla exclusivamente los ejercicios incluidos en las slides de la unidad. Las soluciones enfatizan interpretación, selección de complejidad, generalización y prevención de leakage. No basta identificar una opción: debe justificarse por qué es consistente con el protocolo de evaluación.

Ejercicio 1: compromiso sesgo–varianza

Ejercicio Lectura del gráfico

Explique por qué el error de entrenamiento disminuye con la complejidad, pero el error de prueba puede volver a aumentar. Identifique en el gráfico la zona de complejidad óptima marcada.



Solución 1: Interpretación desarrollada

El error de entrenamiento se calcula sobre los mismos datos utilizados para estimar el modelo. Cuando aumenta la complejidad, el conjunto de funciones candidatas se amplía: el modelo puede reproducir más detalles de la muestra y, por ello, el error de entrenamiento no debería aumentar. En casos extremos puede aproximarse a cero.

El error sobre datos nuevos tiene otro comportamiento. Inicialmente, aumentar complejidad reduce el sesgo y permite recuperar estructura que un modelo rígido omitía. Después de cierto punto, el modelo comienza a aprender fluctuaciones particulares del entrenamiento. Esto eleva su sensibilidad a la muestra, es decir, su varianza, y el error de prueba vuelve a aumentar.

La zona marcada alrededor del mínimo de la curva de prueba representa el mejor compromiso entre sesgo y varianza:

- a la izquierda existe **subajuste**: errores de entrenamiento y prueba relativamente altos;
- cerca del mínimo se encuentra una complejidad compatible con buena generalización;
- a la derecha existe **sobreajuste**: entrenamiento muy favorable y deterioro fuera de muestra.

La zona óptima no se elige observando el test. Debe estimarse mediante validación dentro de los datos de entrenamiento. El test permanece intacto para la evaluación final del procedimiento seleccionado.

Conclusión: el mejor modelo no es necesariamente el que minimiza el error de entrenamiento, sino el que logra el menor error esperado sobre datos no utilizados durante su construcción.

Ejercicio 2: selección de complejidad mediante la regla 1-SE

Ejercicio Seleccionar complejidad

Un modelo lasso tiene error mínimo en $\lambda = 0,03$, pero la regla 1-SE sugiere $\lambda = 0,10$.

- ¿Cuál modelo será más simple?
- ¿Qué modelo probablemente tendrá más coeficientes en cero?
- Si ambos predicen casi igual, ¿cuál recomendaría para gestión industrial?
- ¿Qué riesgo existe si solo se reporta el error mínimo?

Solución 2: Selección e interpretación

- El modelo con $\lambda = 0,10$ será más simple. En lasso, un valor mayor de λ aumenta la penalización aplicada a la suma de valores absolutos de los coeficientes. El modelo acepta más sesgo a cambio de menor flexibilidad.
- El modelo con $\lambda = 0,10$ tendrá probablemente más coeficientes exactamente iguales a cero. La penalización más intensa elimina predictores cuyo aporte no compensa el costo de complejidad impuesto por lasso.
- Si ambos modelos presentan desempeños prácticamente equivalentes, recomendaría inicialmente $\lambda = 0,10$, siempre que la diferencia esté dentro de un error estándar del mínimo y que las variables descartadas no sean obligatorias por diseño.

Esta recomendación se fundamenta en:

- mayor parsimonia;
- menor costo de medición y mantenimiento;
- comunicación más clara a responsables de operación;
- potencialmente menor sensibilidad frente a cambios muestrales;
- desempeño de validación estadísticamente compatible con el mínimo.

La regla 1-SE no afirma que $\lambda = 0,10$ tenga el menor error verdadero. Escoge el modelo más simple cuyo error estimado permanece dentro de una desviación estándar del mejor valor observado.

- Reportar únicamente el error mínimo puede ocultar cuatro riesgos:
 - la diferencia puede ser menor que la variabilidad entre folds;
 - el mínimo puede depender de una partición particular;
 - puede elegirse una complejidad innecesaria;
 - el resultado puede sugerir una precisión que el proceso de validación no respalda.

Debe reportarse, al menos, el error promedio, su error estándar, la curva completa respecto de λ , el número de coeficientes activos y el criterio usado para seleccionar el modelo.

Conclusión: cuando la mejora predictiva es incierta o pequeña, la regla 1-SE permite privilegiar una solución más simple y defendible sin utilizar el conjunto de test para decidir.

Síntesis común

Ambos ejercicios responden la misma pregunta: cómo controlar complejidad sin confundir ajuste con generalización. El primero presenta el problema de forma conceptual; el segundo transforma esa idea en una regla operacional para elegir la intensidad de regularización.

Evidencia	Interpretación	Decisión
Error de entrenamiento decreciente	Mayor capacidad de ajuste	No seleccionar por entrenamiento
Error de validación con mínimo	Compromiso sesgo-varianza	Comparar complejidades con mismos folds
Errores dentro de 1-SE	Desempeños indistinguibles con precisión disponible	Preferir solución más simple
Test intacto	Evaluación no usada en selección	Abrir una vez al final