

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Ejercicios de las Slides

Enunciados y soluciones

Unidad 2: Ensemble Learning

Luis Rojo-González, Ph.D.

Profesor Asistente

Departamento de Ingeniería Industrial

Universidad de Santiago de Chile

Versión: 1.0

Fecha: Julio 2026

Ejercicio 1: interpretar un árbol

Ejercicio Árbol de regresión

Discuta qué significa que una variable aparezca en el primer split y qué ocurre al aumentar la profundidad.

Solución 1

El primer split es la partición que produce la mayor reducción local del error bajo los candidatos examinados. Indica utilidad predictiva temprana, no causalidad ni importancia universal. Aumentar profundidad permite interacciones y regiones más específicas: disminuye error de entrenamiento, pero eleva varianza y riesgo de sobreajuste. La profundidad se selecciona dentro de validación y el árbol debe compararse con un baseline.

Ejercicio 2: Random Forest

Ejercicio Error OOB e importancia

Analice importancia de variables, error OOB y efecto de aumentar `ntree`.

Solución 2

La importancia resume cuánto utiliza el bosque una variable para mejorar predicciones; puede sesgarse hacia variables con muchos cortes y repartirse entre predictores correlacionados. El error OOB usa observaciones no incluidas en cada bootstrap como evaluación interna y aproxima generalización sin reemplazar necesariamente un test externo. Aumentar `ntree` estabiliza promedio y error; no suele causar sobreajuste por sí solo, pero después de la estabilización agrega costo sin mejora sustantiva.

Ejercicio 3: PDP e ICE

Ejercicio Política de mantenimiento

Si el PDP de horas de uso crece hasta 6 horas y luego se aplanan, ¿qué política sugeriría?

Solución 3

El modelo asocia aumentos hasta seis horas con mayor riesgo y luego con saturación. Podría priorizar monitoreo antes o cerca de ese rango, pero no recomendar un umbral causal únicamente desde PDP. Deben revisarse bandas, densidad, ICE y correlaciones: ICE dispersas sugieren políticas diferenciadas. La acción final se valida según costos y capacidad.

Ejercicio 4: Gradient Boosting

Ejercicio Complejidad secuencial

Discuta el efecto de `n.trees`, `shrinkage` y la brecha entrenamiento–validación.

Solución 4

Más árboles amplían el número de correcciones; un *shrinkage* menor hace cada paso más pequeño y normalmente exige más árboles. Pocos árboles o pasos demasiado pequeños pueden subajustar; demasiados árboles con alta profundidad o learning rate pueden sobreajustar. Una brecha creciente con train decreciente y validación empeorando indica exceso de complejidad. Los hiperparámetros se ajustan conjuntamente con mismos resamples.

Ejercicio 5: Stacking

Ejercicio Diversidad de modelos

¿Qué modelos podrían aportar más, qué ocurre si todos son similares y cuándo puede fallar stacking?

Solución 5

Aportan más los modelos con buen desempeño y errores complementarios. Si todos son similares, el meta-modelo tiene poca diversidad que explotar y la combinación se aproxima a un candidato. Stacking falla si usa predicciones dentro de muestra para entrenar el meta-modelo, si hay leakage, pocos datos, sobreajuste del segundo nivel o cambio de distribución. Requiere predicciones out-of-fold y test intacto.

Ejercicio 6: importancia de variables

Ejercicio Atrasos de proyectos

Un Random Forest destaca avance físico, días desde inicio, proveedor, monto y modificaciones contractuales. Distinga causa y señal, proponga acción, explique por qué importancia no implica causalidad y sugiera una variable adicional.

Solución 6

Avance y días pueden ser señales del estado; proveedor o modificaciones podrían relacionarse con mecanismos, pero el modelo no identifica causas. Acciones: revisión de proyectos con bajo avance respecto del tiempo y auditoría de modificaciones, sin penalizar proveedores solo por importancia. La importancia depende de asociaciones, sustitución entre variables y diseño. Agregaría avance planificado versus real, ruta crítica, disponibilidad de materiales o calidad de planificación.

Ejercicio 7: caso integrador

Ejercicio Priorizar 10 máquinas

Ajuste Random Forest y Gradient Boosting para falla próxima, compare con métrica adecuada al desbalance, interprete importancia y PDP, ordene 80 máquinas y recomiende 10 inspecciones.

Solución 7

La unidad es máquina–semana y el target es falla próxima. Se reserva test temporal y se ajustan ambos modelos con mismos resamples; PR-AUC, recall a $K = 10$ y costo son más informativos que accuracy. La importancia se complementa con PDP/ICE sin causalidad. Se ordenan probabilidades de test operativo y se eligen las diez mayores. La recomendación reporta fallas capturadas, falsas alarmas, incertidumbre, capacidad y protocolo de monitoreo.