

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Ejercicios de las Slides

Enunciados y soluciones

Unidad 4: Clasificación no Supervisada

Luis Rojo-González, Ph.D.

Profesor Asistente

Departamento de Ingeniería Industrial

Universidad de Santiago de Chile

Versión: 1.0

Fecha: Julio 2026

Ejercicio 1: elección de linkage

Ejercicio Interpretación geométrica

Discuta qué linkage usaría en cada situación:

1. Detección de grupos alargados en rutas logísticas.
2. Segmentación de clientes compactos y bien separados.
3. Datos con mucho ruido y outliers.
4. Clusters aproximadamente esféricos similares a K-means.
5. Exploración descriptiva donde no se conoce la geometría.

Solución 1

La elección del linkage define qué significa que dos grupos estén “cerca”. Por ello, no existe una regla universal; la respuesta debe relacionar la geometría esperada, la sensibilidad al ruido y el objetivo del análisis.

1. **Grupos alargados en rutas logísticas: single linkage.** Single define la distancia entre dos clusters por el par de observaciones más cercano:

$$d(A, B) = \min_{i \in A, j \in B} d(i, j).$$

Puede recuperar estructuras conectadas y alargadas que otros linkages dividirían. Su debilidad es el *chaining*: unos pocos puntos intermedios pueden unir rutas que operacionalmente deberían permanecer separadas.

2. **Clientes compactos y bien separados: complete o Ward.** Complete linkage controla el diámetro porque utiliza el par más lejano,

$$d(A, B) = \max_{i \in A, j \in B} d(i, j),$$

y favorece clusters compactos. Ward también es apropiado si las variables son continuas, están escaladas y se usa distancia euclídea al cuadrado, pues fusiona los grupos que producen el menor aumento de variabilidad intracluster.

3. **Mucho ruido y outliers: average linkage, acompañado de análisis de sensibilidad.** Average utiliza el promedio de todas las distancias cruzadas y evita depender exclusivamente del par mínimo o máximo. Así, suele ser menos vulnerable que single al encadenamiento y que complete a un único punto extremo. Sin embargo, ningún linkage convierte automáticamente al clustering jerárquico en robusto: conviene revisar outliers, usar una disimilitud adecuada y comparar resultados con PAM, DBSCAN o HDBSCAN.
4. **Clusters aproximadamente esféricos similares a K-means: Ward.** Ambos métodos favorecen grupos compactos y homogéneos. Ward minimiza en cada fusión el incremento de la suma de cuadrados dentro de los clusters. La correspondencia es conceptual, no exacta: el algoritmo jerárquico no puede deshacer fusiones previas y K-means optimiza iterativamente una partición para un K fijado.

5. **Geometría desconocida: average como punto de partida, comparando alternativas.** Average ofrece un compromiso razonable. La conclusión no debe basarse en un solo dendrograma: se comparan correlación cofenética, estabilidad frente a perturbaciones, silhouette después del corte e interpretabilidad sustantiva. Si distintos linkages producen conclusiones incompatibles, esa inestabilidad es parte del resultado.

Una buena respuesta explicita además la distancia utilizada. Linkage y distancia forman una sola decisión geométrica: cambiar cualquiera de ambos puede cambiar el dendrograma y la partición final.

Ejercicio 2: selección de distancia

Ejercicio Distancia y tipo de datos

Usted dispone de una base de productos con:

- precio promedio;
- rotación mensual;
- categoría del producto;
- indicador de promoción;
- margen.

Discuta:

1. ¿Tiene sentido usar K-means directamente?
2. ¿Qué distancia usaría si hay variables mixtas?
3. ¿Qué ventajas tendría PAM sobre K-means?
4. ¿Qué variables deberían escalarse antes de calcular distancias?

Solución 2

1. **No conviene aplicar K-means directamente.** El algoritmo calcula medias y minimiza distancias euclídeas al cuadrado. La media de una categoría o de un indicador binario no representa necesariamente un producto real, y codificar categorías con números arbitrarios impondría un orden inexistente. Además, precio, rotación y margen pueden tener escalas muy diferentes; sin estandarización, la variable de mayor magnitud dominaría la solución.
Una alternativa sería restringir K-means a las variables continuas, correctamente transformadas y escaladas, pero eso respondería una pregunta distinta porque omitiría categoría y promoción.
2. **Usaría distancia de Gower.** Gower calcula una disimilitud por variable y luego las

combina:

$$d_G(i, j) = \frac{\sum_{p=1}^P w_{ijp} \delta_{ijp}}{\sum_{p=1}^P w_{ijp}}.$$

Para variables continuas, divide la diferencia absoluta por el rango; para categóricas y binarias, compara coincidencia o diferencia. Los pesos w_{ijp} permiten excluir pares con valores faltantes. Debe revisarse si promoción es binaria simétrica: si la coincidencia de dos “no promoción” no es informativa, podría tratarse como binaria asimétrica.

3. **PAM puede operar sobre la matriz de Gower** y representa cada cluster mediante un medoide, es decir, un producto observado. Esto facilita describir el perfil por un caso real y reduce la influencia de valores extremos frente al centroide promedio. Sus costos son mayor complejidad computacional y menor escalabilidad; en bases grandes pueden considerarse CLARA o CLARANS.
4. Deben escalarse las variables continuas: **precio promedio, rotación mensual y margen**. Una opción habitual es estandarizar mediante

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Si existen colas largas o outliers, puede ser preferible transformar primero (por ejemplo, $\log(1+x)$ para rotación) y usar escalamiento robusto basado en mediana e IQR. Categoría no se estandariza y promoción debe tratarse como binaria. Con Gower, las continuas ya se normalizan por rango, pero todavía conviene revisar outliers porque un rango extremo puede comprimir casi todas las diferencias.

Antes de fijar K , corresponde evaluar tendencia al agrupamiento con Hopkins bajo una representación coherente y luego comparar estabilidad, silhouette e interpretación de las soluciones candidatas. El algoritmo siempre producirá grupos, incluso si la base no posee estructura natural.

Ejercicio 3: interpretación de métodos

Ejercicio Elegir algoritmo

Para cada situación, proponga un método:

1. Segmentación de clientes con variables continuas bien escaladas y clusters compactos.
2. Segmentación con variables mixtas y presencia de outliers.
3. Identificación de zonas anómalas en patrones de fallas.
4. Clusters elípticos con pertenencia probabilística.
5. Segmentación donde un cliente puede pertenecer parcialmente a dos perfiles.

Solución 3

1. **K-means.** Es eficiente y coherente con variables continuas escaladas y clusters compactos, aproximadamente esféricos y de tamaño comparable. Deben compararse varios valores de K , usar múltiples inicializaciones y revisar estabilidad, silhouette, Calinski–Harabasz, Davies–Bouldin o Gap statistic. Si existen outliers importantes, PAM puede ser una alternativa más robusta.
2. **PAM con distancia de Gower.** Gower admite variables continuas, categóricas y binarias, mientras que los medoides son menos sensibles a valores extremos que las medias. Si la base es grande, PAM puede ser costoso y conviene considerar CLARA. La existencia de outliers no elimina la necesidad de auditarlos: pueden ser errores, casos legítimos o incluso un grupo relevante.
3. **DBSCAN o HDBSCAN.** Ambos identifican regiones densas y etiquetan puntos de baja densidad como ruido, lo que resulta útil para localizar patrones anómalos sin obligarlos a integrarse a un cluster. DBSCAN es adecuado si una sola escala de densidad, definida por ϵ y minPts , describe los datos. HDBSCAN es preferible cuando las densidades varían, pues construye una jerarquía de densidad y selecciona clusters estables. Un punto etiquetado como ruido no es automáticamente una falla: requiere validación operacional.
4. **Gaussian Mixture Model (GMM).** Cada componente puede tener su propia media y matriz de covarianza, lo que permite representar elipses con distinta orientación y dispersión. El modelo entrega responsabilidades

$$\gamma_{ik} = P(Z_i = k \mid x_i),$$

interpretable como pertenencia probabilística bajo el modelo. El número y la parametrización de covarianzas pueden compararse mediante BIC, acompañados por diagnóstico de ajuste, estabilidad y sentido sustantivo. Las probabilidades dependen de que el supuesto de mezcla gaussiana sea razonable.

5. **Fuzzy C-means.** Entrega grados de pertenencia $u_{ik} \in [0, 1]$ tales que $\sum_k u_{ik} = 1$. Un cliente puede, por ejemplo, pertenecer 0.55 al perfil sensible al precio y 0.45 al perfil intensivo en servicio. El parámetro de fuzziness controla cuán difusa es la asignación. Si además se desea una interpretación probabilística generativa y las variables continuas son aproximadamente gaussianas, GMM también sería defendible; fuzzy membership y probabilidad posterior no son conceptos idénticos.

La selección anterior es condicional, no automática. Antes de modelar deben definirse la unidad de análisis, transformación, escala y distancia; evaluar Hopkins; y después contrastar calidad interna, estabilidad, utilidad e interpretabilidad. Sin etiquetas, una métrica alta no prueba que los clusters correspondan a segmentos reales o accionables.