

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Guía de Ejercicios Propuestos

Unidad 1: Regularización, validación cruzada y modelos flexibles

Luis Rojo-González, Ph.D.

Profesor Asistente
Departamento de Ingeniería Industrial
Universidad de Santiago de Chile

Versión: 2.0
Fecha: Septiembre 2026

Cómo utilizar esta guía

Esta guía contiene **50 ejercicios independientes en su numeración**; los incisos son partes del mismo ejercicio. La distribución es: 10 introductorios, 20 medios, 10 avanzados y 10 desafíos. Cada uno de los diez temas tiene presencia en los cuatro niveles.

Los ejercicios 1–40 se resuelven con papel, calculadora y el formulario incluido, salvo que se solicite explícitamente diseñar un procedimiento. Muestre operaciones, indique unidades y justifique las decisiones. En selección múltiple escoja una alternativa y explique por qué; en verdadero/-falso corrija las afirmaciones falsas. Use tres decimales cuando corresponda y conserve precisión en cálculos intermedios.

Los ejercicios 41–50 son etapas de un caso integrador con datos sintéticos incluidos en el paquete. Requieren R, Python u otro software que permita reproducir el análisis. No basta entregar una captura de pantalla: debe documentar procedimiento, resultados y decisión operacional. No se exige un algoritmo particular cuando se admiten alternativas justificadas.

Los tiempos son orientativos: 8 minutos por introductorio, 12 por ejercicio medio, 20 por avanzado y 30–60 por desafío, una vez preparado el entorno. La guía completa es un banco de estudio; no se pretende resolver los 50 ejercicios en una hora.

Mapa de temas y progresión

Tema	Intro.	Medio	Avanz.	Desafío
Particiones y baseline	1	11, 12	31	41
Validación cruzada	2	13, 14	32	42
Preprocesamiento y fuga	3	15, 16	33	43
Ridge	4	17, 18	34	44
Lasso	5	19, 20	35	45
Elastic-net	6	21, 22	36	46
Complejidad y polinomios	7	23, 24	37	47
Splines	8	25, 26	38	48
GAM e interacciones	9	27, 28	39	49
Selección y transporte	10	29, 30	40	50

Práctica combinada de 60 minutos

Para preparar regularización y ensambles del Control 3: resuelva los ejercicios 2, 17 y 25 de esta guía, y 11 y 25 de la guía de Ensamble; reserve 4 minutos para revisar unidades, fórmulas y decisiones. El trabajo con datos se realiza en sesiones adicionales.

Formulario de apoyo

Las expresiones siguientes fijan la convención que se utiliza en los ejercicios. Identifique qué cantidades son conocidas y qué supuestos necesita antes de sustituir valores.

F1: Pérdidas y baseline

$MSE = n^{-1} \sum (y_i - \hat{y}_i)^2$, $RMSE = \sqrt{MSE}$ y $MAE = n^{-1} \sum |y_i - \hat{y}_i|$. Mejora relativa de error: $(E_{base} - E_{modelo})/E_{base}$. La media de entrenamiento minimiza la suma de errores cuadrados entre predictores constantes.

F2: Validación cruzada

Para pliegues de igual tamaño, $\bar{L} = K^{-1} \sum L_k$; si difieren, el error por observación se obtiene ponderando por n_k . $RMSE_{OOF} = \sqrt{\sum_k SSE_k / \sum_k n_k}$ no es, en general, el promedio de los RMSE. Para este banco se usa $SE = s_L / \sqrt{K}$ como resumen descriptivo de variabilidad entre pliegues; su dependencia impide interpretarlo automáticamente como un IC formal.

F3: Preprocesamiento

$z = (x - \mu_{train})/s_{train}$. Si $\hat{y} = a + b_z z$, entonces $b_x = b_z/s_{train}$ e intercepto en escala original $a - b_z \mu_{train}/s_{train}$. Imputadores, escaladores y selección de variables se ajustan exclusivamente con la porción de entrenamiento de cada pliegue.

F4: Ridge: convención del banco

Con intercepto no penalizado y datos centrados, minimice $\frac{1}{2n} \|y - X\beta\|^2 + \frac{\lambda}{2} \|\beta\|_2^2$. Así, $(X^\top X/n + \lambda I)\hat{\beta} = X^\top y/n$. Si $X^\top X/n = I$ y $z = X^\top y/n$, entonces $\hat{\beta}_j = z_j/(1 + \lambda)$. La escala de λ depende de la normalización de la pérdida.

F5: Lasso

Minimice $\frac{1}{2n} \|y - X\beta\|^2 + \lambda \sum_j |\beta_j|$. En diseño ortonormal normalizado, $\hat{\beta}_j = S(z_j, \lambda)$, donde $S(z, t) = \text{sign}(z) \max(|z| - t, 0)$. Para $\beta_j = 0$, la condición de subgradiente es $|X_j^\top (y - X\beta)/n| \leq \lambda$.

F6: Elastic-net

Minimice $\frac{1}{2n} \|y - X\beta\|^2 + \lambda [\frac{1-\alpha}{2} \|\beta\|_2^2 + \alpha \|\beta\|_1]$, $0 \leq \alpha \leq 1$. En diseño ortonormal, $\hat{\beta}_j = S(z_j, \lambda\alpha)/[1 + \lambda(1 - \alpha)]$. $\alpha = 0$ es Ridge y $\alpha = 1$ es Lasso bajo estas convenciones.

F7: Complejidad y sesgo-varianza

En regresión con ruido de media cero: $E[(Y - \hat{f}(x))^2] = \sigma^2 + \text{Bias}(\hat{f}(x))^2 + \text{Var}(\hat{f}(x))$. Un polinomio de grado d usa $1, x, \dots, x^d$; estandarizar la entrada mejora la escala numérica, pero no evita por sí solo sobreajuste o extrapolación.

F8: Splines

Bisagra: $(x - \kappa)_+ = \max(x - \kappa, 0)$. Un spline cúbico en base truncada usa $1, x, x^2, x^3$ y $(x - \kappa_j)_+^3$. Penalización de suavidad: $\sum_i [y_i - f(x_i)]^2 + \lambda \int [f''(t)]^2 dt$. En un suavizador lineal $\hat{y} = Sy$, los grados de libertad efectivos son $EDF = \text{tr}(S)$. Distinga dimensión de la base, número de nudos y EDF.

F9: GAM y efectos parciales

Un GAM de media continua con enlace identidad puede escribirse $E(Y | x) = \beta_0 + \sum_j s_j(x_j) + \beta^\top z$, con restricciones de centrado para identificar cada suave. Un término $s_{12}(x_1, x_2)$ permite interacción. Para respuesta binaria se usa, por ejemplo, $\text{logit}(p) = \eta$ y $p = (1 + e^{-\eta})^{-1}$; un aporte al predictor lineal no es una probabilidad.

F10: Selección y estabilidad

Regla 1-SE: calcule $c = \bar{L}_{min} + SE_{min}$ y escoja el candidato de menor complejidad predefinida con $\bar{L} \leq c$. Para frecuencia de selección, $\hat{\pi}_j = B^{-1} \sum_b I(j \text{ seleccionado en } b)$. No convierte una variable en causa ni mide por sí sola su utilidad operacional. El test final se usa tras fijar todo el procedimiento.

Parte I: Nivel introductorio

Ejercicio 1. Tres conjuntos, tres funciones

Un operador estima horas-persona para el día siguiente y dispone de 1.000 registros independientes para un primer piloto.

- a) Asigne 60 %, 20 % y 20 % a entrenamiento, validación y prueba; indique tamaños y función.
- b) Juzgue: “si el test mejora, puedo seguir probando variables”.
- c) Identifique qué conjunto estima el baseline y cuál decide un hiperparámetro.

Ejercicio 2. K-fold sin dependencia

Se tienen 1.000 observaciones independientes y $K = 5$ pliegues equilibrados. *Apoyo: formulario F2.*

- a) Calcule tamaños de ajuste y validación por iteración y cuántas veces cada observación se evalúa fuera de muestra.
- b) Explique por qué ese conteo cambia si los registros son horas sucesivas del mismo centro.
- c) ¿El promedio de errores de CV reemplaza siempre una prueba final?

Ejercicio 3. Escalar con la referencia correcta

En entrenamiento, pedidos diarios tiene media 100 y desviación 20. En validación aparece un centro con 140 pedidos. *Apoyo: formulario F3.*

- a) Calcule el valor estandarizado.
- b) Elija el procedimiento correcto: A) usar esos parámetros; B) recalcularlos incluyendo validación; C) escalar cada fila por sí sola.
- c) Explique qué haría con un faltante sin consultar el target.

Ejercicio 4. Penalización y coeficientes

En un modelo de recursos, pedidos y dos proxies de carga están muy correlacionados. *Apoyo: formulario F4.*

- a) Compare OLS y Ridge respecto de varianza, sesgo y unicidad cuando $\lambda > 0$.
- b) Juzgue: “Ridge elimina automáticamente todas las variables poco útiles”.
- c) Explique por qué el intercepto no se penaliza bajo la convención del formulario.

Ejercicio 5. Qué significa un cero

Lasso asigna coeficiente cero a distancia, mientras Ridge conserva un valor pequeño. *Apoyo: formulario F5.*

- a) Explique el papel de la penalización L1.

- b) Juzgue: “distancia no influye causalmente en horas-persona”.
- c) Indique cómo la correlación con pedidos podría afectar esa selección.

Ejercicio 6. Combinar penalizaciones

Hay tres sensores de carga redundantes y 20 variables de contexto. *Apoyo: formulario F6.*

- a) Identifique qué valores de α recuperan Ridge y Lasso.
- b) Explique el propósito de una mezcla y el papel separado de λ .
- c) ¿Por qué debe validarse el par (α, λ) dentro del desarrollo?

Ejercicio 7. Descomponer el error

Dos estimadores tienen $(sesgo^2, varianza) = (9, 4)$ y $(1, 16)$ en una condición de carga. El ruido irreducible es 5. *Apoyo: formulario F7.*

- a) Calcule los dos errores cuadrados esperados y elija el menor.
- b) Explique por qué menor sesgo no basta.
- c) ¿La comparación en esa condición garantiza el orden global?

Ejercicio 8. Bases locales y suavidad

Se desea representar una saturación de productividad al aumentar operarios. *Apoyo: formulario F8.*

- a) Explique qué aporta un spline frente a un polinomio global de grado alto.
- b) Distinga nudo, dimensión de la base y EDF.
- c) Juzgue: “agregar nudos siempre disminuye el error de validación”.

Ejercicio 9. Sumar contribuciones

Un GAM con enlace identidad tiene intercepto 40 h, aporte de ocupación +6, de operarios -3 y de turno tarde +2. *Apoyo: formulario F9.*

- a) Calcule la predicción y explique qué significa que los suaves estén centrados.
- b) ¿El aporte +6 es el tiempo total causado por ocupación?
- c) Indique qué supuesto impide que el efecto de ocupación cambie con turno.

Ejercicio 10. Aplicar 1-SE

Cinco modelos ordenados de más a menos complejos tienen errores 12, 10,4, 10,0, 10,3 y 11,2. El SE del mínimo es 0,6. *Apoyo: formulario F10.*

- a) Calcule el umbral y elija por regla 1-SE.

- b) Explique por qué no escoge simplemente el más regularizado de todos.
- c) Distinga esta regla de una prueba formal de equivalencia.

Parte II: Nivel medio


Ejercicio 11. Evaluar una predicción constante

La media de entrenamiento es 40 horas. En validación se observan (32, 40, 48, 40) y el modelo predice (36, 42, 44, 38). *Apoyo: formulario F1.*

- a) Calcule RMSE y MAE del baseline constante 40 y del modelo.
- b) Determine la mejora porcentual del RMSE.
- c) Explique qué conclusión no puede extraerse todavía sobre centros nuevos.

Ejercicio 12. Leer entrenamiento y validación

Se ajustan cuatro modelos al mismo conjunto y se evalúan en una validación común.



- a) Identifique regiones compatibles con subajuste y sobreajuste.
- b) Seleccione por menor RMSE de validación y cuantifique la mejora frente al modelo de dos parámetros.
- c) Indique qué información falta para valorar si la mejora de 10 a 9 horas es estable.

Ejercicio 13. Promedios que no coinciden

Dos pliegues de validación tienen $(n_k, SSE_k) = (20, 80)$ y $(80, 720)$. *Apoyo: formulario F2.*

- a) Calcule RMSE de cada pliegue, su promedio simple y el RMSE conjunto de predicciones fuera de pliegue.
- b) Explique cuál resume el error por registro de los 100 casos.
- c) ¿Por qué sería útil reportar también la variabilidad entre pliegues?

Ejercicio 14. Dibujar una validación temporal

Se observan 18 meses y se desea predecir el mes siguiente en los mismos centros.

- Reserve meses 16–18 para prueba y dibuje tres cortes expansivos dentro de meses 1–15, indicando exactamente meses de ajuste y evaluación.
- Explique cómo cambia el diseño si el horizonte es tres meses.
- Indique qué validación adicional responde a generalizar a centros nunca observados.

Ejercicio 15. Volver a unidades originales

Un modelo utiliza $z = (x - 100)/20$ y estima $\hat{y} = 40 + 6z$, en horas-persona. *Apoyo: formulario F3.*

- Reescriba la ecuación en función de x y prediga para 130 pedidos.
- Interprete la pendiente con unidades.
- Explique por qué comparar 6 con el coeficiente de otra variable no estandarizada resulta engañoso.

Ejercicio 16. Auditar la receta

El procedimiento es: imputar con medianas globales, seleccionar las diez variables más correlacionadas con horas-persona, separar test, escalar dentro de CV y ajustar Ridge.

- Identifique las etapas que ya usaron información reservada.
- Reordene la receta y señale qué se aprende de nuevo en cada pliegue.
- Distinga fuga del target de una transformación fija que solo convierte metros a kilómetros.


Ejercicio 17. Ridge a mano

Con predictores centrados y $X^\top X/n = I$, se tiene $z = (6, -3)$. *Apoyo: formulario F4.*

- Calcule coeficientes con $\lambda = 0, 1$ y 2 .
- Para una nueva fila estandarizada $(1, 2)$ e intercepto 40, calcule las tres predicciones.
- Explique por qué en este caso una predicción particular puede cambiar poco aunque los coeficientes cambien mucho.

Ejercicio 18. Trayectorias de contracción

Las trayectorias se obtuvieron con la misma escala de variables.



Apoyo: formulario F4.

- Lea los coeficientes en $\lambda = 1$ y 3 y calcule el porcentaje de contracción respecto de cero.
- ¿Las curvas bastan para elegir λ ?
- Describa cómo las relacionaría con una curva de error fuera de muestra.


Ejercicio 19. Umbral suave

En diseño ortonormal normalizado se tiene $z = (4, -1, 5, 0, 4)$ y $\lambda = 1$. Apoyo: formulario F5.

- Calcule los tres coeficientes Lasso y el número de variables activas.
- Repita con $\lambda = 2$.
- Calcule ambas predicciones para $x = (1, 2, -1)$ e intercepto 30 y comente el cambio.

Ejercicio 20. Leer una trayectoria Lasso

Se muestran dos coeficientes con predictores ortonormales normalizados.



Apoyo: formulario F5.

- Identifique el primer λ mostrado que excluye la señal auxiliar y el que excluye carga.
- Compare el patrón con Ridge.
- Explique por qué en datos correlacionados una trayectoria puede no ser tan simple.

Ejercicio 21. Coeficientes de elastic-net

Con $X^T X/n = I$, $z = (3, -0,8, 0,2)$, $\lambda = 1$ y $\alpha = 0,5$. *Apoyo: formulario F6.*

- Calcule los coeficientes con umbral suave y contracción.
- Compare con Ridge y Lasso usando el mismo λ y la misma normalización.
- Determine cuáles variables quedan activas y explique por qué las normas resultantes difieren.

Ejercicio 22. Comparación de estabilidad

En 20 ajustes, Lasso selecciona cada uno de tres proxies en 18, 6 y 4 ocasiones; elastic-net en 19, 18 y 17. Los RMSE medios son 8,2 y 8,1 horas. *Apoyo: formulario F10.*

- Calcule frecuencias y compare estabilidad individual.
- Explique por qué estos conteos no revelan cuántas veces se seleccionó el grupo completo.
- Proponga qué evidencia adicional pediría para preferir una familia.


Ejercicio 23. Evaluar una base polinomial

Para ocupación estandarizada z , se ajusta $\hat{y} = 40 + 3z + 2z^2$. *Apoyo: formulario F7.*

- Construya la fila de diseño $(1, z, z^2)$ y prediga para $z = -1, 0, 2$.
- Obtenga la derivada $3 + 4z$ e interprete su cambio de signo.
- Indique por qué una derivada en escala estandarizada requiere conversión para informar horas por punto porcentual.

Ejercicio 24. El grado y el error

Todos los modelos usan los mismos pliegues temporales.



- Seleccione por error medio mínimo y cuantifique la diferencia con grado 2.
- Describa el problema del grado 9 y por qué el error de entrenamiento continúa bajando.
- Proponga un criterio que permita preferir grado 2 si la diferencia es inestable y operacionalmente pequeña.

Ejercicio 25. Calcular una bisagra

Un spline lineal de planificación es $\hat{y} = 20 + 0,3x + 0,5(x - 100)_+$, con x pedidos. *Apoyo: formulario F8.*

- Calcule predicciones para 80, 100 y 120 pedidos.
- Obtenga la pendiente a cada lado de 100 y compruebe continuidad.
- Interprete el cambio de pendiente como asociación, sin atribuirlo automáticamente a un cambio causal de capacidad.

Ejercicio 26. Elegir grados de libertad

Se obtienen los resultados siguientes.


EDF	3	5	8	14
RMSE ajuste	45	35	23	12
RMSE validación	47	38	34	43

Apoyo: formulario F8.

- Identifique el candidato de menor error y la región de sobreajuste.
- ¿Qué datos adicionales necesita para decidir entre EDF 5 y 8?
- Explique por qué EDF 14 no equivale necesariamente a 14 nudos.

Ejercicio 27. Interpretar un suave y su banda

La banda es puntual aproximada del 95 %, no simultánea.



Apoyo: formulario F9.

- Lea la contribución y los límites en 70 y 90 % de ocupación.
- Explique dónde hay mayor incertidumbre y por qué la banda no describe la variabilidad de un turno individual.

- c) ¿Puede sumar bandas marginales de varios suaves para obtener directamente un intervalo de predicción?


Ejercicio 28. Una interacción explícita

Se propone $\hat{y} = 30 + 0,2x + 4I_T + 0,1xI_T$, donde x es carga centrada y $I_T = 1$ en tarde. *Apoyo: formulario F9.*

- Escriba las rectas para cada turno y calcule predicciones para $x = 20$.
- Interprete la diferencia entre turnos como función de x .
- Explique cómo un GAM permitiría una versión no lineal de esa interacción.

Ejercicio 29. Leer el umbral de selección

El índice horizontal ordena λ de menor a mayor; la línea marca el mínimo más su SE, 10,6 h.



Apoyo: formulario F10.

- Identifique los candidatos admisibles y el elegido bajo complejidad decreciente con λ .
- Calcule cuánto error adicional acepta respecto del mínimo.
- Explique qué parte de la selección debe fijarse antes del test.

Ejercicio 30. Diferencias pareadas entre cortes

Los RMSE de A en cuatro cortes son (10, 12, 11, 13) y los de B (9, 11, 12, 12). *Apoyo: formulario F2.*

- Calcule diferencias A menos B, media y SE descriptivo de las diferencias.
- Compare esa información con solo ordenar los promedios.
- Si ahorrar 0,5 h es irrelevante y B cuesta cinco veces más, formule una recomendación condicionada.

Parte III: Nivel avanzado

Ejercicio 31. El test que se volvió entrenamiento

Un equipo compara 40 modelos con el mismo test y reporta solo el mejor. Después agrega variables para corregir sus errores en ese test.

- a) Explique los dos mecanismos de selección que sesgan la evaluación.
- b) Diseñe una recuperación usando desarrollo, validación y un nuevo período final.
- c) Si no hay datos nuevos, especifique qué se puede reportar honestamente y cómo usar validación anidada.

Ejercicio 32. Anidar la selección

Se comparan 12 valores de λ y tres familias mediante CV interna de 4 pliegues dentro de 5 pliegues externos.

- a) Calcule el número de ajustes internos: suponga los 12 valores para cada familia, sin reutilizar ajustes.
- b) Describa qué datos puede usar cada ajuste del escalador.
- c) Explique por qué elegir la familia con el promedio externo y reportar ese mismo promedio como totalmente independiente requiere cautela.

Ejercicio 33. Categorías y centros nuevos

Un modelo incluye indicadores de ocho centros. En producción aparece C9 y 15% de faltantes en distancia, frente a 2% en desarrollo.

- a) Diseñe una política explícita para nivel no observado y explique la interpretación de su predicción.
- b) Proponga un análisis de sensibilidad a faltantes y un indicador de monitoreo.
- c) Justifique por qué imputar no elimina automáticamente el cambio de distribución.

Ejercicio 34. Resolver con correlación

Se tiene $X^\top X/n = \begin{pmatrix} 1 & 0,8 \\ 0,8 & 1 \end{pmatrix}$ y $X^\top y/n = (3, 3)^\top$. Apoyo: formulario F4.

- a) Resuelva OLS y Ridge con $\lambda = 0,2$.
- b) Use los autovalores 1,8 y 0,2 para comparar el cociente de condición antes y después de sumar λI .
- c) Relacione el resultado con estabilidad, sin afirmar que una menor norma garantiza menor error de prueba.

Ejercicio 35. Comprobar un coeficiente cero

En una solución candidata Lasso con $\lambda = 0,8$, las correlaciones normalizadas de tres predictores actualmente excluidos con el residuo son 0,6, $-0,9$ y 0,2. *Apoyo: formulario F5.*

- a) Compruebe la condición de subgradiente para cada cero.
- b) Identifique por qué la solución candidata no puede ser óptima.
- c) Si dos columnas son idénticas, explique por qué la selección individual puede ser inestable aunque la predicción sea estable.

Ejercicio 36. Redistribuir coeficientes idénticos

Dos columnas son idénticas y la predicción depende de $\beta_1 + \beta_2 = 4$, con coeficientes no negativos. *Apoyo: formulario F6.*

- a) Compare penalización L1 de $(4, 0)$ y $(2, 2)$.
- b) Compare sus sumas de cuadrados y deduzca cuál favorece un componente Ridge positivo.
- c) Explique el efecto de agrupamiento y por qué no convierte a los dos sensores en mediciones independientes.

Ejercicio 37. Extrapolar una relación cuadrática

Un ajuste válido para ocupaciones x de 40 a 90 % es $\hat{y} = 15 - 0,4x + 0,008x^2$.

- a) Calcule la derivada en 50 y 90, y las predicciones en 90 y 120.
- b) Explique por qué evaluar la fórmula en 120 no valida esa predicción y por qué esa ocupación requiere revisar su definición.
- c) Proponga restricciones o alertas para uso operacional fuera del soporte.

Ejercicio 38. Base cúbica y continuidad

Considere $f(x) = 2 + x + 0,5(x - 3)_+^3$. *Apoyo: formulario F8.*

- a) Calcule $f(2)$, $f(3)$ y $f(4)$.
- b) Derive a izquierda y derecha y compruebe continuidad de f , f' y f'' en 3.
- c) Explique qué cambiaría si la bisagra fuera de potencia 1 y qué implica para representar un proceso suave.

Ejercicio 39. Auditar un GAM flexible

Un GAM tiene R^2 de ajuste 0,94 y de validación 0,51. Dos suaves alcanzan EDF casi iguales al máximo de su base; los residuos muestran patrón por turno.

- a) Presente al menos dos explicaciones plausibles, sin concluir que EDF alto prueba sobreajuste.
- b) Diseñe diagnósticos para dimensión insuficiente, penalización, interacción y cambio temporal.

- c) Proponga una comparación controlada sin consultar el test.

Ejercicio 40. Transportar a otro centro

Tres modelos tienen RMSE global 8,0; 7,8 y 7,5 h, pero en el último período obtienen 8,2; 8,0 y 12,0. El tercero usa un sensor ausente en el centro nuevo.

- a) Diseñe una regla de selección que combine consistencia, datos disponibles y costo.
- b) Distinga validación temporal de evaluación en un centro no observado.
- c) Formule condiciones medibles de aprobación y monitoreo, incluyendo una alternativa cuando falten sensores.

Parte IV: Desafíos con datos

Caso: planificación de horas-persona en centros de distribución. Se dispone de registros diarios de ocho centros, con carga redundante, faltantes y relaciones potencialmente no lineales. Se quiere planificar recursos al inicio del turno y estudiar transporte a un noveno centro. E41–E50 comparten el mismo protocolo y culminan en una decisión entre modelos.

Ejercicio 41. D41: Definir la planificación

Abra únicamente `entrenamiento.csv`. La respuesta es `horas_persona`, a planificar antes del turno con la información declarada al corte.

- a) Audite unidad, rango temporal, centros y columnas posteriores al cierre.
- b) Calcule un baseline global y otro por turno usando solo entrenamiento.
- c) Entregue una ficha del problema y una tabla de métricas que completará en los siguientes desafíos; reserve prueba y centro nuevo hasta E50.

Ejercicio 42. D42: Protocolo común en el tiempo

Use el entrenamiento de 120 fechas. Ordene fechas únicas, conservando juntos todos los centros de un día. *Apoyo: formulario F2.*

- a) Defina tres cortes: entrenar días 1–60 y validar 61–80; 1–80 y 81–100; 1–100 y 101–120.
- b) Evalúe los baselines y guarde índices reutilizables para todas las familias.
- c) Entregue calendario y errores por corte; explique qué dependencia persiste y por qué no puede interpretar su SE como un IC independiente.

Ejercicio 43. D43: Construir la receta reproducible

Use los cortes de E42. *Apoyo: formulario F3.*

- a) Prepare imputación numérica, codificación de turno y centro, y estandarización dentro de cada

ajuste. Excluya identificadores, `rol_particion` y `costo_cierre_clp`; derive calendario solo desde fecha disponible.

- b) Guarde una tabla con faltantes y parámetros aprendidos en el primer corte.
- c) Pruebe la transformación de una fila con centro nuevo y documente la política que usará en E50.

Ejercicio 44. D44: Ajustar Ridge

Reutilice la receta y los cortes de E42–E43. *Apoyo: formulario F4.*

- a) Explore 25 valores logarítmicos de λ entre 10^{-3} y 10^3 , comprobando la convención de pérdida de su software.
- b) Grafique RMSE por corte y trayectorias; seleccione con una regla declarada antes de abrir `validacion.csv`.
- c) Ajuste sobre todo entrenamiento y registre desempeño en validación externa, sin abrir prueba. Compare con los baselines.

Ejercicio 45. D45: Selección y estabilidad con Lasso

Use exactamente los cortes y el preprocesamiento previos. *Apoyo: formulario F5,10.*

- a) Ajuste una trayectoria Lasso y registre RMSE y número de coeficientes activos por corte.
- b) Repita 30 remuestreos por bloques de fechas dentro de entrenamiento para estudiar selección; declare tamaño de bloque y no use esos remuestreos como test.
- c) Entregue frecuencias de selección de proxies y variables de ruido, y compare validación con Ridge sin interpretar la selección como causalidad.

Ejercicio 46. D46: Grupos correlacionados

Estudie `pedidos`, `carga_proxy_1` y `carga_proxy_2`. *Apoyo: formulario F6.*

- a) Grafique sus asociaciones y ajuste elastic-net con $\alpha \in \{0,1,0,5,0,9\}$ y la malla de E44.
- b) Compare error, tamaño activo y estabilidad con Ridge y Lasso en los mismos cortes.
- c) Entregue una recomendación para medir o retirar sensores que considere redundancia y costo, reconociendo qué información económica no está en la base.

Ejercicio 47. D47: Detectar no linealidad

En entrenamiento, explore horas-persona frente a `ocupacion_pct` y `pedidos`. *Apoyo: formulario F7.*

- a) Compare una base lineal con grados 2 y 3 para esas entradas, manteniendo los demás términos iguales y las transformaciones dentro del ajuste.
- b) Evalúe en los cortes comunes y en validación; inspeccione errores por rango de ocupación.
- c) Entregue curvas sobre el rango observado y justifique si la flexibilidad mejora de manera consistente.

Ejercicio 48. D48: Curvas de saturación

Modele ocupación y operarios con splines, conservando un conjunto común de covariables. *Apoyo: formulario F8.*

- a) Compare dimensiones de base 4, 6 y 10, seleccionadas dentro de los cortes; si usa penalización, reporte también EDF y parámetro de suavidad.
- b) Grafique predicciones para perfiles operacionales plausibles y marque dónde hay pocos datos.
- c) Compare con E47 y entregue una tabla de error, complejidad y comportamiento en los extremos.

Ejercicio 49. D49: Modelo aditivo de recursos

Ajuste un GAM con suaves de pedidos, ocupación y operarios, y factores de turno y centro. *Apoyo: formulario F9.*

- a) Compare versión aditiva con una interacción preespecificada entre ocupación y turno, usando E42 y la validación externa.
- b) Grafique efectos centrados con incertidumbre disponible y distribución de las entradas.
- c) Reporte EDF, error por turno y limitaciones; guarde los candidatos para la decisión común de E50.

Ejercicio 50. D50: Selección congelada y prueba

Integre E41–E49 y fije una regla basada en los cortes y `validacion.csv`. *Apoyo: formulario F10.*

- a) Seleccione familia, hiperparámetros y receta; reajuste sobre entrenamiento más validación con esa decisión congelada.
- b) Abra una sola vez `prueba_final.csv` y luego `centro_nuevo.csv`; compare con baselines y reporte errores separados por centro y período.
- c) Entregue una recomendación de dotación, limitaciones del centro nuevo y plan de seguimiento; no reajuste al observar estas pruebas.

Instructivo del caso integrador

Carpeta: `datos/Unidad_1_Regularizacion/`. Archivos: `entrenamiento.csv`, 960 filas (120 fechas por 8 centros); `validacion.csv`, 240 filas (30 fechas); `prueba_final.csv`, 240 filas (30 fechas); `centro_nuevo.csv`, 30 filas del centro C9 en julio. Cada archivo contiene 21 columnas. La unidad es un centro en una fecha con un turno observado; no son lecturas repetidas dentro de la misma fila.

Protocolo obligatorio del caso. Entrenamiento ocupa los primeros 120 días de 2026; validación, los siguientes 30, y prueba, los últimos 30 del período de 180 días. E42 define los cortes temporales dentro de entrenamiento. E44–E49 usan esos mismos cortes para ajustar hiperparámetros y la validación externa para comparar candidatos ya especificados. En E50 se congela la decisión y se puede reajustar en entrenamiento más validación antes de abrir las dos pruebas. El centro nuevo evalúa otro dominio, no aporta datos para elegir el ganador.

Variables y datos disponibles. Los pedidos y recursos son información planificada al inicio; las horas-persona efectivas se conocen al finalizar. El costo de cierre es posterior y se excluye. Fecha sirve para particionar y crear calendario conocido; registro y rol de partición no son predictores. Los proxies son mediciones redundantes, mientras que las variables de ruido permiten examinar selección espuria. Establezca tratamiento de niveles nuevos de centro sin aprenderlo de la prueba.

Entregables específicos. Conserve índices de los cortes, receta de transformación y tabla común de RMSE/MAE por corte, por familia y por centro. Use la misma respuesta y observaciones evaluables al comparar familias. Si una familia requiere retirar filas, vuelva a evaluar los demás modelos sobre la misma población y reporte la pérdida de cobertura. Registre la convención de penalización del software para que los valores de λ sean interpretables.

Lectura. CSV UTF-8 con coma, punto decimal y NA. `diccionario.csv` detalla variables y faltantes por archivo; `inicio.R` carga entrenamiento. El paquete incluye `generar_datos.py`, semilla 20260910. Los datos son simulados; sus ecuaciones de generación no sustituyen validación ni constituyen una solución que deba recuperarse exactamente.

Entrega y criterios comunes

Entregue un informe breve con secciones E41 a E50, un script o cuaderno ejecutable, tablas exportadas y gráficos con ejes, unidades y leyendas. Incluya la semilla usada, las versiones del software, las variables excluidas y el tratamiento de faltantes. Cada sección debe indicar una decisión, la evidencia que la respalda y una limitación.

Rúbrica orientativa del conjunto de desafíos: formulación y trazabilidad de datos (20%), aplicación y cálculos (30%), validación y manejo de incertidumbre (25%), interpretación y recomendación industrial (15%), reproducibilidad y claridad (10%). El criterio evalúa la calidad del razonamiento; no exige obtener un resultado predeterminado.

Diccionario de variables

Variable	Descripción y unidad	Rol / disponibilidad
registro_id	Centro-turno diario; clave unica (id).	identificador; al corte.
fecha	Fecha de corte al inicio del turno (AAAA-MM-DD).	particion; al corte.
centro	Centro de distribucion (categoria).	predictor; al corte.
turno	Turno planificado (categoria).	predictor; al corte.
pedidos	Pedidos confirmados (pedidos).	predictor; al corte.
unidades	Unidades confirmadas (unidades).	predictor; al corte.
lineas	Lineas confirmadas (lineas).	predictor; al corte.
distancia_m	Recorrido planificado; puede faltar (m).	predictor; al corte.
ocupacion_pct	Ocupacion inicial de almacenamiento; puede faltar (porcentaje).	predictor; al corte.
operarios	Dotacion planificada (personas).	predictor; al corte.
urgentes_pct	Fraccion urgente de pedidos (porcentaje).	predictor; al corte.
promocion	Promocion anunciada (0/1).	predictor; al corte.
carga_proxy_1	Indicador redundante de carga (indice).	predictor; al corte.
carga_proxy_2	Segundo indicador redundante de carga (indice).	predictor; al corte.
horas_persona	Trabajo efectivamente requerido (horas-persona).	respuesta; cierre del turno.
costo_cierre_clp	Costo posterior altamente asociado con respuesta (CLP).	excluir_fuga; cierre del turno.
ruido_1	Indicador auxiliar sin significado operacional (indice).	predictor; al corte.
ruido_2	Indicador auxiliar sin significado operacional (indice).	predictor; al corte.
ruido_3	Indicador auxiliar sin significado operacional (indice).	predictor; al corte.
ruido_4	Indicador auxiliar sin significado operacional (indice).	predictor; al corte.
rol_particion	Separacion temporal fijada; no predictor (categoria).	particion; al corte.