

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Guía de Ejercicios Propuestos

Unidad 2: Ensemble Learning

Luis Rojo-González, Ph.D.

Profesor Asistente
Departamento de Ingeniería Industrial
Universidad de Santiago de Chile

Versión: 2.0
Fecha: Septiembre 2026

Cómo utilizar esta guía

Esta guía contiene **50 ejercicios independientes en su numeración**; los incisos son partes del mismo ejercicio. La distribución es: 10 introductorios, 20 medios, 10 avanzados y 10 desafíos. Cada uno de los diez temas tiene presencia en los cuatro niveles.

Los ejercicios 1–40 se resuelven con papel, calculadora y el formulario incluido, salvo que se solicite explícitamente diseñar un procedimiento. Muestre operaciones, indique unidades y justifique las decisiones. En selección múltiple escoja una alternativa y explique por qué; en verdadero/-falso corrija las afirmaciones falsas. Use tres decimales cuando corresponda y conserve precisión en cálculos intermedios.

Los ejercicios 41–50 son etapas de un caso integrador con datos sintéticos incluidos en el paquete. Requieren R, Python u otro software que permita reproducir el análisis. No basta entregar una captura de pantalla: debe documentar procedimiento, resultados y decisión operacional. No se exige un algoritmo particular cuando se admiten alternativas justificadas.

Los tiempos son orientativos: 8 minutos por introductorio, 12 por ejercicio medio, 20 por avanzado y 30–60 por desafío, una vez preparado el entorno. La guía completa es un banco de estudio; no se pretende resolver los 50 ejercicios en una hora.

Mapa de temas y progresión

Tema	Intro.	Medio	Avanz.	Desafío
Árboles y cortes	1	11, 12	31	41
Bootstrap y bagging	2	13, 14	32	42
Random Forest	3	15, 16	33	43
OOB y evaluación	4	17, 18	34	44
Boosting	5	19, 20	35	45
Comparación y tuning	6	21, 22	36	46
Importancia de variables	7	23, 24	37	47
PDP e ICE	8	25, 26	38	48
Promediado de modelos	9	27, 28	39	49
Stacking e integración	10	29, 30	40	50

Práctica de 60 minutos

Ruta de esta unidad: ejercicios 1, 2, 11, 19 y 21, con 8 minutos finales de revisión. Para la práctica combinada del Control 3, use los ejercicios 11 y 25 junto con 2, 17 y 25 de Regularización; reserve 4 minutos de revisión.

Formulario de apoyo

Las expresiones siguientes fijan la convención que se utiliza en los ejercicios. Identifique qué cantidades son conocidas y qué supuestos necesita antes de sustituir valores.

F1: Árbol de regresión

En una hoja R , $\hat{y}_R = |R|^{-1} \sum_{i \in R} y_i$. Para un corte, $RSS = \sum_{i \in R_L} (y_i - \bar{y}_L)^2 + \sum_{i \in R_R} (y_i - \bar{y}_R)^2$. Elija el menor RSS entre cortes admisibles. En poda por complejidad, $C_\alpha(T) = RSS(T) + \alpha|T|$, con $|T|$ número de hojas; aquí no se normaliza RSS por n .

F2: Bootstrap y bagging

Una réplica bootstrap toma n observaciones con reemplazo desde n filas. $P(i \text{ no seleccionada}) = (1 - 1/n)^n \rightarrow e^{-1} \approx 0,368$. Número esperado de observaciones distintas: $n[1 - (1 - 1/n)^n]$. Bagging de regresión: $\hat{f}_B(x) = B^{-1} \sum_b \hat{f}_b(x)$.

F3: Random Forest y correlación

Si cada predictor de árbol tiene varianza σ^2 y correlación común ρ con los demás, $\text{Var}(\bar{f}_B) = \sigma^2[\rho + (1 - \rho)/B]$. Es una simplificación que mantiene fija la fuerza de cada árbol. Si se sortean m variables sin reemplazo entre p , la probabilidad de incluir una señal específica es m/p .

F4: Predicciones OOB

Para la observación i , $\mathcal{B}_i$ contiene los árboles cuyo bootstrap no la incluyó: $\hat{y}_i^{OOB} = |\mathcal{B}_i|^{-1} \sum_{b \in \mathcal{B}_i} \hat{f}_b(x_i)$. $RMSE_{OOB} = \sqrt{n^{-1} \sum_i (y_i - \hat{y}_i^{OOB})^2}$ si todas tienen predicción. OOB no es una prueba final independiente de una búsqueda que lo utiliza reiteradamente.

F5: Boosting para error cuadrático

Con pérdida $\frac{1}{2} \sum_i (y_i - f_i)^2$, el gradiente negativo es $r_i = y_i - f_i$. Inicialice $f_0 = \bar{y}$. Ajuste un árbol h_m a los residuos y actualice $f_m = f_{m-1} + \nu h_m$, con tasa $\nu > 0$. Profundidad, número de iteraciones y ν se seleccionan conjuntamente.

F6: Comparación y métricas

$RMSE = \sqrt{n^{-1} \sum e_i^2}$, $MAE = n^{-1} \sum |e_i|$. Para cortes comunes, compare diferencias $d_k = L_{A,k} - L_{B,k}$ y su media. La regla 1-SE acepta errores hasta $\bar{L}_{min} + SE_{min}$ y elige la menor complejidad predefinida; el SE entre pliegues dependientes es descriptivo.

F7: Importancia por permutación

En un conjunto de evaluación, $I_j = L(y, \hat{f}(X^{\pi_j})) - L(y, \hat{f}(X))$. Repita permutaciones y reporte variabilidad. Permutar rompe asociaciones con otras variables: entradas correlacionadas requieren cautela y pueden estudiarse también por permutación conjunta. La reducción de impureza de ajuste favorece a veces variables con muchos cortes posibles.

F8: PDP e ICE

$ICE_i(z) = \hat{f}(z, x_{i,-j})$ y $PDP_j(z) = n^{-1} \sum_i ICE_i(z)$. Para comparar cambios, puede centrarse cada ICE restando su valor en un z_0 común. Estos gráficos describen al modelo; al sustituir entradas pueden crear combinaciones alejadas del soporte observado.

F9: Promediado de modelos

Para dos errores de media cero, $e = we_A + (1-w)e_B$: $\text{Var}(e) = w^2\sigma_A^2 + (1-w)^2\sigma_B^2 + 2w(1-w)\sigma_{AB}$. Sin restricción, $w^* = (\sigma_B^2 - \sigma_{AB})/(\sigma_A^2 + \sigma_B^2 - 2\sigma_{AB})$ si el denominador es positivo. Para mezcla convexa restrinja $0 \leq w \leq 1$. Los pesos se aprenden con predicciones fuera de muestra.

F10: Stacking

Para cada fila de desarrollo construya $Z_{im} = \hat{f}_m^{(-k(i))}(x_i)$, predicción de una base entrenada sin el pliegue de i . Ajuste el meta-modelo g sobre (Z, y) . Para producción reajuste las bases en todo desarrollo y use $g(\hat{f}_1(x), \dots, \hat{f}_M(x))$. Evaluar ese sistema durante selección requiere un nivel externo que también excluya la fila del ajuste del meta-modelo y del ajuste de hiperparámetros.

Parte I: Nivel introductorio

Ejercicio 1. Predicción de una hoja

Una hoja de árbol agrupa cuatro ventanas de llegada con esperas 4, 6, 8, 10 minutos. *Apoyo: formulario F1.*

- a) Calcule la predicción de la hoja y su RSS.
- b) Explique por qué cada observación recibe la misma predicción.
- c) ¿Qué ocurre si se crea una hoja con cada observación de entrenamiento?

Ejercicio 2. Muestrear con reemplazo

Desde cinco ventanas identificadas A–E se extrae la réplica (A, C, C, E, A) . *Apoyo: formulario F2.*

- a) Indique multiplicidades, observaciones distintas y observaciones OOB.
- b) ¿Por qué C repetida no constituye información nueva independiente?
- c) Explique cómo contribuye esta perturbación al promediado de árboles inestables.

Ejercicio 3. Elegir variables por nodo

Un problema tiene 16 predictores y un bosque considera 4 al azar por nodo. *Apoyo: formulario F3.*

- a) Calcule la probabilidad de incluir una señal específica en un nodo.
- b) Explique qué cambia frente a bagging de árboles.
- c) Si se usan los 16 predictores, ¿qué diferencia respecto de bagging desaparece, manteniendo los demás ajustes iguales?

Ejercicio 4. Quién puede predecir OOB

Una fila estuvo presente en bootstraps 1 y 3, y ausente en 2, 4 y 5. Los cinco árboles predicen 8, 12, 9, 14 y 10. *Apoyo: formulario F4.*

- a) Obtenga su predicción OOB.
- b) Explique por qué no debe promediar los cinco valores para estimar error OOB.
- c) ¿El caso puede usarse para afinar hiperparámetros sin que OOB siga siendo una prueba final independiente?

Ejercicio 5. Aprender de los residuos

Tres tiempos son (8, 12, 16) y el predictor inicial es la media. *Apoyo: formulario F5.*

- a) Obtenga f_0 y los residuos.
- b) Explique qué debe aproximar el primer árbol y por qué el segundo depende del primero.

- c) Distinga este mecanismo del ajuste paralelo de bagging.

Ejercicio 6. La misma pregunta para todos

Un árbol se evalúa con meses futuros, Random Forest con filas aleatorias y boosting con error de entrenamiento.

- a) Explique por qué sus RMSE no conforman un ranking válido.
- b) Enumere qué debe mantenerse común en una comparación.
- c) Distinga igual presupuesto computacional de idénticos hiperparámetros.

Ejercicio 7. Importancia no es causa

Un bosque asigna gran importancia por impureza a un código aleatorio con 900 valores distintos. Una variable binaria de revisión aparece baja. *Apoyo: formulario F7.*

- a) Explique un mecanismo de sesgo que favorece al código.
- b) Proponga una verificación fuera de muestra.
- c) Juzgue: “cambiar el código reducirá el tiempo de espera”.

Ejercicio 8. Promediar perfiles

Para cola igual a 4, tres curvas ICE predicen 10, 16 y 22 minutos. *Apoyo: formulario F8.*

- a) Calcule el PDP en ese valor.
- b) Explique qué se mantiene fijo y qué se reemplaza al construir cada ICE.
- c) ¿Ese promedio corresponde a una intervención real que modifica cola sin modificar ninguna otra condición?

Ejercicio 9. Mezcla de predicciones

Para un arribo, RF predice 12 y boosting 18 minutos. Se propone peso 0,7 para RF. *Apoyo: formulario F9.*

- a) Calcule la predicción combinada.
- b) Explique por qué los pesos deben sumar uno en una mezcla convexa.
- c) ¿Una mezcla siempre supera a su mejor componente? Justifique con el caso de errores idénticos.

Ejercicio 10. Construir la entrada del meta-modelo

Una fila está en el pliegue 3 de cinco. Hay dos modelos base. *Apoyo: formulario F10.*

- a) Indique con qué cuatro pliegues se entrenan las bases que generan sus dos entradas al meta-modelo.
- b) Explique por qué usar predicciones de ajuste del mismo caso favorece bases sobreajustadas.

- c) Distinga los predictores originales de las columnas de predicciones base.

Parte II: Nivel medio


Ejercicio 11. Evaluar un corte

Para carga $x = (1, 2, 3, 4)$ se observa espera $y = (2, 4, 8, 10)$ minutos. *Apoyo: formulario F1.*

- Calcule RSS sin dividir y con corte $x \leq 2,5$.
- Calcule la reducción de RSS y las dos predicciones.
- Compare con cortar en $x \leq 1,5$ y elija entre ambos.

Ejercicio 12. Geometría de un árbol

El corte propuesto se ubica en cola = 4,5.



Apoyo: formulario F1.

- Obtenga las medias de las hojas usando los seis puntos y dibuje la función escalonada resultante.
- Prediga para cola 5 y 20 y explique la limitación de extrapolación.
- ¿El gráfico permite atribuir causalmente el salto a un camión adicional?

Ejercicio 13. Cuánto dato queda fuera

Una base contiene $n = 10$ ventanas y cada bootstrap tiene tamaño 10. Use $0,9^{10} = 0,348678$. *Apoyo: formulario F2.*

- Calcule la probabilidad de que una fila quede OOB y el número esperado de filas distintas por réplica.
- Para 200 árboles, estime cuántos dejan fuera una fila dada.
- Distinga un valor esperado de un conteo garantizado.

Ejercicio 14. Promediar predicciones

Cinco árboles predicen para una llegada 12, 18, 15, 9, 16 minutos. *Apoyo: formulario F2.*

- Obtenga la predicción bagging y la varianza muestral de estas cinco salidas.
- Si se añade un sexto árbol que predice 14, calcule el nuevo promedio.
- Explique por qué la dispersión entre árboles no es directamente un intervalo de predicción para el tiempo real.


Ejercicio 15. Varianza de un bosque

Dos bosques tienen $\sigma^2 = 100$ y $B = 50$, con correlación media $\rho = 0,6$ y $0,2$. *Apoyo: formulario F3.*

- Calcule varianza del promedio en ambos y su límite cuando $B \rightarrow \infty$.
- Cuantifique la reducción de varianza al pasar de $B = 50$ a 100 en el primer bosque.
- Explique qué supuesto impide concluir que reducir siempre m mejora la predicción.

Ejercicio 16. Rendimientos decrecientes

La figura mantiene fija la varianza individual en 100.



Apoyo: formulario F3.

- Lea y verifique las varianzas para cinco árboles.
- Explique por qué 100 árboles correlacionados pueden promediar peor que diez menos correlacionados bajo estos supuestos.
- Proponga una medición empírica que acompañe la comparación de bosques reales.

Ejercicio 17. Error OOB de tres ventanas


Los tiempos reales son (10, 20, 15) y sus predicciones OOB son (12, 17, 16). *Apoyo: formulario F4.*

- Calcule errores, MSE y RMSE OOB.

- b) Si una cuarta fila no tiene ningún árbol OOB, explique cómo tratar el problema sin asignarle error cero.
- c) Indique por qué importa reportar cobertura de predicción.

Ejercicio 18. Cuántos árboles son suficientes

El mismo bosque se amplía conservando hiperparámetros.



- a) Identifique una zona de estabilización del error OOB y cuantifique la ganancia de 100 a 300 árboles.
- b) Explique por qué el descenso del error de ajuste no decide.
- c) Formule una regla práctica que considere estabilidad de predicciones y tiempo de cómputo.


Ejercicio 19. Una actualización de boosting

El predictor actual para cuatro ventanas es $(10, 10, 10, 10)$, los tiempos son $(8, 12, 16, 20)$ y un árbol de residuos produce $h = (0, 0, 8, 8)$. Use $\nu = 0,25$. *Apoyo: formulario F5.*

- a) Calcule residuos iniciales y nuevas predicciones.
- b) Compare SSE antes y después.
- c) Repita solo la actualización con $\nu = 1$ y explique por qué una mayor reducción de ajuste en este paso no garantiza mejor validación.

Ejercicio 20. Tasa y número de iteraciones

La figura usa iguales particiones y profundidad.



Apoyo: formulario F5.

- Elija la mejor iteración mostrada para cada tasa y compare errores.
- Explique por qué no es justo comparar tasas con un número pequeño fijo de árboles sin considerar convergencia.
- Indique dónde aplicaría parada temprana y qué conjunto conservaría sin consultar.

Ejercicio 21. Diferencias de error por pliegue

En cuatro pliegues comunes, RF obtiene RMSE (6,8,7,9) y boosting (5,5,8,5,6,5,8,5). *Apoyo: formulario F6.*

- Calcule promedios y diferencias RF menos boosting por pliegue.
- ¿Gana una familia en todos los pliegues?
- Formule una decisión si la mejora media es menor que la tolerancia operacional de 0,5 minutos.

Ejercicio 22. Costo de una búsqueda

RF usa 3 valores de `mtry`, 4 tamaños de hoja y 500 árboles fijos. Boosting usa 3 tasas, 3 profundidades y 4 cantidades de iteraciones. Se emplean 5 pliegues.

- Calcule ajustes de modelos completos por familia, sin reutilizar trayectorias.
- Explique qué cambia si boosting reutiliza una trayectoria hasta la mayor iteración.
- Proponga un presupuesto justo que no dependa únicamente del número de configuraciones.

Ejercicio 23. Calcular importancia por permutación


El RMSE base es 6,0 minutos. Al permutar cola tres veces se obtiene 8,0; 8,6 y 8,4; al permutar código, 6,1; 5,9 y 6,0. *Apoyo: formulario F7.*

- Calcule incrementos y sus promedios por variable.
- Interprete un incremento negativo y la variabilidad.

- c) Explique por qué no debe permutar sobre entrenamiento y presentar el resultado como utilidad futura.

Ejercicio 24. Leer el gráfico de importancia

Se grafican incrementos medios de RMSE, calculados en validación.



Apoyo: formulario F7.

- Ordene la evidencia de dependencia predictiva y distinga el valor negativo de peso de un “efecto beneficioso”.
- ¿Puede retirar código con este gráfico solamente?
- Indique qué bandas o repeticiones faltan y cómo afectaría la correlación entre cola y otro sensor.


Ejercicio 25. Construir PDP e ICE centradas

Para colas 2 y 6, las predicciones de tres perfiles son (8, 12), (10, 18) y (14, 16), respectivamente. Apoyo: formulario F8.

- Calcule el PDP en ambas colas.
- Centre cada ICE en cola 2 y obtenga sus cambios hasta cola 6.
- Explique qué heterogeneidad esconde el cambio promedio.

Ejercicio 26. Promedio plano, perfiles opuestos

Los dos perfiles tienen igual peso en el promedio.



Apoyo: formulario F8.

- Calcule las pendientes de A y B y la del promedio.
- Explique por qué el PDP plano no demuestra que el modelo ignora cola.
- Proponga una variable de interacción operacional plausible y un gráfico para verificarla.

Ejercicio 27. Varianza y complementariedad

Dos errores de media cero tienen varianzas 16 y 25 y covarianza 4. *Apoyo: formulario F9.*

- Calcule la varianza de su promedio simple.
- Compare con la mejor varianza individual y obtenga el peso óptimo de A.
- Explique qué cambia si los errores tienen sesgo y por qué entonces varianza no es todo el MSE.

Ejercicio 28. Elegir pesos con datos pequeños

Las respuestas son (10, 20, 30); A predice (12, 18, 28) y B (8, 24, 32). *Apoyo: formulario F9.*

- Calcule MSE de A, B y de pesos $w \in \{0, 25, 0, 5, 0, 75\}$ para A.
- Elija dentro de esa grilla usando estos datos como validación.
- Explique por qué debe evaluar después en otra muestra y por qué tres casos dan una decisión muy inestable.

Ejercicio 29. Evaluar un meta-modelo lineal

Un meta-modelo ya ajustado es $\hat{y} = 1 + 0,4z_{RF} + 0,5z_{GB}$. Para dos llegadas, $(z_{RF}, z_{GB}) = (10, 14)$ y $(20, 16)$. *Apoyo: formulario F10.*

- Calcule sus predicciones.
- Compare con el promedio simple y explique por qué esta combinación no es convexa estricta con esos coeficientes e intercepto.
- ¿Qué datos debieron generar los z usados para ajustar esa ecuación?

Ejercicio 30. Contar ajustes de stacking

Se usan 3 bases, 5 pliegues para generar predicciones OOF y un meta-modelo, con hiperparámetros fijados previamente. *Apoyo: formulario F10.*

- a) Cuente ajustes de bases para OOF, reajustes finales de bases y ajustes del meta-modelo.
- b) Explique qué ajustes adicionales exige evaluar todo el sistema con un nivel externo de 4 pliegues.
- c) No incluya búsqueda de hiperparámetros en su conteo; señale cómo ampliaría el costo.

Parte III: Nivel avanzado**Ejercicio 31. Poda con penalización**

Tres árboles sobre la misma muestra tienen $(RSS, \text{hojas}) = (220, 2), (150, 4), (110, 8)$. *Apoyo: formulario F1.*

- a) Compare C_α para $\alpha = 10$ y 25.
- b) Calcule el valor de α que iguala los árboles de 4 y 8 hojas.
- c) Explique por qué elegir α solo con el menor RSS de entrenamiento favorece complejidad excesiva.

Ejercicio 32. Bootstrap con dependencia

Hay 5.000 registros horarios correspondientes a 25 terminales, con rachas de congestión. Un analista aplica bootstrap de filas y reporta una fuerte reducción de incertidumbre.

- a) Identifique qué dependencias destruye y qué población pretende representar.
- b) Diseñe un remuestreo por terminal o por bloques temporales según el uso futuro.
- c) Explique por qué promediar modelos no corrige por sí solo una evaluación inválida.

Ejercicio 33. Omitir todas las señales

Hay 12 predictores, de los cuales 3 contienen señal. En cada nodo se sortean 4 sin reemplazo. Use $\binom{9}{4} = 126$ y $\binom{12}{4} = 495$.

- a) Calcule la probabilidad de que no se ofrezca ninguna señal y de que se ofrezca al menos una.
- b) Compare con sortear una sola variable.
- c) Discuta el compromiso entre calidad de los cortes y decorrelación sin usar únicamente esta probabilidad para elegir el parámetro.

Ejercicio 34. OOB después de buscar mucho

Se prueban 200 configuraciones y se publica el menor RMSE OOB, 5,1. Un conjunto independiente posterior entrega 7,0.

- a) Distinga sesgo de selección, cambio de población y variabilidad muestral como explicaciones posibles.
- b) Diseñe una comparación con pliegues externos o prueba reservada.
- c) Explique por qué OOB de filas puede ser inadecuado si el objetivo son terminales nuevos.

Ejercicio 35. Dos pasos calculados

Para $y = (4, 6, 14, 16)$, inicialice en la media. Un primer árbol tiene hojas que agrupan observaciones 1–2 y 3–4. Use $\nu = 0,5$ y mantenga esa partición en el segundo paso. *Apoyo: formulario F5.*

- a) Ajuste las medias residuales del primer árbol y actualice.
- b) Recalcule residuos, ajuste el segundo árbol y obtenga f_2 .
- c) Compare SSE en f_0, f_1, f_2 y explique qué limita extrapolar este comportamiento a validación.

Ejercicio 36. Seleccionar con incertidumbre y costo

Los promedios de RMSE y SE descriptivos son: árbol $8,1 \pm 0,5$, RF $6,2 \pm 0,4$ y boosting $6,0 \pm 0,6$. Sus latencias son 1, 4 y 12 ms. *Apoyo: formulario F6.*

- a) Calcule el umbral 1-SE del mínimo y los candidatos admisibles.
- b) Defina explícitamente un orden de simplicidad para decidir entre RF y boosting.
- c) Explique por qué las bandas no constituyen una prueba formal de igualdad de familias.

Ejercicio 37. Importancia diluida por redundancia

Dos proxies casi idénticos tienen incrementos individuales 0,1 y 0,2 minutos; al permutarlos conjuntamente el incremento es 3,5. *Apoyo: formulario F7.*

- a) Explique cómo la sustitución de información produce este patrón.
- b) Distinga permutación marginal, conjunta y condicionada.
- c) Diseñe un experimento de retirada de sensores que compare error y costo sin usar el test para elegir repetidamente.

Ejercicio 38. Combinaciones imposibles

En la base, número de muelles activos nunca supera número de operarios. Un PDP sustituye muelles por 10 para todas las filas, incluyendo filas con 4 operarios.

- a) Identifique el problema de soporte.
- b) Proponga restringir perfiles, usar gráficos condicionados o una alternativa local y explique qué pregunta responde cada opción.
- c) Diseñe una comunicación que no interprete predicciones fuera de soporte como mejoras factibles de capacidad.

Ejercicio 39. Un modelo peor puede ayudar

A y B tienen RMSE 10 y 10,5 con correlación de errores 0,95. C tiene RMSE 12 y correlación 0,1 con A. Suponga errores centrados. *Apoyo: formulario F9.*

- a) Compare el MSE de promediar A–B con el de A–C.
- b) Relacione precisión individual y complementariedad.
- c) Diseñe una selección de pesos con restricciones para evitar explotar ruido de la validación.

Ejercicio 40. La segunda fuga del stacking

Las bases generan predicciones OOF correctamente. Sin embargo, el meta-modelo se ajusta y evalúa sobre toda esa misma matriz OOF. Luego se selecciona entre 15 meta-modelos usando ese error.

- a) Identifique el error de evaluación que persiste.
- b) Diseñe un esquema anidado que excluya cada caso también de selección y ajuste del meta-modelo.
- c) Describa cómo entrenaría el sistema definitivo y reservaría una prueba completamente externa.

Parte IV: Desafíos con datos

Caso: anticipar espera al ingresar a un terminal logístico. La empresa dispone de ventanas operacionales independientes, con congestión, recursos y documentación conocidos al arribo. Quiere estimar minutos de espera para coordinar muelles. El caso compara árboles, bagging, Random Forest, boosting y combinaciones; importancia y gráficos parciales apoyan la interpretación del modelo seleccionado.

Ejercicio 41. D41: Un árbol para tiempos de espera

Abra `desarrollo.csv`. La unidad es una ventana independiente de operación con un camión evaluado al arribo.

- a) Audite variables y excluya identificadores y costos posteriores. Prepare cinco pliegues comunes con semilla 20260911, estratificando aproximadamente por terminal.
- b) Evalúe baseline de media y árbol con profundidades 2, 4 y 6.
- c) Entregue un árbol interpretable, error fuera de pliegue y una explicación de dos cortes industriales.

Ejercicio 42. D42: Bagging y estabilidad

Reutilice los pliegues de E41; dentro de cada ajuste construya bootstraps solo con sus filas de entrenamiento. *Apoyo: formulario F2.*

- a) Compare bagging con 50, 200 y 500 árboles, manteniendo todas las variables candidatas en cada corte.
- b) Estudie la variación de predicciones de 10 ventanas al cambiar semilla y compare con un árbol individual.

- c) Entregue curvas de error, costo de ajuste y una explicación del efecto del promediado.

Ejercicio 43. D43: Diversidad de un bosque

Compare Random Forest con bagging usando `mtry` proporcional a p : aproximadamente $p/3$, $p/2$ y p , redondeando y declarando si p cuenta columnas codificadas. *Apoyo: formulario F3.*

- a) Mantenga comunes pliegues, número de árboles y tamaño mínimo de hoja.
- b) Estime correlación entre predicciones de árboles sobre una misma muestra de evaluación y compare con RMSE.
- c) Entregue una tabla que separe diversidad, precisión y costo; no elija usando prueba final.

Ejercicio 44. D44: Contrastar OOB con validación

Para un bosque seleccionado dentro de desarrollo, obtenga predicciones OOB. *Apoyo: formulario F4.*

- a) Compare RMSE OOB con el RMSE de predicciones fuera de los pliegues de E41 y con error de entrenamiento.
- b) Explique las diferencias de tamaño efectivo de ajuste y reutilización para seleccionar.
- c) Entregue un gráfico OOB frente a número de árboles; reserve `prueba_final.csv` y no lo use para confirmar cada ajuste.

Ejercicio 45. D45: Boosting de espera

Use los mismos pliegues y variables del caso. *Apoyo: formulario F5.*

- a) Compare tasas 0,02, 0,05 y 0,1, profundidades 1, 2 y 3, y hasta 500 iteraciones. Determine iteración con evaluación interna a cada ajuste, o con una grilla fijada sin usar el pliegue externo.
- b) Grafique error frente a iteración y contraste árboles superficiales con interacciones.
- c) Entregue un candidato y su costo de ajuste y predicción.

Ejercicio 46. D46: Comparación defendible

Consolide E41–E45. *Apoyo: formulario F6.*

- a) Compare baseline, árbol, bagging, RF y boosting sobre las mismas predicciones de evaluación, con RMSE, MAE, errores por terminal y tiempo de predicción.
- b) Prepare diferencias por pliegue y una regla de decisión operacional antes de crear ensambles entre familias.
- c) Entregue una tabla con incertidumbre y costos, documentando qué hiperparámetros se ajustaron internamente y cuáles quedaron fijados.

Ejercicio 47. D47: Auditar la importancia

Use el RF de E43 y las particiones de desarrollo. *Apoyo: formulario F7.*

- Compare importancia por impureza y por permutación fuera de pliegue, repitiendo 20 permutaciones.
- Evalúe conjuntamente `camionesCola` y `cola_proxy`. Para una auditoría separada agregue `codigo_aleatorio`, dejando el modelo de producción sin ese identificador.
- Entregue un gráfico con dispersión y una explicación de por qué un ranking no demuestra efectos de intervenciones.

Ejercicio 48. D48: Explicar patrones del modelo

Para RF y boosting, construya PDP e ICE de cola y muelles sobre una grilla dentro de percentiles 5–95 de entrenamiento. *Apoyo: formulario F8.*

- Coloree ICE por revisión documental y terminal, y compare heterogeneidad entre familias.
- Revise combinaciones de cola con su proxy para identificar sustituciones poco plausibles; complemente con perfiles coherentes.
- Entregue dos gráficos comentados y una hipótesis operacional que requeriría un estudio adicional.

Ejercicio 49. D49: Combinar familias

Use predicciones fuera de pliegue de RF y boosting, con hiperparámetros ajustados dentro del desarrollo correspondiente. *Apoyo: formulario F9.*

- Estime correlación y sesgo de errores y compare promedio simple con pesos 0; 0,25; 0,5; 0,75; 1.
- Evalúe selección de pesos dentro de un nivel interno y conserve un nivel externo común para estimar desempeño.
- Entregue pesos, error y costo; justifique si la mejora compensa mantener dos modelos.

Ejercicio 50. D50: Decisión final del sistema

Construya stacking con árbol, RF y boosting, y un meta-modelo lineal regularizado o mezcla convexa. *Apoyo: formulario F10.*

- Genere OOF sin fuga y evalúe todo el sistema con el nivel externo de E49; compare contra las familias y el promedio simple.
- Congele receta y elección, reajuste en desarrollo y abra una sola vez `prueba_final.csv`.
- Entregue error global y por terminal, explicación de patrones, costos y una recomendación de operación que integre E41–E49.

Instructivo del caso integrador

Carpeta: datos/Unidad_2_Ensamble/.

`desarrollo.csv` contiene 900 ventanas y `prueba_final.csv`, 300; ambos tienen 12 columnas. Son ventanas sintéticas independientes de condiciones comparables, no una serie horaria ni múltiples filas del mismo camión. Esta premisa permite el esquema de pliegues aleatorios; si se reutilizara con datos dependientes habría que rediseñarlo.

Particiones. Cree cinco pliegues externos comunes con semilla 20260911. Para una estimación honesta después de ajustar hiperparámetros, use tres pliegues internos dentro de cada porción externa de entrenamiento. El escalado o imputación, cuando se utilicen, también se aprende dentro del ajuste. Mantenga los identificadores de los pliegues para comparar errores por las mismas ventanas. OOB sirve para diagnóstico y ajuste dentro de desarrollo, sin reemplazar la prueba final.

Secuencia y complejidad. E41–E45 establecen las familias; E46 las compara; E47–E48 auditan interpretación; E49–E50 combinan y deciden. Las matrices OOF destinadas a pesos o meta-modelos deben generarse de nuevo dentro del entrenamiento de cada pliegue externo. No basta que las bases excluyan la fila si su etiqueta ya intervino en elegir sus hiperparámetros o en entrenar el meta-modelo que la evalúa.

Datos disponibles. Al arribo se conocen cola, muelles, peso, dotación, revisión documental y prioridad. El tiempo real y el costo por espera se conocen después. `codigo_aleatorio` es un identificador numérico sin significado operativo; puede incorporarse solo en la auditoría de E47 y debe marcarse como tal. `cola_proxy` contiene información redundante y exige cautela en importancia y PDP.

Prueba y entrega. Abra prueba únicamente en E50, tras seleccionar todo el sistema, y compare con el baseline calculado en desarrollo. Informe minutos de error y costo computacional medido en el mismo equipo, sin prometer causalidad a partir de cortes o importancias. Se entregan `diccionario.csv`, `inicio.R` y generador reproducible con semilla 20260911; CSV UTF-8, coma y punto decimal.

Entrega y criterios comunes

Entregue un informe breve con secciones E41 a E50, un script o cuaderno ejecutable, tablas exportadas y gráficos con ejes, unidades y leyendas. Incluya la semilla usada, las versiones del software, las variables excluidas y el tratamiento de faltantes. Cada sección debe indicar una decisión, la evidencia que la respalda y una limitación.

Rúbrica orientativa del conjunto de desafíos: formulación y trazabilidad de datos (20 %), aplicación y cálculos (30 %), validación y manejo de incertidumbre (25 %), interpretación y recomendación industrial (15 %), reproducibilidad y claridad (10 %). El criterio evalúa la calidad del razonamiento; no exige obtener un resultado predeterminado.

Diccionario de variables

Variable	Descripción y unidad	Rol / disponibilidad
ventana_id	Ventana independiente; un camion evaluado por ventana (id).	identificador; al corte.
terminal	Terminal observado (categoria).	predictor; al corte.
camionesCola	Camiones en cola al llegar (camiones).	predictor; al corte.
muelles_activos	Muelles disponibles (muelles).	predictor; al corte.
peso_t	Peso declarado de carga (t).	predictor; al corte.
revision_documental	Necesidad de revision conocida al llegar (0/1).	predictor; al corte.
operarios	Dotacion disponible (personas).	predictor; al corte.
prioridad	Servicio prioritario contratado (0/1).	predictor; al corte.
cola_proxy	Medicion redundante de cola (indice).	predictor; al corte.
codigo_aleatorio	Identificador numerico arbitrario; usar solo en auditoria de importancia (codigo).	identificador; al corte.
espera_min	Espera realizada hasta entrar al muelle (min).	respuesta; despues.
costo_espera_real_clp	Costo realizado despues de esperar (CLP).	excluir_fuga; despues.