

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Guía de Ejercicios Propuestos

Unidad 4: Clasificación no Supervisada

Luis Rojo-González, Ph.D.

Profesor Asistente
Departamento de Ingeniería Industrial
Universidad de Santiago de Chile

Versión: 2.0
Fecha: Septiembre 2026

Cómo utilizar esta guía

Esta guía contiene **50 ejercicios independientes en su numeración**; los incisos son partes del mismo ejercicio. La distribución es: 10 introductorios, 20 medios, 10 avanzados y 10 desafíos. Cada uno de los diez temas tiene presencia en los cuatro niveles.

Los ejercicios 1–40 se resuelven con papel, calculadora y el formulario incluido, salvo que se solicite explícitamente diseñar un procedimiento. Muestre operaciones, indique unidades y justifique las decisiones. En selección múltiple escoja una alternativa y explique por qué; en verdadero/-falso corrija las afirmaciones falsas. Use tres decimales cuando corresponda y conserve precisión en cálculos intermedios.

Los ejercicios 41–50 son etapas de un caso integrador con datos sintéticos incluidos en el paquete. Requieren R, Python u otro software que permita reproducir el análisis. No basta entregar una captura de pantalla: debe documentar procedimiento, resultados y decisión operacional. No se exige un algoritmo particular cuando se admiten alternativas justificadas.

Los tiempos son orientativos: 8 minutos por introductorio, 12 por ejercicio medio, 20 por avanzado y 30–60 por desafío, una vez preparado el entorno. La guía completa es un banco de estudio; no se pretende resolver los 50 ejercicios en una hora.

Mapa de temas y progresión

Tema	Intro.	Medio	Avanz.	Desafío
Propósito y tendencia	1	11, 12	31	41
Escala y disimilitud	2	13, 14	32	42
K-means	3	15, 16	33	43
PAM y representantes	4	17, 18	34	44
Jerárquico y linkage	5	19, 20	35	45
DBSCAN	6	21, 22	36	46
HDBSCAN	7	23, 24	37	47
GMM y pertenencia	8	25, 26	38	48
Validación y estabilidad	9	27, 28	39	49
Perfiles, PCA y tiempo	10	29, 30	40	50

Práctica de 60 minutos

Resuelva los ejercicios 2, 9, 15, 19 y 25; reserve 8 minutos para revisar distancias, unidades y supuestos. Use el formulario. Los desafíos integradores se realizan en sesiones adicionales con datos.

Formulario de apoyo

Las expresiones siguientes fijan la convención que se utiliza en los ejercicios. Identifique qué cantidades son conocidas y qué supuestos necesita antes de sustituir valores.

F1: Tendencia al agrupamiento

Convención de Hopkins de esta guía en dimensión d : $H = \sum_i u_i^d / [\sum_i u_i^d + \sum_i w_i^d]$, donde u_i es distancia desde un punto uniforme de referencia al dato más cercano y w_i desde un dato muestreado a su vecino distinto más cercano. En esta convención valores altos sugieren concentración respecto de la referencia y valores cerca de 0,5 son compatibles con ella. Algunas implementaciones invierten el cociente o no elevan a d : declare su convención y contraste con una referencia simulada.

F2: Escala y distancias

$z_j = (x_j - \mu_j)/s_j$; $d_E(x, y) = \sqrt{\sum_j (x_j - y_j)^2}$. Gower con pesos iguales promedia contribuciones disponibles: $d_G = \sum_j \delta_j s_j / \sum_j \delta_j$. Para variable numérica $s_j = |x_j - y_j|/R_j$; para categórica nominal, $s_j = I(x_j \neq y_j)$. $\delta_j = 0$ si no puede compararse. Declare rangos, pesos y si una binaria es simétrica o asimétrica.

F3: K-means

Minimiza $W_K = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$. Asigne al centroide más cercano y actualice $\mu_k = |C_k|^{-1} \sum_{i \in C_k} x_i$. Use distancia euclídea y múltiples inicializaciones. Cada paso no aumenta el objetivo, pero no garantiza el óptimo global.

F4: PAM y medoides

PAM busca representantes observados m_k que minimicen $\sum_i \min_k d(x_i, m_k)$. Para un grupo fijo, evalúe cada representante por su suma de distancias a los demás. Puede usar disimilitudes como Gower. Su objetivo con distancias no es el mismo que el de K-means con distancias al cuadrado.

F5: Clustering jerárquico

Single linkage: $d(A, B) = \min_{i \in A, j \in B} d(i, j)$; complete: máximo; average: promedio entre todos los pares. Ward con datos euclídeos une el par de menor incremento $\Delta W = \frac{n_A n_B}{n_A + n_B} \|\bar{x}_A - \bar{x}_B\|^2$. Las alturas pueden representarse con convenciones distintas de escala; use la declarada en el ejercicio.

F6: DBSCAN

$N_\varepsilon(x) = \{z : d(x, z) \leq \varepsilon\}$. En esta guía **minPts** incluye el propio punto: núcleo si $|N_\varepsilon(x)| \geq \text{minPts}$; borde si está junto a un núcleo sin ser núcleo; ruido si no pertenece a un grupo alcanzable desde núcleos. Una cadena de puntos núcleo puede conectar regiones. Un punto borde compartido puede depender de una regla de asignación.

F7: HDBSCAN

Distancia de alcance mutuo: $d_{mr}(a, b) = \max\{core_k(a), core_k(b), d(a, b)\}$. En los cálculos de esta guía $core_k$ es la distancia al k -ésimo vecino distinto; declare convenciones del software. Densidad inversa $\lambda = 1/d$. Estabilidad simplificada de un grupo: $S(C) = \sum_{i \in C} (\lambda_{salida,i} - \lambda_{nacimiento,C})$. La selección compara persistencia de grupos en una jerarquía, no fija un único radio global.

F8: Mezclas gaussianas

$p(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \Sigma_k)$ y responsabilidad $\tau_{ik} = \pi_k \phi_k(x_i) / \sum_j \pi_j \phi_j(x_i)$. Paso M: $N_k = \sum_i \tau_{ik}$, $\pi_k = N_k/n$, $\mu_k = \sum_i \tau_{ik} x_i / N_k$. Convención de este banco: $BIC = -2\ell + q \log n$, menor es mejor, con q parámetros libres. Una mezcla univariada con varianzas propias tiene $q = 3K - 1$.

F9: Validación y estabilidad

Silhouette: $s(i) = [b(i) - a(i)] / \max\{a(i), b(i)\}$, con a distancia media a su grupo y b la menor distancia media a otro; singleton se fija en 0. Gap: $Gap(K) = E^*[\log W_K^*] - \log W_K$; regla: menor K con $Gap(K) \geq Gap(K+1) - s_{K+1}$. ARI: $\frac{\sum_{ij} \binom{n_{ij}}{2} - AB/N}{(A+B)/2 - AB/N}$, con $A = \sum_i \binom{a_i}{2}$, $B = \sum_j \binom{b_j}{2}$, $N = \binom{n}{2}$. Jaccard de grupos emparejados: $|C \cap D| / |C \cup D|$.

F10: Representación y perfiles

En PCA sobre matriz centrada X , scores $T = XW$; proporción de varianza del componente j : $\lambda_j / \sum \lambda$. La escala previa cambia la solución. Para comparar segmentos en el tiempo, mantenga la representación de referencia y distinga asignación con modelo congelado de reagrupamiento. Las etiquetas numéricas son arbitrarias: permutarlas no cambia una partición ni su ARI.

Parte I: Nivel introductorio

Ejercicio 1. ¿Qué es un segmento útil?

Un operador desea agrupar clientes para definir frecuencias de visita comercial.

- Distinga la pregunta de clustering de predecir abandono.
- Defina unidad y dos variables que describan comportamiento previo al corte.
- Juzgue: “obtener cuatro grupos demuestra que existen cuatro tipos naturales de clientes”.

Ejercicio 2. Unidades que dominan

Dos clientes difieren en 100.000 CLP de ticket y en 5 puntos porcentuales de margen. *Apoyo: formulario F2.*

- Calcule la contribución de cada diferencia a distancia euclídea al cuadrado en esas unidades.
- Explique por qué cambiar CLP a miles de CLP altera la geometría.
- Proponga una escala y una precaución ante valores extremos.

Ejercicio 3. Asignar al centroide cercano

Un cliente es $x = (2, 3)$ y los centroides son $(1, 1)$ y $(5, 5)$. *Apoyo: formulario F3.*

- Calcule distancias al cuadrado y asigne el cliente.
- Si empatan dos centroides, proponga una regla reproducible.
- Explique por qué un centroide no tiene que coincidir con un cliente real.

Ejercicio 4. Qué representa un medoide

En un grupo de clientes, el centroide presenta 2,6 contratos y un canal promedio inexistente. *Apoyo: formulario F4.*

- Explique por qué esas coordenadas no describen un cliente real.
- Compare centroide y medoide para comunicación comercial.
- Indique qué disimilitud permite considerar canales nominales de forma explícita.

Ejercicio 5. Dos definiciones de cercanía

Entre los grupos $A = \{a_1, a_2\}$ y $B = \{b_1, b_2\}$, las cuatro distancias son 2, 4, 6 y 8. *Apoyo: formulario F5.*

- Calcule single, complete y average linkage.
- Explique qué definición es más sensible a una conexión cercana aislada.
- ¿Las tres alturas deben producir el mismo dendrograma?

Ejercicio 6. Núcleo, borde y ruido

Con $\varepsilon = 1$ y $\text{minPts}=4$, A tiene 5 puntos en su vecindario contando A; B tiene 2 contando B y está a distancia 0,5 de A; C tiene solo a sí mismo y no está cerca de ningún núcleo. *Apoyo: formulario F6.*

- a) Clasifique A, B y C.
- b) Explique por qué B puede pertenecer a un grupo sin ser núcleo.
- c) ¿C es necesariamente un error de registro?

Ejercicio 7. Grupos que persisten

Dos concentraciones de clientes permanecen separadas en un rango amplio de densidades, mientras un grupo pequeño aparece solo brevemente. *Apoyo: formulario F7.*

- a) Explique qué información aporta una jerarquía de densidad frente a un único ε .
- b) Distinga tamaño mínimo de grupo de número de vecinos usado para estimar densidad.
- c) ¿Toda implementación utiliza esos nombres y convenciones idénticos? Indique qué debe documentarse.

Ejercicio 8. Pertenencia incierta

Un modelo de mezcla asigna a un cliente responsabilidades (0,50; 0,47; 0,03). *Apoyo: formulario F8.*

- a) Determine la asignación por máximo y explique la incertidumbre que pierde.
- b) Compare con (0,95; 0,03; 0,02).
- c) Explique por qué las responsabilidades dependen del modelo y no demuestran tipos naturales.

Ejercicio 9. Silhouette de un cliente

Para un cliente, distancia media a su grupo $a = 2$ y al grupo alternativo más próximo $b = 5$. Para otro, $a = 4, b = 3$. *Apoyo: formulario F9.*

- a) Calcule ambos silhouettes.
- b) Interprete valores positivo, cercano a cero y negativo.
- c) Explique por qué un valor negativo no exige eliminar automáticamente al cliente.

Ejercicio 10. Nombrar grupos con evidencia

Un grupo presenta alta frecuencia de pedidos y bajo margen; otro, baja frecuencia y alto ticket.

- a) Proponga nombres descriptivos sin calificar a las personas.
- b) Distinga un perfil de grupo de una propiedad de todos sus miembros.
- c) Explique por qué observar mayor abandono en un grupo no prueba que cambiar su canal reduzca abandono.

Parte II: Nivel medio


Ejercicio 11. Calcular Hopkins

En un espacio de dimensión 2, se informa $\sum u_i^2 = 18$ y $\sum w_i^2 = 2$. *Apoyo: formulario F1.*

- Calcule Hopkins y compare con el caso en que ambas sumas valen 10.
- Explique el papel de la distribución uniforme de referencia.
- ¿Puede concluir con este valor que $K = 4$ es óptimo?

Ejercicio 12. Mirar una nube de puntos

Cada punto representa un cliente en dos variables estandarizadas.



- Proponga una cantidad inicial de grupos y describa separación y dispersión.
- Explique dos razones por las que una proyección bidimensional podría resultar engañosa.
- Indique qué evidencia adicional pediría antes de diseñar campañas diferentes.

Ejercicio 13. Estandarizar y medir

Para pedidos y recencia, medias de referencia (20, 30) y desviaciones (10, 20). Los clientes A y B son (10, 10) y (30, 50). *Apoyo: formulario F2.*

- Estandarice ambos y calcule distancia euclídea.
- Compare con la distancia original.
- Explique por qué los parámetros de enero deben conservarse al asignar clientes de julio a grupos congelados.

Ejercicio 14. Gower para datos mixtos


A tiene ticket 40, margen 20 % y canal Web; B tiene ticket 70, margen 10 % y canal Ejecutivo. Los rangos de referencia son 100 y 40 puntos. *Apoyo: formulario F2.*

- Calcule tres contribuciones y Gower con pesos iguales.

- b) Repita si falta margen en B, comparando solo variables disponibles.
- c) Explique el riesgo de comparar clientes usando cantidades muy distintas de información.

Ejercicio 15. Una iteración completa

Los clientes son A (1, 1), B (2, 1), C (8, 8) y D (9, 8); centroides iniciales (1, 1) y (8, 8).



Apoyo: formulario F3.

- a) Asigne los cuatro puntos y recalcule centroides.
- b) Calcule W_2 después de actualizar y compruebe si otra asignación los cambia.
- c) ¿La convergencia demuestra optimalidad global para cualquier base?

Ejercicio 16. Inicialización desafortunada

En una dimensión hay clientes con valores 0, 1, 2, 8, 9, 10. Los centros iniciales son 0 y 1. En empates asigne al centro de menor índice. Apoyo: formulario F3.

- a) Realice dos iteraciones completas de asignación y actualización.
- b) Compare con iniciar en 0 y 10.
- c) Explique por qué se repite el ajuste desde varios inicios y qué objetivo se usa para elegir entre ellos.

Ejercicio 17. Buscar el medoide

Las distancias entre cuatro clientes son simétricas, diagonal cero: $d_{AB} = 2, d_{AC} = 5, d_{AD} = 6, d_{BC} = 4, d_{BD} = 5, d_{CD} = 1$. Apoyo: formulario F4.

- a) Calcule suma de distancias de cada candidato y seleccione medoide, declarando una regla si hay empate.
- b) Con medoides A y C, asigne B y D y calcule objetivo total.
- c) Explique por qué no corresponde promediar códigos categóricos.


Ejercicio 18. Evaluar un intercambio PAM

En una dimensión hay puntos 0, 2, 3, 9, 10. Los medoides son 0 y 9. *Apoyo: formulario F4.*

- Calcule objetivo de suma de distancias absolutas al medoide más cercano.
- Evalúe intercambiar 0 por 2 y luego por 3, manteniendo 9.
- Elija el mejor intercambio y explique por qué un paso local no prueba óptimo global en problemas grandes.

Ejercicio 19. Leer un dendrograma

Las alturas representan las disimilitudes de fusión declaradas en esta figura.



Apoyo: formulario F5.

- Identifique las primeras dos fusiones.
- Enumere grupos al cortar en altura 3 y en altura 5.
- Determine la distancia cofenética de A–B, A–C y A–E y explique qué representa.

Ejercicio 20. Calcular una fusión de Ward

Dos grupos tienen tamaños 3 y 2 y centroides (1, 2) y (4, 2). *Apoyo: formulario F5.*

- Calcule incremento de suma de cuadrados al fusionarlos.
- Compárelo con otro par de tamaños 1 y 1 y centroides separados por distancia 4.
- Explique por qué Ward no se aplica sin justificación a cualquier matriz Gower.

Ejercicio 21. DBSCAN en una recta


Los puntos son 0; 0,2; 0,4; 1,0; 1,2; 3,0. Use $\varepsilon = 0,25$ y $\text{minPts}=3$, incluyendo al propio punto. *Apoyo: formulario F6.*

- Liste vecindarios y clasifique núcleos, bordes y ruido.

- b) Determine los grupos.
- c) Explique qué ocurre al subir ε a 0,65 y revise si aparece una cadena de conexión.

Ejercicio 22. Leer distancias ordenadas

La distancia mostrada corresponde al tercer vecino distinto; se considera explorar $\text{minPts}=4$ contando el propio punto.



Apoyo: formulario F6.

- a) Proponga dos valores de ε cercanos al cambio de pendiente.
- b) Explique qué ocurre con puntos de distancia superior al radio y por qué el gráfico no determina por sí solo todos los puntos borde.
- c) Indique una comprobación de sensibilidad.

Ejercicio 23. Alcance mutuo

Para A, B y C, $\text{core}_k = (0,2; 0,5; 0,3)$ y distancias $d_{AB} = 0,1$, $d_{AC} = 0,7$, $d_{BC} = 0,4$. Apoyo: formulario F7.

- a) Calcule las tres distancias de alcance mutuo.
- b) Determine las dos aristas de menor peso que conectan los tres puntos sin ciclo.
- c) Explique por qué una cercanía euclídea muy pequeña puede aumentar al considerar densidad local.

Ejercicio 24. Persistencia simplificada

Un grupo nace en $\lambda = 2$ y sus tres puntos salen en 5, 6, 4. Otro nace en 2 y sus cuatro puntos salen en 3, 3, 3, 3. Apoyo: formulario F7.

- a) Calcule las dos estabilidades simplificadas.
- b) Explique qué combina la medida y por qué tamaño no es el único criterio.
- c) Si el primero tiene subgrupos, ¿basta comparar su estabilidad con la de un grupo ajeno para describir toda la selección jerárquica?

Ejercicio 25. Un paso de responsabilidades

Dos componentes tienen pesos $\pi_1 = 0,6$ y $\pi_2 = 0,4$. Para un cliente, sus densidades gaussianas son 0,2 y 0,3. *Apoyo: formulario F8.*

- Calcule densidad de mezcla y responsabilidades.
- Repita si las densidades pasan a 0,4 y 0,1.
- Explique por qué no basta comparar densidades sin considerar los pesos.


Ejercicio 26. Actualizar medias con EM

Los datos unidimensionales son $x = (0, 2, 8)$; responsabilidades del componente 1: $(0,9, 0,8, 0,1)$; del 2, sus complementos. *Apoyo: formulario F8.*

- Calcule N_1, N_2 , nuevos pesos y medias.
- Compare con medias obtenidas al asignar por máximo.
- Explique por qué estas operaciones son un paso y no aseguran convergencia global.

Ejercicio 27. Leer silhouettes individuales

El gráfico presenta seis clientes con igual peso.




Apoyo: formulario F9.

- Calcule silhouette promedio y detecte qué casos requieren revisión.
- Explique por qué el promedio puede ocultar un grupo completo mal definido si ese grupo es pequeño.
- Proponga un gráfico adicional por grupo y reporte de tamaños.

Ejercicio 28. Codo y Gap

La suma interna se muestra a continuación.




Para $K = 2, 3, 4, 5$, Gap vale 0,30; 0,46; 0,49; 0,50, con $s_3 = 0,04$, $s_4 = 0,05$, $s_5 = 0,04$. *Apoyo: formulario F9.*

- Proponga un codo y calcule la regla Gap desde $K = 2$.
- Explique por qué el máximo Gap no es la misma regla.
- Indique qué evidencia de estabilidad y utilidad falta.

Ejercicio 29. PCA y varianza acumulada

La figura resume PCA sobre seis variables estandarizadas.



Apoyo: formulario F10.

- Calcule varianza acumulada con dos, tres y cuatro componentes.
- Elija el mínimo para superar 80 %.
- Explique por qué preservar 82 % de varianza no garantiza preservar la separación más útil para segmentar.

Ejercicio 30. Migración entre segmentos

Con modelo y escala congelados, 100 clientes comunes tienen matriz de transición enero-julio $\begin{pmatrix} 35 & 5 \\ 15 & 45 \end{pmatrix}$, filas de enero y columnas de julio.

- a) Calcule porcentaje que cambia y probabilidades de transición por grupo inicial.
- b) Distinga cambio de comportamiento de cambio de nombres de grupos.
- c) Explique por qué clientes nuevos o perdidos no deben mezclarse con el denominador de clientes comunes.

Parte III: Nivel avanzado

Ejercicio 31. La referencia cambia la conclusión

Hopkins se repite 20 veces y entrega media 0,91. Los datos presentan dos variables muy correlacionadas y se compara con puntos uniformes en todo el rectángulo que las contiene. *Apoyo: formulario F1.*

- a) Explique por qué una nube alargada continua puede apartarse de esa referencia sin formar segmentos discretos.
- b) Diseñe referencias y gráficos de sensibilidad.
- c) Proponga una condición para concluir que no hay segmentación útil aunque el estadístico sea alto.

Ejercicio 32. Pesos y variables redundantes

Una segmentación incluye pedidos, unidades y monto, fuertemente relacionados, además de cinco variables binarias de servicio. Se estandariza cada columna y se usa euclídea.

- a) Explique por qué cada columna con igual varianza no equivale a igual peso de cada concepto de negocio.
- b) Proponga ponderación por bloques o una representación alternativa y cómo evaluarla.
- c) Distinga elección sustantiva de pesos de optimizarlos solo para maximizar silhouette.

Ejercicio 33. Un extremo mueve el centro

Un grupo unidimensional contiene 1, 2, 3, 4; se agrega un cliente con valor 30. *Apoyo: formulario F3.*

- a) Calcule el centroide y la suma de cuadrados antes y después, conservando el grupo fijo.
- b) Explique cómo ese punto podría consumir un centroide cuando se reajusta K-means.
- c) Proponga una auditoría y un método alternativo sin eliminar automáticamente al cliente de alto valor.

Ejercicio 34. Robustez y costo

Se desea segmentar 40.000 clientes con una matriz completa de disimilitud simétrica. Suponga almacenar una matriz densa en 8 bytes por entrada.

- a) Calcule memoria en bytes y GB decimales.
- b) Explique por qué usar medoides no elimina el costo de calcular distancias.

- c) Proponga muestreo de candidatos y validación en clientes no usados para elegir representantes, conservando una evaluación de segmentos pequeños.

Ejercicio 35. Preservar distancias o separar grupos

Single linkage obtiene correlación cofenética 0,88 y silhouette 0,34 con tres grupos; Ward, 0,79 y 0,57 sobre la misma representación euclídea.

- a) Distinga qué evalúa cada indicador.
- b) Explique por qué mayor correlación cofenética no implica mejores segmentos operacionales.
- c) Proponga inspecciones de encadenamiento, tamaños y estabilidad antes de elegir.

Ejercicio 36. Densidades distintas

Con $\varepsilon = 0,3$, DBSCAN recupera clientes muy densos y marca otro conjunto más disperso como ruido; con 0,8 conecta ambos por una cadena.

- a) Explique el conflicto de un radio global.
- b) Proponga revisar representación y un método de densidad variable.
- c) Defina cómo reportaría fracción de ruido, estabilidad y perfiles, sin elegir únicamente el menor porcentaje de ruido.

Ejercicio 37. Parámetros y abstención

Con tamaño mínimo 10, HDBSCAN entrega 8 grupos y 12 % de ruido; con 40, entrega 3 grupos y 28 % de ruido. Los grupos pequeños tienen perfiles distintos pero pocos clientes.

- a) Discuta resolución, estabilidad y tamaño operacional mínimo.
- b) Explique por qué más ruido no implica automáticamente peor modelo.
- c) Diseñe un criterio que combine cobertura, persistencia y capacidad de atender segmentos, sin presentar pertenencia como certeza causal.

Ejercicio 38. BIC y covarianzas

Para $n = 100$ datos unidimensionales, mezclas con $K = 1, 2, 3$ tienen log-verosimilitudes $-220, -190, -184$. Cada componente tiene su propia varianza. Use $\log 100 = 4,6052$. *Apoyo: formulario F8.*

- a) Calcule cantidad de parámetros y BIC de cada opción.
- b) Elija con la convención de menor BIC.
- c) Explique por qué múltiples inicios y restricciones ante varianzas casi nulas siguen siendo necesarios.

Ejercicio 39. ARI y cambio de nombres

Dos particiones de seis clientes producen tabla de coincidencias $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, con totales marginales 3 y 3.

Apoyo: formulario F9.

- a) Calcule ARI usando $\binom{6}{2} = 15$ y $\binom{3}{2} = 3$.
- b) ¿Qué ARI obtendría si solo intercambiara los nombres de dos grupos idénticos?
- c) Explique cómo emparejar grupos y distinguir renombrado, fragmentación y cambio real de miembros.

Ejercicio 40. Alta dimensión y causalidad

Se agrupan 300 cuentas con 800 características de transacciones. Las distancias son casi iguales. Después de PCA aparece un grupo con mayor abandono y se propone imponer una frecuencia de compra mínima.

- a) Diseñe una reducción de dimensión y evaluación de estabilidad sin usar abandono para elegir todo el pipeline.
- b) Explique el riesgo de perder variables de baja varianza relevantes.
- c) Identifique el salto causal y proponga un piloto de intervención con resultados y costos observables.

Parte IV: Desafíos con datos

Caso: segmentación de una cartera industrial. Un distribuidor desea organizar servicio y visitas comerciales usando comportamiento de clientes. La base mezcla escalas, categorías, faltantes, densidades y observaciones extremas. Se comparan familias de clustering y se estudia si sus segmentos son estables y útiles seis meses después. No se proporcionan etiquetas de “grupo verdadero”.

Ejercicio 41. D41: Auditar clientes y tendencia

Abra únicamente `clientes_enero.csv`. *Apoyo: formulario F1.*

- a) Audite identificadores, faltantes, rangos y extremos; defina propósito y ventana de comportamiento.
- b) En variables numéricas escaladas, repita Hopkins 20 veces con submuestras y compare con referencias simuladas de igual dimensión; declare la convención.
- c) Entregue gráficos y una conclusión provisional sobre tendencia, sin decidir aún K ni usar resultados futuros.

Ejercicio 42. D42: Dos representaciones explícitas

Prepare A: variables numéricas imputadas y escaladas; B: representación mixta para Gower con canal, contrato y región. *Apoyo: formulario F2.*

- a) Documente rangos, pesos y tratamiento de binarios y faltantes; excluya ID.
- b) Compare vecinos de cinco clientes en ambas representaciones y evalúe una escala robusta frente a extremos.
- c) Guarde transformaciones de enero para julio y explique por qué las métricas internas de A y B no forman automáticamente un ranking comparable.

Ejercicio 43. D43: K-means con múltiples inicios

Use representación numérica A de E42. *Apoyo: formulario F3.*

- a) Ajuste $K = 2, \dots, 8$ con al menos 30 inicios y semilla registrada; conserve el mejor objetivo y su variación entre inicios.
- b) Grafique W_K , tamaños y perfiles en unidades originales para dos candidatos.
- c) Entregue una partición provisional y analice sensibilidad a la escala robusta, sin confundir menor W_K con evidencia concluyente de más grupos.

Ejercicio 44. D44: Segmentos representados por clientes

Ajuste PAM en representación B con $K = 2, \dots, 8$. *Apoyo: formulario F4.*

- a) Presente medoides reales, tamaños y perfiles; explique semejanzas entre cada representante y su grupo.
- b) Para comparar algoritmo con K-means, repita PAM en A usando euclídea y la misma muestra.
- c) Entregue dos comparaciones separadas: efecto de algoritmo en A y efecto de representación en PAM; no ordene todos los silhouettes como si midieran lo mismo.

Ejercicio 45. D45: Jerarquía de segmentos

Sobre A, compare average, complete y Ward; documente convención de Ward de su software. *Apoyo: formulario F5.*

- a) Trace dendrogramas legibles de una submuestra reproducible y calcule particiones sobre la muestra de análisis declarada.
- b) Compare cortes con $K = 3, 4, 5$, perfiles y correlación cofenética, sin seleccionar solo por esta última.
- c) Entregue una jerarquía comentada y distinga conclusiones de la submuestra de las de los 720 clientes.

Ejercicio 46. D46: Segmentación por densidad

Use A y declare que `minPts` incluye el punto. *Apoyo: formulario F6.*

- a) Explore `minPts` de 5, 10 y 20 y radios sustentados en gráficos de vecinos.

- b) Reporte número y tamaño de grupos, fracción de ruido y estabilidad ante cambios moderados de radio.
- c) Si calcula silhouette sin ruido, informe cobertura y no compárelo sin más con particiones de todos los clientes. Entregue perfiles de ruido para revisión, sin etiquetarlos automáticamente como fraude o errores.

Ejercicio 47. D47: Densidad variable

Sobre la misma A de E46, ajuste HDBSCAN y documente los parámetros efectivos disponibles en su software, incluida la convención de vecinos. *Apoyo: formulario F7.*

- a) Explore tamaños mínimos de 10, 25 y 50, y un rango razonable del parámetro de densidad si es independiente.
- b) Compare persistencia, ruido y perfiles con DBSCAN, respetando la misma cobertura al contrastar métricas.
- c) Entregue una recomendación sobre grupos estables y clientes para los que conviene abstenerse de asignar.

Ejercicio 48. D48: Segmentos probabilísticos

Use las variables numéricas de A. *Apoyo: formulario F8.*

- a) Compare GMM con $K = 2, \dots, 6$ y covarianzas diagonal y completa, usando múltiples inicios y la misma muestra. Reporte convergencia, regularización de covarianzas y BIC bajo una convención explícita.
- b) Identifique clientes con responsabilidad máxima inferior a 0,60 y describa su posición.
- c) Entregue perfiles ponderados y contraste con K-means sin tratar la pertenencia probabilística como etiqueta verdadera.

Ejercicio 49. D49: Elegir con estabilidad

Retenga tres candidatos de E43–E48. *Apoyo: formulario F9.*

- a) Realice 30 submuestras sin reemplazo del 80 % de clientes; reajuste el procedimiento y compare etiquetas solo en clientes comunes con la referencia.
- b) Calcule ARI y Jaccard por grupos emparejados; declare tratamiento de ruido y perfiles pequeños.
- c) Integre evidencia interna comparable, estabilidad, cobertura y utilidad; elija una solución o justifique que ninguna sirve. Guarde la representación y la regla de asignación.

Ejercicio 50. D50: Segmentos en operación

Abra `clientes_julio.csv` y `resultados_semestre.csv` solo después de E49. *Apoyo: formulario F10.*

- a) Congele escala y representantes de enero; defina asignación compatible con el algoritmo elegido y reporte abstenciones. Separe clientes comunes, nuevos y ausentes; calcule transiciones solo en comunes.
- b) Use resultados futuros únicamente para describir utilidad externa, con tamaños e incertidumbre, sin reoptimizar la segmentación con abandono.
- c) Entregue perfiles, continuidad de nombres y una propuesta de piloto que integre E41–E49 o una conclusión justificada de falta de utilidad.

Instructivo del caso integrador

Carpeta: `datos/Unidad_4_Clustering/`. `clientes_enero.csv` contiene 720 clientes y 10 columnas con resúmenes de los seis meses anteriores al corte de enero. `clientes_julio.csv` tiene 720 clientes y las mismas columnas, con historia al corte de julio. Comparten 660 identificadores: hay 60 clientes de enero ausentes en julio y 60 nuevos. `resultados_semestre.csv` contiene 720 filas y 3 columnas con abandono y margen del semestre posterior a enero para los clientes de la base original.

Representación. E41–E49 usan únicamente enero. La representación A incluye las seis variables numéricas de comportamiento; B puede incorporar además canal, contrato y región mediante Gower. ID no define semejanza. Documente imputación, escala, transformaciones de asimetría y pesos. No descarte automáticamente tickets altos: podrían representar clientes relevantes. Compare métricas internas entre algoritmos solo cuando comparten población y representación o disimilitud apropiada. Reporte claramente la cobertura cuando se excluye ruido.

Estabilidad. En E49 reajuste también la representación en cada submuestra para evaluar el procedimiento completo y compare etiquetas sobre IDs comunes. Puede agregar un análisis secundario con representación fija para aislar variación del algoritmo. Los nombres de grupos no están identificados: use emparejamiento para Jaccard y perfiles; ARI ya es invariante a permutaciones. Una etiqueta que cambia de número no es fragmentación.

Asignación futura. Para K-means use centroides congelados; para PAM, medoides; para GMM, responsabilidades. Una partición jerárquica o de densidad requiere una regla adicional explícita: por ejemplo, asignación al representante dentro de un radio validado, con abstención fuera de soporte, o un método de predicción propio de la implementación. Esa regla es una extensión operacional, no el mismo acto de reagrupar toda la base. Reagrupar julio puede ser un análisis secundario, distinguiéndolo de migración con modelo congelado.

Uso externo. E50 use resultados por ID a los grupos de enero; no usa abandono ni margen futuro como entrada, ni para reoptimizar K antes de declarar validación. Reporte asociaciones e incertidumbre y evite convertirlas en efectos causales. Un piloto comercial debe definir intervención, control y costos, aunque no se ejecute en esta guía.

Archivos auxiliares. CSV UTF-8, coma, punto decimal y NA; `diccionario.csv` registra disponibilidad y `inicio.R` abre enero. El generador usa semilla 20260913. Los patrones son sintéticos; recuperar la estructura interna del generador no es el objetivo ni una prueba de que existan segmentos naturales en datos reales.

Entrega y criterios comunes

Entregue un informe breve con secciones E41 a E50, un script o cuaderno ejecutable, tablas exportadas y gráficos con ejes, unidades y leyendas. Incluya la semilla usada, las versiones del software, las variables excluidas y el tratamiento de faltantes. Cada sección debe indicar una decisión, la evidencia que la respalda y una limitación.

Rúbrica orientativa del conjunto de desafíos: formulación y trazabilidad de datos (20%), aplicación y cálculos (30%), validación y manejo de incertidumbre (25%), interpretación y recomendación industrial (15%), reproducibilidad y claridad (10%). El criterio evalúa la calidad del razonamiento; no exige obtener un resultado predeterminado.

Diccionario de variables

Variable	Descripción y unidad	Rol / disponibilidad
cliente_id	Identificador estable del cliente (id).	identificador; al corte.
pedidos_mes	Promedio mensual en los seis meses previos (pedidos/mes).	predictor; al corte.
ticket_mclp	Ticket medio (millones de CLP).	predictor; al corte.
recencia_dias	Dias desde ultima compra (dias).	predictor; al corte.
margen_pct	Margen comercial medio; puede faltar (porcentaje).	predictor; al corte.
devoluciones_pct	Porcentaje de pedidos devueltos (porcentaje).	predictor; al corte.
variabilidad_pedidos	Coeficiente de variacion mensual (razon).	predictor; al corte.
canal	Canal habitual (categoria).	predictor; al corte.
contrato	Contrato comercial vigente (0/1).	predictor; al corte.
region	Region de atencion (categoria).	predictor; al corte.
abandono_semestre	Abandono observado despues de enero; solo evaluacion externa (0/1).	evaluacion_externa; julio.
margen_semestre_mclp	Margen observado del semestre; nunca entrada del clustering de enero (millones de CLP).	evaluacion_externa; julio.