

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

---

ESTADÍSTICA APLICADA

# Solucionario - Guía de Ejercicios Propuestos

Unidad 1: Regularización, validación cruzada y modelos  
flexibles

**Luis Rojo-González, Ph.D.**

Profesor Asistente

Departamento de Ingeniería Industrial

Universidad de Santiago de Chile

Versión: 2.0

Fecha: Septiembre 2026

---

### Alcance y uso de la pauta

Este solucionario responde a los **50 ejercicios** de la guía correspondiente, conservando número y letras de cada inciso. Los ejercicios 1–40 incluyen cálculos, interpretación de gráficos y respuestas razonadas; los ejercicios 41–50 presentan una solución reproducible del caso integrador con los datos sintéticos entregados.

No se exige memorizar fórmulas. Se evalúa reconocer el método, sustituir cantidades correctamente, interpretar unidades y distinguir incertidumbre, magnitud y utilidad operacional. El formulario de la guía fija convenciones; aquí se muestran las operaciones necesarias para verificar los resultados.

Los desafíos admiten alternativas. Un modelo, partición o decisión distinta puede ser correcta si respeta disponibilidad temporal, datos reservados, supuestos, criterio declarado y evidencia reproducible. Los valores aquí reportados corresponden a una ejecución de referencia, no son una meta que deba alcanzarse ajustando reiteradamente sobre prueba.

En tablas, un guion indica una cantidad indefinida o no aplicable. No debe reemplazarse silenciosamente por cero. Los redondeos se realizan al presentar, conservando precisión de cálculo.

## Correspondencia de contenidos

| Tema                     | Intro. | Medio  | Avanz. | Desafío |
|--------------------------|--------|--------|--------|---------|
| Particiones y baseline   | 1      | 11, 12 | 31     | 41      |
| Validación cruzada       | 2      | 13, 14 | 32     | 42      |
| Preprocesamiento y fuga  | 3      | 15, 16 | 33     | 43      |
| Ridge                    | 4      | 17, 18 | 34     | 44      |
| Lasso                    | 5      | 19, 20 | 35     | 45      |
| Elastic-net              | 6      | 21, 22 | 36     | 46      |
| Complejidad y polinomios | 7      | 23, 24 | 37     | 47      |
| Splines                  | 8      | 25, 26 | 38     | 48      |
| GAM e interacciones      | 9      | 27, 28 | 39     | 49      |
| Selección y transporte   | 10     | 29, 30 | 40     | 50      |

## I. Soluciones de nivel introductorio

### Solución 1: Tres conjuntos, tres funciones

- a) Entrenamiento: 600, para estimar parámetros; validación: 200, para elegir especificación e hiperparámetros; prueba: 200, para evaluar el procedimiento congelado.
- b) Falso. Elegir nuevas variables mirando el test lo transforma en información de desarrollo; su error deja de ser una evaluación independiente de la selección.
- c) La media del baseline se calcula con entrenamiento. La validación decide hiperparámetros. Después de congelarlos se puede reajustar usando entrenamiento y validación, recalculando también el baseline antes del test.

### Solución 2: K-fold sin dependencia

- a) Cada iteración ajusta con 800 y valida con 200. Hay cinco ajustes; cada observación recibe exactamente una predicción fuera de su pliegue y participa en cuatro entrenamientos.
- b) Las horas de un mismo centro pueden ser dependientes. Aunque el conteo formal siga siendo 800/200, separar filas al azar puede colocar observaciones vecinas en ambos lados y evaluar una tarea más fácil que predecir futuro.
- c) No siempre. Si CV se usa para elegir modelos, su mínimo sufre selección. Se requiere prueba final o evaluación anidada acorde con la población objetivo.

### Solución 3: Escalar con la referencia correcta

- a)  $z = (140 - 100)/20 = 2$ .
- b) **A.** Media y escala se estiman en entrenamiento y luego se aplican a los casos nuevos; usar validación para recalcularlas altera el procedimiento evaluado.
- c) Imputar con una regla aprendida en entrenamiento, por ejemplo su mediana. No utilizar la respuesta para imputar un predictor que debe estar disponible antes de conocerla; documentar la ausencia y su significado.

### Solución 4: Penalización y coeficientes

- a) Ridge agrega  $\lambda I$  a  $X^T X/n$ , dando unicidad para  $\lambda > 0$  en los coeficientes penalizados y reduciendo sensibilidad a direcciones casi singulares. Introduce sesgo y puede reducir varianza frente a OLS.
- b) Falso. La penalización L2 contrae coeficientes, pero en general no los vuelve exactamente cero.
- c) El intercepto representa el nivel de la respuesta. No penalizarlo mantiene invariancia frente a trasladar el origen de  $y$  y permite trabajar con datos centrados.

**Solución 5: Qué significa un cero**

- a) L1 tiene un vértice en cero y una condición de subgradiente que permite soluciones exactamente nulas; L2 produce contracción suave.
- b) Falso. Un cero es una decisión predictiva condicionada al conjunto de variables, escala, muestra y penalización; no demuestra ausencia de efecto causal.
- c) Si pedidos ya contiene información semejante a distancia, Lasso puede asignar la contribución a una de ellas. Otra muestra o penalización podría cambiar cuál se conserva.

**Solución 6: Combinar penalizaciones**

- a)  $\alpha = 0$  recupera Ridge y  $\alpha = 1$ , Lasso con las convenciones dadas.
- b)  $\alpha$  fija la combinación de L1 y L2;  $\lambda$  determina la intensidad total. La mezcla permite contracción de grupos correlacionados junto con selección de variables.
- c) Elegirlos con desarrollo evita utilizar las respuestas de prueba para configurar el modelo. Debe ajustarse también el preprocesamiento dentro de cada entrenamiento de CV.

**Solución 7: Descomponer el error**

- a) Errores esperados: A  $9 + 4 + 5 = 18$  y B  $1 + 16 + 5 = 22$ . Se prefiere A en esa condición.
- b) La disminución de sesgo de 8 unidades no compensa el aumento de varianza de 12.
- c) No. El error global promedia condiciones según su distribución de uso; en otras cargas las componentes pueden ser distintas. También debe considerarse si la condición evaluada es representativa.

**Solución 8: Bases locales y suavidad**

- a) El spline permite cambios de forma locales; un polinomio global de grado alto puede oscilar e imponer comportamiento extremo poco razonable. La penalización ayuda a controlar rugosidad.
- b) Un nudo marca dónde cambian las piezas; dimensión es número de funciones base/coeficientes; EDF mide flexibilidad efectiva después de restricciones y penalización.
- c) Falso. Más nudos permiten más flexibilidad, pero validación puede empeorar. El número de nudos y el grado de penalización deben evaluarse conjuntamente.

**Solución 9: Sumar contribuciones**

- a)  $\hat{y} = 40 + 6 - 3 + 2 = \mathbf{45}$  horas-persona. Centrar los suaves hace que sus aportes promedien cero en la referencia de ajuste y permite identificar el intercepto.
- b) No. Es una contribución del modelo al predictor medio, condicionada a las otras entradas y al centrado; no una fracción causal del trabajo.
- c) La aditividad sin interacción impone la misma curva de ocupación en ambos turnos, salvo un desplazamiento por el factor turno.

**Solución 10: Aplicar 1-SE**

- a) Umbral  $c = 10,0 + 0,6 = \mathbf{10,6}$ . Son admisibles los modelos segundo, tercero y cuarto; como la complejidad decrece en el orden dado, se elige el **cuarto**, error 10,3.
- b) El quinto tiene error 11,2 y queda fuera del umbral; máxima regularización no es sinónimo de selección 1-SE.
- c) La regla expresa una preferencia por simplicidad dentro de una tolerancia basada en variabilidad. No prueba equivalencia ni igualdad de riesgos poblacionales.

## II. Soluciones de nivel medio

### Solución 11: Evaluar una predicción constante

- a) Baseline: errores  $(-8, 0, 8, 0)$ ,  $RMSE = \sqrt{32} = 5,657$  y  $MAE = 4$ . Modelo:  $(-4, -2, 4, 2)$ ,  $RMSE = \sqrt{10} = 3,162$  y  $MAE = 3$  horas-persona.
- b) Mejora  $= 100(1 - \sqrt{10/32}) = 44,098\%$ .
- c) Son cuatro casos de una validación particular. No permiten asegurar transporte a centros con otras escalas de carga, sensores o relaciones entre entradas y respuesta.

### Solución 12: Leer entrenamiento y validación

- a) Dos parámetros muestran alto error incluso en ajuste, compatible con subajuste. Con veinte, ajuste baja a 3 mientras validación sube a 15: señal de sobreajuste o inestabilidad.
- b) Diez parámetros minimizan validación con RMSE 9; mejoran 4 horas, o  $4/13 = 30,769\%$ , respecto de dos parámetros.
- c) Se requieren errores por pliegue o período, diferencias pareadas e incertidumbre. También debe definirse si una hora-persona es relevante para la planificación.

### Solución 13: Promedios que no coinciden

- a)  $RMSE_1 = \sqrt{80/20} = 2$  y  $RMSE_2 = \sqrt{720/80} = 3$ . Promedio simple  $= 2,5$ . Error conjunto:  $\sqrt{800/100} = 2,828$ .
- b) El último es el RMSE por observación de los 100 casos OOF. Promediar RMSE pondera pliegues, no errores cuadrados individuales, y aplica la raíz en otro orden.
- c) La variación entre pliegues puede revelar condiciones donde el modelo falla; un único agregado puede ocultarlas.

### Solución 14: Dibujar una validación temporal

- a) Una opción: ajustar 1–9 y validar 10; ajustar 1–11 y validar 12; ajustar 1–14 y validar 15. Cada corte predice un mes a futuro; los meses 16–18 quedan reservados. También son válidos más cortes expansivos de horizonte mensual.
- b) Para horizonte de tres meses, cada evaluación debe incluir un bloque futuro de tres meses y respetar la disponibilidad de las etiquetas. Por ejemplo, 1–6 frente a 7–9, 1–9 frente a 10–12 y 1–12 frente a 13–15.
- c) Reservar centros completos, manteniendo el orden temporal, responde a transferencia a centros no observados. La validación temporal de los mismos centros responde a otra pregunta.

**Solución 15: Volver a unidades originales**

- a)  $\hat{y} = 40 + 6(x - 100)/20 = 10 + 0,3x$ . Para 130 pedidos:  $\hat{y} = 49$  horas-persona.
- b) La pendiente equivale a 0,3 horas-persona por pedido adicional en el rango del estudio.
- c) El coeficiente 6 mide cambio por una desviación estándar de pedidos; otro coeficiente en escala original puede corresponder a una unidad muy diferente. Antes de compararlos hay que uniformar escala e interpretar contexto.

**Solución 16: Auditar la receta**

- a) Medianas globales y selección por correlación utilizan la muestra que luego se llamará test. La segunda etapa usa explícitamente sus etiquetas; escalar correctamente después no elimina esa fuga anterior.
- b) Separar prueba primero. En cada pliegue, ajustar imputación, selección y escala con el entrenamiento correspondiente; transformar validación con esas reglas y ajustar el modelo sin utilizarla. Seleccionar la receta en desarrollo y evaluar al final.
- c) Convertir metros a kilómetros es una transformación fija que no aprende de los datos reservados. No es equivalente a estimar una mediana o elegir variables con todas las respuestas.

**Solución 17: Ridge a mano**

- a)  $\hat{\beta} = z/(1 + \lambda)$ . Para  $\lambda = 0$ : (6, -3); para 1: (3, -1,5); para 2: (2, -1).
- b) Con  $x = (1, 2)$ , los productos son  $6 - 6 = 0$ ,  $3 - 3 = 0$  y  $2 - 2 = 0$ . Las tres predicciones son **40**.
- c) En esta fila las contribuciones se cancelan exactamente y la contracción es proporcional. No implica que todas las predicciones sean iguales ni que los coeficientes carezcan de efecto en otras entradas.

**Solución 18: Trayectorias de contracción**

- a) En  $\lambda = 1$ , carga 4 y distancia 2; en  $\lambda = 3$ , 2 y 1. Respecto de 8 y 4 iniciales, las contracciones son **50 %** y **75 %**, respectivamente.
- b) No. Las trayectorias muestran coeficientes, no error de generalización.
- c) Relacionarlas con la curva de RMSE de cortes comunes; fijar una regla como mínimo o 1-SE. Evaluar además estabilidad y unidades de los coeficientes.

**Solución 19: Umbral suave**

- a) Para  $\lambda = 1$ ,  $S(z, 1) = (3, -0,5, 0)$ : dos variables activas.
- b) Para  $\lambda = 2$ ,  $(2, 0, 0)$ : una activa.
- c) Primera predicción:  $30 + 3 - 1 = 32$ . Segunda:  $30 + 2 = 32$ . La coincidencia es específica de la fila; el modelo sí cambia su dependencia de la segunda entrada.

**Solución 20: Leer una trayectoria Lasso**

- a) La señal auxiliar llega a cero en  $\lambda = 2$  y carga en  $\lambda = 5$ . Son los primeros valores mostrados que las excluyen.
- b) Ridge contrae sin producir generalmente ceros exactos; Lasso admite selección mediante el umbral suave en este diseño.
- c) Con predictores correlacionados, los coeficientes interactúan: al modificar uno cambia lo que los demás explican. Pueden aparecer entradas, salidas y trayectorias no monótonas; no se aplica directamente la fórmula ortonormal.

**Solución 21: Coeficientes de elastic-net**

- a) Umbral  $\lambda\alpha = 0,5$  y denominador  $1 + \lambda(1 - \alpha) = 1,5$ . Elastic-net da  $(2,5/1,5, -0,3/1,5, 0) = (1,667, -0,2, 0)$ .
- b) Ridge:  $(1,5, -0,4, 0,1)$ ; Lasso:  $(2, 0, 0)$ .
- c) Elastic-net conserva dos variables, Ridge tres y Lasso una. L1 introduce el umbral; L2 agrega contracción de los coeficientes no nulos. Igual  $\lambda$  no implica igual norma ni igual flexibilidad entre familias.

**Solución 22: Comparación de estabilidad**

- a) Lasso: frecuencias  $(0,90, 0,30, 0,20)$ ; elastic-net:  $(0,95, 0,90, 0,85)$ . La mezcla conserva cada proxy con mayor frecuencia en estas repeticiones.
- b) Son frecuencias marginales. Sin los indicadores conjuntos por ajuste no se sabe cuántas veces aparecieron los tres simultáneamente.
- c) Pedir diferencias pareadas de error, frecuencia conjunta, estabilidad de signos y magnitudes, costo de sensores y comportamiento temporal. Una mejora de 0,1 horas puede ser irrelevante o incierta.

**Solución 23: Evaluar una base polinomial**

- a) Filas  $(1, -1, 1)$ ,  $(1, 0, 0)$  y  $(1, 2, 4)$ ; predicciones **39, 40 y 54** horas-persona.
- b)  $d\hat{y}/dz = 3 + 4z$ , nula en  $z = -0,75$ ; negativa debajo y positiva encima. La relación cuadrática tiene un mínimo allí.
- c) Si  $z = (x - \mu)/s$ ,  $d\hat{y}/dx = (3 + 4z)/s$ . Sin dividir por  $s$ , se informaría el efecto por desviación estándar como si fuera por punto porcentual.

**Solución 24: El grado y el error**

- a) El grado 3 tiene menor RMSE de validación, 13, frente a 14 del grado 2: mejora de **1 hora-persona**.
- b) Grado 9 ajusta casi perfectamente pero valida con error 31, compatible con sobreajuste. Añadir términos amplía el espacio de ajuste, por lo que el mínimo error de entrenamiento no aumenta.
- c) Una regla de simplicidad con tolerancia operacional o 1-SE puede preferir grado 2 si queda dentro del margen fijado. Se necesitan errores por pliegue y variabilidad, no solo las medias del gráfico.

**Solución 25: Calcular una bisagra**

- a) Para 80, 100 y 120 pedidos:  $20 + 0,3(80) = \mathbf{44}$ ;  $20 + 30 = \mathbf{50}$ ;  $20 + 36 + 0,5(20) = \mathbf{66}$ .
- b) Pendiente 0,3 por debajo de 100 y 0,8 por encima. En 100 la bisagra vale cero y ambas expresiones dan 50: hay continuidad, aunque cambia la derivada.
- c) El modelo describe aceleración de requerimientos asociada con carga superior a 100. Para atribuir el quiebre a capacidad habría que estudiar diseño, cambios simultáneos y plausibilidad operacional.

**Solución 26: Elegir grados de libertad**

- a) EDF 8 minimiza validación con 34. Pasar de 8 a 14 reduce ajuste de 23 a 12, pero aumenta validación a 43: indicio de exceso de flexibilidad.
- b) Pedir error por pliegue, diferencias pareadas, incertidumbre y costo/interpretación de las curvas. No se puede decidir 5 frente a 8 con una regla 1-SE sin el SE correspondiente.
- c) EDF es traza del suavizador; puede ser fraccionario y depende de penalización y restricciones. No cuenta directamente nudos.

**Solución 27: Interpretar un suave y su banda**

- a) A 70 %: aporte **0 h**, banda **[-2;2]**. A 90 %: aporte **12 h**, banda **[5;19]**. Son contribuciones centradas al predictor medio.
- b) La banda es más ancha en 90 %, compatible con menor información local. Describe incertidumbre del suave estimado, no dispersión de una respuesta individual; un intervalo predictivo añade otras fuentes de variación.
- c) No se suman límites marginales directamente. Debe utilizarse la covarianza conjunta de los coeficientes/términos, la transformación del enlace y, para predicción, el ruido individual.

**Solución 28: Una interacción explícita**

- a) Mañana:  $\hat{y} = 30 + 0,2x$ ; tarde:  $\hat{y} = 34 + 0,3x$ . Para  $x = 20$ : **34 y 40 h**.
- b) Tarde menos mañana es  $4 + 0,1x$ , no una diferencia constante. En  $x = 20$  equivale a 6 h.
- c) Un GAM puede utilizar un suave común más un suave diferencial de carga por turno, con restricciones de identificación y penalización. Su aporte debe evaluarse fuera de muestra.

**Solución 29: Leer el umbral de selección**

- a) Son admisibles los índices **1, 2, 3**, con errores 10,4; 10,0 y 10,3. Bajo complejidad decreciente con  $\lambda$ , se selecciona el **índice 3**.
- b) Acepta  $10,3 - 10,0 = \mathbf{0,3}$  h adicionales respecto del mínimo.
- c) Deben fijarse pliegues, métrica, definición del SE, orden de complejidad y regla antes de consultar el test. Reordenar simplicidad después de mirar resultados haría la regla oportunista.

**Solución 30: Diferencias pareadas entre cortes**

- a) Diferencias  $A - B = (1, 1, -1, 1)$ , media **0,5**; desviación muestral  $s_d = 1$  y  $SE = 1/\sqrt{4} = \mathbf{0,5}$ .
- b) A promedia 11,5 y B 11,0, pero B pierde en un corte. El análisis pareado muestra consistencia e incertidumbre que el ranking de promedios oculta.
- c) Si 0,5 h es irrelevante y B cuesta cinco veces más, preferir A mientras cumpla los requisitos. El SE es descriptivo si los cortes son dependientes; no es una prueba concluyente de equivalencia.

### III. Soluciones de nivel avanzado

#### Solución 31: El test que se volvió entrenamiento

- a) Elegir el mínimo entre 40 errores explota variación favorable del test. Corregir sus casos difíciles añade adaptación directa a sus etiquetas. Ambos convierten prueba en desarrollo.
- b) Relegar el conjunto consultado a desarrollo; construir una validación para selección y reservar un período nuevo para evaluar una sola vez el procedimiento congelado.
- c) Sin datos nuevos, reportar el sesgo potencial y usar CV anidada que rehaga toda la búsqueda dentro de cada entrenamiento externo. Su alcance depende de la independencia/orden temporal; no recupera mágicamente un test ya usado.

#### Solución 32: Anidar la selección

- a) Ajustes internos:  $12 \cdot 3 \cdot 4 \cdot 5 = 720$ . No incluye los reajustes para evaluar los pliegues externos ni un ajuste final de producción.
- b) Cada escalador utiliza solo su entrenamiento interno. Una vez elegidos hiperparámetros, se reajusta con todo el entrenamiento externo para predecir su evaluación externa.
- c) Si se escoge la familia con esos resultados externos, el mínimo vuelve a ser seleccionado. Para una evaluación final de esa elección conviene una prueba adicional, o reportar explícitamente el papel de selección de los resultados externos.

#### Solución 33: Categorías y centros nuevos

- a) Una opción: codificación con referencia y niveles desconocidos como vector cero, documentando que C9 recibe la contribución de referencia y no un efecto estimado propio. Otra es un modelo sin identidad de centro. Debe validarse la política con centros retenidos.
- b) Comparar imputación, indicador de ausencia y error por patrón de faltantes; monitorear tasa de ausencia y cobertura del modelo por centro. No aprender la política mirando etiquetas del centro nuevo.
- c) Imputar completa la representación, pero no restaura sensores, distribuciones ni relaciones entre entradas y respuesta. Puede haber cambio de mecanismo de medición o del proceso.

#### Solución 34: Resolver con correlación

- a) Por simetría  $b_1 = b_2 = b$ . OLS:  $1,8b = 3$ ,  $b = 1,667$ . Ridge:  $(1,2 + 0,8)b = 3$ ,  $b = 1,5$ .
- b) Cociente de condición:  $1,8/0,2 = 9$ ; con  $\lambda = 0,2$ ,  $2,0/0,4 = 5$ .
- c) La penalización estabiliza direcciones con poca información y reduce sensibilidad a perturbaciones. Introduce sesgo; una norma menor o mejor condición no garantiza por sí sola menor error de prueba.

**Solución 35: Comprobar un coeficiente cero**

- a) Los valores absolutos son 0,6; 0,9 y 0,2. El primer y tercer cero cumplen  $|g_j| \leq 0,8$ ; el segundo no.
- b) La segunda variable tiene gradiente residual de magnitud superior a  $\lambda$ : un movimiento desde cero puede reducir el objetivo. La candidata no satisface una condición necesaria de optimalidad.
- c) Con columnas idénticas distintas reparticiones de coeficientes pueden producir las mismas predicciones y penalización L1. La variable elegida individualmente puede variar sin cambiar mucho el error.

**Solución 36: Redistribuir coeficientes idénticos**

- a) L1 de (4,0) y (2,2) es **4** en ambos. La pérdida también coincide cuando las columnas son idénticas.
- b) Sumas de cuadrados: **16** y **8**. Para  $\lambda > 0$  y  $\alpha < 1$ , el término L2 favorece (2,2); la diferencia de penalización es  $4\lambda(1 - \alpha)$ .
- c) La mezcla favorece compartir coeficientes entre entradas equivalentes. No aumenta el número de mediciones independientes ni identifica la importancia causal individual de los sensores.

**Solución 37: Extrapolar una relación cuadrática**

- a)  $f'(x) = -0,4 + 0,016x$ : en 50 vale **0,4** y en 90 **1,04**.  $f(90) = \mathbf{43,8}$  y  $f(120) = \mathbf{82,2}$  horas-persona.
- b) 120 está fuera del rango 40–90; calcular una cifra no valida la forma funcional allí. Si ocupación significa fracción física del almacenamiento, superar 100 % exige revisar definición, capacidad nominal o registro.
- c) Alertar fuera del soporte y utilizar un modelo/regla operacional validado para sobrecarga. Se pueden imponer restricciones de forma justificadas, pero no reemplazan obtener datos representativos.

**Solución 38: Base cúbica y continuidad**

- a)  $f(2) = \mathbf{4}$ ,  $f(3) = \mathbf{5}$  y  $f(4) = 2 + 4 + 0,5 = \mathbf{6,5}$ .
- b) Para  $x < 3$ ,  $f' = 1$ ,  $f'' = 0$ ; para  $x > 3$ ,  $f' = 1 + 1,5(x - 3)^2$  y  $f'' = 3(x - 3)$ . En 3 coinciden función, primera y segunda derivadas.
- c) Una bisagra de potencia 1 mantiene la función continua, pero produce un salto de pendiente. La cúbica ofrece dos derivadas continuas, más apropiadas cuando se desea representar una respuesta suave.

**Solución 39: Auditar un GAM flexible**

- a) Posibles explicaciones: complejidad excesiva, cambio de distribución, interacción faltante o base insuficiente para una forma real. EDF cercano al máximo indica que la capacidad de la base podría estar restringiendo la forma; no prueba por sí solo sobreajuste.
- b) Aumentar base manteniendo penalización controlada, revisar residuos por turno y tiempo, comparar penalizaciones e interacción con los mismos cortes. Inspeccionar soporte y covariables entre períodos.
- c) Cambiar un componente cada vez y comparar fuera de muestra dentro del desarrollo. Exigir estabilidad, mejora relevante y diagnóstico coherente antes de abrir el test y decidir despliegue.

**Solución 40: Transportar a otro centro**

- a) Regla posible: exigir disponibilidad de todas las entradas y desempeño temporal sin deterioros críticos; después comparar mejora, incertidumbre y costo. El tercero no es viable tal como está por sensor ausente y RMSE reciente 12.
- b) Temporal evalúa futuro en centros conocidos; retener centros evalúa población no observada. Deben estudiarse ambas si ambos usos están previstos.
- c) Exigir mejora frente a baseline y límite de error por centro/turno, además de cobertura de sensores. Monitorear faltantes y error; ante sensor ausente usar un candidato reducido validado y registrar abstenciones o revisión humana.

## IV. Soluciones de los desafíos con datos

Las tablas completas, predicciones, índices y gráficos están en la carpeta **resultados/Unidad\_1/** del paquete. Para reproducir este caso ejecute `codigo/resolver_1.py`; el script común de gráficos y diagnósticos se ejecuta después de los cinco casos. El instructivo final explica el orden. Los nombres citados sin extensión se corresponden con CSV, entradas del resumen o gráficos indicados en cada solución.

### Solución 41: Definir la planificación

- a) Unidad: centro-día/turno planificado; 960 filas, 120 fechas y 8 centros en entrenamiento. La respuesta es horas-persona. Excluir registro ID, rol de partición y costo posterior; fecha ordena el calendario y no justifica usar información del cierre.
- b) Baseline global 10,2794 horas-persona. Por turno: Mañana 9,6840 y Tarde 10,9293. Son medias de entrenamiento; en cada corte deben recalcularse con su parte histórica.
- c) Reservas: 240 filas de validación, 240 de prueba temporal y 30 del centro nuevo. La ficha debe registrar horizonte, fecha de disponibilidad de las entradas y nueva población. La tabla final se completa en E 50; no consultar esas respuestas para elegir grillas.

### Solución 42: Protocolo común en el tiempo

- a) Cortes por fecha única: 1-60/61-80 (480/160 filas), 1-80/81-100 (640/160), 1-100/101-120 (800/160). Todos los centros del mismo día quedan juntos.
- b) *Resultados de referencia.*

| Corte | Baseline        | RMSE  | MAE   |
|-------|-----------------|-------|-------|
| 1     | Media           | 3,257 | 2,559 |
| 1     | Media por turno | 3,237 | 2,555 |
| 2     | Media           | 3,464 | 2,814 |
| 2     | Media por turno | 3,500 | 2,870 |
| 3     | Media           | 3,779 | 2,988 |
| 3     | Media por turno | 3,683 | 2,895 |

- c) Los índices exactos se guardan en **E42\_indices**. Los entrenamientos se solapan y días/centros pueden compartir condiciones; el SE de tres errores sirve como descripción de estabilidad, no como IC de réplicas independientes.

**Solución 43: Construir la receta reproducible**

- a) Medianas, medias y desviaciones se aprenden dentro de cada entrenamiento. 14 columnas numéricas; turno y centro se codifican con referencia fija observada en ese ajuste. Se conserva una receta completa por modelo.
- b) *Resultados de referencia.*

| Primer corte: variable | Mediana  | Media    | DE      |
|------------------------|----------|----------|---------|
| pedidos                | 150,000  | 150,390  | 12,423  |
| unidades               | 382,500  | 378,704  | 90,706  |
| lineas                 | 172,000  | 172,733  | 26,053  |
| distancia_m            | 1247,789 | 1275,527 | 534,199 |
| ocupacion_pct          | 63,921   | 64,158   | 16,512  |

La tabla completa y faltantes se entregan en `E43_receta` y `E41_auditoria`. Las variables posteriores nunca se imputan como si fueran predictores válidos.

- c) Centro no visto: sus dummies se fijan en cero, usando el efecto del centro de referencia C 1; se registra explícitamente este supuesto y se audita C 9 en E 50. No se aprende un coeficiente nuevo con sus respuestas. La fila transformada está en `E43_centro_no_visto`.

**Solución 44: Ajustar Ridge**

- a) Se exploran 25 valores entre  $10^{-3}$  y  $10^3$ . Para la convención de la guía  $(2n)^{-1}RSS + \lambda\|\beta\|^2/2$ , Ridge de scikit-learn recibe `alpha=n*lambda`; intercepto sin penalizar.
- b) Se selecciona mínimo RMSE medio en los tres cortes:  $\lambda = 0,1$ , RMSE 2,964 y SE descriptivo 0,030. Las curvas y trayectorias están en `E44_E45_CV_Ridge` y `E44_E45_trayectoria_Ridge`. La escala y la redundancia explican la contracción; ningún cero exacto constituye selección de Ridge.
- c) Validación externa: RMSE 2,712, MAE 2,200,  $R^2 = 0,270$ . El error es mucho menor que el baseline, pero la familia lineal puede omitir curvatura. Los EDF lineales de Ridge se calculan por traza y se distinguen del conteo de coeficientes en `E44_E49_complejidad`. En el ajuste completo, EDF de Ridge=16,800, frente a 23 coeficientes contando el intercepto; son cantidades diferentes.

**Solución 45: Selección y estabilidad con Lasso**

- a) Lasso usa pérdida normalizada de la guía: **alpha=lambda**. Se elige  $\lambda = 0,05623$ , RMSE CV 2,956, y 12 coeficientes activos más intercepto en el ajuste completo. El conteo activo aproximado no es un cálculo general de EDF tras selección.
- b) Se remuestran 30 series de 120 fechas mediante bloques consecutivos de 7 días, manteniendo juntos los 8 centros por fecha; receta reajustada en cada réplica. Los hiperparámetros quedan fijados, por lo que se estudia estabilidad condicional a esa elección.

| Variable      | Frecuencia seleccionada |
|---------------|-------------------------|
| carga_proxy_1 | 0,500                   |
| carga_proxy_2 | 0,033                   |
| pedidos       | 1,000                   |
| ruido_1       | 0,767                   |
| ruido_2       | 0,800                   |
| ruido_3       | 0,667                   |
| ruido_4       | 0,667                   |

- c) Validación: RMSE 2,694 frente a 2,712 de Ridge, diferencia 0,018 horas-persona. No basta para afirmar superioridad sustantiva. Selección de ruido en algunas réplicas y sustitución entre proxies ilustran por qué los coeficientes seleccionados no deben presentarse como causas.

**Solución 46: Grupos correlacionados**

- a) Correlaciones de pedidos con proxies 1 y 2: 0,970 y 0,923; entre proxies 0,894. Se exploran mezclas 0,1; 0,5; 0,9 y las 25 penalizaciones. Los dispersogramas se incluyen en **E46\_proxies**.
- b) Elastic-net seleccionado: mezcla 0,9,  $\lambda = 0,05623$ , 12 coeficientes activos más intercepto; CV 2,956 y validación 2,695. Es muy próximo a Lasso en error; revisar frecuencias de selección por bloque en **E45\_E46\_seleccion** para comparar estabilidad.
- c) Ensayar retirar un proxy solo con evaluación interna común y comparando costo, calidad de medición y disponibilidad. La base no contiene costos de sensores ni costo de perder redundancia. Correlación alta no demuestra que dos mediciones sean operacionalmente intercambiables en todos los estados.

**Solución 47: Detectar no linealidad**

- a) La comparación mantiene otras entradas y añade potencias de pedidos y ocupación, aprendiendo escala solo en entrenamiento. El mejor grado es 2; grado 1 constituye el modelo lineal de referencia y grado 3 se evalúa en los mismos cortes.
- b) Grado 2: RMSE CV 1,772 (SE 0,111) y validación 1,700, frente a 2,712 de Ridge. Reducción de 1,012 horas-persona en validación, mucho mayor que diferencias entre regularizadores lineales. Error por rango en **E47\_E49\_subgrupos**.
- c) Las curvas **E47\_E49\_curvas** muestran curvatura para un perfil C 1/Mañana con las demás entradas en medianas. Son predicciones condicionadas del modelo, no efectos causales; los extremos requieren soporte y no se deben extrapolar polinomios sin diagnóstico.

**Solución 48: Curvas de saturación**

- a) Se comparan bases cúbicas de dimensión 4, 6 y 10 para ocupación y operarios, con covariables lineales comunes. Se elige dimensión 4 sin penalización; al centrar se elimina una columna por término para identificar el intercepto. EDF totales 27.
- b) Los perfiles fijan covariables en medianas y centro/turno de referencia. Examinar distribución de entradas y pocos datos en extremos antes de interpretar la curva. Se usa extrapolación lineal fuera de límites, aunque la guía gráfica se restringe al soporte.
- c) RMSE CV 1,692 (SE 0,109), validación 1,660; frente al polinomio la mejora es 0,040 horas-persona en validación. La mayor flexibilidad no basta por sí sola para elegir. Resultados y tamaños de base quedan en **E44\_E49\_configuraciones**.

**Solución 49: Modelo aditivo de recursos**

- a) GAM: suaves cúbicos centrados de pedidos, ocupación y operarios; demás covariables comunes lineales y factores. Penalización de segundas diferencias. Se comparan aditivo e interacción ocupación–turno con cinco suavidades; gana aditivo, dimensión 6,  $\lambda = 0,1$ .
- b) Las curvas centradas y bandas puntuales 95 % se obtienen de la covarianza del estimador penalizado, condicionales a base y suavidad seleccionadas. Se incluyen marcas de distribución de entradas. No son intervalos de predicción ni incorporan toda la incertidumbre de selección. Archivo **E49\_suaves**.
- c) EDF 31,606; RMSE CV 1,676 (SE 0,113), validación 1,615. Errores por turno y rango en **E47\_E49\_subgrupos**; la mejora media sobre spline es 0,044 horas-persona. Las bandas y SE no prueban equivalencia de familias.

**Solución 50: Selección congelada y prueba**

a) *Resultados de referencia.*

| Familia     | CV    | RMSE  | SE | Validación | RMSE  |
|-------------|-------|-------|----|------------|-------|
| Ridge       | 2,964 | 0,030 |    |            | 2,712 |
| Lasso       | 2,956 | 0,022 |    |            | 2,694 |
| Elastic-net | 2,956 | 0,021 |    |            | 2,695 |
| Polinomio   | 1,772 | 0,111 |    |            | 1,700 |
| Spline      | 1,692 | 0,109 |    |            | 1,660 |
| GAM         | 1,676 | 0,113 |    |            | 1,615 |

Regla fijada: umbral CV  $1,6757 + 0,1135 = 1,7891$ ; entre admisibles a no más de 0,2 horas-persona del mejor en validación, elegir familia más simple según orden previo. Se elige polinomio grado 2 y se reajusta con 1.200 filas.

b) *Resultados de referencia.*

| Dominio      | Modelo    | RMSE  | MAE   |
|--------------|-----------|-------|-------|
| Temporal     | Polinomio | 1,694 | 1,326 |
| Temporal     | Media     | 3,775 | 2,993 |
| Centro nuevo | Polinomio | 2,582 | 2,043 |
| Centro nuevo | Media     | 6,088 | 5,189 |


Los resultados por centro se entregan separados en **E50\_centros**. C 9 se codifica con el efecto de referencia declarado; su error más alto indica que la transportabilidad requiere atención.

c) Usar el pronóstico como apoyo de dotación, añadiendo costo de sub/sobredotación y restricciones de turnos antes de decidir personal. Treinta casos de C 9 aportan evidencia limitada; monitorear error por centro, ocupación y período, y reservar una evaluación nueva para cualquier actualización.

## Gráficos de referencia comentados


Selección de gráficos de los desafíos. El paquete incluye las figuras adicionales con datos y código reproducible.

### E47–E49: complejidad y curvatura




Perfil C1/Mañana, restantes entradas en medianas. Las familias capturan una curvatura similar; se selecciona con error y costo, no por la apariencia más flexible.

### E49: suave centrado de ocupación



Bandas puntuales condicionales a base y suavidad; no incorporan toda la selección ni son intervalos de predicción. El archivo de gráficos incluye además pedidos, operarios y distribución de entradas.

**E45: trayectorias Lasso**

La penalización puede fijar coeficientes en cero; la elección entre proxies y la selección ocasional de ruido requieren estudiar estabilidad.

## Reproducción y criterios de corrección

### Cómo reproducir los desafíos

Descomprima el paquete conservando las carpetas `codigo`, `datos` y `resultados`. Use Python 3 y las versiones registradas en `requirements.txt`. Desde la raíz del paquete ejecute, en este orden:

```
python codigo/resolver_0.py
python codigo/resolver_1.py
python codigo/resolver_2.py
python codigo/resolver_3.py
python codigo/resolver_4.py
python codigo/graficos_y_diagnostics.py
```

Cada caso utiliza sus propias particiones y guarda resultados antes de abrir las pruebas correspondientes. El script final genera gráficos y diagnósticos a partir de esas decisiones fijadas. Los ensambles con validación anidada requieren más tiempo que los cálculos de los ejercicios escritos.

Los archivos de datos ya están incluidos; no se descarga información. Se fijan semillas en los scripts. Versiones, tolerancias numéricas y hardware pueden producir diferencias pequeñas; los tiempos de ejecución son orientativos. Las etiquetas de clustering pueden permutarse sin cambiar la solución.

Los `.tex` de los solucionarios contienen los gráficos de referencia como coordenadas vectoriales y se compilan de forma independiente con `pdflatex`. El resto de figuras del paquete se entrega en PDF/PNG.

**Ejercicios escritos.** Dar crédito al procedimiento correcto aunque exista un error aritmético menor, sin duplicar la penalización en incisos que dependan de él. Exigir unidades, denominador y convención cuando cambien la interpretación. En preguntas abiertas, aceptar argumentos diferentes si responden al caso y están sustentados.

**Desafíos.** Rúbrica orientativa del caso completo: formulación y trazabilidad (20 %); aplicación y cálculos (30 %); validación e incertidumbre (25 %); interpretación y decisión industrial (15 %); reproducibilidad y claridad (10 %). No calificar por coincidir con el modelo ganador de esta pauta.

**Errores sustantivos.** Deben revisarse especialmente fuga de información, uso del test para seleccionar, pérdida de pares o unidades, comparación de métricas con poblaciones distintas, confusión entre odds y riesgos, omisión de capacidad, interpretación causal no sustentada y ocultamiento de métricas indefinidas.

**Convenciones del código.** La pérdida de [Ridge](#) de [scikit-learn](#) requiere `alpha=n*lambda` para coincidir con la normalización de la guía. En [ElasticNet](#), `alpha` es la intensidad de penalización y `l1_ratio` la mezcla. Las bases usan [SplineTransformer](#); el GAM de referencia implementa explícitamente penalización de segundas diferencias, no depende de un paquete GAM externo.