

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Solucionario - Guía de Ejercicios Propuestos

Unidad 2: Ensemble Learning

Luis Rojo-González, Ph.D.

Profesor Asistente
Departamento de Ingeniería Industrial
Universidad de Santiago de Chile

Versión: 2.0
Fecha: Septiembre 2026

Alcance y uso de la pauta

Este solucionario responde a los **50 ejercicios** de la guía correspondiente, conservando número y letras de cada inciso. Los ejercicios 1–40 incluyen cálculos, interpretación de gráficos y respuestas razonadas; los ejercicios 41–50 presentan una solución reproducible del caso integrador con los datos sintéticos entregados.

No se exige memorizar fórmulas. Se evalúa reconocer el método, sustituir cantidades correctamente, interpretar unidades y distinguir incertidumbre, magnitud y utilidad operacional. El formulario de la guía fija convenciones; aquí se muestran las operaciones necesarias para verificar los resultados.

Los desafíos admiten alternativas. Un modelo, partición o decisión distinta puede ser correcta si respeta disponibilidad temporal, datos reservados, supuestos, criterio declarado y evidencia reproducible. Los valores aquí reportados corresponden a una ejecución de referencia, no son una meta que deba alcanzarse ajustando reiteradamente sobre prueba.

En tablas, un guion indica una cantidad indefinida o no aplicable. No debe reemplazarse silenciosamente por cero. Los redondeos se realizan al presentar, conservando precisión de cálculo.

Correspondencia de contenidos

Tema	Intro.	Medio	Avanz.	Desafío
Árboles y cortes	1	11, 12	31	41
Bootstrap y bagging	2	13, 14	32	42
Random Forest	3	15, 16	33	43
OOB y evaluación	4	17, 18	34	44
Boosting	5	19, 20	35	45
Comparación y tuning	6	21, 22	36	46
Importancia de variables	7	23, 24	37	47
PDP e ICE	8	25, 26	38	48
Promediado de modelos	9	27, 28	39	49
Stacking e integración	10	29, 30	40	50

I. Soluciones de nivel introductorio

Solución 1: Predicción de una hoja

- a) $\hat{y} = (4 + 6 + 8 + 10)/4 = 7$ min; $RSS = 9 + 1 + 1 + 9 = 20$ min².
- b) El árbol estima una constante por región: no distingue puntos dentro de la misma hoja.
- c) El RSS de ajuste puede ser cero; la estimación se vuelve sensible al ruido y no asegura bajo error futuro.

Solución 2: Muestrear con reemplazo

- a) Multiplicidades: A=2, B=0, C=2, D=0, E=1. Hay 3 filas distintas y B,D son OOB.
- b) Repetir C cambia su peso; no agrega una realización independiente del proceso.
- c) Muestras perturbadas generan cortes distintos; promediar reduce la variación que no comparten los árboles.

Solución 3: Elegir variables por nodo

- a) $P = 4/16 = 0,25$.
- b) RF introduce además aleatoriedad en los candidatos de cada nodo, lo que puede reducir correlación entre árboles.
- c) Desaparece la selección aleatoria de un subconjunto de variables; con bootstrap, crecimiento y demás opciones iguales, se obtiene bagging de árboles.

Solución 4: Quién puede predecir OOB

- a) $\hat{y}^{OOB} = (12 + 14 + 10)/3 = 12$.
- b) Los árboles 1 y 3 fueron ajustados usando la respuesta de esta fila; incluirlos contamina su evaluación OOB.
- c) Sí puede afinarse con OOB, pero el mínimo seleccionado deja de ser una estimación final independiente de la búsqueda.

Solución 5: Aprender de los residuos

- a) $f_0 = 12$; residuos $(-4, 0, 4)$.
- b) El primer árbol aproxima esos residuos. Tras actualizar, cambian los residuos que debe aproximar el segundo.
- c) Bagging ajusta réplicas de forma paralela; boosting construye correcciones secuenciales del predictor vigente.

Solución 6: La misma pregunta para todos

- a) Las poblaciones, tamaños efectivos y grados de independencia difieren; el error de ajuste es particularmente optimista.
- b) Mantener target, disponibilidad de variables, filas de evaluación, métrica y presupuesto de búsqueda declarados; preprocesar dentro de cada ajuste.
- c) Igual tiempo o recursos puede requerir grillas distintas. Los hiperparámetros no tienen significados equivalentes entre familias.

Solución 7: Importancia no es causa

- a) Muchos valores ofrecen numerosos cortes con los que aprovechar fluctuaciones del ajuste.
- b) Permutar el código en evaluación externa al ajuste y comparar un modelo sin código en los mismos pliegues.
- c) La afirmación causal es injustificada: importancia describe dependencia del predictor, no el efecto de modificar un identificador.

Solución 8: Promediar perfiles

- a) $PDP(4) = (10 + 16 + 22)/3 = 16$ min.
- b) En cada perfil se sustituye cola por 4 y se conservan las otras entradas de esa fila.
- c) No necesariamente: la sustitución puede romper dependencias o generar situaciones imposibles; faltan supuestos causales y factibilidad operacional.

Solución 9: Mezcla de predicciones

- a) $0,7(12) + 0,3(18) = 13,8$ min.
- b) Pesos no negativos y suma uno sitúan la combinación entre las predicciones componentes y conservan su escala.
- c) No: si ambos cometen exactamente el mismo error, cualquier mezcla convexa conserva ese error.

Solución 10: Construir la entrada del meta-modelo

- a) Entrenar cada base con pliegues 1,2,4,5 y predecir la fila del 3.
- b) Una base que memoriza puede parecer excelente en ajuste; sus predicciones no representan el error que verá el meta-modelo en operación.
- c) X contiene condiciones operacionales; Z contiene pronósticos de las bases. Incorporar también X al meta-modelo es otra arquitectura y exige validación propia.

II. Soluciones de nivel medio

Solución 11: Evaluar un corte

- a) Sin corte: media 6 y $RSS = 16 + 4 + 4 + 16 = 40$. Con corte 2,5: medias 3 y 9; $RSS = 1 + 1 + 1 + 1 = 4$.
- b) Reducción $40 - 4 = 36$; predicciones 3 y 9 min.
- c) Con corte 1,5: medias 2 y $22/3$; $RSS = 56/3 \approx 18,67$. Se prefiere 2,5 entre estos candidatos.

Solución 12: Geometría de un árbol

- a) Medias: $(2 + 3 + 4)/3 = 3$ y $(10 + 12 + 11)/3 = 11$. Función $\hat{f}(x) = 3$ si $x \leq 4,5$ y 11 si $x > 4,5$.
- b) Ambas predicciones son 11. El árbol mantiene constante la última hoja y no extrapola una tendencia fuera del rango observado (cola 1-8).
- c) No. El salto es una decisión de partición estadística; el gráfico no identifica una intervención causal.

Solución 13: Cuánto dato queda fuera

- a) $P(OOB) = 0,348678$ y $E(N_{dist}) = 10(1 - 0,348678) = 6,51322$.
- b) $200(0,348678) = 69,7356$ árboles, en promedio.
- c) Réplicas concretas fluctúan: ni 6,51 filas ni 69,74 árboles son conteos observados obligatorios.

Solución 14: Promediar predicciones

- a) Media $70/5 = 14$; $s^2 = (4 + 16 + 1 + 25 + 4)/4 = 12,5 \text{ min}^2$.
- b) $(70 + 14)/6 = 14 \text{ min}$.
- c) Los árboles son dependientes y esa dispersión no incorpora por sí sola ruido irreducible ni errores sistemáticos. No es un intervalo calibrado para una nueva espera.

Solución 15: Varianza de un bosque

- a) Para $\rho = 0,6$: $100(0,6 + 0,4/50) = 60,8$, límite 60. Para 0,2: 21,6, límite 20.
- b) Con 100 árboles la primera varianza es 60,4; reducción 0,4, equivalente a 0,658 %.
- c) La fórmula mantiene fija la fuerza/varianza individual. Reducir candidatos puede empeorar cortes y aumentar sesgo o variación individual.

Solución 16: Rendimientos decrecientes

- a) Con 5 árboles: $100(0,6 + 0,4/5) = 68$ y $100(0,2 + 0,8/5) = 36$.
- b) Cien árboles con $\rho = 0,6$ dan 60,4; diez con $\rho = 0,2$, 28. La correlación fija un piso.
- c) Comparar RMSE común, correlación de errores, estabilidad por semillas y tiempo; correlación de predicciones entre filas no equivale exactamente al ρ teórico a x fijo.

Solución 17: Error OOB de tres ventanas

- a) Con $e = y - \hat{y}$: $(-2, 3, -1)$. $MSE = 14/3 = 4,667$; $RMSE = \sqrt{14/3} = 2,160$.
- b) Aumentar árboles para obtener cobertura; si se informa provisionalmente, marcar la fila sin predicción y calcular sobre las cubiertas, declarando el denominador.
- c) Un error de pocas filas cubiertas puede representar una muestra distinta; reportar cobertura permite evaluar esa limitación.

Solución 18: Cuántos árboles son suficientes

- a) Se estabiliza aproximadamente entre 100 y 600 árboles. De 100 a 300, OOB baja 6,1 a 6,0: 0,1 min.
- b) El ajuste puede mejorar aun cuando el error externo se estabiliza; no mide generalización.
- c) Fijar tolerancia, por ejemplo 0,1 min, y comprobar estabilidad en varios tamaños y semillas; elegir el menor presupuesto que la cumple.

Solución 19: Una actualización de boosting

- a) Residuos $(-2, 2, 6, 10)$; $f_{nuevo} = (10, 10, 12, 12)$.
- b) SSE inicial $4 + 4 + 36 + 100 = 144$; nuevo $4 + 4 + 16 + 64 = 88$.
- c) Con $\nu = 1$, $f = (10, 10, 18, 18)$ y SSE=16. Esa ganancia utiliza estas mismas respuestas y puede sobreajustar; la tasa se decide con validación.

Solución 20: Tasa y número de iteraciones

- a) Tasa 0,1: mínimo mostrado 6,0 a 100 iteraciones. Tasa 0,02: 6,2 a 400; podría requerir más exploración para localizar su mínimo.
- b) Una tasa pequeña avanza más lentamente; fijar pocas iteraciones puede dejarla subajustada.
- c) Parada en validación interna al entrenamiento de cada pliegue externo; conservar prueba final sin consultas.

Solución 21: Diferencias de error por pliegue

- a) Medias RF=7,5 y boosting=7,25. Diferencias (0,5, -0,5, 0,5, 0,5); media 0,25 min.
- b) Boosting gana en tres pliegues, RF en el segundo.
- c) La mejora media no supera 0,5; si RF es más simple o barato se justifica conservarlo, documentando variación y errores operacionales.

Solución 22: Costo de una búsqueda

- a) RF: $3 \cdot 4 \cdot 5 = 60$ ajustes. Boosting: $3 \cdot 3 \cdot 4 \cdot 5 = 180$.
- b) Reutilizar cada trayectoria reduce boosting a $3 \cdot 3 \cdot 5 = 45$ ajustes hasta el máximo; se evalúan cuatro puntos de cada uno.
- c) Comparar tiempo total, hardware, latencia, paralelismo y esfuerzo de búsqueda. Un ajuste de 500 árboles no cuesta lo mismo que uno de 50.

Solución 23: Calcular importancia por permutación

- a) Cola: incrementos (2, 2,6, 2,4), media $7/3 = 2,333$ min. Código: (0,1, -0,1, 0), media cero.
- b) Un negativo indica mejora en esa permutación, compatible con ruido o uso perjudicial; no es un efecto causal beneficioso.
- c) El ajuste favorece patrones memorizados. La utilidad futura requiere filas excluidas del entrenamiento y de la selección que se evalúa.

Solución 24: Leer el gráfico de importancia

- a) Cola=4, muelles=1,5, código=0,1, peso=-0,2 min. La dependencia aparente es mayor para cola; el negativo no demuestra que aumentar peso ayude.
- b) Es evidencia para ensayar retirada, no una prueba definitiva: faltan dispersión, relevancia económica y comparación reajustada.
- c) Repeticiones y dispersión de incrementos; un proxy correlacionado puede sustituir cola y diluir su importancia individual. Añadir permutación conjunta.

Solución 25: Construir PDP e ICE centradas

- a) $PDP(2) = 32/3 = 10,667$ y $PDP(6) = 46/3 = 15,333$.
- b) ICE centradas: (0, 4), (0, 8), (0, 2); cambio promedio $14/3 = 4,667$.
- c) El promedio oculta respuestas entre 2 y 8 min; estudiar condiciones que explican esa heterogeneidad.

Solución 26: Promedio plano, perfiles opuestos

- a) Pendiente $A=(10-4)/6=1$, $B=(4-10)/6=-1$, promedio=0.
- b) El predictor sí cambia dentro de cada perfil; efectos opuestos se cancelan al promediar.
- c) Revisión documental o terminal podrían modificar la relación. Graficar ICE centradas coloreadas por ese factor y verificar soporte conjunto.

Solución 27: Varianza y complementariedad

- a) $\text{Var}[(e_A + e_B)/2] = (16 + 25 + 8)/4 = 12,25$.
- b) Es menor que 16. $w_A^* = (25 - 4)/(16 + 25 - 8) = 21/33 = 7/11 \approx 0,6364$; varianza mínima $(16 \cdot 25 - 4^2)/33 = 128/11 \approx 11,636$.
- c) $MSE = \text{Var}(e) + E(e)^2$; con sesgos importa además el sesgo combinado y el óptimo puede cambiar.

Solución 28: Elegir pesos con datos pequeños

- a) Errores $\hat{y} - y$: $A=(2, -2, -2)$, $B=(-2, 4, 2)$. $MSE\ A=4$, $B=8$. Para $w_A = 0,25, 0,5, 0,75$: $MSE=2,75; 1/3; 0,75$.
- b) Seleccionar $w_A = 0,5$ dentro de esta grilla.
- c) Ese mínimo está seleccionado con las tres respuestas: necesita prueba nueva. Un solo caso distinto puede alterar radicalmente el ranking.

Solución 29: Evaluar un meta-modelo lineal

- a) Primera: $1 + 0,4(10) + 0,5(14) = 12$. Segunda: $1 + 0,4(20) + 0,5(16) = 17$.
- b) Promedios simples: 12 y 18. Los coeficientes suman 0,9 y existe intercepto 1; no satisfacen la forma convexa estricta.
- c) Cada entrada de ajuste debe ser predicción de una base que excluyó esa fila; la evaluación del meta-modelo exige otra exclusión externa.

Solución 30: Contar ajustes de stacking

- a) OOF: $3 \cdot 5 = 15$ ajustes de bases; finales: 3; meta-modelo: 1. Total 19.
- b) Cada uno de 4 pliegues externos repite los 19 ajustes dentro de su entrenamiento: 76 para evaluar el sistema. Si además se entrena el definitivo, total 95.
- c) No se cuentan configuraciones alternativas. Una búsqueda interna multiplica ajustes según grilla y capas de validación; debe excluir también la evaluación externa.

III. Soluciones de nivel avanzado

Solución 31: Poda con penalización

- a) Con $\alpha = 10$, costos (240, 190, 190): empate entre 4 y 8 hojas, preferir 4 por parsimonia. Con 25: (270, 250, 310), gana 4 hojas.
- b) $150 + 4\alpha = 110 + 8\alpha$ implica $\alpha = 10$.
- c) RSS siempre puede disminuir al subdividir; seleccionar penalización por ese mismo RSS ignora el costo de generalizar. Usar validación.

Solución 32: Bootstrap con dependencia

- a) Se rompen dependencias dentro de terminal y rachas temporales; 5.000 filas no equivalen a 5.000 unidades independientes. Falta explicitar si se predicen terminales nuevos o futuro en los actuales.
- b) Para terminales nuevos, remuestrear terminales completos; para futuro en los mismos, bloques temporales que mantengan dependencia y particiones hacia adelante. Puede requerirse un esquema combinado.
- c) Promediar no vuelve independientes las observaciones de evaluación ni elimina información compartida entre entrenamiento y evaluación.

Solución 33: Omitir todas las señales

- a) $P(0 \text{ señales}) = 126/495 = 0,2545$ y $P(\geq 1) = 0,7455$.
- b) Con una candidata, probabilidades $9/12 = 0,75$ y $3/12 = 0,25$.
- c) Más candidatas facilitan cortes informativos pero pueden correlacionar árboles; menos candidatas pueden debilitar cada árbol. Elegir con error validado y costo.

Solución 34: OOB después de buscar mucho

- a) El mínimo entre 200 ensayos puede aprovechar ruido; otra población puede ser más difícil; ambas cifras fluctúan por muestreo. La brecha sola no identifica la causa.
- b) Ajustar dentro de pliegues internos y evaluar la búsqueda completa en pliegues externos; reservar prueba para el procedimiento congelado.
- c) OOB puede excluir una fila mientras conserva otras del mismo terminal. No representa necesariamente generalización a terminales nunca observados.

Solución 35: Dos pasos calculados

- a) $f_0 = 10$; residuos $(-6, -4, 4, 6)$; medias residuales $(-5, 5)$. $f_1 = (7,5, 7,5, 12,5, 12,5)$.
- b) Residuos $(-3,5, -1,5, 1,5, 3,5)$; segundo árbol $(-2,5, -2,5, 2,5, 2,5)$; $f_2 = (6,25, 6,25, 13,75, 13,75)$.
- c) SSE: 104, 29 y 10,25. Las correcciones se estiman con estas respuestas; no prueban descenso del error futuro.

Solución 36: Seleccionar con incertidumbre y costo

- a) Umbral $6,0 + 0,6 = 6,6$; admitidos RF y boosting.
- b) Si simplicidad significa menor latencia y menor mantenimiento, ordenar RF antes de boosting: 4 frente a 12 ms; seleccionar RF.
- c) El SE de pliegues dependientes es descriptivo y no una prueba pareada de equivalencia. La tolerancia operacional y el orden deben declararse.

Solución 37: Importancia diluida por redundancia

- a) Al alterar uno, el otro conserva señal; al alterar ambos se elimina una fuente informativa compartida.
- b) Marginal: baraja una variable libremente. Conjunta: baraja el par con la misma permutación. Condicionada: altera una variable preservando aproximadamente su distribución dada las demás, midiendo información adicional.
- c) Comparar modelos con ambos, con cada uno y sin ninguno en validación interna común; incluir costos de sensores. Congelar la elección antes de prueba.

Solución 38: Combinaciones imposibles

- a) Muelles=10 con operarios=4 contradice el soporte declarado; el modelo extrapola a una configuración no observada.
- b) Restringir a perfiles con personal suficiente describe ese subgrupo; un gráfico condicionado describe asociaciones dentro de condiciones observadas; una alternativa local examina cambios pequeños con soporte. Ninguna identifica automáticamente causalidad.
- c) Marcar región admisible, explicar población de referencia y evitar recomendaciones de capacidad basadas en combinaciones imposibles.

Solución 39: Un modelo peor puede ayudar

- a) Covarianza $AB=0,95(10)(10,5) = 99,75$; MSE promedio $AB=(100 + 110,25 + 199,5)/4 = 102,4375$. Covarianza $AC=12$; MSE promedio $AC=(100 + 144 + 24)/4 = 67$.
- b) C es menos preciso individualmente pero complementa A; B añade poca diversidad y su promedio puede empeorar A.
- c) Pesos convexos en una grilla corta, selección interna común y evaluación externa del procedimiento completo; considerar tolerancia y costo.

Solución 40: La segunda fuga del stacking

- a) OOF protege la generación de entradas base, pero el meta-modelo se evalúa sobre las respuestas con que se ajustó y eligió entre 15 alternativas.
- b) En cada corte externo generar OOF solo dentro de su entrenamiento, seleccionar y ajustar meta-modelo allí, reajustar bases allí y predecir el corte excluido. El tuning de bases también queda dentro.
- c) Elegir arquitectura con la evaluación externa, generar OOF en todo desarrollo para el meta-modelo, reajustar bases y abrir una única prueba final del sistema congelado.

IV. Soluciones de los desafíos con datos

Las tablas completas, predicciones, índices y gráficos están en la carpeta **resultados/Unidad_2/** del paquete. Para reproducir este caso ejecute `codigo/resolver_2.py`; el script común de gráficos y diagnósticos se ejecuta después de los cinco casos. El instructivo final explica el orden. Los nombres citados sin extensión se corresponden con CSV, entradas del resumen o gráficos indicados en cada solución.

Solución 41: Un árbol para tiempos de espera

- a) 900 ventanas independientes de desarrollo, una llegada por fila. Excluir ID, código aleatorio y costo real posterior; conservar variables disponibles al arribo. Cinco pliegues externos estratificados por terminal, semilla 20260911. Dentro de cada entrenamiento externo, tres pliegues internos para seleccionar profundidad 2,4,6.
- b) *Resultados de referencia.*

Modelo	RMSE externo	MAE	SE por pliegue
Arbol	3,203	2,476	0,053
Media	7,465	5,960	0,242

- c) Se elige profundidad 6 al ajustar desarrollo completo. El árbol textual en **E41_arbol.txt** permite seguir cortes de cola, proxy y muelles; un corte de cola distingue niveles de congestión y uno de muelles distingue capacidad disponible. Interpretar la predicción como media de una hoja, no como efecto causal de abrir muelles. En particular, la raíz separa $\text{cola_proxy} \leq 6,75$; en esa rama, $\text{muelles_activos} \leq 3,5$ distingue hasta tres muelles de cuatro o más. Los cortes describen estados operacionales, manteniendo la interpretación asociativa.

Solución 42: Bagging y estabilidad

- a) Bagging se implementa mediante bosque bootstrap con todas las columnas candidatas en cada nodo y hoja mínima 2. Se comparan 50,200,500 árboles dentro de cada entrenamiento; el ajuste completo selecciona 500. RMSE externo 2,629 min, frente a 3,203 del árbol.
- b) Cambiar solo la semilla deja aquí casi invariante el árbol CART sobre la misma muestra; no es evidencia de estabilidad frente a cambios de datos. Por ello se agrega una perturbación bootstrap común de entrenamiento a ambos métodos y se evalúan 10 ventanas excluidas. **E42_estabilidad** separa variación de semilla y **E42_estabilidad_bootstrap** variación de muestra. En la perturbación bootstrap, DE media entre las diez ventanas: árbol 1,911 min y bagging 0,894 min; el promediado reduce esta fuente de variación.
- c) Las curvas de error están en **E42_E45_trayectorias**; tiempos del ajuste final en **resumen.json**. Bagging reduce variación de cortes frente a perturbaciones que los árboles no comparten; no elimina sesgo, dependencia de datos ni costo computacional. La comparación por semilla sola debe interpretarse con esa limitación.

Solución 43: Diversidad de un bosque

- a) Se consideran fracciones 1/3, 1/2 y 1 de las columnas codificadas, con 200 árboles y hoja mínima 2. Las columnas categóricas cuentan en p ; la implementación toma la parte entera con mínimo 1. Las métricas siguientes usan los 200 árboles en el primer corte externo como diagnóstico descriptivo.

Fracción	Cor. pred.	Cor. error	RMSE
0,333	0,766	0,371	2,567
0,500	0,813	0,402	2,456
1,000	0,865	0,492	2,532

- b) Menor correlación no garantiza menor error: también cambia la calidad de cada árbol. Estas correlaciones se calculan entre salidas sobre distintas ventanas, no como estimaciones exactas de la correlación teórica de estimadores a un x fijo.
- c) La selección final interna usa fracción 0,5 y 200 árboles; error externo de la búsqueda RF 2,633 min. `E46_costo_RF` en el resumen registra tiempo de ajuste y predicción; el test permanece reservado.

Solución 44: Contrastar OOB con validación

- a) *Resultados de referencia.*

Árboles	Cobertura	RMSE OOB	RMSE ajuste
10	0,989	2,974	1,605
50	1,000	2,671	1,476
100	1,000	2,625	1,455
300	1,000	2,589	1,451
600	1,000	2,573	1,446

Comparar con RMSE externo RF 2,633, evaluando todo el tuning; el error de ajuste es claramente menor.

- b) OOB promedia árboles que excluyeron una fila; cada bootstrap tiene aproximadamente 63,2 % de filas distintas. La CV externa ajusta con 80 % de desarrollo y protege además la búsqueda interna. No son estimaciones idénticas; tampoco el OOB usado reiteradamente para elegir se vuelve prueba independiente.
- c) Con 10 árboles, cobertura 88 de cada 90 filas aproximadamente (0,9889); no se asigna error cero a las no cubiertas. El gráfico `E44_OOB` muestra estabilización al aumentar árboles; se conserva la prueba final hasta E 50.

Solución 45: Boosting de espera

- a) Grilla: tasas 0,02;0,05;0,1, profundidades 1;2;3 e iteraciones 50;100;250;500. Se reutiliza una trayectoria hasta 500 para evaluar sus etapas. El mínimo se elige en pliegues internos; ningún pliegue externo determina su propia parada.
- b) El candidato de desarrollo completo usa tasa 0,1, profundidad 2 y 250 árboles. Curvas en **E42_E45_trayectorias**; árboles de profundidad 2 admiten interacciones que un stump no representa en una sola etapa. La comparación externa debe evaluar la selección completa, no solo el mínimo interno.
- c) RMSE externo 2,337 min. Ajuste final 0,314 s y predicción 0,01130 ms/fila en una tanda de 200 casos. Son tiempos del entorno de referencia, no garantías de latencia productiva; no incluyen toda la búsqueda.

Solución 46: Comparación defendible

- a) *Resultados de referencia.*

Modelo	RMSE OOF	MAE	SE descriptivo
Arbol	3,203	2,476	0,053
Bagging	2,629	2,040	0,053
RF	2,633	2,013	0,061
Boosting	2,337	1,839	0,057
Media	7,465	5,960	0,242

- b) Boosting mejora RF en 0,296min globales; se entregan errores pareados por corte y terminal en **E41_E50_externo** y **E46_terminales**. La regla fijada acepta candidatos a 0,2min del menor error y elige menor complejidad de sistema según orden explícito; antes de mezclar, favorece boosting.
- c) Grillas seleccionadas dentro de cada entrenamiento; semilla, folds, hoja mínima y presupuesto de árboles declarados. Comparar tiempos medidos sobre el mismo equipo. El SE entre folds no es una prueba formal de igualdad, y cualquier ahorro necesita contrastarse con tolerancias del terminal.

Solución 47: Auditar la importancia

- a) La auditoría agrega código aleatorio a un modelo separado, conservando la especificación RF elegida sin código. Se permuta cada variable 20 veces en pliegues externos; impureza se calcula en ajuste y no se interpreta como validación. Producción sigue sin código.
- b) *Resultados de referencia.*

Variable o bloque	Incremento RMSE	DE de permutación
camiones_cola	1,285	0,058
codigo_aleatorio	-0,002	0,009
cola_proxy	3,608	0,160
cola_y_proxy	6,022	0,188
muelles_activos	3,115	0,106

La permutación conjunta del par usa la misma permutación para ambas columnas, preservando su relación interna.

- c) El bloque cola/proxy tiene más importancia que cada entrada separada. Código tiene incremento cercano a cero; impureza alta no probaría utilidad futura. Las barras con dispersión se entregan en `E47_importancia`. Ni el ranking ni permutar equivalen a intervenir sobre el proceso.

Solución 48: Explicar patrones del modelo

- a) Se generan 12 perfiles ICE y PDP para RF y boosting en percentiles 5–95. Los gráficos `E48_ICE_camiones_cola` y `E48_ICE_muelles_activos` muestran perfiles coloreados por revisión y terminal, manteniendo las mismas referencias.
- b) Cambiar cola dejando fijo su proxy crea pares poco plausibles. Se agrega PDP coherente que modifica ambos a la vez; no estima el efecto aislado de cola y debe etiquetarse como perfil de cambio conjunto. Su separación del PDP marginal muestra sensibilidad a la construcción de la explicación.
- c) Hipótesis operacional: el efecto de congestión podría cambiar con capacidad y revisión documental. Validarla requiere mediciones de soporte y un diseño de intervención o comparación adecuado. Los PDP describen al modelo; niveles y pendientes de ICE pueden variar entre perfiles sin que eso demuestre causalidad.

Solución 49: Combinar familias

- a) Correlación de errores OOF RF–boosting 0,879: elevada, por lo que la complementariedad es limitada. El promedio simple alcanza RMSE 2,408, frente a 2,337 de boosting. Los sesgos se pueden reproducir promediando predicción menos real en E46_OOF.
- b) Se evalúa grilla de peso RF 0;0,25;0,5;0,75;1. En cada corte externo los pesos se eligen con OOF generada solo dentro de su entrenamiento, incluyendo tuning de bases excluyendo cada fila. RMSE del procedimiento de pesos 2,346.
- c) El peso final de RF es 0: se conserva boosting. La combinación no ofrece mejora que justifique mantener dos modelos bajo la regla. Las selecciones por corte y el peso final quedan en el resumen; elegir peso con todo OOF y evaluar allí mismo habría sido optimista.

Solución 50: Decisión final del sistema

- a) Stacking usa árbol, RF y boosting; meta-modelo Ridge con penalización fijada en 1. Entradas OOF dentro de cada entrenamiento externo y selección de bases en una capa interior. RMSE externo 2,350: no mejora boosting 2,337. El reajuste final del meta-modelo estima $-0,395 - 0,106z_A + 0,248z_{RF} + 0,888z_{GB}$; no es mezcla convexa.
- b) Se congela boosting antes de abrir prueba. En 300 ventanas: RMSE 2,416, MAE 1,897, frente a baseline RMSE 8,081. Stacking obtiene 2,375 en esa prueba, pero esa observación no autoriza cambiar la selección ya congelada: exigiría una evaluación nueva.


Terminal	RMSE prueba	MAE
Centro	2,279	1,779
Norte	2,330	1,907
Sur	2,642	2,010

- c) Usar pronóstico para planificar capacidad con tolerancia al error y monitoreo por terminal. Revisar especialmente Sur, donde RMSE 2,642 es mayor. Medir esperas extremas, drift y costo de decisiones, no solo error medio. Congelar versiones y registrar cualquier nueva selección como un ciclo de validación distinto.

Gráficos de referencia comentados


Selección de gráficos de los desafíos. El paquete incluye las figuras adicionales con datos y código reproducible.

E44: error OOB y de ajuste




El error de ajuste permanece por debajo de OOB. Diez árboles dejan algunas filas sin predicción OOB; la tabla informa cobertura.

E47: importancia fuera de pliegue



El par cola/proxy tiene mayor importancia conjunta. Las dispersiones de las 20 permutaciones están en la tabla; el incremento no es un efecto causal.

E48: soporte en un PDP

El cambio conjunto modifica también el proxy; responde a una pregunta diferente del PDP que deja el proxy fijo. Ambos describen predicciones, no intervenciones identificadas.

Reproducción y criterios de corrección

Cómo reproducir los desafíos

Descomprima el paquete conservando las carpetas `codigo`, `datos` y `resultados`. Use Python 3 y las versiones registradas en `requirements.txt`. Desde la raíz del paquete ejecute, en este orden:

```
python codigo/resolver_0.py
python codigo/resolver_1.py
python codigo/resolver_2.py
python codigo/resolver_3.py
python codigo/resolver_4.py
python codigo/graficos_y_diagnostics.py
```

Cada caso utiliza sus propias particiones y guarda resultados antes de abrir las pruebas correspondientes. El script final genera gráficos y diagnósticos a partir de esas decisiones fijadas. Los ensambles con validación anidada requieren más tiempo que los cálculos de los ejercicios escritos.

Los archivos de datos ya están incluidos; no se descarga información. Se fijan semillas en los scripts. Versiones, tolerancias numéricas y hardware pueden producir diferencias pequeñas; los tiempos de ejecución son orientativos. Las etiquetas de clustering pueden permutarse sin cambiar la solución.

Los `.tex` de los solucionarios contienen los gráficos de referencia como coordenadas vectoriales y se compilan de forma independiente con `pdflatex`. El resto de figuras del paquete se entrega en PDF/PNG.

Ejercicios escritos. Dar crédito al procedimiento correcto aunque exista un error aritmético menor, sin duplicar la penalización en incisos que dependan de él. Exigir unidades, denominador y convención cuando cambien la interpretación. En preguntas abiertas, aceptar argumentos diferentes si responden al caso y están sustentados.

Desafíos. Rúbrica orientativa del caso completo: formulación y trazabilidad (20 %); aplicación y cálculos (30 %); validación e incertidumbre (25 %); interpretación y decisión industrial (15 %); reproducibilidad y claridad (10 %). No calificar por coincidir con el modelo ganador de esta pauta.

Errores sustantivos. Deben revisarse especialmente fuga de información, uso del test para seleccionar, pérdida de pares o unidades, comparación de métricas con poblaciones distintas, confusión entre odds y riesgos, omisión de capacidad, interpretación causal no sustentada y ocultamiento de métricas indefinidas.