

Universidad de Santiago de Chile

Departamento de Ingeniería Industrial

ESTADÍSTICA APLICADA

Solucionario - Guía de Ejercicios Propuestos

Unidad 4: Clasificación no Supervisada

Luis Rojo-González, Ph.D.

Profesor Asistente
Departamento de Ingeniería Industrial
Universidad de Santiago de Chile

Versión: 2.0
Fecha: Septiembre 2026

Alcance y uso de la pauta

Este solucionario responde a los **50 ejercicios** de la guía correspondiente, conservando número y letras de cada inciso. Los ejercicios 1–40 incluyen cálculos, interpretación de gráficos y respuestas razonadas; los ejercicios 41–50 presentan una solución reproducible del caso integrador con los datos sintéticos entregados.

No se exige memorizar fórmulas. Se evalúa reconocer el método, sustituir cantidades correctamente, interpretar unidades y distinguir incertidumbre, magnitud y utilidad operacional. El formulario de la guía fija convenciones; aquí se muestran las operaciones necesarias para verificar los resultados.

Los desafíos admiten alternativas. Un modelo, partición o decisión distinta puede ser correcta si respeta disponibilidad temporal, datos reservados, supuestos, criterio declarado y evidencia reproducible. Los valores aquí reportados corresponden a una ejecución de referencia, no son una meta que deba alcanzarse ajustando reiteradamente sobre prueba.

En tablas, un guion indica una cantidad indefinida o no aplicable. No debe reemplazarse silenciosamente por cero. Los redondeos se realizan al presentar, conservando precisión de cálculo.

Correspondencia de contenidos

Tema	Intro.	Medio	Avanz.	Desafío
Propósito y tendencia	1	11, 12	31	41
Escala y disimilitud	2	13, 14	32	42
K-means	3	15, 16	33	43
PAM y representantes	4	17, 18	34	44
Jerárquico y linkage	5	19, 20	35	45
DBSCAN	6	21, 22	36	46
HDBSCAN	7	23, 24	37	47
GMM y pertenencia	8	25, 26	38	48
Validación y estabilidad	9	27, 28	39	49
Perfiles, PCA y tiempo	10	29, 30	40	50

I. Soluciones de nivel introductorio

Solución 1: ¿Qué es un segmento útil?

- a) Clustering busca semejanzas sin una etiqueta objetivo; predecir abandono estima un desenlace definido con datos etiquetados.
- b) Unidad: cliente al corte; ejemplos: frecuencia mensual de pedidos y recencia en los seis meses previos.
- c) Falso: un algoritmo puede imponer cuatro grupos incluso en una nube continua; faltan estabilidad, separación y utilidad.

Solución 2: Unidades que dominan

- a) Contribuciones: $100000^2 = 10^{10}$ y $5^2 = 25$.
- b) En miles CLP el primer término pasa a $100^2 = 10000$; cambia su peso relativo sin cambiar al cliente.
- c) Estandarizar o usar escala robusta con mediana/IQR; auditar asimetría y extremos antes de decidir transformaciones o pesos.

Solución 3: Asignar al centroide cercano

- a) Distancias al cuadrado: $(2 - 1)^2 + (3 - 1)^2 = 5$ y $(2 - 5)^2 + (3 - 5)^2 = 13$. Asignar al primero.
- b) Elegir el centro de menor índice en empate, o una regla fija registrada.
- c) El centroide es una media coordenada a coordenada y puede ubicarse donde no existe ninguna observación.

Solución 4: Qué representa un medoide

- a) Un número fraccionario de contratos y un canal promedio no representan categorías o conteos de un cliente concreto.
- b) Centroide resume medias; medoide es un cliente observado elegido por cercanía al grupo, más fácil de ejemplificar sin inventar un perfil imposible.
- c) Gower combina diferencias numéricas normalizadas y coincidencias nominales con pesos declarados.

Solución 5: Dos definiciones de cercanía

- a) Single=2; complete=8; average= $(2 + 4 + 6 + 8)/4 = 5$.
- b) Single puede encadenar grupos por una sola conexión cercana.
- c) No: definiciones diferentes pueden cambiar orden y altura de fusiones, aunque a veces coinciden.

Solución 6: Núcleo, borde y ruido

- a) A núcleo, B borde, C ruido.
- b) B no alcanza cuatro vecinos, pero es alcanzable desde un núcleo.
- c) No: puede ser un cliente legítimo poco frecuente, un patrón raro o un problema de medición; requiere revisión sustantiva.

Solución 7: Grupos que persisten

- a) La jerarquía sigue grupos a distintas densidades y favorece estructuras persistentes frente a elegir un único radio.
- b) Tamaño mínimo fija cuántos miembros debe tener un grupo; vecinos de densidad controlan escala local y conservadurismo de clasificación como ruido.
- c) No. Registrar paquete, versión, parámetros efectivos, inclusión del propio punto y regla de extracción de grupos.

Solución 8: Pertenencia incierta

- a) Máximo: grupo1, pero 0,50 frente a 0,47 indica ambigüedad entre los dos primeros.
- b) Con 0,95 la asignación es mucho más concentrada, condicionada al modelo.
- c) Las responsabilidades dependen de componentes, covarianzas, pesos y representación; no son certificación de tipos naturales.

Solución 9: Silhouette de un cliente

- a) Primero: $(5 - 2)/5 = 0,6$. Segundo: $(3 - 4)/4 = -0,25$.
- b) Positivo: más cerca del propio grupo en promedio; cerca de cero: frontera; negativo: otro grupo es más próximo en esa métrica.
- c) Puede revelar solapamiento, mala partición o un caso legítimo; diagnosticar antes de eliminar.

Solución 10: Nombrar grupos con evidencia

- a) Ejemplos: “Pedidos frecuentes y margen bajo” y “Pedidos esporádicos de ticket alto”.
- b) El perfil es un resumen con dispersión interna; no describe por igual a todos los clientes del grupo.
- c) Grupo, canal y abandono pueden compartir causas; la asociación no identifica el efecto de imponer un canal.

II. Soluciones de nivel medio

Solución 11: Calcular Hopkins

- a) $H = 18/(18 + 2) = 0,90$; con ambas sumas $H = 0,50$.
- b) Compara distancias de puntos uniformes de referencia con distancias de observaciones; detecta apartamiento de esa referencia, que no equivale exclusivamente a clusters discretos.
- c) No determina K ; se necesitan criterios de partición, estabilidad y utilidad.

Solución 12: Mirar una nube de puntos

- a) Tres concentraciones visibles, aproximadamente en $(-2, -1)$, $(0, 1)$, $(2, -1)$, pequeñas respecto de su separación en esta proyección.
- b) Se omiten variables donde podría haber solapamiento o separación; escala o proyección pueden exagerar huecos y densidad.
- c) Examinar espacio completo, sensibilidad de representación, estabilidad por remuestreo y diferencias útiles para diseñar servicio.

Solución 13: Estandarizar y medir

- a) $z_A = (-1, -1)$ y $z_B = (1, 1)$; distancia $\sqrt{8} = 2,8284$.
- b) Original $\sqrt{20^2 + 40^2} = \sqrt{2000} = 44,7214$, mezclando escalas.
- c) Recalcular escala en julio cambiaría la geometría y haría que migración combine cambio de comportamiento con cambio de regla.

Solución 14: Gower para datos mixtos

- a) Contribuciones $30/100 = 0,30$, $10/40 = 0,25$ y 1 por canal distinto; Gower $= 1,55/3 = 0,5167$.
- b) Sin margen comparable: $(0,30 + 1)/2 = 0,65$.
- c) Distancias basadas en pocas variables tienen menor soporte informativo; registrar disponibilidad y revisar vecinos con escaso solapamiento.

Solución 15: Una iteración completa

- a) A,B al primer grupo y C,D al segundo; centroides $(1,5, 1)$ y $(8,5, 8)$.
- b) $W_2 = 4(0,5^2) = 1$; las asignaciones no cambian al repetir.
- c) Convergencia garantiza un punto fijo/local del procedimiento, no optimalidad global para cualquier problema.

Solución 16: Inicialización desafortunada

- a) Inicio (0, 1). Iteración1: grupos {0} y {1, 2, 8, 9, 10}; centros (0, 6). Iteración2: grupos {0, 1, 2} y {8, 9, 10}; centros (1, 9).
- b) Inicio (0, 10) obtiene los grupos finales en la primera asignación y actualiza a (1, 9). Ambos llegan aquí a $W = 4$.
- c) Otros datos pueden dar mínimos locales diferentes; repetir inicios y elegir menor suma de cuadrados para el mismo K , sin usar eso solo para escoger K .

Solución 17: Buscar el medoide

- a) Sumas: A13, B11, C10, D12; medoide C. No hay empate.
- b) B va con A (2 frente a4), D con C (1 frente a6); objetivo $0 + 2 + 0 + 1 = 3$.
- c) Los códigos nominales no tienen distancias aritméticas significativas; promediarlos depende de una codificación arbitraria.

Solución 18: Evaluar un intercambio PAM

- a) Con medoides0 y9: distancias mínimas (0, 2, 3, 0, 1), objetivo6.
- b) Con2 y9: (2, 0, 1, 0, 1), objetivo4. Con3 y9: (3, 1, 0, 0, 1), objetivo5.
- c) Intercambiar0 por2. Un mejor intercambio local no demuestra que ninguna combinación de varios cambios pueda mejorar la solución.

Solución 19: Leer un dendrograma

- a) Primeras fusiones: A–B a altura1 y D–E a2.
- b) A altura3: {A, B}, {C}, {D, E}. A altura5: {A, B, C}, {D, E}.
- c) Cofenéticas A–B=1, A–C=4, A–E=6: altura donde cada par comparte por primera vez un grupo.

Solución 20: Calcular una fusión de Ward

- a) Ward: $\Delta W = \frac{3 \cdot 2}{3+2} \|(1, 2) - (4, 2)\|^2 = \frac{6}{5}(9) = 10,8$.
- b) Para tamaños1 y1 y distancia4: $\Delta W = \frac{1}{2}(16) = 8$; Ward preferiría ese par entre estas opciones.
- c) Su criterio deriva de suma de cuadrados euclídea; una matriz Gower arbitraria no garantiza esa geometría ni esa interpretación.

Solución 21: DBSCAN en una recta

- a) Con radio 0,25: vecindarios $N(0) = \{0; 0,2\}$, $N(0,2) = \{0; 0,2; 0,4\}$, $N(0,4) = \{0,2; 0,4\}$, $N(1) = N(1,2) = \{1; 1,2\}$, $N(3) = \{3\}$. Núcleo 0,2; bordes 0 y 0,4; resto ruido.
- b) Un grupo $\{0; 0,2; 0,4\}$ y tres puntos ruido.
- c) A radio 0,65: núcleos 0,2; 0,4; 1,0; borde 1,2. La conexión 0,4–1,0 de 0,6 une los cinco primeros en un grupo; 3 sigue ruido.

Solución 22: Leer distancias ordenadas

- a) Valores exploratorios 0,25 y 0,50, alrededor del cambio de pendiente; también es defendible estudiar un intervalo cercano explicitado.
- b) Distancia al tercer vecino distinta mayor que radio implica no ser núcleo para minPts 4, pero el punto puede ser borde si queda cerca de otro núcleo.
- c) Repetir con radios algo menores/mayores y vecinos alternativos; registrar cobertura, tamaños y estabilidad.

Solución 23: Alcance mutuo

- a) $d_{mr}(A, B) = \max(0,2, 0,5, 0,1) = 0,5$; $AC=0,7$; $BC=0,5$.
- b) Aristas AB y BC conectan todos con peso total 1,0, sin ciclo.
- c) Alcance mutuo impone un piso dado por la densidad local; cercanía geométrica aislada no basta para una conexión densa.

Solución 24: Persistencia simplificada

- a) Primero: $(5 - 2) + (6 - 2) + (4 - 2) = 9$. Segundo: $4(3 - 2) = 4$.
- b) Combina cantidad de puntos y cuánto persisten desde el nacimiento; un grupo mayor puede durar poco.
- c) No: la selección jerárquica compara alternativas padre–descendientes y evita solapamientos; no se resuelve comparando dos grupos ajenos.

Solución 25: Un paso de responsabilidades

- a) Densidad mezcla $0,6(0,2) + 0,4(0,3) = 0,24$; responsabilidades $(0,5, 0,5)$.
- b) Nuevos términos 0,24 y 0,04; mezcla 0,28; responsabilidades $(6/7, 1/7) = (0,8571, 0,1429)$.
- c) Los pesos codifican frecuencia relativa de componentes y modifican su contribución a la densidad total.

Solución 26: Actualizar medias con EM

- a) $N_1 = 1,8$, $N_2 = 1,2$; pesos 0,6 y 0,4. $\mu_1 = (0 + 1,6 + 0,8)/1,8 = 4/3$; $\mu_2 = (0 + 0,4 + 7,2)/1,2 = 19/3$.
- b) Asignación dura: 0 y 2 al primero, 8 al segundo; medias 1 y 8.
- c) Las responsabilidades se recalculan con nuevos parámetros y deben actualizarse covarianzas; EM puede converger a diferentes óptimos locales.

Solución 27: Leer silhouettes individuales

- a) Suma $0,7 + 0,6 + 0,2 - 0,3 + 0,1 + 0,8 = 2,1$; media 0,35. Revisar especialmente cliente 4 y los débiles 3 y 5.
- b) Un grupo pequeño aporta poco al promedio ponderado, aunque esté completamente mal separado.
- c) Diagrama de silhouettes ordenados dentro de cada grupo, con medias y tamaños; complementar con perfiles y distancias a representantes.

Solución 28: Codo y Gap

- a) Codo plausible $K = 3$: la reducción pasa de 250 entre 2–3 a 50 entre 3–4. Gap: para 2, $0,30 < 0,46 - 0,04 = 0,42$; para 3, $0,46 \geq 0,49 - 0,05 = 0,44$. Regla elige 3.
- b) El máximo observado es 0,50 en 5, pero la regla busca el menor K compatible con la incertidumbre del siguiente.
- c) Faltan estabilidad, tamaños mínimos, perfiles accionables y sensibilidad a representación y referencia de Gap.

Solución 29: PCA y varianza acumulada

- a) Acumuladas: dos 70 %, tres 82 %, cuatro 90 %.
- b) Mínimo para superar 80 %: tres componentes.
- c) La variación dominante puede responder a escala o ruido; una señal de segmentación relevante puede estar en componentes de baja varianza.

Solución 30: Migración entre segmentos

- a) Cambian $(5 + 15)/100 = 20\%$. Desde grupo 1: $(35/40, 5/40) = (0,875, 0,125)$. Desde grupo 2: $(15/60, 45/60) = (0,25, 0,75)$.
- b) Con escala y representantes congelados, números conservan significado; si se reajustaran, habría que emparejar nombres antes de interpretar migración.
- c) Solo comunes tienen ambas asignaciones; nuevos y ausentes se informan aparte para no alterar artificialmente tasas de transición.

III. Soluciones de nivel avanzado

Solución 31: La referencia cambia la conclusión

- a) Una franja continua correlacionada deja gran parte del rectángulo vacía; puntos uniformes caen lejos de ella y elevan Hopkins sin segmentos discretos.
- b) Comparar gráficos, referencia uniforme en espacio transformado y una referencia unimodal con correlación similar; repetir con escalas y submuestras.
- c) Si las particiones son inestables o no generan decisiones de servicio útiles, puede descartarse segmentación operacional aunque H sea alto.

Solución 32: Pesos y variables redundantes

- a) Tres medidas redundantes de volumen repiten el mismo concepto: igual varianza por columna le da mayor peso total.
- b) Ponderar bloques de volumen y servicio, resumir volumen con PCA o elegir una variable representativa; comparar estabilidad y perfiles bajo alternativas declaradas.
- c) Pesos de negocio expresan propósito. Elegirlos exclusivamente para maximizar silhouette puede fabricar separación que no mejora decisiones.

Solución 33: Un extremo mueve el centro

- a) Antes: media_{2,5} y $W = 2,25 + 0,25 + 0,25 + 2,25 = 5$. Después: media₈ y $W = 49 + 36 + 25 + 16 + 484 = 610$.
- b) El alto costo cuadrático del extremo puede hacer rentable reservarle un centroide y fusionar otros grupos.
- c) Verificar registro, unidades y valor comercial; comparar PAM, escala robusta o transformación justificada conservando reporte del cliente extremo.

Solución 34: Robustez y costo

- a) $40000^2 \cdot 8 = 12.800.000.000$ bytes=12,8 GB decimales, sin contar copias ni otros objetos.
- b) Elegir representantes reales no elimina construir o consultar distancias; una implementación densa conserva costo cuadrático.
- c) Usar muestras para elegir medoides (por ejemplo estrategia CLARA), luego asignar/evaluar en clientes restantes; estratificar o auditar cobertura de segmentos pequeños y repetir muestras.

Solución 35: Preservar distancias o separar grupos

- a) Correlación cofenética mide preservación global de distancias por la jerarquía; silhouette mide separación/compactación de una partición concreta.
- b) Una jerarquía puede reproducir distancias y a la vez producir grupos encadenados poco útiles; cifras no miden capacidad comercial.
- c) Inspeccionar dendrograma, cadenas, tamaños mínimos, perfiles y estabilidad bajo remuestreo; Ward tiene aquí mayor silhouette pero requiere esos diagnósticos.

Solución 36: Densidades distintas

- a) Un radio pequeño conserva densos y pierde dispersos; uno grande puede conectarlos mediante puentes.
- b) Revisar escala, redundancias y soporte, y comparar HDBSCAN para densidades variables.
- c) Reportar cobertura, ruido y perfiles, Jaccard/ARI bajo perturbaciones y sil solo con denominador explícito; minimizar ruido no es criterio suficiente.

Solución 37: Parámetros y abstención

- a) Tamaño10 permite resolución fina, pero grupos pequeños pueden ser variables y costosos de atender. Tamaño40 agrega o descarta estructuras y exige suficiente masa operacional.
- b) El ruido puede representar abstención razonable ante evidencia débil; forzar asignación no asegura calidad.
- c) Fijar tamaño mínimo atendible, examinar persistencia, estabilidad y cobertura; aceptar segmentos solo si perfiles son reproducibles y su uso tiene valor verificable.

Solución 38: BIC y covarianzas

- a) $q = 3K - 1: 2, 5, 8$. BIC: $440 + 2(4,6052) = 449,2104$; $380 + 5(4,6052) = 403,026$; $368 + 8(4,6052) = 404,8416$.
- b) Elegir $K = 2$, mínimo BIC.
- c) La verosimilitud de mezclas puede tener óptimos locales y singularidades cuando una varianza colapsa; usar múltiples inicios y un piso de covarianza, documentando ambos.

Solución 39: ARI y cambio de nombres

- a) Suma de combinaciones de celdas=2. $A = B = 6$, $N = 15$, esperado $AB/N = 2,4$. $ARI = (2 - 2,4)/(6 - 2,4) = -1/9 = -0,1111$.
- b) Solo renombrar grupos idénticos da $ARI=1$.
- c) Emparejar grupos maximizando coincidencias/Jaccard; una permutación conserva miembros, fragmentación los reparte entre varios grupos, migración con regla congelada cambia su pertenencia.

Solución 40: Alta dimensión y causalidad

- a) Imputar/escalar y ajustar PCA sin abandono, elegir dimensiones y clustering con estabilidad y criterios internos declarados; repetir todo en remuestras.
- b) Varianza pequeña no implica poca relevancia: contrastar alternativas y conservar interpretación en variables originales.
- c) Mayor abandono del grupo no prueba que imponer compras lo reduzca. Proponer piloto con asignación aleatoria a oferta voluntaria/control, medir abandono, margen, costo y efectos no deseados.

IV. Soluciones de los desafíos con datos

Las tablas completas, predicciones, índices y gráficos están en la carpeta **resultados/Unidad_4/** del paquete. Para reproducir este caso ejecute `codigo/resolver_4.py`; el script común de gráficos y diagnósticos se ejecuta después de los cinco casos. El instructivo final explica el orden. Los nombres citados sin extensión se corresponden con CSV, entradas del resumen o gráficos indicados en cada solución.

Solución 41: Auditar clientes y tendencia

- a) 720 clientes de enero, IDs únicos. Se analizan seis variables numéricas del comportamiento de seis meses previos, sin abandono ni margen futuros. Auditar faltantes, rangos y extremos antes de imputar; un ticket alto no es por definición un error.
- b) Hopkins con dimensión 6,50 puntos por repetición y 20 repeticiones: media clientes 0,99710, rango [0,97461;0,99965]; referencia uniforme media 0,50483. Convención: distancias elevadas a 6 y H grande indica apartamiento de uniformidad.
- c) El gráfico **E41_Hopkins** y proyección PCA están incluidos. Hopkins muy alto no determina *K*: correlación, asimetría y extremos también separan la nube de la referencia rectangular. La conclusión es explorar particiones y estabilidad, no proclamar segmentos naturales.

Solución 42: Dos representaciones explícitas

- a) A: imputación por mediana y estandarización con DE poblacional de enero. B: Gower con seis diferencias numéricas divididas por rango, canal y región nominales y contrato binario simétrico; nueve contribuciones con pesos iguales. Faltantes categóricos se imputan por moda. Los parámetros quedan guardados.
- b) Se comparan cinco vecinos de cinco clientes en **E42_vecinos**, incluyendo escala robusta mediana/IQR. A y B pueden dar vecinos diferentes porque responden a distintas nociones de semejanza; igual peso por columna no equivale a igual peso por concepto de negocio.
- c) Para julio se reutilizan medianas, medias, DE, rangos y política categórica de enero. **E42_transformaciones** registra valores y **E42_modos** en el resumen registra categorías. No ordenar silhouettes de A y B como si midieran la misma geometría. El rango de Gower es sensible a extremos y debe auditarse.

Solución 43: K-means con múltiples inicios

- a) Se ajustan 30 inicializaciones independientes para cada $K = 2, \dots, 8$ y se conserva menor suma de cuadrados; E43_inicios incluye todos los objetivos.

K	W_K	Silhouette	n mínimo	ARI escala robusta
2	3131,818	0,256	249	0,896
3	2497,289	0,265	131	0,914
4	2175,636	0,242	119	0,965
5	1976,662	0,229	109	0,751
6	1831,525	0,233	5	0,933
7	1690,449	0,208	5	0,948
8	1604,281	0,199	5	0,913

- b) Regla declarada: grupos de al menos 30 miembros; entre los candidatos dentro de 0,01 del máximo silhouette admisible, elegir menor K . El máximo es 0,2653 para 3 y $K = 2$ obtiene 0,2556, diferencia 0,0097; por parsimonia se retiene 2, provisionalmente.
- c) Se comparan perfiles de 2 y 4 grupos en unidades originales en E43_perfiles_elegido y E43_perfiles_K4; el gráfico E43_codo muestra rendimientos decrecientes. Menor W con más grupos no prueba que haya más segmentos; la sensibilidad robusta requiere revisar estabilidad y significado.

Solución 44: Segmentos representados por clientes

- a) PAM usa fase BUILD seguida de intercambios SWAP que mejoran el objetivo hasta no hallar mejora; no se confunde con actualizar medias. Se exploran $K = 2, \dots, 8$ en B y se entregan IDs de medoides, perfiles y tamaños en E44_medoides y E44_perfiles_B.
- b) *Resultados de referencia.*

PAM, $K = 2$	Objetivo	Silhouette	Mínimo	Máximo
A	1429,672	0,250	262	458
B	167,732	0,161	331	389

En A se repite PAM con distancia euclídea sobre la misma muestra; el objetivo de PAM suma distancias, mientras K-means suma cuadrados.

- c) Comparación de algoritmo: K-means y PAM en A, mismas filas y distancia para silhouette. Comparación de representación: PAM en A frente a B, describiendo qué cambia en vecinos y perfiles; sus valores de silhouette no forman un ranking universal. Un medoide ejemplifica al grupo, no sustituye su dispersión interna.

Solución 45: Jerarquía de segmentos

- a) Se ajustan average, complete y Ward sobre los 720 clientes de A. Ward de SciPy trabaja con distancia euclídea y su altura reporta $\sqrt{2\Delta W}$; no es directamente ΔW . Dendrogramas de una submuestra fija de 24 clientes se entregan en `E45_dendrogramas.png`.
- b) *Resultados de referencia.*

Linkage	K	Cof.	Silhouette	n mínimo
average	3	0,714	0,500	1
average	4	0,714	0,435	1
average	5	0,714	0,205	1
complete	3	0,531	0,175	3
complete	4	0,531	0,173	3
complete	5	0,531	0,136	3
ward	3	0,518	0,256	117
ward	4	0,518	0,226	117
ward	5	0,518	0,197	80

- c) Average puede dar silhouette alto separando pocos extremos: con 3 grupos, uno tiene 714 clientes y hay un singleton. Ese resultado no es automáticamente útil para servicio comercial. Los perfiles completos y tamaños prevalecen sobre una lectura del dendrograma de 24 puntos; revisar estabilidad antes de elegir.

Solución 46: Segmentación por densidad

- a) DBSCAN usa minPts 5,10,20 incluyendo el propio punto. Para cada valor, radios elegidos en cuantiles 0,5;0,7;0,9 de la distancia al vecino correspondiente y perturbaciones $\pm 10\%$. El gráfico de vecinos `E46_kdist` sustenta la exploración.
- b) *Resultados de referencia.*

minPts	Cuantil	Radio	K	Fracción ruido
5	0,500	0,955	4	0,322
5	0,700	1,126	3	0,138
5	0,900	1,408	1	0,046
10	0,500	1,137	3	0,225
10	0,700	1,325	1	0,087
10	0,900	1,614	1	0,029
20	0,500	1,318	1	0,201
20	0,700	1,522	1	0,060
20	0,900	1,859	1	0,015

`E46_DBSCAN` registra también ARI respecto del radio central y tamaños; estos ARI incluyen ruido como etiqueta y deben leerse junto a cobertura.

- c) Silhouette se calcula solo en asignados y únicamente si existen al menos dos grupos. Un único grupo o todo ruido produce métrica indefinida, no cero. Se incluyen perfiles del ruido en `E46_perfiles`; clientes fuera de densidad no son automáticamente fraude ni errores.

Solución 47: Densidad variable

- a) HDBSCAN de scikit-learn: tamaños mínimos 10,25,50; `min_samples` 5,10,20; selección EOM, vecinos incluyendo el propio punto. El paquete externo homónimo puede usar otra convención; no trasladar valores sin comprobarla.

Tamaño mínimo	Vecinos	K	Ruido	Sil. asignados
10	5	2	0,278	0,279
10	10	2	0,749	0,458
10	20	2	0,807	0,486
25	5	2	0,278	0,279
25	10	2	0,749	0,458
25	20	2	0,807	0,486
50	5	2	0,708	0,428
50	10	2	0,749	0,458
50	20	0	1,000	—

- b) Para configuración 25/10, estabilidad EOM calculada desde la jerarquía de alcance mutuo:

Grupo EOM	n	λ nacimiento	Estabilidad
0	120	1,060	20,797
1	61	1,060	2,779

La extracción implementada reproduce exactamente la partición de scikit-learn (ARI 1); estas son sumas de persistencia, no probabilidades. Separadamente se entrega Jaccard ante cambios de parámetros. En la intersección con DBSCAN quedan 181 clientes; DBSCAN tiene un solo grupo allí, por lo que su silhouette es indefinido y no se fuerza una comparación.

- c) El alto silhouette con 25/10 cubre solo $181/720=25,14\%$ de clientes. Aumentar cobertura cambia la estructura: no basta elegir el máximo. Recomendar abstención en ruido y auditar estabilidad/capacidad antes de usar grupos de densidad para toda la cartera; el agrupamiento de menor densidad no admite una asignación futura automática sin una regla adicional.

Solución 48: Segmentos probabilísticos

- a) Se exploran $K = 2, \dots, 6$, covarianza diagonal/completa, 10 inicios, regularización 10^{-6} . $BIC = -2\ell + q \log n$, menor mejor. Gana diagonal con 5 componentes, BIC 9678,861, convergencia declarada; se entregan todos los BIC en E48_GMM.
- b) Cinco clientes tienen responsabilidad máxima menor que 0,60. Sus IDs y probabilidades están en E48_responsabilidades; revisar fronteras y solapamiento de componentes. La pertenencia concentrada sigue siendo condicional al modelo, no una etiqueta real conocida.
- c) *Resultados de referencia.*

Componente	Masa efectiva	Pedidos/mes	Ticket MCLP	Recencia días
0	216,304	11,585	0,735	15,599
1	119,420	16,729	2,835	24,321
2	217,546	4,251	0,241	35,107
3	157,733	21,526	1,570	10,043
4	8,997	24,550	7,343	17,352

Los perfiles ponderan por responsabilidades. Comparar con K-means en A como soluciones distintas; una mezcla puede usar componentes para aproximar densidad sin que cada uno represente un segmento operacional.

Solución 49: Elegir con estabilidad

- a) Se retienen K-means 2, PAM en B con 2 grupos y GMM diagonal 5. Para 30 submuestras sin reemplazo de 80 % (576 clientes), se reajusta también imputación/escala o rangos. ARI se evalúa solo en los IDs comunes con referencia; Jaccard usa emparejamiento óptimo de grupos. Estos tres candidatos asignan todos los puntos, sin ruido.
- b) *Resultados de referencia.*

Candidato	ARI medio	Mínimo	Máximo
GMM	0,955	0,834	1,000
Kmeans	0,995	0,979	1,000
PAM_B	0,567	0,002	1,000

K-means: Jaccard medio mínimo entre grupos 0,9962. PAM muestra gran variación; no ocultarla tras promedios. Los resultados por grupo y réplica se entregan en E49_Jaccard.

- c) Se conserva K-means 2 por regla simple de asignación y estabilidad: supera criterios prefijados ARI medio 0,75 y Jaccard medio por grupo 0,70. Silhouette 0,256 indica separación moderada/baja; alta estabilidad no prueba grupos naturales. Guardar escala y centroides para un piloto de utilidad, no dar por demostrado el beneficio comercial.

Solución 50: Segmentos en operación

- a) Se congelan escala y centroides de enero y se asigna julio por centroide más cercano. Regla sin abstención: cobertura 100 %, que debe acompañarse de revisión de distancia y soporte. Hay 660 comunes, 60 nuevos y 60 ausentes. Transiciones de comunes, filas enero/columnas julio:

$$\begin{pmatrix} 430 & 7 \\ 6 & 217 \end{pmatrix}.$$

Cambian $13/660=1,970\%$; tasas por grupo: $7/437=1,602\%$ y $6/223=2,691\%$.

- b) *Resultados de referencia.*

Grupo enero	n	Abandono	Wilson inferior	Wilson superior
0	471	0,113	0,087	0,144
1	249	0,269	0,218	0,327


Margen semestral medio: 46,087 y 2,364 MCLP, con intervalos bootstrap incluidos en `E50_resultados_externos`. Los resultados futuros describen asociaciones; no se usan para volver a elegir grupos.

- c) Conservar nombres descriptivos basados en perfiles de enero y su dispersión. Proponer piloto con visitas/servicio definidos, asignación aleatoria a intervención/control dentro de segmentos, costos, margen y abandono como resultados. Una diferencia de abandono entre grupos no identifica cómo reducirlo; la estabilidad observada sustenta continuidad de regla, no beneficio causal de segmentar.

Gráficos de referencia comentados


Selección de gráficos de los desafíos. El paquete incluye las figuras adicionales con datos y código reproducible.

E43: curva de K-means




La disminución de W no identifica por sí sola el número útil de segmentos; se incorporan tamaño, estabilidad y parsimonia.

E49: proyección de la solución elegida



Los grupos elegidos sobre seis variables presentan solapamiento en esta proyección. La estabilidad alta del procedimiento no implica separación completa ni tipos naturales.

E49: estabilidad en submuestras

Treinta submuestras de 576 clientes con representación reajustada. PAM en Gower varía mucho más que K-means o GMM; ARI es invariante a renombrar grupos.

Reproducción y criterios de corrección

Cómo reproducir los desafíos

Descomprima el paquete conservando las carpetas `codigo`, `datos` y `resultados`. Use Python 3 y las versiones registradas en `requirements.txt`. Desde la raíz del paquete ejecute, en este orden:

```
python codigo/resolver_0.py
python codigo/resolver_1.py
python codigo/resolver_2.py
python codigo/resolver_3.py
python codigo/resolver_4.py
python codigo/graficos_y_diagnostics.py
```

Cada caso utiliza sus propias particiones y guarda resultados antes de abrir las pruebas correspondientes. El script final genera gráficos y diagnósticos a partir de esas decisiones fijadas. Los ensambles con validación anidada requieren más tiempo que los cálculos de los ejercicios escritos.

Los archivos de datos ya están incluidos; no se descarga información. Se fijan semillas en los scripts. Versiones, tolerancias numéricas y hardware pueden producir diferencias pequeñas; los tiempos de ejecución son orientativos. Las etiquetas de clustering pueden permutarse sin cambiar la solución.

Los `.tex` de los solucionarios contienen los gráficos de referencia como coordenadas vectoriales y se compilan de forma independiente con `pdflatex`. El resto de figuras del paquete se entrega en PDF/PNG.

Ejercicios escritos. Dar crédito al procedimiento correcto aunque exista un error aritmético menor, sin duplicar la penalización en incisos que dependan de él. Exigir unidades, denominador y convención cuando cambien la interpretación. En preguntas abiertas, aceptar argumentos diferentes si responden al caso y están sustentados.

Desafíos. Rúbrica orientativa del caso completo: formulación y trazabilidad (20 %); aplicación y cálculos (30 %); validación e incertidumbre (25 %); interpretación y decisión industrial (15 %); reproducibilidad y claridad (10 %). No calificar por coincidir con el modelo ganador de esta pauta.

Errores sustantivos. Deben revisarse especialmente fuga de información, uso del test para seleccionar, pérdida de pares o unidades, comparación de métricas con poblaciones distintas, confusión entre odds y riesgos, omisión de capacidad, interpretación causal no sustentada y ocultamiento de métricas indefinidas.

Convenciones del código. `HDBSCAN` de `scikit-learn` incluye el propio punto en `min_samples`. La persistencia se calcula explícitamente desde alcance mutuo y se contrasta con la partición de esa implementación. `Ward` de `SciPy` requiere geometría euclídea; su altura y el incremento de suma de cuadrados deben distinguirse. Los puntajes de pertenencia de `HDBSCAN` no son las responsabilidades de una mezcla gaussiana.