



**INGENIERÍA
INDUSTRIAL**

UNIVERSIDAD DE SANTIAGO DE CHILE

Estadística Aplicada

Luis Rojo-González, Ph.D.



Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso

2. Fundamentos estadísticos

3. Regularización, validación cruzada y modelos flexibles


4. Ensemble Learning

5. Clasificación supervisada

6. Clasificación no supervisada

7. Cierre del curso

8. Anexos





Objetivo general

Comprender y aplicar herramientas de estadística aplicada, modelamiento predictivo y análisis de datos para estimar, contrastar e interpretar evidencia empírica en problemas de Ingeniería Industrial.


¿Qué busca desarrollar el curso?

- ▶ Razonamiento bajo incertidumbre.
- ▶ Interpretación de evidencia estadística.
- ▶ Modelamiento de fenómenos industriales.
- ▶ Uso de herramientas estadísticas en R.
- ▶ Validación de modelos predictivos.
- ▶ Comunicación de resultados.

Aplicaciones típicas

- ▶ Calidad y productividad.
- ▶ Pronóstico de demanda.
- ▶ Inventarios y logística.
- ▶ Costos y desempeño operacional.
- ▶ Mantenimiento predictivo.
- ▶ Gestión de proyectos.

De inferencia a Estadística Aplicada




Idea clave

El objetivo de la estadística aplicada no es solamente analizar datos, sino desarrollar modelos que permitan entender procesos, anticipar comportamientos y mejorar decisiones en sistemas industriales complejos.





1. Bienvenida al curso
2. Fundamentos estadísticos
3. Regularización, validación cruzada y modelos flexibles
4. Ensemble Learning
5. Clasificación supervisada
6. Clasificación no supervisada
7. Cierre del curso
8. Anexos



Planificación



Semana	Unidad	Evaluación	Profesor	Lab.
1 (21/09/26)	Bienvenida al curso (L1)		FG + LR	
	Fundamentos estadísticos I (L2-M3)		FG	
2 (28/09/26)	Fundamentos estadísticos II (L2-M3)	(5 %) Control 1 L1	FG	
3 (05/10/26)	Fundamentos estadísticos III (L1-L2)		FG	Presencial (M3)
4 (12/10/26)	FERIADO (L1-L2)	LIBRE (M3)		
5 (19/10/26)	Regularización I (L2)	(10 %) Control 2 L1	LR	Presencial (M3)
6 (26/10/26)	Regularización II (L1)		LR	
	Ensemble Learning (L2-M3)			
7 (02/11/26)	Clasificación supervisada I (L2)	(10 %) Control 3 L1	FG	Presencial (M3)
8 (09/11/26)	LIBRE			
9 (16/11/26)		(35 %) Caso de estudio 1	FG + LR	
10 (23/11/26)	Clasificación supervisada II (L1-L2)		FG	
11 (30/11/26)	Clasificación supervisada III (L1-L2)		FG	
12 (07/12/26)	RECESO (L1-L2)	FERIADO (M3)		
13 (14/12/26)	Clasificación no supervisada I (L1-L2)		LR	Presencial (M3)
14 (21/12/26)	Clasificación no supervisada II (L1-L2)		LR	Presencial (M3)
15 (28/12/26)		(15 %) Control 4 L1-L2	LR	Online (M3)
16 (04/01/27)		(25 %) Caso de estudio 2	FG + LR	
17 (11/01/27)		Examen ponderado L1-L2	LR	



Actividades DataCamp



Inicio	Actividad	Observación	Horas	Entrega
21/09/26	Exploratory Data Analysis in R		4	28/09/26
21/09/26	Machine Learning with caret in R - U4	Preprocessing Data	1	28/09/26
28/09/26	Statistical Inference in R		16	19/10/26
19/10/26	Machine Learning with caret in R - U1	Regression Models: Fitting and Evaluating Their Performance	1	26/10/26
19/10/26	Nonlinear Modeling with Generalized Additive Models (GAMs) in R - U1 + U2	Introduction to Generalized Additive Models + Interpreting and Visualizing GAMs	2	26/10/26
19/10/26	Supervised Learning in R: Regression - U4	Dealing with Non-Linear Responses	1	26/10/26
26/10/26	Machine Learning with Tree-Based Models in R - U2	Regression Trees and Cross-Validation	1	02/11/26
16/11/26	Machine Learning with caret in R - U2	Classification Models: Fitting and Evaluating Their Performance	1	23/11/26
16/11/26	Supervised Learning in R: Classification		4	23/11/26
23/11/26	Support Vector Machines in R		4	30/11/26
14/12/26	Cluster Analysis in R - U1 + U3	Calculating Distance Between Observations + K-means Clustering	2	21/12/26
14/12/26	Mixture Models in R - U1 + U2 + U3	Introduction to Mixture Models + Structure of Mixture Models and Parameters Estimation + Mixture of Gaussians with flexmix	3	21/12/26
21/12/26	Cluster Analysis in R - U2	Hierarchical Clustering	1	28/12/26

De las evaluaciones



Todas las evaluaciones utilizan una escala de calificación con 60 % de exigencia.

Evaluación	Fecha	Ponderación	Contenido
Control 1	28/09/26	5 %	Diagóstico
Control 2	19/10/26	10 %	Fundamentos estadísticos
Control 3	02/11/26	10 %	Regularización y Ensemble Learning
Control 4	28/12/26	15 %	Clasificación supervisada y Clasificación no supervisada

	Caso de estudio	Inicio (M3)	Entrega (11:59 am)	Presentación (L1-L2-M3)
1	Regresión	06/10/26	11/11/26	16/11/26
2.1	Clasificación supervisada	15/12/26	30/12/26	04/01/26
2.2	Clasificación no supervisada	15/12/26	30/12/26	04/01/26

- ▶ Para el caso de estudio 2: el enfoque (supervisado o no supervisado) será por sorteo el día 15/12/26 al inicio del bloque M3.
- ▶ Las entregas serán mediante un formulario de Google dispuesto y comunicado oportunamente.
- ▶ Cualquier envío a través de otro medio será considerado como no entregado y evaluado con la nota mínima (1,0).

¿Cómo se aprueba el curso? I



1. Nota de presentación de cátedra

$$N_{PC} = 0.05C_1 + 0.10C_2 + 0.10C_3 + 0.15C_4 \\ + 0.35CE_1 + 0.25CE_2.$$

Evaluación	Ponderación	Contenido
Control 1	5 %	Diagnóstico
Control 2	10 %	Fundamentos estadísticos
Control 3	10 %	Regularización y <i>Ensemble Learning</i>
Control 4	15 %	Clasificación supervisada y no supervisada
Caso de estudio 1	35 %	Aplicación e integración de contenidos
Caso de estudio 2	25 %	Aplicación e integración de contenidos
Total	100 %	



¿Cómo se aprueba el curso? II



2. Examen ponderado de cátedra

Eximición

Se eximen quienes obtengan una presentación de cátedra **igual o superior a 5,0**:

$$N_{PC} \geq 5.0 \implies$$

$$N_C = N_{PC}.$$

Al rendir el examen

La nota definitiva de cátedra se calcula como:

$$N_C = 0.70N_{PC} + 0.30N_E.$$

- ▶ N_{PC} : presentación de cátedra.
- ▶ N_E : nota del examen.
- ▶ N_C : nota definitiva de cátedra.

3. Nota de laboratorio

$$N_L = 0.30N_D + 0.35N_{Cod1} + 0.35N_{Cod2}.$$

- ▶ N_D : actividades de *DataCamp*.
- ▶ N_{Cod1} : código del caso de estudio 1.
- ▶ N_{Cod2} : código del caso de estudio 2.
- ▶ El laboratorio **no tiene evaluación final**.

4. Aprobación del curso

Se deben aprobar ambos componentes:

$$N_C \geq 4.0 \quad \text{y} \quad N_L \geq 4.0.$$

Si ambos están aprobados:

$$N_F = 0.60N_C + 0.40N_L.$$

Según el Artículo 12: **DE LA NOTA FINAL DE UNA ASIGNATURA**

(<https://usach.cl/reglamento-general-regimen-estudios-pregrado>)

"La nota o calificación final de una asignatura se calculará según se haya informado por escrito a los y las alumnas la primera clase de cada asignatura. Dicha forma de cálculo deberá estar acorde a las normativas de cada Unidad Académica.

Para una asignatura que consta de Teoría y Laboratorio o Práctica Clínica, las calificaciones finales de estas partes se registrarán por separado. La calificación final de estas asignaturas será el promedio aritmético o ponderado, según lo defina la Unidad Académica, siempre y cuando ambas sean superiores a cuatro, de lo contrario, la nota final será igual a la menor de ellas, lo que implica la inmediata reprobación de la asignatura.

El o la alumna tendrá que cursar solamente la parte reprobada en el semestre siguiente en que se dicte la asignatura. Si la reprueba nuevamente, la asignatura será reprobada por segunda vez."

Idea clave

En consecuencia:

- ▶ Si aprueba cátedra y reprueba laboratorio, entonces se guardan las notas de los controles.
- ▶ Si reprueba cátedra y aprueba laboratorio, entonces se guardan las notas de DataCamp.

Estructura pedagógica de cada unidad



Secuencia de aprendizaje

1. Problema industrial.
2. Intuición visual.
3. Formulación matemática.
4. Implementación en R.
5. Interpretación del resultado.
6. Discusión crítica y errores comunes.

Idea clave


El curso no busca “aplicar paquetes”, sino formar criterio para modelar, validar e interpretar evidencia cuantitativa en decisiones industriales.

Actividad: Dinámica recurrente

En cada clase se interpretan gráficos, tablas, outputs de R y decisiones de modelamiento.



Flujo general de modelamiento estadístico



Cómo leer este diagrama

Cada método del curso puede ubicarse en este flujo: parte desde una pregunta industrial, utiliza datos observados, ajusta un modelo, valida sus supuestos o desempeño y finalmente apoya una decisión. El ciclo no termina en la decisión: un modelo en producción debe monitorearse, porque los datos y el proceso que describen cambian con el tiempo (ver la sección de cierre del curso).

Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso

2. Fundamentos estadísticos

- 2.1 Del problema industrial a los datos
- 2.2 Inferencia para tomar decisiones
- 2.3 Comparación de grupo y ANOVA
- 2.4 Variables categóricas y asociación
- 2.5 Asociación continua y regresión lineal
- 2.6 Diagnóstico, selección y evaluación de modelos

3. Regularización, validación cruzada y modelos flexibles


4. Ensemble Learning

5. Clasificación supervisada

6. Clasificación no supervisada

7. Cierre del curso

8. Anexos



Una planta no necesita un valor-p: necesita decidir




Lectura ingenieril


Una planta de bombas centrífugas sufre detenciones no programadas. Cada viernes debe decidir qué equipos inspeccionar durante la semana siguiente, con capacidad limitada a 12 inspecciones.

Idea clave

La pregunta no es “¿qué variable resulta significativa?”, sino “¿qué información permite priorizar equipos antes de que fallen?”.




La historia que construiremos



Idea clave

Hoy construiremos los cuatro primeros eslabones y dejaremos explícito por qué condicionan todos los demás.




Primero: traducir la necesidad en una decisión



Pregunta	Definición para la planta
¿Quién decide?	Jefatura de mantenimiento, cada viernes.
¿Qué acción toma?	Inspeccionar, postergar o detener preventivamente.
¿Sobre qué unidad?	Cada bomba operativa al cierre del viernes.
¿Con qué restricción?	Doce inspecciones y cuatro detenciones por semana.
¿Qué error cuesta más?	No intervenir una bomba que fallará.

Idea clave

Una pregunta estadística útil nace de una decisión, sus restricciones y las consecuencias de equivocarse.



La unidad de análisis define qué significa una fila



Unidad de análisis


Entidad y momento sobre los cuales se observarán variables y se tomará una decisión.

Lectura ingenieril

Una fila será una **bomba-viernes**. Resume únicamente información disponible hasta ese viernes.

Discusión crítica.

Una fila por sensor-segundo respondería otra pregunta; una fila por falla excluiría justamente los períodos sin falla.



Target y horizonte deben existir antes del modelo



Lectura ingenieril

Resultado: falla funcional que detiene producción.


Horizonte: próximos 7 días.

Instante de predicción: viernes, 18:00.

Target: 1 si ocurre la falla dentro del horizonte; 0 en otro caso.

Idea clave

Sin instante y horizonte, no podemos decidir qué información estaba realmente disponible ni evaluar una predicción futura.




Población, muestra y población objetivo no son sinónimos




Objeto	En el caso	Pregunta crítica
Población observada	Bombas de la planta Norte, 2022–2025	¿Qué quedó registrado?
Muestra analítica	Semanas con sensores y órdenes conciliadas	¿Qué filas sobrevivieron?
Población objetivo	Bombas Norte y nueva planta Sur desde 2026	¿Dónde se usará?

Idea clave

Generalizar exige justificar por qué la muestra representa el contexto futuro; aumentar (n) no corrige una representación sesgada.




Los datos son huellas de un proceso industrial



Idea clave

La tabla no es la realidad: es el resultado de decisiones de medición, registro, integración y exclusión.




Una variable necesita significado operacional



Variable	Rol	Definición operacional
vib_rms	Predictora	RMS de vibración en las 24 h previas al corte.
temp_max	Predictora	Máxima temperatura de rodamiento en 24 h.
horas	Exposición	Horas efectivamente operadas en la semana.
mant_7d	Contexto	Intervención registrada durante los 7 días previos.
falla_7d	Resultado	Detención funcional en los 7 días posteriores.

Lectura ingenieril

Nombre, unidad, ventana temporal, fuente y regla de cálculo deben acompañar cada variable.




Errores frecuentes



- ▶ Empezar con las columnas disponibles y recién después inventar la decisión.
- ▶ Mezclar bombas, eventos y semanas como si fueran la misma unidad de análisis.
- ▶ Definir el target sin instante de corte ni horizonte.
- ▶ Confundir la muestra registrada con la población donde operará el modelo.
- ▶ Tratar una variable administrativa como si midiera directamente el fenómeno físico.

Idea clave

Estos errores no se reparan eligiendo un algoritmo más sofisticado.



Variabilidad: señal industrial más fuentes de fluctuación



Pensar en variabilidad


Preguntar qué parte del cambio observado proviene del estado del equipo y qué parte proviene de operación, ambiente, medición o azar.

Lectura ingenieril

La vibración cambia por desgaste, carga, producto procesado, temperatura ambiente y calibración.

Discusión crítica.

Dos mediciones distintas no prueban dos estados distintos; dos mediciones iguales tampoco garantizan el mismo riesgo.



Describir antes de explicar o predecir




- ▶ ¿Qué valores son plausibles?
- ▶ ¿Dónde se concentra la operación?
- ▶ ¿Hay colas, saltos o multimodalidad?
- ▶ ¿La dispersión cambia por régimen?
- ▶ ¿Qué observaciones requieren trazabilidad?

Idea clave

Media y desviación estándar resumen; el gráfico revela estructura. Ninguno reemplaza conocer cómo se produjo el dato.

Lectura ingenieril

Una segunda moda puede corresponder a otro régimen de carga, no a “outliers” que deban eliminarse.



¿Cómo cambia la vibración entre regímenes de carga?



```
library(tidyverse)

bombas |>
  ggplot(aes(vib_rms, fill = regimen)) +
  geom_histogram(bins = 25, alpha = 0.55,
                 position = "identity") +
  facet_wrap(~ regimen, scales = "free_y") +
  labs(x = "Vibración RMS (mm/s)", y = "Semanas")
```

Lectura ingenieril

Interpretación: si la distribución se desplaza con la carga, comparar vibraciones sin considerar el régimen mezcla contextos y puede fabricar falsas alertas.




Errores frecuentes



- ▶ Resumir distribuciones asimétricas solo con la media.
- ▶ Eliminar automáticamente todo valor extremo sin revisar su origen.
- ▶ Confundir variación de medición con cambio físico del equipo.
- ▶ Comparar grupos que operan bajo exposiciones distintas.
- ▶ Interpretar un patrón gráfico como causalidad.

Idea clave

La exploración genera preguntas y controles; todavía no cuantifica evidencia inferencial ni capacidad predictiva.




Datos faltantes: la ausencia también tiene un mecanismo



Patrón	Consecuencia para la decisión
Sensor desconectado al azar	Reduce información y aumenta incertidumbre.
Sensor satura con alta vibración	Oculta precisamente semanas de mayor riesgo.
Equipo detenido no transmite	Ausencia informa sobre el estado operacional.
Planta Sur usa otro sistema	Cambia disponibilidad al trasladar el modelo.

Idea clave

Imputar rellena una celda; no corrige por sí solo el mecanismo que produjo la ausencia.



Sesgo de selección: ¿quién llega a la tabla?




Lectura ingenieril


Si solo analizamos bombas inspeccionadas, sobre-representamos equipos que ya parecían riesgosos. Si exigimos semanas completas, excluimos detenciones y fallas con registros truncados.

Idea clave

La selección puede cambiar una asociación, una estimación y el desempeño futuro, aunque todos los cálculos sean correctos.




Información futura: una fuga que parece desempeño



Idea clave

Una variable es válida solo si existiría, con la misma definición, en el instante real de decidir.




Errores frecuentes



- ▶ Imputar sin estudiar por qué faltan datos.
- ▶ Analizar únicamente casos completos y asumir que siguen siendo representativos.
- ▶ Usar fecha de cierre de una orden creada después de la decisión.
- ▶ Calcular promedios con una ventana que cruza el instante de predicción.
- ▶ Celebrar alta exactitud sin auditar disponibilidad temporal.

Idea clave

La fuga de información produce confianza artificial: el modelo conoce fragmentos del futuro que en producción no tendrá.




Significativo, relevante y predictivo responden preguntas distintas



Juicio	Pregunta	Ejemplo
Evidencia	¿El patrón es compatible con puro azar bajo un supuesto?	Diferencia de vibración entre estados.
Relevancia	¿La magnitud cambia una decisión o costo?	Aumento suficiente para justificar inspección.
Predicción	¿Ayuda a anticipar resultados nuevos?	Reduce fallas omitidas fuera de muestra.

Idea clave

Significativo no implica relevante; relevante no garantiza capacidad predictiva.



El criterio de éxito debe reflejar el costo



Lectura ingenieril


Una falla omitida cuesta horas de producción; una falsa alarma consume inspección; demasiadas alertas exceden capacidad. El éxito exige comparar ambos errores bajo la restricción semanal.

Idea clave

La métrica estadística futura será un sustituto explícito de una consecuencia operacional, no un número elegido por costumbre.

Discusión crítica.

¿Preferiría la planta detectar más fallas si eso duplica inspecciones innecesarias?




Ejercicio 1: auditar la pregunta



Ejercicio 1. De una solicitud vaga a una decisión

La jefatura pide “predecir el estado de las bombas” usando sensores históricos. Sin realizar cálculos:

- ▶ reformule la solicitud indicando unidad de análisis, instante de decisión, horizonte y resultado;
- ▶ identifique un error costoso y una restricción operacional;
- ▶ señale qué información debe prohibirse por no estar disponible a tiempo.




Ejercicio 2: cuestionar una tabla perfecta



Ejercicio 2. Representatividad y calidad

El dataset contiene 40.000 semanas sin valores faltantes, pero excluye bombas dadas de baja y semanas con detenciones. La planta desea usarlo también en una sede nueva.

- ▶ identifique dos mecanismos que pueden sesgar las conclusiones;
- ▶ proponga dos comparaciones gráficas o descriptivas antes de modelar;
- ▶ explique por qué un gran tamaño muestral no resuelve el problema.




¿Por qué esto será importante en Machine Learning?



- ▶ La unidad de análisis se convertirá en la estructura de la matriz de entrenamiento.
- ▶ El instante y horizonte impedirán fuga de información y guiarán la partición temporal.
- ▶ La población objetivo determinará si la validación representa el uso futuro.
- ▶ La variabilidad y la calidad de medición limitarán la señal que cualquier algoritmo puede recuperar.
- ▶ El costo de errores orientará métricas, umbrales y comparación de modelos.

Idea clave

Machine Learning comienza mucho antes de entrenar: comienza al diseñar una pregunta que pueda generalizar.



Cierre de la clase



Qué debe quedar claro

- ▶ La decisión precede al dato.
- ▶ Target y horizonte delimitan el futuro de interés.

Checklist de interpretación

- ▶ Auditar unidad de análisis, disponibilidad temporal y población objetivo.
- ▶ Separar evidencia, relevancia y predicción.

Actividad:

Para preparar la siguiente clase Revisar el diccionario de variables y marcar toda medición cuyo origen, ventana o disponibilidad no esté documentado.

Idea clave

La calidad de la pregunta limita la calidad de cualquier modelo.

La decisión continúa, pero los datos son incompletos




Lectura ingenieril


La planta aplicó una nueva pauta de lubricación a 30 bombas. La vibración promedio disminuyó, pero la jefatura debe decidir si adopta el cambio para toda la flota.

Idea clave

La muestra muestra lo ocurrido en equipos observados; la decisión exige razonar sobre equipos y semanas aún no observados.




Inferir es pasar de lo observado a lo no observado



Idea clave

La inferencia es defendible solo si el diseño permite conectar muestra y población objetivo.



El estimando debe corresponder a la decisión



Estimando


Cantidad de la población que necesitamos conocer para decidir.

Lectura ingenieril

Estimando: cambio promedio en vibración RMS, después menos antes, para bombas comparables durante una semana de operación.

Discusión crítica.

¿Interesa el promedio de mediciones, el promedio por bomba o la proporción de bombas que supera un umbral crítico?



Un estimador es una regla; una estimación es su resultado



Estimador


Regla que transforma una muestra aleatoria en una aproximación del estimando.

Estimación

Valor obtenido al aplicar esa regla a la muestra observada.

Lectura ingenieril

Si el cambio medio observado es $(-0,42)$ mm/s, ese número es una estimación puntual, no una verdad exacta sobre toda la flota.




La incertidumbre nace del muestreo



- ▶ Otra selección de bombas produciría otro promedio.
- ▶ Más variabilidad entre bombas implica estimaciones menos estables.
- ▶ Más información independiente suele reducir el error estándar.
- ▶ Repetir sensores en una misma bomba no equivale a sumar bombas.

Idea clave

El error estándar describe cuánto variaría el estimador entre muestras hipotéticas del mismo diseño.



El intervalo expresa precisión, no certeza absoluta



Intervalo de confianza

Procedimiento que, al repetirse bajo el mismo diseño, produce intervalos que contienen el parámetro con una frecuencia establecida.

Lectura ingenieril

Un IC 95 % de $([-0,61; -0,23])$ mm/s indica una reducción compatible con los datos y el modelo de muestreo.

Idea clave

No significa que exista 95 % de probabilidad de que este parámetro fijo esté dentro del intervalo calculado.




Leer un intervalo para decidir



Lectura	Pregunta para la planta
Dirección	¿Todos los valores plausibles indican reducción?
Magnitud	¿Incluye reducciones operacionalmente pequeñas?
Precisión	¿Es suficientemente estrecho para decidir?
Supuestos	¿Diseño y modelo justifican el intervalo?
Transportabilidad	¿Representa la operación futura?

Idea clave

Un intervalo puede excluir cero y aun incluir efectos demasiado pequeños para justificar el cambio.



¿Cuál es el cambio medio y cuán precisa es la estimación?




```
cambios <- bombas |>
  mutate(cambio = vibracion_despues - vibracion_antes)

t.test(cambios$cambio, mu = 0, conf.level = 0.95)
```

Lectura ingenieril


Interpretación: el resultado debe reportarse como cambio estimado con intervalo de confianza; el valor-p complementa esa lectura, pero no reemplaza la magnitud ni la precisión.



Errores frecuentes



- ▶ Interpretar el error estándar como dispersión de las bombas individuales.
- ▶ Afirmar que el IC contiene 95 % de las observaciones.
- ▶ Confundir intervalo estrecho con ausencia de sesgo.
- ▶ Tratar mediciones repetidas como observaciones independientes.
- ▶ Reportar solo los extremos del intervalo sin unidad ni contexto.



Una prueba organiza una decisión bajo incertidumbre



Hipótesis nula


Modelo de referencia que representa ausencia de cambio o un valor específico del efecto.

Hipótesis alternativa

Conjunto de efectos que contradicen la referencia y responden a la pregunta planteada.

Idea clave

La prueba no demuestra hipótesis: evalúa cuán compatibles son datos y modelo nulo mediante una regla previamente definida.



El valor-p mide compatibilidad condicional



Valor-p


Probabilidad, suponiendo la hipótesis nula y los demás supuestos, de observar un resultado al menos tan extremo como el obtenido.

Lectura ingenieril

Un valor-p pequeño indica tensión entre los datos y el modelo nulo.

Idea clave

No es la probabilidad de que (H_0) sea verdadera, ni la probabilidad de que el resultado se deba al azar.



El umbral controla una conducta de largo plazo




Realidad	No cambiar pauta	Cambiar pauta
Sin beneficio real	Decisión correcta	Error tipo I
Con beneficio real	Error tipo II	Decisión correcta

Lectura ingenieril


El costo de adoptar una pauta inútil y el costo de rechazar una mejora real no tienen por qué ser iguales.

Idea clave

Elegir α es aceptar una tasa de falsas alarmas bajo repetición, no certificar una conclusión individual.




Significancia estadística no mide importancia



Idea clave

Un efecto minúsculo puede ser significativo con muchos datos; un efecto importante puede quedar impreciso con pocos datos.



El tamaño del efecto traduce diferencia a magnitud



Cohen d para cambios pareados


Cambio promedio dividido por la desviación estándar de los cambios; expresa la diferencia en unidades comparables de variabilidad.

Lectura ingenieril

El cambio en mm/s mantiene interpretación física; d ayuda a comparar magnitudes entre estudios o escalas. Ambos deben acompañarse de incertidumbre.

Idea clave

Los rótulos “pequeño”, “mediano” y “grande” no sustituyen un umbral definido por ingeniería.



¿La reducción es grande respecto de la variabilidad?



```
resumen <- cambios |>
  summarise(
    n = n(),
    cambio_medio = mean(cambio),
    d = cambio_medio / sd(cambio)
  )
```

resumen

Lectura ingenieril


Interpretación: d estandariza la magnitud, pero la adopción debe decidirse también con el cambio absoluto, su intervalo y el costo operacional.



Errores frecuentes



- ▶ Interpretar el valor-p como probabilidad de (H_0).
- ▶ Equiparar valor-p pequeño con efecto grande.
- ▶ Cambiar una prueba bilateral a unilateral después de ver los datos.
- ▶ Usar 0,05 como frontera entre verdad y falsedad.
- ▶ Reportar Cohen d sin cambio absoluto ni intervalo.




Los supuestos sostienen la interpretación



Supuesto	Pregunta de auditoría
Diseño pertinente	¿Las bombas representan el uso futuro?
Independencia entre unidades	¿Una bomba aporta información realmente nueva?
Pareo correcto	¿Antes y después corresponden al mismo equipo?
Distribución del cambio	¿Asimetría o extremos dominan el promedio con n pequeño?
Medición estable	¿El sensor conserva escala y calibración?

Idea clave

Una prueba robusta frente a cierta no normalidad no corrige sesgo, dependencia ni mala medición.



Potencia: capacidad de detectar un efecto relevante




Potencia

Probabilidad de rechazar (H_0) cuando existe un efecto específico bajo el diseño supuesto.

- ▶ Aumenta con un efecto mayor y menor variabilidad.
- ▶ Aumenta con más unidades independientes.
- ▶ Depende del umbral y de la prueba planificada.
- ▶ Debe calcularse para el mínimo efecto operacionalmente relevante.

Idea clave

Una prueba no significativa con baja potencia puede ser inconclusa, no evidencia de equivalencia.



Más datos mejoran precisión, no necesariamente validez




Lectura ingenieril

Registrar millones de señales por bomba puede precisar su promedio, pero no crea más bombas independientes ni representa otra planta.

Idea clave

El tamaño efectivo depende de la estructura de dependencia. Un sesgo sistemático puede estimarse con enorme precisión y seguir siendo incorrecto.




De la evidencia a la recomendación



1. Declare el cambio estimado en unidades físicas.
2. Muestre el intervalo y evalúe su precisión.
3. Informe el valor-p como evidencia bajo H_0 , no como veredicto.
4. Compare la magnitud con el mínimo relevante y los costos.
5. Audite supuestos, sesgos y población objetivo.
6. Separe la conclusión inferencial de la utilidad predictiva futura.

Idea clave

Una recomendación defendible integra evidencia, magnitud, incertidumbre y consecuencias.




Ejercicio 1: dos estudios, dos decisiones



Ejercicio 3. Significancia y relevancia

El estudio A estima una reducción de 0,08 mm/s, IC 95 % [0,05; 0,11], $p < 0,001$. El estudio B estima 0,55 mm/s, IC 95 % $[-0,05; 1,15]$, $p = 0,07$. El mínimo relevante es 0,35 mm/s.

- ▶ Interprete evidencia, magnitud e incertidumbre en ambos estudios.
- ▶ Indique qué decisión adicional permitiría reducir la incertidumbre relevante.




Ejercicio 2: cuestionar la evidencia



Ejercicio 4. Diseño e independencia

Un analista usa 10.000 mediciones por segundo de tres bombas y obtiene $p < 0,001$ para el cambio de vibración.

- ▶ Explique por qué 30.000 mediciones no equivalen a 30.000 bombas.
- ▶ Identifique la unidad independiente y la población objetivo.
- ▶ Redacte una conclusión que no exceda la evidencia disponible.




¿Por qué esto será importante en Machine Learning?



- ▶ La variabilidad muestral reaparecerá al comparar métricas entre particiones.
- ▶ Los intervalos inspirarán cuantificación de incertidumbre en desempeño y predicciones.
- ▶ Los errores tipo I y II reaparecerán como falsas alarmas y fallas omitidas.
- ▶ La potencia anticipa cuándo los datos son insuficientes para distinguir modelos.
- ▶ La población objetivo y la independencia condicionarán validación cruzada y generalización.

Idea clave

Un modelo con mejor resultado observado no necesariamente generaliza: la diferencia también está sujeta a incertidumbre.



Una comparación industrial rara vez tiene solo dos opciones




Lectura ingenieril

La planta opera sus bombas en carga baja, media y alta. La jefatura sospecha que el régimen altera la vibración y, por tanto, los umbrales de alerta.

Idea clave

La decisión no es encontrar “el grupo significativo”, sino determinar si las diferencias justifican políticas distintas por régimen.



La pregunta global debe preceder a las parejas




Pregunta ANOVA

¿Son compatibles las medias observadas con una misma media poblacional, considerando la variabilidad dentro de cada grupo?

$$H_0 : \mu_{baja} = \mu_{media} = \mu_{alta}$$

Idea clave

La alternativa afirma que no todas las medias son iguales; no identifica cuáles difieren ni cuánto.



¿Por qué no ejecutar tres pruebas t ?




Lectura ingenieril

Con tres regímenes existen tres parejas; con diez alternativas existen 45. Cada nueva prueba abre otra oportunidad de falsa alarma.

Idea clave

ANOVA realiza primero una prueba global que controla una pregunta común; las comparaciones específicas vienen después y requieren ajuste.




Comparar exige mirar distribución, no solo promedios



- ▶ Centro de cada régimen.
- ▶ Dispersión dentro del régimen.
- ▶ Asimetría y valores extremos.
- ▶ Tamaños muestrales.
- ▶ Solapamiento entre distribuciones.

Lectura ingenieril

Una diferencia de medias puede provenir de un desplazamiento estable o de unas pocas semanas anómalas. Las dos historias conducen a decisiones distintas.



¿Cómo se distribuye la vibración en cada régimen?



```
library(tidyverse)

bombas |>
  ggplot(aes(regimen, vib_rms, fill = regimen)) +
  geom_boxplot(width = 0.55, alpha = 0.65) +
  geom_jitter(width = 0.10, alpha = 0.35) +
  guides(fill = "none") +
  labs(x = "Régimen", y = "Vibración RMS (mm/s)")
```

Lectura ingenieril


Interpretación: el gráfico permite evaluar magnitud, dispersión, solapamiento y observaciones influyentes antes de condensar la comparación en un valor-p.




Errores frecuentes



- ▶ Comparar barras de medias sin mostrar dispersión ni datos.
- ▶ Interpretar cualquier diferencia visual como evidencia concluyente.
- ▶ Ignorar tamaños de grupo muy desiguales.
- ▶ Eliminar extremos únicamente porque cambian el resultado.
- ▶ Realizar todas las pruebas por parejas sin controlar multiplicidad.




ANOVA separa dos fuentes de variación



Idea clave

Las medias deben separarse bastante respecto de la variación interna para producir evidencia contra una media común.



La razón (F) responde una pregunta comparativa



$$F = \frac{\text{variación explicada por diferencias entre grupos}}{\text{variación no explicada dentro de los grupos}}$$

Lectura ingenieril


(F cercano a 1: la separación entre medias es comparable con el ruido interno.

Lectura ingenieril

(F) grande: la separación resulta difícil de atribuir solo a la variación interna bajo (H_0).

Idea clave

El estadístico no expresa directamente unidades físicas ni relevancia operacional.




El diseño determina qué variación es legítima



Pregunta	Riesgo para el caso
¿Quién asignó el régimen?	Bombas distintas pueden operar bajo políticas distintas.
¿Qué unidad es independiente?	Varias semanas de una bomba están correlacionadas.
¿Qué más cambia?	Carga puede confundirse con producto, turno o antigüedad.
¿A quién se generaliza?	La muestra puede omitir bombas críticas o nuevas.

Idea clave

ANOVA compara grupos observados; no transforma una comparación observacional en efecto causal.




Supuestos: preguntas de validez, no rituales



- ▶ **Independencia:** la estructura del muestreo justifica tratar unidades como información separada.
- ▶ **Errores aproximadamente normales:** importa especialmente con muestras pequeñas y extremos.
- ▶ **Varianzas comparables:** el ANOVA clásico agrupa una variabilidad residual común.
- ▶ **Modelo aditivo pertinente:** el factor y la respuesta representan la pregunta industrial.

Idea clave

La independencia depende del diseño; ningún histograma puede demostrarla.



ANOVA significativo abre una pregunta, no la cierra




Conclusión permitida

Existe evidencia de que al menos una media poblacional difiere bajo los supuestos.

Conclusiones no permitidas

Todos los grupos difieren; el régimen causa el cambio; la diferencia es grande; el modelo predecirá bien.



La magnitud global: proporción de variación explicada

 (η^2)

Proporción de la variación total observada atribuida a diferencias entre grupos en la muestra.

$$\eta^2 = \frac{SS_{\text{entre}}}{SS_{\text{total}}}$$

Lectura ingenieril

Si $\eta^2 = 0,18$, el régimen organiza 18 % de la variación observada; el 82 % restante sigue dentro de los regímenes.

Idea clave

(η^2) describe asociación global y tiende a ser optimista como estimación poblacional.



(ω^2) corrige parte del optimismo muestral

 (ω^2)


Estimación de la proporción de variación poblacional explicada, ajustada por grados de libertad y variación residual.

Lectura ingenieril

Reportar (η^2) o (ω^2) responde “¿cuánto organiza el factor la respuesta?”.

Idea clave

Una proporción explicada no informa qué pares difieren ni garantiza utilidad predictiva fuera de muestra.



Post-hoc: localizar diferencias después de la pregunta global



Comparaciones de Tukey

Contrastes entre todas las parejas que controlan el error familiar bajo el modelo ANOVA.

- ▶ Entregan diferencias estimadas entre medias.
- ▶ Incluyen intervalos ajustados por multiplicidad.
- ▶ Permiten identificar qué pares son compatibles con igualdad.
- ▶ Deben leerse en unidades físicas y frente al mínimo relevante.

Idea clave

El ajuste ensancha intervalos porque la familia completa de decisiones debe protegerse, no cada comparación aislada.



¿Qué regímenes difieren y cuál es la magnitud global?




```
modelo <- aov(vib_rms ~ regimen, data = bombas)
summary(modelo)
TukeyHSD(modelo)

anova_tab <- anova(modelo)
eta2 <- anova_tab$'Sum Sq'[1] / sum(anova_tab$'Sum Sq')
eta2
```

Lectura ingenieril


Interpretación: primero se evalúa la diferencia global; luego los intervalos de Tukey ubican pares y (η^2) cuantifican la variación organizada del régimen.



Errores frecuentes



- ▶ Creer que (F) identifica qué grupos difieren.
- ▶ Concluir que todos los pares difieren tras un ANOVA significativo.
- ▶ Omitir post-hoc o aplicar pruebas sin ajuste.
- ▶ Confundir (η^2) con porcentaje de predicciones correctas.
- ▶ Usar etiquetas universales de efecto sin criterio industrial.



Cuando las varianzas difieren: Welch cambia la referencia




Lectura ingenieril

Si el régimen de carga alta muestra mucha más dispersión y los tamaños son desiguales, el ANOVA clásico puede ser poco confiable.

Idea clave

El ANOVA de Welch permite medias y varianzas distintas sin agrupar una varianza común; la elección debe basarse en diseño y distribución, no en buscar significancia.




Kruskal–Wallis no es un ANOVA sin supuestos



Kruskal–Wallis

Prueba basada en rangos que evalúa si las distribuciones de los grupos ocupan posiciones similares bajo condiciones de forma comparables.

- ▶ Puede ser útil frente a extremos o escalas ordinales.
- ▶ No resuelve dependencia ni confusión.
- ▶ No compara automáticamente medianas en cualquier situación.
- ▶ También requiere post-hoc ajustado para localizar diferencias.




La significancia global debe traducirse a una política



Resultado	Decisión posible
Alta difiere y supera umbral físico	Umbral o frecuencia específica para carga alta.
Diferencias pequeñas pero precisas	Mantener política común; monitorear tendencia.
Efecto grande pero impreciso	Ampliar diseño antes de cambiar la política.
Gran variación dentro de grupos	Buscar otras variables que expliquen heterogeneidad.

Idea clave

Una diferencia estadística solo importa si cambia una acción bajo restricciones reales.



Comparar grupos anticipa comparar modelos




Lectura ingenieril

Hoy comparamos medias de vibración bajo una fuente explícita de variación: el régimen.

Idea clave

Más adelante compararemos errores de varios modelos sobre particiones relacionadas. También necesitaremos pregunta global, magnitud, incertidumbre, multiplicidad e independencia.




Ejercicio 1: interpretar sin sobreafirmar



Ejercicio 5. ANOVA y efecto global

Para tres regímenes se obtiene $F = 9,4$, $p < 0,001$, $\eta^2 = 0,07$. Tukey detecta diferencias entre alta y baja, pero no entre media y las otras dos.

- ▶ Redacte una conclusión sobre evidencia, localización y magnitud.
- ▶ Indique qué información operacional falta para cambiar umbrales.




Ejercicio 2: auditar el diseño



Ejercicio 6. Pseudorreplicación

La carga baja se midió en 20 semanas de una bomba; media, en 20 semanas de otra; alta, en 20 semanas de una tercera.

- ▶ Explique por qué régimen y bomba están confundidos.
- ▶ Identifique cuál es la unidad independiente real.
- ▶ Proponga un diseño que permita una comparación defendible.




¿Por qué esto será importante en Machine Learning?



- ▶ Compararemos múltiples modelos sin fabricar ganadores por azar.
- ▶ La variación dentro de grupos anticipa el error irreducible y la heterogeneidad.
- ▶ Los tamaños de efecto complementarán diferencias de métricas.
- ▶ La independencia será central en particiones y validación cruzada.
- ▶ ANOVA reaparecerá como modelo lineal con variables indicadoras y en selección de variables.

Idea clave

El modelo con menor error promedio no es automáticamente mejor: importa cuánto mejora, con qué incertidumbre y bajo qué diseño de evaluación.



Ahora la respuesta es una categoría




Lectura ingenieril

La planta clasifica cada semana como “con falla” o “sin falla” y cada bomba como centrífuga, axial o de desplazamiento positivo.

Idea clave

Cuando ambas variables son categóricas, la pregunta cambia: comparamos distribuciones de frecuencias y probabilidades, no medias.




Categorizar es una decisión de representación



Variable	Categorías	Riesgo de definición
Tipo de bomba	centrífuga, axial, desplazamiento	taxonomías inconsistentes
Falla en 7 días	sí, no	horizonte ambiguo
Criticidad	baja, media, alta	cortes arbitrarios
Turno	día, noche	cambios de calendario

Idea clave

Una categoría comprime información; su definición determina qué patrones puede encontrar el análisis.




La tabla de contingencia organiza la pregunta



Tipo de bomba	Sin falla	Con falla	Total
Centrífuga	420	30	450
Axial	210	30	240
Desplazamiento	165	45	210
Total	795	105	900

Lectura ingenieril

Los conteos describen volumen. Para comparar riesgo entre tipos necesitamos proporciones con el denominador correcto.



El denominador define la interpretación



Proporción por fila


Entre semanas de un tipo de bomba, ¿qué fracción termina en falla?

Proporción por columna


Entre semanas con falla, ¿qué fracción corresponde a cada tipo?

Idea clave

Responder “¿qué tipo tiene mayor riesgo?” exige condicionar por tipo, no mirar qué tipo aporta más fallas absolutas.




Visualizar proporciones evita confundir tamaño y riesgo



Idea clave

La bomba centrífuga aporta muchas observaciones, pero el mayor riesgo condicional aparece en desplazamiento positivo.



¿Cómo cambia la proporción de falla por tipo?



```
library(tidyverse)

bombas |>
  count(tipo, falla_7d) |>
  group_by(tipo) |>
  mutate(proporcion = n / sum(n)) |>
  ggplot(aes(tipo, proporcion, fill = falla_7d)) +
  geom_col(position = "fill")
```

Lectura ingenieril


Interpretación: normalizar dentro de cada tipo permite comparar distribuciones condicionales; las barras de conteos responderían una pregunta diferente.



Errores frecuentes



- ▶ Comparar conteos sin considerar denominadores distintos.
- ▶ Cambiar el orden de condicionamiento y conservar la misma conclusión.
- ▶ Crear categorías después de mirar qué cortes producen significancia.
- ▶ Interpretar una categoría ordinal como distancia numérica uniforme.
- ▶ Ocultar niveles poco frecuentes dentro de “otros” sin justificarlo.



Independencia propone una distribución de referencia




Independencia

Conocer el tipo de bomba no cambia la distribución de falla en la población objetivo.

$$P(\text{falla} \mid \text{tipo}) = P(\text{falla})$$

Lectura ingenieril

Si tipo y falla fueran independientes, cada tipo conservaría aproximadamente la tasa global de falla, 105 de 900 semanas.



Las frecuencias esperadas materializan (H_0)




$$E_{ij} = \frac{(\text{total fila } i)(\text{total columna } j)}{n}$$

Lectura ingenieril

Para centrífugas con falla:
 $450 \times 105/900 = 52,5$ semanas esperadas
bajo independencia.

Idea clave

Comparar 30 observadas con 52,5 esperadas
muestra dirección; aún falta ponderar todas
las celdas y su escala.




Chi-cuadrado agrega discrepancias estandarizadas



$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- ▶ Es cero si observado y esperado coinciden exactamente.
- ▶ Crece cuando las discrepancias son grandes respecto de lo esperado.
- ▶ Resume toda la tabla en una evidencia global.
- ▶ Depende del tamaño muestral y no mide por sí solo importancia.



La prueba global no dice dónde está la asociación



Conclusión permitida


Existe evidencia de asociación entre las variables bajo diseño y supuestos.

Conclusiones no permitidas

El tipo causa fallas; todas las categorías difieren; la asociación es fuerte; predeciremos bien.

Idea clave

Como en ANOVA, una prueba global abre el análisis de magnitud y localización.



Los residuos localizan celdas informativas



Residuo estandarizado

Diferencia entre frecuencia observada y esperada, escalada por su variabilidad bajo independencia.

- ▶ Residuo positivo: más casos de los esperados.
- ▶ Residuo negativo: menos casos de los esperados.
- ▶ Magnitud grande: celda con contribución importante.
- ▶ Muchas celdas inspeccionadas requieren cautela por multiplicidad.

Lectura ingenieril

Las fallas en bombas de desplazamiento pueden estar sobrerrepresentadas, mientras las centrífugas aparecen subrepresentadas.



El tamaño del efecto separa asociación de tamaño muestral



V de Cramer

Medida entre 0 y 1 que estandariza la asociación de una tabla usando χ^2 , n y su dimensión.


$$V = \sqrt{\frac{\chi^2}{n \min(r-1, c-1)}}$$

Lectura ingenieril

En tablas 2×2 , $\phi = \sqrt{\chi^2/n}$. Para tablas mayores, V de Cramer permite una escala comparable.

Idea clave

Una asociación pequeña puede ser muy significativa con miles de semanas y seguir aportando poca separación predictiva.



¿Existe asociación, dónde aparece y cuánto mide?



```
tabla <- table(bombas$tipo, bombas$falla_7d)
prueba <- chisq.test(tabla)
```

```
prueba
prueba$expected
prueba$stdres
```

```
V <- sqrt(unnname(prueba$statistic) /
           (sum(tabla) * min(dim(tabla) - 1)))
V
```

Lectura ingenieril


Interpretación: el valor-p evalúa independencia, los residuos ubican discrepancias y (V) cuantifica magnitud; ninguno establece causalidad.



Errores frecuentes



- ▶ Concluir causalidad a partir de chi-cuadrado.
- ▶ Informar solo el valor-p y omitir (V) de Cramer.
- ▶ Creer que (χ^2) grande implica asociación fuerte.
- ▶ Ignorar residuos y no identificar qué celdas explican el resultado.
- ▶ Examinar residuos como pruebas independientes sin cautela.



En 2×2 , el riesgo relativo habla el idioma de la decisión



Riesgo relativo


Razón entre la probabilidad del evento en un grupo expuesto y la probabilidad en el grupo de referencia.

Lectura ingenieril

Si bombas sin sensor redundante fallan en 12 % de las semanas y las equipadas en 6 %, (RR=2): el riesgo observado es el doble.

Idea clave

El riesgo relativo expresa asociación relativa; debe acompañarse de riesgos absolutos e intervalo de confianza.



Odds ratio no es riesgo relativo




Odds

Cociente entre la probabilidad de que ocurra el evento y la probabilidad de que no ocurra: $(p/(1-p))$.

- ▶ El odds ratio compara odds entre dos grupos.
- ▶ Se aproxima al riesgo relativo cuando el evento es raro.
- ▶ Puede parecer mucho mayor cuando el evento es frecuente.
- ▶ Será la escala natural de la regresión logística.

Idea clave

Traducir odds a probabilidades evita recomendaciones exageradas.



Celdas escasas cambian la herramienta




Lectura ingenieril

Un tipo nuevo de bomba acumula solo dos fallas. La aproximación chi-cuadrado puede ser inadecuada si varias frecuencias esperadas son pequeñas.

Idea clave

En tablas 2×2 pequeñas, la prueba exacta de Fisher evalúa asociación sin depender de la aproximación asintótica. Agrupar categorías requiere sentido sustantivo, no conveniencia estadística.




La independencia de observaciones sigue siendo central



Problema	Consecuencia
Muchas semanas por bomba	Conteos correlacionados; n efectivo menor.
Fallas repetidas de un mismo equipo	Una bomba puede dominar la asociación.
Registro selectivo	La tabla no representa la flota objetivo.
Cambios de clasificación	Categorías no comparables en el tiempo.

Idea clave

La prueba exacta corrige celdas pequeñas, no dependencia, sesgo ni definiciones defectuosas.



Una tercera variable puede fabricar o esconder asociación




Lectura ingenieril

Las bombas de desplazamiento operan principalmente con fluidos abrasivos. La mayor falla podría reflejar el fluido, el tipo de bomba o ambos.

Idea clave

Comparar tablas estratificadas puede revelar confusión o interacción. Una asociación marginal no describe necesariamente cada contexto operacional.



Asociación no equivale a clasificación útil




Lectura ingenieril

Conocer el tipo puede cambiar la probabilidad de falla, pero dentro de cada tipo la mayoría de las semanas aún termina sin falla.

Idea clave

Una variable puede estar asociada con el target y aportar poca capacidad para separar casos individuales. La predicción exige evaluar errores fuera de muestra.




Ejercicio 1: elegir el denominador



Ejercicio 7. Conteos versus riesgo

La planta A registra 80 fallas entre 1.000 semanas; la planta B, 50 entre 300 semanas.
Sin realizar pruebas largas:

- ▶ explique qué planta aporta más fallas y cuál presenta mayor riesgo;
- ▶ indique qué gráfico construiría;
- ▶ identifique una variable que podría confundir la comparación.




Ejercicio 2: evidencia, efecto y predicción



Ejercicio 8. Interpretación integral

Una tabla 4×2 produce $p < 0,001$ y $V = 0,08$ con 20.000 semanas.

- ▶ interprete por separado evidencia y magnitud;
- ▶ explique por qué no puede concluir causalidad;
- ▶ discuta si el tipo de bomba bastaría como clasificador de fallas.




¿Por qué esto será importante en Machine Learning?



- ▶ Las categorías se transformarán en variables indicadoras para los modelos.
- ▶ La tabla de contingencia anticipa la matriz de confusión en clasificación.
- ▶ Riesgo, odds y probabilidades reaparecerán en regresión logística.
- ▶ Las categorías raras exigirán decisiones de agrupación y regularización.
- ▶ Asociación no garantiza capacidad predictiva ni generalización.

Idea clave

Clasificar requiere algo más que detectar asociación: requiere separar casos futuros con costos de error explícitos.



Pasamos de grupos a variables continuas




Lectura ingenieril

La planta observa que bombas con mayor vibración suelen consumir más energía. Quiere cuantificar la relación y anticipar el consumo semanal.

Idea clave

Asociación pregunta si dos variables cambian juntas; predicción pregunta cuánto error tendremos al anticipar una observación nueva.




El diagrama de dispersión viene antes del coeficiente



- ▶ ¿La relación parece lineal o curva?
- ▶ ¿Su intensidad cambia con el nivel de vibración?
- ▶ ¿Existen grupos operacionales superpuestos?
- ▶ ¿Hay observaciones extremas o influyentes?
- ▶ ¿El rango observado cubre el uso futuro?

Idea clave

Un único número puede ocultar curvatura, agrupamiento y cambios de variabilidad que sí modifican la decisión.



¿Qué forma tiene la relación entre vibración y consumo?



```
library(tidyverse)

bombas |>
  ggplot(aes(vib_rms, consumo_kwh, colour = regimen)) +
  geom_point(alpha = 0.55) +
  geom_smooth(method = "lm", se = TRUE) +
  labs(x = "Vibración RMS (mm/s)",
       y = "Consumo semanal (kWh)")
```

Lectura ingenieril

Interpretación: la nube permite evaluar forma, dispersión y grupos. La recta resume una tendencia lineal; no prueba que vibración cause consumo.




Covarianza: dirección conjunta con escala



Covarianza

Promedio de los productos de las desviaciones de dos variables respecto de sus medias.

- ▶ Positiva: valores altos tienden a coincidir con valores altos.
- ▶ Negativa: valores altos tienden a coincidir con valores bajos.
- ▶ Cercana a cero: poca asociación lineal, aunque puede existir asociación no lineal.
- ▶ Su magnitud depende de las unidades de ambas variables.



Correlación estandariza la asociación lineal



Correlación de Pearson


r es la covarianza dividida por las desviaciones estándar; toma valores entre -1 y 1 .

Lectura ingenieril



El signo indica dirección y $|r|$ resume cuán estrechamente se alinea la nube con una recta.

Idea clave

r no mide pendiente, causalidad, acuerdo ni capacidad predictiva completa.




La misma correlación puede esconder historias distintas



Idea clave


Correlación baja no significa ausencia de estructura; significa poca estructura lineal global.



Errores frecuentes



- ▶ Asumir causalidad a partir de correlación.
- ▶ Interpretar $r = 0$ como independencia.
- ▶ Comparar correlaciones sin mirar rangos ni subgrupos.
- ▶ Ignorar relaciones no lineales.
- ▶ Permitir que una observación extrema determine el coeficiente.




La regresión convierte asociación en una regla de predicción



$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

Elemento	Interpretación industrial
Y_i	consumo semanal de la bomba i
X_i	vibración RMS observada antes de predecir
β_0	consumo medio esperado cuando $X = 0$
β_1	cambio medio esperado en consumo por unidad de vibración
ε_i	variación no explicada por la recta



Mínimos cuadrados define qué significa ajustar




$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

Lectura ingenieril

El ajuste elige la recta que minimiza la suma de residuos cuadrados en la muestra. Los errores grandes reciben una penalización especialmente alta.

Idea clave

Optimizar el ajuste observado no garantiza minimizar el error sobre bombas futuras.



La pendiente debe conservar contexto y unidades



Lectura ingenieril

Si $\hat{\beta}_1 = 18,4$, un aumento de 1 mm/s en vibración se asocia con 18,4 kWh adicionales de consumo semanal promedio, dentro del rango observado.

Discusión crítica.

La frase debe incluir unidad, dirección, magnitud, población y condición “en promedio”.
¿Es 1 mm/s un cambio operacionalmente grande?

Idea clave

Una pendiente estadísticamente distinta de cero puede representar un cambio irrelevante para energía o mantenimiento.



El intercepto puede ser matemático pero no sustantivo




Lectura ingenieril

Si ninguna bomba opera cerca de vibración cero, $\hat{\beta}_0$ es necesario para posicionar la recta, pero carece de interpretación operacional directa.

Idea clave

Centrar X en un valor relevante, como la vibración media o un umbral nominal, hace que el intercepto responda una pregunta interpretable.




El intervalo de la pendiente cuantifica incertidumbre inferencial



- ▶ El estimador cambia entre muestras de bombas.
- ▶ El error estándar depende de ruido, tamaño y dispersión de X .
- ▶ El intervalo muestra pendientes compatibles con datos y supuestos.
- ▶ El valor-p contrasta una pendiente poblacional de referencia, usualmente cero.

Idea clave

Reportar $\hat{\beta}_1$, su intervalo y unidades informa más que reportar únicamente significancia.



El coeficiente R^2 describe ajuste muestral

 R^2


Proporción de la variación observada de Y que la recta explica respecto de predecir siempre la media.

Lectura ingenieril

$R^2 = 0,36$ indica que la vibración organiza 36 % de la variación observada del consumo.

Idea clave

R^2 alto no implica causalidad, buen diagnóstico ni generalización; R^2 bajo no invalida una pendiente útil.



¿Qué estima la recta y qué incertidumbre reporta?




```
modelo <- lm(consumo_kwh ~ vib_rms, data = bombas)
summary(modelo)
confint(modelo)

nuevas <- tibble(vib_rms = c(2.5, 4.0, 5.5))
predict(modelo, nuevas, interval = "prediction")
```

Lectura ingenieril

Interpretación: coeficientes e intervalos describen la relación media; el intervalo de predicción es más ancho porque incorpora variación de una bomba nueva.



Intervalo medio e intervalo predictivo responden preguntas distintas



Intervalo de confianza


¿Dónde está el consumo promedio de muchas bombas con la misma vibración?

Intervalo de predicción

¿Dónde podría caer el consumo de una bomba individual nueva?

Idea clave


La decisión sobre una bomba individual necesita incertidumbre predictiva, generalmente mucho mayor que la incertidumbre de la media.



Errores frecuentes



- ▶ Interpretar R^2 como porcentaje de predicciones correctas.
- ▶ Extrapolar fuera del rango observado.
- ▶ Interpretar el intercepto en un valor imposible de X .
- ▶ Confundir intervalo de confianza con intervalo de predicción.
- ▶ Creer que mayor R^2 garantiza mejor generalización.




Los residuos auditan lo que la recta dejó atrás



$$e_i = y_i - \hat{y}_i$$

Patrón residual	Señal de alerta
Curvatura	relación media mal especificada
Abanico	variabilidad no constante
Bloques por bomba	dependencia no modelada
Puntos aislados	observaciones extremas o influyentes
Tendencia temporal	cambio de proceso o autocorrelación



Linealidad y homocedasticidad tienen funciones distintas



Linealidad


La media condicional de Y cambia aproximadamente como una recta con X .

Varianza constante

La dispersión alrededor de la media es similar a lo largo de X .

Idea clave

Una recta puede estimar una tendencia media útil y aun producir intervalos incorrectos si la variabilidad cambia.




Una observación puede ser extrema o influyente



- ▶ Un residuo grande indica respuesta inusual dada su predicción.
- ▶ Un valor de X alejado posee alto leverage.
- ▶ Una observación influyente cambia sustancialmente el ajuste.
- ▶ Investigar origen y contexto precede a eliminar.

Lectura ingenieril

Una bomba prototipo puede ser válida, pero no representar la flota; excluirla cambia la población sobre la que hablamos.



Confusión: una pendiente puede mezclar mecanismos




Lectura ingenieril

La carga eleva simultáneamente vibración y consumo. Una regresión simple puede atribuir a vibración una relación generada parcialmente por el régimen.

Idea clave

Agregar variables puede ajustar comparaciones, pero la interpretación causal sigue dependiendo del diseño y de supuestos no verificables solo con datos.



Regresión múltiple interpreta “manteniendo constante”




$$E(Y | X) = \beta_0 + \beta_1 \text{vibración} + \beta_2 \text{temperatura} + \beta_3 \text{carga}$$

Lectura ingenieril

β_1 compara bombas con igual temperatura y carga, pero distinta vibración, dentro del soporte observado.

Idea clave

“Mantener constante” puede describir comparaciones inexistentes si los predictores están fuertemente ligados.



Multicolinealidad vuelve inestables los efectos individuales




Lectura ingenieril

Temperatura y carga pueden moverse casi juntas. El modelo logra predecir consumo, pero tiene dificultad para separar cuál coeficiente recibe el efecto.

Idea clave

Predicción conjunta razonable puede coexistir con coeficientes imprecisos y sensibles. Regularización retomará este problema en la clase 0.6.




Ejercicio 1: correlación sin causalidad



Ejercicio 9. Lectura crítica

Se observa $r = 0,72$ entre vibración y consumo. Al separar por régimen, las tres correlaciones son cercanas a cero.

- ▶ proponga una explicación para el cambio;
- ▶ indique qué gráfico construiría;
- ▶ redacte una conclusión que no afirme causalidad.




Ejercicio 2: inferencia versus predicción



Ejercicio 10. Interpretar un modelo

Una pendiente es 18,4 kWh por mm/s, IC 95 % [15,1; 21,7], $p < 0,001$, $R^2 = 0,31$. Para una bomba nueva, el intervalo predictivo abarca 180 kWh.

- ▶ interprete efecto, evidencia y ajuste;
- ▶ explique por qué la predicción individual sigue siendo incierta;
- ▶ indique si recomendaría usar solo vibración para planificar energía.




¿Por qué esto será importante en Machine Learning?



- ▶ La función de pérdida cuadrática reaparecerá en numerosos algoritmos.
- ▶ Los residuos se convertirán en errores de entrenamiento y validación.
- ▶ La multicolinealidad motivará Ridge y LASSO.
- ▶ La curvatura motivará transformaciones, polinomios y splines.
- ▶ La separación entre ajuste y predicción exigirá validación cruzada.

Idea clave

Un modelo interpretable y significativo todavía debe demostrar desempeño sobre datos que no participaron en su ajuste.



Un buen ajuste no es todavía un buen modelo




Lectura ingenieril

La planta dispone de vibración, temperatura, carga, antigüedad, tipo de bomba y mantenimiento. Varios modelos explican bien el historial, pero recomiendan inspecciones distintas.

Idea clave

Seleccionar un modelo exige separar tres preguntas: ¿representa el proceso?, ¿predice datos nuevos? y ¿mejora la decisión operacional?




Diagnóstico y evaluación cumplen funciones distintas



Tarea	Pregunta	Evidencia
Diagnóstico	¿Cómo falla el modelo?	residuos, influencia, estructura
Selección	¿Qué complejidad conviene?	validación comparable
Evaluación	¿Cuánto error futuro esperar?	datos no usados en decisiones
Decisión	¿Es operacionalmente útil?	costos, capacidad, riesgo

Idea clave

No existe una única cifra que responda adecuación, generalización y utilidad.




Los residuos deben revelar lo que el modelo omite




- ▶ Curvatura: falta estructura no lineal.
- ▶ Abanico: la incertidumbre cambia con el nivel predicho.
- ▶ Bloques temporales: existe dependencia o cambio de proceso.
- ▶ Grupos separados: falta una variable o interacción.
- ▶ Observaciones influyentes: pocas filas gobiernan el ajuste.

Idea clave

Un patrón residual es información pendiente, no ruido que deba ocultarse.




Complejidad: flexibilidad con un costo



Menor sesgo aparente Mayor sensibilidad muestral

Idea clave

Agregar términos nunca aumenta el error de entrenamiento de mínimos cuadrados, pero puede empeorar el error futuro.



Sesgo y varianza describen dos modos de fallar



Sesgo


Error sistemático por una representación demasiado rígida del patrón.

Varianza

Sensibilidad de la regla aprendida a cambios en la muestra de entrenamiento.

Lectura ingenieril

Una recta puede omitir curvatura; un polinomio extremo puede cambiar radicalmente al reemplazar unas pocas semanas.



El sobreajuste imita detalles que no se repiten




Lectura ingenieril

Un modelo con muchas variables e interacciones alcanza $R^2 = 0,96$ en el historial, pero sus coeficientes cambian entre años y falla en la planta Sur.

Idea clave


Sobreajuste es una brecha entre aprender estructura reproducible y memorizar particularidades de la muestra.



Errores frecuentes



- ▶ Elegir el modelo con mayor R^2 de entrenamiento.
- ▶ Agregar variables mientras disminuya el valor-p global.
- ▶ Eliminar observaciones hasta limpiar los residuos.
- ▶ Confundir flexibilidad con capacidad de generalización.
- ▶ Diagnosticar y evaluar sobre los mismos datos sin reconocer optimismo.




Tres particiones, tres responsabilidades



Partición	Uso	Regla
Entrenamiento	estimar parámetros	puede participar en el ajuste
Validación	elegir modelo y configuración	puede guiar decisiones de diseño
Prueba	estimar desempeño final	se consulta una sola vez al final

Idea clave

Un conjunto deja de ser prueba cuando sus resultados influyen en la construcción del modelo.




El tiempo impone el orden de la evaluación



tiempo

Lectura ingenieril

Predecir semanas futuras exige entrenar con pasado. Una partición aleatoria puede filtrar regímenes, mantenimiento y condiciones futuras hacia el entrenamiento.



Grupos repetidos también condicionan la partición




Lectura ingenieril

Si semanas de la misma bomba aparecen en entrenamiento y prueba, el modelo puede reconocer características del equipo en vez de generalizar a bombas nuevas.

Idea clave

La unidad de partición debe representar la novedad real: semana futura, bomba nueva, planta nueva o alguna combinación.




La métrica debe representar el costo del error



Métrica	Qué enfatiza	Pregunta operacional
MAE	error absoluto típico	¿cuántos kWh erramos en promedio?
RMSE	penaliza errores grandes	¿son críticas las desviaciones extremas?
R^2 de prueba	mejora frente a la media	¿superamos un baseline constante?
Costo	consecuencias asimétricas	¿qué error daña más la operación?

Idea clave

La mejor métrica no es la más conocida: es la que ordena modelos como ordenaría consecuencias la organización.



Todo modelo debe superar un baseline




Baseline

Regla sencilla y reproducible que representa el nivel mínimo de desempeño útil.

- ▶ Predecir el consumo medio histórico.
- ▶ Usar el consumo de la semana anterior.
- ▶ Aplicar el promedio específico por régimen.
- ▶ Mantener la política actual de inspección.

Idea clave

Una técnica sofisticada que no supera una regla simple añade complejidad sin evidencia de valor.




Una partición de validación permite comparar candidatos



1. Reservar un período posterior como validación.
2. Ajustar todos los candidatos usando el mismo entrenamiento.
3. Evaluarlos con la misma métrica y las mismas observaciones.
4. Comparar contra un baseline previamente definido.
5. Congelar la decisión antes de abrir el conjunto de prueba.

Idea clave

La validación simple aporta una primera estimación honesta del desempeño; su conclusión sigue dependiendo del período elegido.



¿El modelo supera el baseline en validación?



```
rmse <- function(y, pred) sqrt(mean((y - pred)^2))

corte <- as.Date("2025-01-01")
train <- filter(bombas, fecha_corte < corte)
valid <- filter(bombas, fecha_corte >= corte)

ajuste <- lm(consumo_kwh ~ vib_rms + temp_max + horas,
             data = train)
rmse(valid$consumo_kwh, predict(ajuste, valid))
rmse(valid$consumo_kwh, mean(train$consumo_kwh))
```


Lectura ingenieril

Interpretación: ambos errores se calculan sobre el mismo futuro reservado; la mejora debe ser suficientemente grande para justificar complejidad y costo.

Errores frecuentes



- ▶ Preprocesar todos los datos antes de dividir.
- ▶ Elegir el modelo usando el conjunto de prueba.
- ▶ Mezclar futuro y pasado en una división aleatoria.
- ▶ Separar filas cuando la novedad real son bombas completas.
- ▶ Reportar solo el error del modelo sin baseline ni análisis por período.




Preprocesar también es aprender de los datos



- ▶ Imputar medianas estima valores desde entrenamiento.
- ▶ Estandarizar estima medias y desviaciones.
- ▶ Agrupar categorías aprende qué niveles son raros.
- ▶ Seleccionar variables utiliza información del target.
- ▶ Elegir transformaciones responde a patrones observados.

Idea clave

Cada operación aprendida debe estimarse solo con entrenamiento y aplicarse después a validación y prueba; de lo contrario aparece fuga.



Seleccionar por valores-p responde una pregunta limitada




Lectura ingenieril

Eliminar predictores con $p > 0,05$ busca coeficientes individualmente distinguibles de cero bajo un modelo, no necesariamente menor error futuro.

Idea clave

Una variable puede estabilizar predicciones sin ser significativa individualmente; otra puede ser significativa y no mejorar generalización.




AIC y BIC equilibran ajuste y complejidad



- ▶ Ambos penalizan modelos que usan más parámetros.
- ▶ AIC orienta comparación relativa bajo supuestos y misma respuesta.
- ▶ BIC aplica una penalización que crece más con n .
- ▶ No reemplazan diagnóstico, validación externa ni costo operacional.

Idea clave

Un criterio de información selecciona dentro de una familia candidata; no certifica que la familia represente el proceso.



La multicolinealidad exige una decisión de representación




Lectura ingenieril

Temperatura, carga y vibración pueden transportar información muy similar. Incluirlas juntas puede inflar errores estándar y volver sensibles los coeficientes.

Idea clave

Antes de eliminar variables, debemos distinguir el objetivo: interpretar mecanismos, controlar confusión o predecir con información disponible.




Parsimonia no significa selección automática



- ▶ Conservar variables justificadas por la pregunta y el diseño.
- ▶ Evitar duplicar mediciones sin aporte conceptual o predictivo.
- ▶ Comparar candidatos con una validación común y un baseline.
- ▶ Revisar estabilidad de coeficientes y errores por subgrupos.
- ▶ Documentar toda exclusión antes de evaluar en test.

Idea clave

Un modelo más pequeño es preferible cuando conserva utilidad y reduce fragilidad, costo o ambigüedad.



Splines permiten curvatura controlada




Spline

Función suave construida con segmentos polinómicos unidos en puntos llamados nudos.

- ▶ Representa relaciones no lineales sin un polinomio global extremo.
- ▶ Su flexibilidad depende de nudos o grados de libertad.
- ▶ Mayor flexibilidad reduce sesgo y puede aumentar varianza.
- ▶ La complejidad debe elegirse con validación y diagnóstico.

Idea clave

Modelar curvatura no autoriza extrapolar más allá del soporte observado.



Los modelos lineales generalizados amplían la respuesta



Regresión logística


Modela el log-odds de falla como combinación lineal de predictores y entrega probabilidades entre 0 y 1.

Regresión de Poisson

Modela conteos mediante una media positiva y puede incorporar exposición operacional.

Idea clave

La estructura lineal permanece en una escala transformada; distribución y función de enlace deben corresponder a la respuesta.



¿Qué relaciones entre predictores debemos auditar?




```
predictoras <- bombas |>
  select(vib_rms, temp_max, horas, antiguedad_anios)

cor(predictoras, use = "complete.obs")
pairs(predictoras)
```

Lectura ingenieril


Interpretación: correlaciones altas alertan sobre información redundante y coeficientes sensibles; no deciden automáticamente qué variable eliminar.



Errores frecuentes




- ▶ Eliminar una variable solo porque su valor-p supera 0,05.
- ▶ Confundir correlación entre predictores con causalidad.
- ▶ Seleccionar variables usando validación o prueba y luego reutilizarlas para evaluar.
- ▶ Preferir el modelo más grande porque ajusta mejor el entrenamiento.
- ▶ Ignorar el costo de medir variables en producción.



El test final estima el procedimiento completo



1. Congelar variables, transformaciones, métrica y configuración.
2. Reentrenar el procedimiento elegido usando los datos permitidos.
3. Predecir el conjunto de prueba una sola vez.
4. Reportar métrica, incertidumbre y comparación con baseline.
5. Analizar errores por régimen, bomba, tiempo y criticidad.
6. Traducir desempeño a capacidad y costo operacional.



El promedio puede ocultar fallas críticas




Lectura ingenieril

Dos modelos tienen RMSE similar. Uno falla especialmente en bombas críticas; el otro distribuye errores de forma más homogénea.

Idea clave

Evaluar subgrupos no es buscar el mejor resultado: es auditar dónde la política puede fallar y quién absorbe el costo.




De un modelo a una decisión desplegable



Evidencia			Pregunta de aprobación
Desempeño	fuera	de	¿supera baseline con magnitud útil?
muestra			
Estabilidad			¿cambia mucho entre períodos o bombas?
Diagnóstico			¿quedan patrones de error previsibles?
Operación			¿cabe en capacidad y reduce costo total?
Monitoreo			¿cómo detectaremos degradación futura?

Idea clave

Desplegar no termina la inferencia: inicia una nueva etapa de observación, comparación y actualización.




Ejercicio 1: seleccionar sin tocar el test



Ejercicio 11. Tres modelos candidatos

Una recta simple, una regresión múltiple y un spline logran RMSE de validación 42, 36 y 35 kWh. En el período más reciente sus errores son 44, 37 y 49 kWh, respectivamente.

- ▶ compare desempeño global y comportamiento en el período reciente;
- ▶ identifique qué información operacional falta;
- ▶ proponga una regla de selección antes de abrir el test.




Ejercicio 2: detectar fuga



Ejercicio 12. Auditoría del pipeline

Un equipo imputa faltantes, estandariza y selecciona 12 variables con todo el dataset; después crea conjuntos de entrenamiento, validación y prueba.

- ▶ identifique dónde ocurre la fuga;
- ▶ reorganice conceptualmente el procedimiento;
- ▶ explique cómo la fuga altera el error estimado.




¿Por qué esto será importante en Machine Learning?



- ▶ La unidad siguiente introducirá métodos de selección y estabilización.
- ▶ Modelos flexibles profundizarán el tratamiento de no linealidad.
- ▶ Los GLM conectarán regresión con clasificación y conteos.
- ▶ Nuevos protocolos ampliarán la evaluación de configuraciones.
- ▶ Pipelines formalizarán la prevención de fuga durante el preprocesamiento.
- ▶ El test y monitoreo convertirán ajuste en evidencia de generalización.

Idea clave

La Unidad 3 termina donde comienza Machine Learning: construir procedimientos que aprendan de datos y rindan cuentas ante datos futuros.




Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Fundamentos estadísticos
3. Regularización, validación cruzada y modelos flexibles
 - 3.1 Validación y sobreajuste
 - 3.2 Regularización
 - 3.3 No linealidad: splines y GAM
4. Ensemble Learning
5. Clasificación supervisada
6. Clasificación no supervisada
7. Cierre del curso
8. Anexos




Objetivos de aprendizaje



Al final de la clase, el estudiante debería poder

1. Explicar el compromiso sesgo–varianza.
2. Implementar validación cruzada para seleccionar hiperparámetros.
3. Comparar ridge, lasso y elastic-net.
4. Reconocer no linealidad y usar splines/GAM.
5. Entender árboles y ensambles como modelos predictivos flexibles.
6. Interpretar curvas de error, importancia de variables y riesgo de leakage.




Motivación: demasiadas variables, demasiada flexibilidad



En planificación industrial solemos tener:

- ▶ múltiples indicadores de demanda;
- ▶ variables correlacionadas de producción;
- ▶ promociones, calendario y eventos;
- ▶ sensores de mantenimiento;
- ▶ indicadores financieros y operacionales.



Lectura ingenieril

Más variables no siempre significa mejor modelo. Puede aumentar la varianza y degradar la predicción futura.






Procedimiento

1. Dividir entrenamiento en K folds.
2. Ajustar el modelo con $K - 1$ folds.
3. Evaluar en el fold restante.
4. Repetir hasta usar todos los folds como validación.
5. Seleccionar hiperparámetros por error promedio.

Idea clave

El conjunto de test debe permanecer intocable hasta la evaluación final. Usarlo para elegir hiperparámetros produce leakage.



Validación cruzada y selección de hiperparámetros





Diagrama: compromiso sesgo-varianza



Actividad: Lectura del gráfico


Explique por qué el error de entrenamiento disminuye con la complejidad, pero el error de prueba puede volver a aumentar. Identifique en el gráfico la zona de complejidad óptima marcada.

R: validación cruzada con tidymodels



¿Por qué normalizamos dentro del recipe y no antes de separar train/test?

```
library(tidymodels)
set.seed(123)
split <- initial_split(mtcars, prop = 0.8)
train <- training(split)
test <- testing(split)
folds <- vfold_cv(train, v = 5)
rec <- recipe(mpg ~ ., data = train) %>%
  step_normalize(all_predictors())
```




Ridge: reducir varianza



Problema penalizado

$$\hat{\beta}^{ridge} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

- ▶ Contrae coeficientes hacia cero.
- ▶ No suele hacerlos exactamente cero.
- ▶ Útil con variables correlacionadas.
- ▶ Requiere estandarización.



Lasso: regularizar y seleccionar



Problema penalizado

$$\hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \frac{1}{2} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

Lectura ingenieril

Cuando muchas variables candidatas compiten, lasso puede producir un modelo más interpretable al dejar coeficientes en cero.

Discusión crítica. Cuidado

Con variables muy correlacionadas, lasso puede elegir una y descartar otra casi equivalente, lo que dificulta la interpretación causal.

Elastic-net: combinar ambos mundos




$$\hat{\beta}^{EN} = \arg \min_{\beta} \left\{ RSS(\beta) + \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^p \beta_j^2 \right] \right\}.$$

α cercano a 1

Comportamiento más parecido a lasso: mayor selección y más coeficientes exactamente cero.

α cercano a 0

Comportamiento más parecido a ridge: mayor contracción conjunta y estabilidad con predictores correlacionados.



¿Qué cambia realmente con la regularización?



Ridge, lasso y elastic-net

La regularización modifica principalmente:


- ▶ el tamaño de los coeficientes;
- ▶ la cantidad de variables activas;
- ▶ la estabilidad del modelo;
- ▶ el error fuera de muestra.

Importante


Si los predictores originales entran linealmente, los tres métodos siguen produciendo una superficie lineal.

Idea clave


La regularización controla la complejidad de los coeficientes; la forma funcional depende también de las variables o bases que ingresan al modelo.




Trayectorias de coeficientes: ridge, lasso y elastic-net



Todos se contraen, pero normalmente no llegan exactamente a cero.



Algunos coeficientes llegan exactamente a cero.



Combina contracción y selección, con mayor estabilidad entre variables correlacionadas.

Idea clave


La trayectoria muestra cómo cambia cada coeficiente al aumentar la penalización. No muestra directamente el error predictivo.

R: glmnet para ridge/lasso/elastic-net



Compare 'lambda.min' con 'lambda.1se'. ¿Cuál elegiría para un informe ejecutivo y por qué?

```
library(glmnet)
X <- model.matrix(mpg ~ . - 1, data = mtcars)
y <- mtcars$mpg
cv_lasso <- cv.glmnet(X, y, alpha = 1)
cv_ridge <- cv.glmnet(X, y, alpha = 0)
cv_enet <- cv.glmnet(X, y, alpha = 0.5)
plot(cv_lasso)
coef(cv_lasso, s = "lambda.1se")
```



Regularizar una curva: bases polinomiales




Modelo utilizado

En lugar de ajustar solamente $Y = \beta_0 + \beta_1 X$, utilizamos:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \beta_{10} X^{10} + \varepsilon.$$

La penalización controla cuánto pueden contribuir los términos de orden alto.




Ejercicio interpretativo: curva de validación



Ejercicio 1. Seleccionar complejidad

Un modelo lasso tiene error mínimo en $\lambda = 0.03$, pero la regla 1-SE sugiere $\lambda = 0.10$.


1. ¿Cuál modelo será más simple?
2. ¿Qué modelo probablemente tendrá más coeficientes en cero?
3. Si ambos predicen casi igual, ¿cuál recomendaría para gestión industrial?
4. ¿Qué riesgo existe si solo se reporta el error mínimo?



Cuando la relación no es lineal




- ▶ La productividad puede saturarse.
- ▶ Los descuentos no impactan linealmente la demanda.
- ▶ La temperatura puede tener un rango óptimo.
- ▶ La edad de maquinaria puede afectar fallas de forma acelerada.



Idea clave

Un modelo lineal en parámetros puede representar relaciones no lineales usando transformaciones o funciones base.



Splines: flexibilidad local controlada




Idea

Dividir el dominio en regiones y ajustar polinomios unidos suavemente en nodos.


$$f(x) = \beta_0 + \beta_1 x + \beta_2 (x - \xi_1)_+ + \beta_3 (x - \xi_2)_+.$$

Lectura ingenieril

En demanda, un spline permite que el efecto del precio cambie por tramos: descuentos pequeños pueden no mover demanda, pero descuentos grandes sí.



Regresión lineal versus spline



Modelo lineal


- ▶ Una pendiente global.
- ▶ Fácil de interpretar.
- ▶ Puede subajustar.

Spline

- ▶ Pendiente local variable.
- ▶ Captura saturación y puntos óptimos.
- ▶ Su flexibilidad se controla mediante nodos o penalización.

Idea clave

Una planta puede aumentar su productividad con la temperatura hasta un rango óptimo y luego deteriorarse. Una recta no representa este comportamiento.



GAM: modelo aditivo generalizado




$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_p(X_p) + \varepsilon.$$

Ventaja

Permite interpretar efectos no lineales variable por variable.

Discusión crítica. Limitación

La aditividad puede ser restrictiva si existen interacciones fuertes, por ejemplo temperatura y humedad en defectos de calidad.



¿Qué modela $s()$ en un GAM? I



Idea principal

En un modelo lineal clásico asumimos:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

es decir:

- ▶ el efecto marginal de X sobre Y es constante;
- ▶ la relación es lineal.

En un GAM reemplazamos la relación lineal por una función suave:

$$Y = \beta_0 + s(X) + \varepsilon$$

donde:

- ▶ $s(X)$ es estimada desde los datos;
- ▶ el efecto marginal puede cambiar según el valor de X .



¿Qué modela $s()$ en un GAM? II



Modelo lineal

$$Y = \beta_0 + \beta_1 X$$

- ▶ pendiente constante;
- ▶ relación rígida;
- ▶ extrapolación simple.


GAM

$$Y = \beta_0 + s(X)$$

- ▶ pendiente variable;
- ▶ relaciones no lineales;
- ▶ comportamiento flexible.

Idea clave

La función $s()$ permite aprender automáticamente relaciones no lineales sin imponer explícitamente una forma funcional fija.




Spline univariado

$$Y = \beta_0 + s_1(X_1) + \varepsilon$$

Modela flexiblemente el efecto de una variable.

- ▶ Una curva ajustada.
- ▶ Un predictor principal.
- ▶ Una penalización de suavidad.



De un spline a un GAM II




GAM

$$Y = \beta_0 + s_1(X_1) + s_2(X_2) + s_3(X_3) + \varepsilon$$


Combina varios efectos lineales y no lineales.

- ▶ Una curva por predictor.
- ▶ Efectos parciales interpretables.
- ▶ Posibilidad de diferentes grados de suavidad.



Idea clave

Un GAM no compite conceptualmente con los splines: normalmente utiliza splines como componentes para construir un modelo aditivo completo.



¿Cómo se construye $s()$?




Representación mediante funciones base

La función suave normalmente se aproxima mediante:


$$s(X) = \sum_{k=1}^K \beta_k b_k(X)$$

donde:

- ▶ $b_k(X)$ son funciones base;
- ▶ los coeficientes β_k son estimados;
- ▶ la suavidad se controla mediante penalización.



La curva final se obtiene combinando múltiples funciones locales suaves.






Modelo aditivo generalizado

Un GAM típico posee la forma:

$$g(\mathbb{E}[Y]) = \beta_0 + s_1(X_1) + s_2(X_2) + \cdots + s_p(X_p)$$

donde:

- ▶ $g(\cdot)$ es la función link;
- ▶ cada $s_j(\cdot)$ es una función suave;
- ▶ cada variable puede poseer una forma funcional distinta.



Estructura matemática de un GAM II



Ejemplo lineal

$$mpg = \beta_0 + \beta_1 wt + \beta_2 hp$$

Impone:

- ▶ efecto constante;
- ▶ linealidad global.

Ejemplo GAM

$$mpg = \beta_0 + s(wt) + s(hp)$$

Permite:

- ▶ curvaturas;
- ▶ saturaciones;
- ▶ cambios de pendiente.

Idea clave


Los GAM extienden los GLM permitiendo relaciones funcionales complejas sin abandonar interpretabilidad estadística.



Identifique:

- ▶ dónde el efecto marginal parece mayor;
- ▶ dónde la relación parece aproximadamente lineal;
- ▶ dónde la curva se aplana;
- ▶ dónde existe mayor incertidumbre.

```
library(mgcv)
modelo_gam <- gam(mpg ~ s(wt) + s(hp) + am, data = mtcars)
summary(modelo_gam)
plot(modelo_gam, pages = 1, shade = TRUE)
```



¿Qué representa $s()$?

En un *Generalized Additive Model (GAM)*, la función

$$s(x)$$

representa una función suave (*smoother*) estimada desde los datos. La idea es:

$$Y = \beta_0 + f_1(X_1) + f_2(X_2) + \dots + \varepsilon$$

donde:

- ▶ las funciones $f_j(\cdot)$ no se asumen lineales,
- ▶ sino que son estimadas flexiblemente mediante splines.



R: GAM con mgcv III




En este ejemplo

$$\text{mpg} \sim s(\text{wt}) + s(\text{hp}) + \text{am}$$

- ▶ $s(\text{wt})$: efecto no lineal del peso.
- ▶ $s(\text{hp})$: efecto no lineal de la potencia.
- ▶ am : efecto lineal de transmisión manual/automática.

Alternativas a $s()$

- ▶ $\text{te}()$: tensor product smooths.
- ▶ $\text{ti}()$: interacciones suaves.
- ▶ $\text{t2}()$: smooths anisotrópicos.
- ▶ $\text{bs} = \text{"cr"}$: cubic regression splines.
- ▶ $\text{bs} = \text{"tp"}$: thin plate splines.
- ▶ $\text{bs} = \text{"ps"}$: P-splines.




Alternativas a $s()$ y cuándo se usan



Función	Qué modela	Uso típico
$s(x)$	Smooth univariado	Relación no lineal simple
$te(x,z)$	Tensor product smooth	Interacción suave entre variables con distintas escalas
$ti(x,z)$	Interacción suave pura	Separar efectos principales e interacción
$t2(x,z)$	Tensor anisotrópico	Modelos complejos multidimensionales
$s(x, bs="cr")$	Cubic regression splines	Spline cúbico clásico
$s(x, bs="tp")$	Thin plate splines	Default en mgcv; muy flexible
$s(x, bs="ps")$	P-splines	Control explícito de penalización


► ¿Cómo funcionan?






¿Qué modelo captura cada tipo de estructura?

Modelo	Forma	Control de complejidad	Salida que debemos inspeccionar
Regresión lineal	Recta o hiperplano	Número de predictores	Coefficientes, residuos, intervalos
Ridge	Lineal en las variables o bases	Penalización L_2	Trayectorias y error CV
Lasso	Lineal y disperso	Penalización L_1	Coefficientes en cero y error CV
Elastic-net	Lineal y parcialmente disperso	Combinación $L_1 + L_2$	Trayectorias, α , λ y error CV
Spline	Curva suave para una variable	Nodos, dimensión de base y penalización	Curva estimada e incertidumbre
GAM	Suma de efectos suaves	Penalización por cada smooth	Efectos parciales, EDF y diagnóstico



¿Cómo elegir entre estas alternativas?



Idea clave

La estructura observada orienta la familia de modelos, pero no reemplaza la validación fuera de muestra.



La selección del modelo no termina con la forma



Evidencia predictiva

Comparar los modelos mediante:

- ▶ error de validación cruzada;
- ▶ estabilidad entre folds;
- ▶ diferencia entre train y validación;
- ▶ desempeño final en test;
- ▶ incertidumbre de las métricas.

Evidencia diagnóstica

Revisar también:

- ▶ residuos;
- ▶ patrones no modelados;
- ▶ observaciones influyentes;
- ▶ extrapolación;
- ▶ sensibilidad a la muestra.


Criterios de implementación

La decisión industrial depende además de:

- ▶ interpretabilidad requerida;
- ▶ costo computacional;
- ▶ facilidad de actualización;
- ▶ disponibilidad futura de predictores;
- ▶ restricciones de despliegue;
- ▶ costo de los errores.

Idea clave

La elección final combina forma funcional, generalización, interpretabilidad y viabilidad operacional.




Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Fundamentos estadísticos
3. Regularización, validación cruzada y modelos flexibles
- 4. Ensemble Learning**
 - 4.1 Motivación: de un modelo a un comité de modelos
 - 4.2 Árboles como weak learners
 - 4.3 Bagging y Random Forest
 - 4.4 Interpretabilidad: más allá de la importancia de variables
 - 4.5 Boosting y combinación de modelos
5. Clasificación supervisada
6. Clasificación no supervisada
7. Cierre del curso
8. Anexos




Objetivos de aprendizaje



Al finalizar esta clase, el estudiante debería poder:


1. Comprender la motivación detrás de los métodos ensemble.
2. Explicar el concepto de *weak learner* y el rol de los árboles de decisión como modelos base.
3. Comprender cómo Random Forest introduce diversidad mediante bootstrap de observaciones y selección aleatoria de variables.
4. Interpretar medidas de importancia de variables en modelos ensemble, incluyendo PDP e ICE.
5. Implementar modelos ensemble básicos en R e interpretar sus resultados predictivos.
6. Evaluar ventajas y limitaciones de ensembles.



Problema fundamental

Un único modelo puede:

- ▶ poseer alta varianza;
- ▶ subajustar o sobreajustar;
- ▶ ser sensible al conjunto de entrenamiento;
- ▶ generalizar pobremente.



Idea de ensemble

Combinar múltiples modelos para obtener: menor error; mayor robustez; mejor generalización; menor sensibilidad al ruido.

Idea clave

Ensemble learning combina múltiples modelos débiles o inestables para construir predictores más robustos y precisos.



Árbol de regresión

Un árbol aproxima:

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

donde:

- ▶ R_m : regiones particionadas;
- ▶ c_m : promedio local;
- ▶ cada split minimiza error residual.

Weak learner

Un weak learner:


- ▶ posee capacidad predictiva limitada;
- ▶ puede tener alta varianza;
- ▶ pero combinado con otros modelos produce ensembles muy poderosos.

Idea clave


Un árbol de regresión aproxima una función compleja mediante cortes sucesivos del espacio de variables explicativas.



Árboles de regresión: partición y reglas



El árbol divide el espacio de predictores en regiones rectangulares.



Cada hoja entrega una predicción promedio local.



R: Árbol de regresión




```
library(rpart)
library(rpart.plot)
modelo_tree <- rpart(
  mpg ~ wt + hp + disp,
  data = mtcars
)
rpart.plot(modelo_tree)
```

Actividad: Interpretación

Discuta:

- ▶ ¿Qué variable aparece primero?
- ▶ ¿Qué significa un split temprano?
- ▶ ¿Qué ocurre si aumentamos la profundidad?



Bagging: Bootstrap Aggregation




Idea principal

$$\hat{f}_{bag}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(x)$$

Idea clave

Bagging reduce principalmente la varianza mediante promediado de modelos entrenados sobre muestras bootstrap.




Bootstrap sampling en Random Forest




Idea

Cada árbol se entrena con una muestra bootstrap: se seleccionan observaciones **con reemplazo**. Algunas observaciones se repiten y otras quedan fuera.



Cada árbol se entrena con una muestra distinta.

Muestras bootstrap con reemplazo: algunas observaciones se repiten y otras no aparecen.



Random feature selection

En cada split, Random Forest:

- ▶ no evalúa todas las variables disponibles;
- ▶ selecciona aleatoriamente un subconjunto;
- ▶ busca el mejor split solo dentro de ese subconjunto.

Si existen p variables:


$$mtry < p$$

Idea clave

Random Forest introduce diversidad tanto mediante bootstrap de observaciones como mediante selección aleatoria de variables.



Aleatoriedad de variables en cada árbol II



Las variables pueden repetirse entre árboles,
pero cada árbol observa subconjuntos distintos.



Idea

Una variable es importante si, al usarla en los splits de los árboles, contribuye a reducir el error predictivo del bosque.

Dos lecturas comunes

- ▶ **Reducción de impureza:** cuánto disminuye el error al dividir usando esa variable.
- ▶ **Permutación:** cuánto empeora el error si se rompe la relación entre esa variable y la respuesta.

Cuidado

Alta importancia no implica causalidad. Una variable puede ser importante porque es predictiva, proxy de otra variable o está correlacionada con el objetivo.



¿Cómo se calcula la importancia de variables?



Idea general

Una variable es importante si:

- ▶ aparece frecuentemente en los árboles;
- ▶ produce grandes reducciones del error;
- ▶ o el modelo empeora significativamente al alterar esa variable.

Mean decrease impurity

Cada vez que una variable participa en un split:

$$\Delta RSS$$

o reducción de impureza es registrada. Luego: se acumulan las reducciones; sobre todos los árboles; y sobre todos los splits.

Permutation importance

Se altera aleatoriamente una variable:

$$X_j \rightarrow \pi(X_j)$$

Si el error predictivo aumenta mucho:


$$\Delta Error \uparrow$$

la variable era importante.

Interpretación

La importancia refleja utilidad predictiva dentro del modelo, no necesariamente causalidad.

Agregación de importancia a través de muchos árboles



Idea clave

La importancia final resume cuánto contribuye cada variable a reducir error a través de muchos árboles y muchos splits.

R: Random Forest




```
library(randomForest)
modelo_rf <- randomForest(
  mpg ~ .,
  data = mtcars,
  ntree = 500
)
print(modelo_rf)
varImpPlot(modelo_rf)
```

Actividad: Interpretación

Analice:

- ▶ importancia de variables;
- ▶ error OOB;
- ▶ efecto de aumentar ntree.




De “cuánto importa” a “cómo afecta”



Limitación

La importancia indica qué tan útil es una variable para el bosque, pero no muestra en qué dirección ni con qué forma modifica la predicción.



- ▶ ICE similares: efecto relativamente homogéneo.
- ▶ ICE con pendientes o formas distintas: posible interacción.
- ▶ El PDP puede ocultar comportamientos individuales opuestos.

Idea clave

Las curvas grises (ICE) muestran cómo cambia la predicción para observaciones individuales. La curva naranja (PDP) resume el efecto promedio.

Partial Dependence Plot (PDP)

Promedia la predicción del modelo al fijar $X_j = x$ para todas las observaciones y conservar las demás variables en sus valores observados:

$$\widehat{PD}_j(x) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x, x_{i,-j}).$$

Resume el efecto promedio de X_j sobre la predicción.

Individual Conditional Expectation (ICE)

En lugar de promediar, construye una curva para cada observación:

$$\widehat{ICE}_{ij}(x) = \hat{f}(x, x_{i,-j}).$$

Muestra cómo cambiaría la predicción individual si solo variara X_j .

Idea clave

El PDP resume la tendencia promedio; las curvas ICE revelan heterogeneidad entre observaciones y posibles interacciones.





Lectura del gráfico

- ▶ Tramo creciente y pronunciado: la variable es una palanca accionable en ese rango.
- ▶ Tramo plano (saturación): seguir invirtiendo en esa variable ya no cambia mucho la predicción.
- ▶ ICE muy dispersas: el efecto de X_j depende de otras variables (interacción), y una recomendación única para todos los casos puede ser incorrecta.

Cuidado


PDP asume que se puede variar X_j manteniendo el resto fijo, lo cual puede generar combinaciones poco realistas si X_j está correlacionada con otras variables. SHAP y LIME son alternativas que explican predicciones individuales de forma local y son más robustas ante esa correlación, a costa de mayor complejidad de cómputo.

Actividad: Interpretación


Si el PDP de “horas de uso” es creciente hasta las 6 horas y luego se aplanan, ¿qué política de mantenimiento sugeriría?

Idea principal

$$f_M(x) = \sum_{m=1}^M \gamma_m h_m(x)$$



Cada nuevo modelo intenta corregir los errores cometidos por los anteriores.



R: Gradient Boosting




```
library(gbm)
modelo_gbm <- gbm(
  mpg ~ .,
  data = mtcars,
  distribution = "gaussian",
  n.trees = 300,
  interaction.depth = 3,
  shrinkage = 0.05
)
```

Actividad: Interpretación

Discuta:


- ▶ efecto de n.trees;
- ▶ efecto de shrinkage;
- ▶ sobreajuste train vs validation.



Promedio ponderado de modelos

$$\hat{f}(x) = \sum_{m=1}^M w_m \hat{f}_m(x)$$

$$\sum_{m=1}^M w_m = 1$$



Idea clave


El promedio funciona mejor cuando los modelos poseen errores poco correlacionados.



Meta-learning

$$\hat{y} = g(\hat{y}_1, \hat{y}_2, \dots, \hat{y}_M)$$

- ▶ modelos base generan predicciones;
- ▶ un meta-modelo aprende cómo combinarlas;
- ▶ el meta-modelo aprende pesos automáticamente.



Idea clave

Stacking aprende automáticamente cómo combinar modelos usando un segundo nivel de aprendizaje.



R: Stacking




```
library(caretEnsemble)
models <- caretList(
  mpg ~ .,
  data = mtcars,
  methodList = c("lm", "rf", "gbm")
)
stack <- caretStack(
  models,
  method = "glm"
)
```

Actividad: Interpretación

Discuta:

- ▶ ¿Qué modelos podrían aportar más?
- ▶ ¿Qué ocurre si todos los modelos son muy similares?
- ▶ ¿Cuándo stacking podría fallar?




Comparación conceptual de ensembles



Método	Paralelo	Secuencial	Reduce	Interpretabilidad
Bagging	Sí	No	Varianza	Media
Random Forest	Sí	No	Varianza	Baja
Boosting	No	Sí	Sesgo	Baja
Model Averaging	Sí	No	Ambos	Alta
Stacking	Parcial	Parcial	Ambos	Baja

Idea clave

No existe un ensemble universalmente mejor: la elección depende del tipo de datos, tamaño muestral, ruido, interpretabilidad y objetivo operacional.




Ejercicio interpretativo: importancia de variables



Ejercicio 1. Lectura de importance plot

Un random forest para predecir atrasos de proyectos muestra como variables más importantes: avance físico, días desde inicio, proveedor, monto y número de modificaciones contractuales.

1. ¿Cuál de estas variables podría ser causa y cuál solo señal temprana?
2. ¿Qué acción de gestión se podría tomar?
3. ¿Por qué importancia de variables no implica causalidad?
4. ¿Qué variable adicional sugeriría medir?




Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Fundamentos estadísticos
3. Regularización, validación cruzada y modelos flexibles
4. Ensemble Learning
5. Clasificación supervisada
 - 5.1 Regresión logística y SVM
 - 5.2 De la predicción a la decisión: costos y valor esperado
 - 5.3 KNN, árboles y ensambles de clasificación
6. Clasificación no supervisada
7. Cierre del curso
8. Anexos




Objetivos de aprendizaje



Al finalizar esta clase, el estudiante debería poder:

1. Formular problemas de clasificación binaria.
2. Interpretar regresión logística y odds ratios.
3. Elegir umbrales de clasificación.
4. Interpretar matriz de confusión, sensibilidad y especificidad.
5. Leer curvas ROC y AUC.
6. Entender intuición geométrica de SVM.
7. Interpretar precision, recall, F1 y balanced accuracy.
8. Detectar problemas de desbalance y leakage.




Motivación: decisiones binarias



- ▶ ¿Un producto será defectuoso?
- ▶ ¿Un pedido llegará atrasado?
- ▶ ¿Una máquina fallará esta semana?
- ▶ ¿Un cliente abandonará el servicio?

Lectura ingenieril

En clasificación, el error no es solo numérico: tiene consecuencias distintas según falso positivo o falso negativo.




¿Por qué estratificar los folds?



Problema

Si dividimos los datos aleatoriamente:

- ▶ algunos folds pueden quedar desbalanceados;
- ▶ ciertas clases pueden quedar subrepresentadas;
- ▶ la evaluación del modelo se vuelve inestable.



Idea clave

En clasificación:

90 % clase A, 10 % clase B

un fold podría contener muy pocos ejemplos de la clase minoritaria.



Stratified Cross-Validation



Idea

Cada fold debe preservar aproximadamente la proporción de clases observada en los datos originales.

Datos originales: 8 azules + 2 naranjos



Proporción: 80 % azul, 20 % naranja

Fold 1



4 azules + 1 naranja

Fold 2



4 azules + 1 naranja

Idea clave

Cada fold representa mejor la distribución original de clases.

Problema: clases desbalanceadas



Situación frecuente

En muchos problemas reales una clase es mucho más frecuente que la otra:

- ▶ fraude,
 - ▶ fallas,
 - ▶ enfermedades,
 - ▶ incumplimientos.
-
- ▶ El modelo puede favorecer la clase mayoritaria.
 - ▶ Accuracy puede ser engañosa.
 - ▶ La frontera de decisión puede ignorar la clase minoritaria.

Dataset desbalanceado




80 % clase azul

20 % clase naranja

Idea clave

Necesitamos equilibrar la representación de las clases durante el entrenamiento.



Random down-sampling





Idea

Reducir artificialmente la clase mayoritaria eliminando observaciones.

- ▶ Balancea rápidamente las clases.
- ▶ Reduce costo computacional.
- ▶ Puede eliminar información útil.

Clase mayoritaria → submuestra



Random up-sampling





Idea

Duplicar observaciones de la clase minoritaria.

- ▶ Mantiene toda la información original.
- ▶ Fácil de implementar.
- ▶ Puede inducir sobreajuste.

Clase minoritaria → duplicados



SMOTE: Synthetic Minority Over-sampling Technique





Idea

En lugar de duplicar observaciones, SMOTE genera nuevas observaciones sintéticas.

$$x_{\text{nuevo}} = x_i + \lambda(x_j - x_i)$$

donde:

- ▶ x_i y x_j son vecinos cercanos;
- ▶ $\lambda \in [0, 1]$.
- ▶ Reduce sobreajuste.
- ▶ Genera fronteras más suaves.
- ▶ Puede introducir regiones artificiales.



Estratificación con múltiples factores




Más de una dimensión importante

A veces queremos preservar simultáneamente:

- ▶ la clase objetivo;
- ▶ segmentos de clientes;
- ▶ zonas geográficas;
- ▶ niveles de riesgo;
- ▶ períodos temporales.

	Región Norte	Región Sur
Clase A		
Clase B		

Ahora los folds deben representar simultáneamente: (Clase, Región), y no solamente la clase objetivo.




R: partición train/test estratificada I



```
library(caret)
data(iris)
set.seed(123)
# Split estratificado: conserva
#   proporción de clases
idx <- createDataPartition(
  iris$Species,
  p = 0.8,
  list = FALSE
)
```

```
train <- iris[idx, ]
test <- iris[-idx, ]
# Proporciones originales
prop.table(table(iris$Species))
# Proporciones en train
prop.table(table(train$Species))
# Proporciones en test
prop.table(table(test$Species))
```




R: partición train/test estratificada II



Actividad: Interpretación

Compare la proporción de clases en la muestra original y en cada fold.

- ▶ ¿Se mantienen proporciones similares?
- ▶ ¿Por qué esto es importante en clasificación?
- ▶ ¿Qué podría ocurrir si una clase queda subrepresentada en un fold?





Problema

En clasificación binaria $Y \in \{0, 1\}$, queremos modelar:

$$\mathbb{P}(Y = 1 \mid X = x) = p(x).$$

Problema del modelo lineal

Si usamos:

$$p(x) = x^T \beta$$

podemos obtener:

$$p(x) < 0 \quad \text{o} \quad p(x) > 1.$$

Las probabilidades deben permanecer entre 0 y 1.

Transformación logística

La regresión logística modela:

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = x^T \beta$$

donde:

$$\frac{p(x)}{1 - p(x)}$$

corresponde a los **odds**.

Forma equivalente

$$p(x) = \frac{e^{x^T \beta}}{1 + e^{x^T \beta}}$$

Interpretación de coeficientes y odds ratio



Interpretación de coeficientes


En regresión logística:

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

cada coeficiente representa un cambio en **log-odds**.

Odds ratio e^{β_j}

Representa el cambio multiplicativo en los odds ante un incremento unitario en X_j .
 $e^{\beta_j} > 1$ aumenta odds. $e^{\beta_j} < 1$ disminuye odds.



relación entre variables y probabilidad es no lineal.

Idea clave

Los coeficientes no representan cambios directos en probabilidad, sino cambios en log-odds.



Decision boundary en regresión logística



Regla de clasificación


Una vez estimada la probabilidad:

$$p(x) = \mathbb{P}(Y = 1 \mid X = x)$$

debemos convertirla en una decisión.

Usualmente:

$$\hat{Y} = \begin{cases} 1 & \text{si } p(x) > 0.5 \\ 0 & \text{si } p(x) \leq 0.5 \end{cases}$$



Idea clave

La regresión logística clasifica observaciones utilizando una frontera de decisión definida por las probabilidades estimadas.



Interpretación de odds ratio



Ejercicio 1. Lectura de coeficientes

Un modelo para atraso de entrega entrega:

$$\hat{\beta}_{\text{distancia}} = 0.04$$

1. Calcule:

$$e^{0.04}$$

2. Interprete el resultado por kilómetro adicional.
3. ¿Cómo cambia la interpretación si la distancia está medida en 100 km?
4. ¿Por qué no se interpreta como cambio directo en probabilidad?



El parámetro de dispersión en GLM



Estructura general de un GLM

$$\text{Var}(Y_i) = \phi V(\mu_i),$$

- ▶ $V(\mu_i)$ es la función de varianza;
- ▶ ϕ es el parámetro de dispersión.

Caso binomial

En regresión logística: $Y_i \sim \text{Bernoulli}(p_i)$, y $\text{Var}(Y_i) = p_i(1 - p_i)$.

Interpretación de ϕ

El parámetro de dispersión controla:

- ▶ cuánta variabilidad existe;
- ▶ más allá de la explicada por la media.

Consecuencia $\phi = 1$

No se estima un parámetro adicional de varianza. La incertidumbre queda completamente determinada por p_i .

Idea clave

Varianza en regresión logística



Varianza Bernoulli

En regresión logística:


$$\text{Var}(Y_i) = p_i(1 - p_i).$$

La varianza depende de:

$$p_i = \mathbb{P}(Y_i = 1 \mid X_i).$$

- ▶ Si $p_i \approx 0$: baja incertidumbre.
- ▶ Si $p_i \approx 1$: baja incertidumbre.
- ▶ Si $p_i \approx 0.5$: máxima incertidumbre.

El modelo es más incierto cerca de la frontera de decisión.



Idea clave

La incertidumbre en clasificación es máxima cuando el modelo asigna probabilidades cercanas a 0.5.

El umbral de clasificación no siempre es 0.5




Clasificación usando probabilidades

La regresión logística estima:

$$p(x) = \mathbb{P}(Y = 1 \mid X = x)$$

Hasta ahora usamos:

$$\hat{Y} = \begin{cases} 1 & \text{si } p(x) > 0.5 \\ 0 & \text{si } p(x) \leq 0.5 \end{cases}$$



Idea clave

El umbral de clasificación controla el balance entre detectar positivos y evitar falsas alarmas. Ejemplos: fraude; churn; mantenimiento predictivo; diagnóstico médico. Formalizaremos este balance más adelante mediante costos explícitos de cada tipo de error.

Matriz de confusión



	Pred. Positivo	Pred. Negativo
Real Positivo	TP	FN
Real Negativo	FP	TN

Métricas

$$\text{Sensibilidad} = \frac{TP}{TP + FN},$$

$$\text{Especificidad} = \frac{TN}{TN + FP}.$$

Lectura ingenieril

El umbral óptimo depende del costo relativo de cada tipo de error: formalizaremos esto en la subsección “De la predicción a la decisión”.



Métricas importantes en clasificación desbalanceada



Recall (Sensibilidad)

$$Recall = \frac{TP}{TP + FN}$$

Mide qué proporción de positivos reales fue detectada. Alta sensibilidad $\Rightarrow$ menos falsos negativos.

Precision

$$Precision = \frac{TP}{TP + FP}$$

Mide qué proporción de positivos predichos realmente era positiva. Alta precisión $\Rightarrow$ menos falsas alarmas.

	Pred. Positivo	Pred. Negativo
Real Positivo	True Positive	False negative
Real Negativo	False Positive	True Negative

Trade-off

Aumentar recall muchas veces disminuye precision.

El problema de clases desbalanceadas




Situación común

En muchos problemas reales:

$$\mathbb{P}(Y = 1) \ll \mathbb{P}(Y = 0)$$

Ejemplos: fraude; churn; fallas industriales; enfermedades raras.

Clase mayoritaria



Clase minoritaria

Problema

La accuracy puede ser engañosa.

Si: 99 % “normales” un modelo que predice siempre “normal” obtiene: *Accuracy* = 99 %.

Pero: *Recall* = 0.

Consecuencia

Debemos usar métricas que evalúen correctamente:

- ▶ detección de positivos;
- ▶ falsas alarmas;
- ▶ balance entre ambas.



F1-score

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Penaliza modelos desequilibrados; exige simultáneamente buena sensibilidad y buena precisión.

Idea clave


En clasificación desbalanceada, F1-score y AUC suelen ser más informativos que accuracy.

Idea clave

#sc AUC mide capacidad global de discriminación entre clases.

AUC ROC

El área bajo la curva ROC: $AUC \in [0, 1]$.
Probabilidad de ordenar un positivo real por encima de un negativo real.



Índice de Youden en la curva ROC



Recordatorio

La curva ROC muestra, para distintos umbrales:

$$TPR = \text{Sensibilidad}$$

$$FPR = 1 - \text{Especificidad}$$


Idea clave

El índice de Youden busca el punto de la curva ROC más alejado de la línea de clasificación aleatoria.

Índice de Youden

Para cada umbral c :

$$J(c) = \text{Sensibilidad}(c) + \text{Especificidad}(c) - 1$$



Selección de umbral mediante el índice de Youden



Criterio

El umbral óptimo según Youden se define como:

$$c^* = \arg \max_c [TPR(c) - FPR(c)].$$

Umbral	Sens.	Esp.	J	Decisión
0.30	0.92	0.55	0.47	
0.50	0.78	0.76	0.54	
0.65	0.66	0.88	0.54	★
0.80	0.41	0.95	0.36	

Interpretación

El umbral c^* busca balancear:

- ▶ detectar correctamente positivos;
- ▶ evitar falsas alarmas;
- ▶ maximizar separación entre clases.

Cuidado


Youden asume implícitamente que sensibilidad y especificidad tienen igual importancia. Si los costos de error son asimétricos, el umbral debe ajustarse según el problema.

R: logística y ROC



```
library(tidyverse)
library(pROC)
data(mtcars)
mtcars$am <- factor(mtcars$am)
fit <- glm(am ~ mpg + wt + hp,
           data = mtcars,
           family = binomial)
summary(fit)
prob <- predict(fit,
                type = "response")
roc_obj <- roc(mtcars$am, prob)
auc(roc_obj)
```

```
plot(roc_obj, col = "blue", lwd = 3,
     main = "ROC Curve")
(youden <- coords(roc_obj, x = "best",
                  best.method = "youden",
                  ret = c("threshold",
                        "sensitivity",
                        "specificity")))
points(1 - youden["specificity"],
       youden["sensitivity"], pch = 19,
       col = "red", cex = 1.5)
text(1 - youden["specificity"],
     youden["sensitivity"],
     labels = "Youden optimum",
     pos = 4, col = "red")
```



Regresión logística para más de dos clases



¿Qué ocurre con tres clases?

Si existen varias clases,

$$Y \in \{A, B, C\},$$


ya no basta una sola probabilidad.

Ahora debemos estimar simultáneamente

$$P(A|x), P(B|x), P(C|x),$$

cumpliendo que

$$P(A|x) + P(B|x) + P(C|x) = 1.$$



Las probabilidades deben sumar exactamente 1.

Discusión crítica.

Pregunta ¿Cómo construir un modelo que entregue varias probabilidades coherentes al mismo tiempo?

Softmax: extensión natural de la regresión logística



Idea


Para cada clase se calcula un puntaje lineal

$$\eta_k = \beta_k^T x.$$


Softmax transforma esos puntajes en probabilidades:

$$P(Y = k|x) = \frac{e^{\eta_k}}{\sum_{j=1}^K e^{\eta_j}}.$$

- ▶ Todas las probabilidades son positivas.
- ▶ Siempre suman uno.
- ▶ La clase predicha es aquella con mayor probabilidad.



Softmax convierte los puntajes lineales en una distribución de probabilidades sobre todas las clases.



¿Por qué desaparece el umbral de discriminación?



1. Clasificación binaria

Estimamos $P(Y = 1 | x)$.

Como sólo existen dos clases,

$$P(Y = 0 | x) = 1 - P(Y = 1 | x).$$

La decisión se obtiene comparando con un umbral.

Clase	Prob.
0	0.18
1	0.82



$$0.82 > 0.5$$



Clase 1

El umbral decide entre dos clases.

2. Clasificación multiclase

Estimamos simultáneamente

$$P(A|x), P(B|x), P(C|x).$$

Todas las probabilidades compiten entre sí.

Clase	Prob.
A	0.18
B	0.27
C	0.55



$$\max(P_k)$$



Clase C

No existe un umbral fijo.



Softmax: Paso 1 — amplificar los puntajes



Puntajes lineales

Una observación recibe un puntaje para cada clase:

$$\eta_A = 1.2, \quad \eta_B = 0.7, \quad \eta_C = 2.5.$$

Estos valores pueden ser negativos, positivos o muy grandes.

¿Por qué aplicar la exponencial?

La función exponencial: e^η

- ▶ garantiza valores positivos;
- ▶ amplifica diferencias entre puntajes;
- ▶ preserva el orden de las clases.

Clase	Puntaje
A	1.20
B	0.70
C	2.50



Clase	e^η
A	3.32
B	2.01
C	12.18

Discusión crítica.

Observación La clase C sigue siendo la mejor, pero ahora la diferencia con las demás es mucho más evidente.

Softmax: Paso 2 — convertir puntajes en probabilidades



Normalización

Los valores

3.32, 2.01, 12.18

todavía no son probabilidades.

Softmax divide cada uno por la suma total:

$$3.32 + 2.01 + 12.18 = 17.51.$$

$$P(Y = k|x) = \frac{e^{\eta_k}}{\sum_j e^{\eta_j}}$$

Así obtenemos

Clase	e^{η}
A	3.32
B	2.01
C	12.18




Dividir por la suma

Clase	Prob.
A	0.19
B	0.11
C	0.70



Clase C



R: regresión logística multiclase



```
library(nnet)

# Ajustar modelo
modelo <- multinom(
  Species ~ .,
  data = iris
)

# Probabilidades para nuevas
observaciones
prob <- predict(
  modelo,
  newdata = iris[1:5, ],
  type = "probs"
)
```

```
# Clase predicha (argmax)
pred <- predict(
  modelo,
  newdata = iris[1:5, ]
)

pred
```

Discusión crítica.

Observación El modelo calcula internamente la función *Softmax*. La predicción final corresponde a la clase con la mayor probabilidad estimada (argmax).

SVM: intuición geométrica




Idea central

Support Vector Machine busca una frontera que separe clases maximizando el margen:

$$\text{margen} = \frac{2}{\|w\|}$$

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.a.} \quad y_i(w^T x_i + b) \geq 1.$$



Lectura ingenieril

SVM es útil cuando interesa una frontera de decisión robusta, incluso si la interpretación directa de coeficientes no es prioritaria.

SVM con margen suave



Cuando las clases no son perfectamente separables

Permitimos violaciones del margen mediante variables de holgura:

$$\xi_i \geq 0$$

$$y_i(w^T x_i + b) \geq 1 - \xi_i.$$

Problema de optimización


$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Rol de C

- ▶ C grande: penaliza mucho errores.
- ▶ C pequeño: acepta más errores.
- ▶ Controla el trade-off entre margen amplio y clasificación correcta.

Discusión crítica. Cuidado

Un C muy grande puede producir fronteras demasiado ajustadas a los datos de entrenamiento.



Kernels en SVM: cambiar el espacio de representación



Problema

En el espacio original, las clases pueden no ser separables linealmente.

Intuición

Un kernel permite construir fronteras no lineales en el espacio original manteniendo una separación lineal en un espacio transformado.


Kernel trick

SVM puede trabajar como si transformara los datos:


$$x \mapsto \phi(x)$$

sin calcular explícitamente $\phi(x)$. El modelo usa:

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j).$$



Decision boundaries con distintos kernels



Kernel lineal

$$w^T x + b = 0$$

Soft margin:

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

Kernel polinomial

$$K(x, z) = (\gamma x^T z + r)^d$$

Soft margin:

$$y_i f(x_i) \geq 1 - \xi_i$$

Kernel RBF

$$K(x, z) = e^{-\gamma \|x - z\|^2}$$

$$(x_1 - a)^2 + (x_2 - b)^2 = R^2$$

Kernel sigmoidal

$$K(x, z) = \tanh(\gamma x^T z + r)$$

Conexión:
frontera tipo logística

Predice clase azul



Predice clase naranja



Frontera



Márgenes



Falso positivo



Falso negativo



Support vector

Kernels más usados en SVM



Kernel	Forma	Uso típico
Lineal	$K(x, z) = x^T z$	Cuando la separación es aproximadamente lineal o hay muchas variables.
Polinomial	$K(x, z) = (\gamma x^T z + r)^d$	Cuando se esperan interacciones globales entre variables.
RBF/Gaussiano	$K(x, z) = \exp(-\gamma \ x - z\ ^2)$	Cuando la frontera puede ser compleja y local.
Sigmoidal	$K(x, z) = \tanh(\gamma x^T z + r)$	Menos común; relacionado históricamente con redes neuronales.

Discusión crítica. Cuidado

Kernels flexibles requieren validación cruzada: pueden mejorar desempeño, pero también sobreajustar.

Hiperparámetros principales en SVM




Parámetro	Dónde aparece	Interpretación
C	Todos los kernels	Penalización por errores o violaciones del margen. Alto C: frontera más ajustada. Bajo C: margen más amplio.
kernel	Todas las librerías	Define el tipo de frontera: lineal, polinomial, RBF, sigmoidal.
gamma	RBF, polinomial, sigmoidal	Controla influencia local de observaciones. Alto γ : frontera más flexible/local. Bajo γ : frontera más suave.
degree	Polinomial	Grado del polinomio. Aumentarlo permite fronteras más complejas.
coef0	Polinomial, sigmoidal	Constante adicional que modifica el peso de términos independientes.
scale	Preprocesamiento	Estandarizar variables es crítico porque SVM depende de distancias y productos internos.



```
library(caret)
library(kernlab)
data(iris)
set.seed(123)
# Split estratificado train/test
idx <- createDataPartition(
  iris$Species,
  p = 0.8,
  list = FALSE
)
train <- iris[idx, ]
test <- iris[-idx, ]
```


```
# Validación cruzada estratificada
ctrl <- trainControl(
  method = "cv",
  number = 5,
  classProbs = TRUE,
  summaryFunction = multiClassSummary,
  savePredictions = "final"
)
# Grilla de hiperparámetros para SVM RBF
grid_svm <- expand.grid(
  sigma = c(0.01, 0.05, 0.10),
  C = c(0.1, 1, 10)
)
```





```
# Entrenamiento
svm_fit <- train(
  Species ~ .,
  data = train,
  method = "svmRadial",
  trControl = ctrl,
  tuneGrid = grid_svm,
  preProcess = c("center", "scale"),
  metric = "Accuracy"
)
svm_fit
plot(svm_fit)
```

```
# Evaluación final en test
pred <- predict(svm_fit, newdata = test)
confusionMatrix(
  pred,
  test$Species
)
```




SVM multiclase: One-vs-Rest



Idea

Entrenar un clasificador para cada clase:

Clase k vs todas las demás.



Cada modelo compara una clase
contra el resto.

Para tres clases:

A vs (B, C) , B vs (A, C) , C vs (A, B) .

Decisión

Cada SVM entrega un margen. La clase con mayor margen gana:

$$\hat{y} = \arg \max_k f_k(x).$$



SVM multiclase: One-vs-One



Idea

Entrenar un clasificador para cada par de clases.

Con tres clases:

A vs B , A vs C , B vs C .


En general, con K clases se entrenan:

$$\frac{K(K-1)}{2}$$

clasificadores binarios.

Decisión

Cada clasificador emite un voto. La clase con más votos gana.



Cada comparación entrega un voto para una de las dos clases.


Estrategias para clasificación multiclase



Método	Número de modelos	Predicción	Uso habitual
Softmax	1	Mayor probabilidad	Regresión logística
One-vs-Rest	K	Mayor margen	SVM y clasificadores lineales
One-vs-One	$\frac{K(K-1)}{2}$	Mayor número de votos	SVM (implementación clásica)

Discusión crítica.

Mensaje principal La regresión logística dispone de una formulación multiclase natural mediante Softmax. Las SVM, en cambio, resuelven el problema entrenando varios clasificadores binarios y combinando sus decisiones.



La matriz de costos detrás de un umbral



Regla de Bayes con costos

Si C_{FP} es el costo de un falso positivo y C_{FN} el costo de un falso negativo, el umbral que minimiza el costo esperado es

$$\hat{Y} = 1 \quad \text{si} \quad p(x) > c^*,$$

$$c^* = \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

		Predicción	
		1	0
Real	1	0 C_{FN}	C_{FP}
	0	C_{FP}	0

- ▶ Si $C_{FN} \gg C_{FP}$, el umbral disminuye y el modelo se vuelve más sensible.
- ▶ Si $C_{FP} \gg C_{FN}$, el umbral aumenta y el modelo se vuelve más conservador.
- ▶ Cuando $C_{FP} = C_{FN}$ se recupera el umbral clásico $c^* = 0.5$.

Idea clave

El umbral óptimo depende del costo relativo de los errores. Si un falso negativo es muy costoso, el umbral disminuye para detectar más casos positivos; si un falso positivo es más costoso, el umbral aumenta para evitar falsas alarmas.




Curva de ganancia (gain) y lift

Definición

Se ordenan las observaciones por probabilidad predicha, de mayor a menor, y se calcula qué porcentaje acumulado de positivos reales se captura al contactar/inspeccionar/revisar el $x\%$ superior.

- ▶ Útil cuando el recurso (presupuesto, tiempo de inspección, cupos de contacto) es limitado.
- ▶ El lift compara esa captura contra la que lograría un modelo aleatorio.




Idea clave

Contactar al 20 % de los casos con mayor probabilidad puede capturar más de la mitad de los positivos: esta lectura es directamente accionable cuando el presupuesto solo alcanza para revisar una fracción de los casos (como en el Caso de estudio 1 de mantenimiento predictivo).



Valor esperado de la decisión en función del umbral



Idea clave

El mejor umbral no es el que maximiza accuracy, sino el que minimiza el costo esperado del proceso que el modelo apoya. Accuracy trata todos los errores como iguales; el costo esperado no.




Sesgo y equidad al automatizar decisiones con umbrales



Discusión crítica.

Un único umbral global puede tratar injustamente a subgrupos con distinta tasa base o distinta calidad de datos históricos (por ejemplo, zonas con menos mantenciones registradas, o clientes nuevos con poco historial). Antes de desplegar un modelo de clasificación en una decisión de alto impacto (crédito, selección, priorización de inspecciones), es recomendable revisar recall y precision por subgrupo relevante, no solo el promedio global, y documentar explícitamente qué trade-off de costos se está asumiendo.




Ejercicio interpretativo: umbral



Ejercicio 2. Decisión con costos

Un modelo predice probabilidad de falla de máquina. Reparar preventivamente cuesta 1; no reparar y que falle cuesta 10.

1. Calcule $c^* = C_{FP} / (C_{FP} + C_{FN})$ para este caso y compárelo con 0.5.
2. ¿Qué tipo de error es más costoso?
3. ¿Qué métrica priorizaría?
4. ¿Cómo comunicaría esta decisión al jefe de mantenimiento?



KNN: aprender por vecinos



Regla

Clasificar un punto nuevo según la mayoría de sus K vecinos más cercanos.

- ▶ KNN no estima una ecuación ni una frontera explícita.
- ▶ Guarda los datos históricos y predice por comparación local.
- ▶ La noción clave es la distancia entre observaciones.
- ▶ Requiere escalamiento de variables para que ninguna domine artificialmente.

Efecto de K

- ▶ K pequeño: baja sesgo, alta varianza.
- ▶ K grande: mayor suavizamiento, mayor sesgo.

Lectura ingenieril


Útil cuando casos históricos similares sugieren decisiones similares, por ejemplo reclamos, fraude o mantenciones.

KNN: clasificación por mayoría local



1. Se observa un nuevo punto x_{nuevo} .
2. Se calculan las distancias a los casos históricos.
3. Se seleccionan los K vecinos más cercanos.
4. Se asigna la clase mayoritaria.



$$\hat{y} = \arg \max_c \sum_{i \in N_K(x_{\text{nuevo}})} \mathbf{1}(y_i = c)$$



Ejemplo


Si $K = 5$ y entre los vecinos hay 3 azules y 2 rojos, entonces: $\hat{y} = \text{azul}$.

Árboles de clasificación: partición y reglas



Cada camino desde la raíz hasta una hoja define una regla de clasificación.

El árbol divide el espacio en regiones y asigna una clase a cada hoja.



Fronteras de decisión: árbol sin kernel




Idea

Un árbol de decisión clásico genera cortes del tipo:

$$X_j < c.$$

- ▶ Cada división usa una sola variable.
- ▶ Las fronteras son paralelas a los ejes.
- ▶ El espacio queda dividido en regiones rectangulares.
- ▶ Para capturar patrones curvos se requieren muchos cortes.



Discusión crítica.

Interpretación La ventaja es que cada regla es fácil de leer: $X_1 < 0.45$, $X_2 < 0.65$.


Fronteras de decisión: árbol con muchas particiones



Aproximación escalonada

Un árbol puede aproximar una frontera curva usando muchos cortes rectangulares.

- ▶ Mayor profundidad permite fronteras más flexibles.
- ▶ La frontera sigue siendo escalonada.
- ▶ Puede mejorar el ajuste en entrenamiento.
- ▶ También aumenta el riesgo de sobreajuste.



Discusión crítica.

Lectura El árbol no aprende una curva directamente. La aproxima mediante muchas reglas simples.

Fronteras de decisión: transformación kernel




Idea

Un árbol clásico corta con umbrales sobre variables originales:

$$X_1, X_2, \dots, X_p.$$

Con una transformación no lineal se construyen nuevas variables:

$$\phi(X) = (X_1, X_2, X_1^2, X_2^2, X_1X_2, \dots).$$




Discusión crítica.

Precaución En árboles, esto no es tan estándar como en SVM. La idea es usar variables kernelizadas o transformaciones no lineales antes del árbol.


Árbol sin kernel vs. árbol con variables no lineales



Sin transformación



Con variables no lineales



Discusión crítica.

Mensaje clave Los árboles clásicos generan fronteras rectangulares. Las transformaciones no lineales pueden hacer que reglas simples produzcan fronteras curvas en el espacio original.

Árboles de clasificación: pureza del nodo



Objetivo

Elegir cortes que separen las observaciones en nodos cada vez más puros.

Impureza de Gini

$$Gini(t) = 1 - \sum_{k=1}^K p_{k,t}^2$$

- ▶ $p_{k,t}$ es la proporción de la clase k en el nodo t .
- ▶ Un nodo puro tiene observaciones de una sola clase.
- ▶ Un buen corte reduce la impureza total de los nodos hijos.

Entropía

$$H(t) = - \sum_{k=1}^K p_{k,t} \log(p_{k,t})$$

Ganancia de pureza

$$\Delta I = I(t) - \left[\frac{n_L}{n_t} I(t_L) + \frac{n_R}{n_t} I(t_R) \right].$$

Árboles de clasificación: predicción en una hoja



Predicción por mayoría


Una nueva observación baja por el árbol hasta una hoja. La clase predicha es la clase más frecuente en esa hoja:

$$\hat{y} = \arg \max_k p_{k, \text{hoja}}.$$

Probabilidades estimadas


Además de una clase, el árbol puede entregar:

$$\hat{p}_k(x) = \frac{\#\{\text{observaciones de clase } k \text{ en la hoja}\}}{\#\{\text{observaciones en la hoja}\}}.$$



Predicción: $\hat{y} = B$

La hoja puede interpretarse como un segmento local de clientes, reclamos o equipos similares.




Random forest para clasificación



Idea

Construir muchos árboles distintos y combinar sus predicciones.

- ▶ Cada árbol se entrena con una muestra bootstrap.
- ▶ En cada división se prueba un subconjunto aleatorio de variables.
- ▶ La predicción final se obtiene por voto mayoritario.
- ▶ Las probabilidades se pueden promediar entre árboles.



Muchos árboles débiles o inestables se combinan para una decisión más robusta.

Discusión crítica.

Interpretabilidad Random forest mejora estabilidad, pero reduce interpretabilidad respecto a un árbol único.

Random forest: error OOB e importancia de variables



Out-of-bag

Como cada árbol usa una muestra bootstrap, algunas observaciones quedan fuera del entrenamiento de ese árbol.

- ▶ Esas observaciones se llaman *out-of-bag*.
- ▶ Permiten estimar error sin separar explícitamente un conjunto de validación.
- ▶ El error OOB aproxima desempeño fuera de muestra.

Importancia de variables

Random forest permite medir qué variables ayudan más a clasificar.

- ▶ Por reducción promedio de impureza.
- ▶ Por deterioro del desempeño al permutar una variable.
- ▶ Útil para interpretación exploratoria.

Discusión crítica.

Precaución La importancia de variables no implica causalidad.




Idea

Construir árboles secuencialmente. Cada nuevo árbol intenta corregir los errores cometidos por el modelo acumulado.

- ▶ Alta capacidad predictiva.
- ▶ Funciona muy bien en datos tabulares.
- ▶ Requiere validación cuidadosa.
- ▶ Puede sobreajustar si se entrena demasiado.

Árboles pequeños agregados de forma secuencial



Hiperparámetros clave

Profundidad de los árboles, número de árboles, learning rate, regularización y proporción de variables/filas usadas.


Random forest vs. gradient boosting



Aspecto	Random forest	Gradient boosting / XGBoost
Construcción	Árboles en paralelo	Árboles secuenciales
Objetivo	Reducir varianza	Reducir sesgo y error residual
Predicción	Voto o promedio	Suma ponderada de árboles
Riesgo principal	Menor interpretabilidad	Sobreajuste si no se valida bien
Tuning	Moderado	Más exigente
Uso típico	Baseline robusto	Modelo competitivo de alto desempeño

Discusión crítica.

Idea práctica Random forest suele ser una primera opción robusta. Boosting suele ganar desempeño, pero exige mejor control experimental.



Métricas para clases desbalanceadas



Métrica	Uso
Accuracy	Puede engañar si una clase domina.
Precision	De los predichos positivos, cuántos eran realmente positivos.
Recall	De los positivos reales, cuántos detectamos.
F1	Promedio armónico entre precision y recall.
Balanced accuracy	Promedia el desempeño por clase.
AUC-ROC	Evalúa ranking global, pero puede ser optimista con fuerte desbalance.
AUC-PR	Más informativa cuando la clase positiva es escasa.

Discusión crítica.


Aplicación En fraude, fallas o reclamos críticos, accuracy rara vez basta. La métrica debe reflejar el costo de equivocarse.



R: random forest de clasificación



```
library(randomForest)
library(caret)
data(iris)
set.seed(123)
idx <- createDataPartition(iris$Species, p = 0.8, list = FALSE)
train <- iris[idx,]
test <- iris[-idx,]
rf <- randomForest(Species ~ ., data = train, importance = TRUE)
pred <- predict(rf, test)
confusionMatrix(pred, test$Species)
varImpPlot(rf)
```




Ejercicio interpretativo: matriz de confusión



Ejercicio 3. Clasificación de fallas

Un modelo para detectar fallas críticas obtiene alto accuracy, pero recall de la clase falla crítica igual a 0.35.

1. ¿Por qué accuracy puede ser engañoso?
2. ¿Qué consecuencia operacional tiene bajo recall?
3. ¿Qué métrica reportaría adicionalmente?
4. Proponga dos estrategias para mejorar detección.



¿Qué clasificador utilizar? Guía práctica



Método	Conviene cuando...	Fortalezas	Debilidades	Interpretabilidad
Regresión logística	Las clases son aproximadamente separables de forma lineal.	Simple, rápida, entrega probabilidades.	No modela relaciones muy complejas.	Muy alta
KNN	Casos similares producen respuestas similares.	Flexible, sin entrenamiento explícito.	Sensible a escala, dimensión y costo de predicción.	Baja
Árbol de decisión	Se necesitan reglas fáciles de explicar.	Reglas tipo "si-entonces", captura no linealidad.	Inestable y propenso al sobreajuste.	Alta
SVM lineal	Muchas variables y frontera aproximadamente lineal.	Buen margen de separación.	No entrega probabilidades naturalmente.	Media
SVM con kernel	Las clases tienen fronteras curvas o complejas.	Captura relaciones no lineales.	Requiere elegir kernel y ajustar parámetros.	Baja
Random Forest	Se busca robustez con poco ajuste fino.	Reduce varianza e informa importancia de variables.	Menor interpretabilidad que un árbol único.	Baja
Gradient Boosting / XGBoost	La prioridad es maximizar desempeño predictivo.	Muy competitivo en datos tabulares.	Requiere tuning y validación cuidadosa.	Muy baja

Discusión crítica.

Idea central A mayor flexibilidad del modelo, normalmente mejora el desempeño predictivo, pero disminuye la interpretabilidad.

KNN: extensión a más de dos clases




Misma regla

KNN no cambia cuando hay más de dos clases:

$$\hat{y} = \arg \max_{c \in \mathcal{C}} \sum_{i \in N_K(x_{\text{nuevo}})} \mathbf{1}(y_i = c).$$

- ▶ El voto se realiza entre todas las clases presentes.
- ▶ La clase con más vecinos dentro del vecindario gana.
- ▶ Si hay empate, se define una regla adicional.



Ejemplo con $K = 7$

Azul = 2, Rojo = 3, Verde = 2.

Entonces: $\hat{y} = \text{rojo}$.

Árboles de clasificación: más de dos clases




Extensión multiclase

No cambia la lógica del árbol. En cada nodo se calcula la distribución de clases:

$$(p_{1,t}, p_{2,t}, \dots, p_{K,t}).$$

- ▶ Los criterios Gini y entropía suman sobre todas las clases.
- ▶ Cada hoja predice la clase más frecuente.
- ▶ También puede entregar probabilidades por clase.



La salida puede ser una clase o un vector de probabilidades.

Ejemplo

$$(\hat{p}_A, \hat{p}_B, \hat{p}_C) = (0.20, 0.30, 0.50) \Rightarrow \hat{y} = C.$$

Mapa del curso



INGENIERÍA
INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso

2. Fundamentos estadísticos

3. Regularización, validación cruzada y
modelos flexibles

4. Ensemble Learning

5. Clasificación supervisada

6. Clasificación no supervisada

6.1 Introducción: ¿existe estructura en los
datos?

6.2 Hard clustering


6.3 Soft clustering

6.4 Clustering jerárquico

6.5 Síntesis y comparación general

7. Cierre del curso

8. Anexos




Objetivos de aprendizaje




Al finalizar esta clase, el estudiante será capaz de:

- ▶ Formular clustering como un problema exploratorio basado en similitud o disimilitud.
- ▶ Evaluar tendencia al agrupamiento usando el test de Hopkins, antes de elegir un algoritmo.
- ▶ Aplicar e interpretar métodos de **hard clustering** (K-means, PAM, DBSCAN, HDBSCAN).
- ▶ Aplicar e interpretar métodos de **soft clustering** (Gaussian Mixture Models).
- ▶ Construir e interpretar dendrogramas mediante **clustering jerárquico** y distintas reglas de linkage.
- ▶ Seleccionar métricas de validación adecuadas a cada familia de métodos (hard, soft, jerárquico).




Flujo general de un análisis de clustering



Idea clave

En clustering no existe una “verdad” observable: distancia, escala, algoritmo y validación definen la estructura encontrada.



Antes de aplicar clustering...



Pregunta

¿Tiene sentido buscar clusters en estos datos?

No todo conjunto de datos posee grupos naturales.

Datos con estructura
(clusterizables)

Datos aleatorios
(sin clusters)

Si los datos fueran completamente aleatorios,

cualquier algoritmo producirá clusters

aunque éstos no representen una estructura real.

Lectura ingenieril

Antes de ejecutar K-means, un GMM o clustering jerárquico debemos preguntarnos si existe evidencia de agrupamiento.

Distancias: la decisión antes del algoritmo



Distancia	Uso típico	Comentarios
Euclídea	Var. continuas escaladas	Base natural de K-means. Sensible a escala y outliers.
Manhattan	Var. continuas con diferencias absolutas	Más robusta que euclídea en algunos contextos.
Mahalanobis	Var. continuas correlacionadas	Incorpora estructura de covarianza.
Bray-Curtis	Conteos, abundancias, perfiles	Útil cuando importa diferencia relativa entre perfiles.
Jaccard	Var. binarias presencia/ausencia	Ignora coincidencias de ceros.
Gower	Datos mixtos	Admite var. continuas, binarias y categóricas.

Idea clave

K-means está naturalmente ligado a distancia euclídea y variables continuas; PAM puede trabajar con una matriz de disimilitud general.



Idea intuitiva del test de Hopkins



Supongamos dos escenarios.

Datos aleatorios

Los puntos reales tienen una distribución parecida a puntos generados completamente al azar.

$\text{Puntos reales} \approx \text{Puntos aleatorios}$

Datos con clusters

Los puntos reales están mucho más cerca entre sí que puntos colocados aleatoriamente.

$\text{Puntos reales} < \text{Puntos aleatorios}$

Idea clave

Hopkins compara qué tan "especiales" son las distancias entre los datos observados respecto de una nube completamente aleatoria.



¿Cómo se calcula?



Para un subconjunto de observaciones:


1. Seleccionar m puntos reales.
2. Generar m puntos aleatorios dentro del mismo dominio.
3. Para cada punto real: calcular la distancia a su vecino más cercano.
4. Para cada punto aleatorio: calcular la distancia al punto real más cercano.
5. Comparar ambas colecciones de distancias.

$$H = \frac{\sum_i w_i}{\sum_i u_i + \sum_i w_i}$$

donde

u_i = distancia desde puntos reales

w_i = distancia desde puntos aleatorios.



El papel de la distancia



El estadístico Hopkins depende completamente de la distancia utilizada. Por ejemplo,

Euclídea

puede producir un resultado distinto de

Manhattan

si los datos presentan anisotropías o escalas diferentes.

Siempre debe utilizarse la misma distancia que posteriormente utilizará el algoritmo de clustering.

Lectura ingenieril

Interpretación del estadístico de Hopkins



Valor	Interpretación
$H \approx 0.5$	Distribución compatible con aleatoriedad
$H > 0.7$	Evidencia de agrupamiento
$H > 0.9$	Fuerte estructura de clusters
$H < 0.3$	Patrones regulares o casi uniformes

Idea clave

Hopkins no identifica cuántos clusters existen. Sólo responde la pregunta:

¿Vale la pena buscar clusters?




¿El test de Hopkins sirve para todo tipo de clustering?



Lo que realmente evalúa Hopkins

El estadístico de Hopkins no evalúa un algoritmo: evalúa los **datos**. Compara la geometría observada contra una nube generada al azar en el mismo dominio, *antes* de que exista cualquier partición o modelo.

- ▶ Se calcula sobre los datos crudos (o transformados), no sobre etiquetas de cluster.
- ▶ Por eso puede usarse como diagnóstico previo tanto para **hard clustering** (K-means, PAM, DBSCAN, HDBSCAN) como para **soft clustering** (GMM) y para **clustering jerárquico**.
- ▶ Lo que cambia entre familias no es si Hopkins “aplica”, sino qué tan informativo es el resultado.



Soft clustering vs Hierarchical clustering



Soft clustering

Un H alto sigue siendo evidencia de tendencia al agrupamiento. Pero un GMM puede ajustar componentes incluso con $H \approx 0.5$: en ese caso, las probabilidades de pertenencia serán poco informativas (cercanas a las proporciones a priori) en vez de reflejar estructura real.

Clustering jerárquico

Hopkins no depende del linkage ni de K , así que puede calcularse antes de construir el dendrograma. Si $H \approx 0.5$, cualquier corte producirá grupos artificiales, aunque el dendrograma *siempre* pueda construirse.

Idea clave

Hopkins responde una pregunta común a las tres familias: ¿existe evidencia de estructura antes de imponer una partición o un modelo? No indica cuántos clusters hay ni qué familia de algoritmos usar.



¿Siempre una observación pertenece a un único cluster?



Hasta ahora...


Todos los algoritmos estudiados asignan cada observación a **un único cluster**.

$$x_i \longrightarrow C_k$$

Es una decisión determinística.

Pregunta

¿Qué ocurre cuando una observación se encuentra entre dos grupos? ¿Es razonable obligarla a pertenecer solamente a uno?



Idea clave

La frontera entre clusters no siempre es evidente. En muchos problemas una observación podría pertenecer razonablemente a más de un grupo.

Hard clustering vs. Soft clustering



Hard clustering

Cada observación pertenece a un único cluster.

$$P(C_k|x) = \begin{cases} 1 \\ 0 \end{cases}$$

Ejemplos: i) K-means, ii) PAM, iii) DBSCAN, iv) HDBSCAN.

Soft clustering

Una observación puede pertenecer simultáneamente a varios clusters.

$$\sum_{k=1}^K P(C_k|x) = 1$$

Ejemplo:

$$P(C_1|x) = 0.35; \quad P(C_2|x) = 0.65$$

Idea clave

El cambio fundamental no es geométrico sino probabilístico: ya no buscamos decidir el cluster de una observación, sino cuantificar la incertidumbre de esa decisión.

Dos filosofías de clustering



Hard clustering

Cada observación pertenece a un único grupo.



$$x_i \rightarrow C_k$$

Produce una partición del conjunto de datos.

Soft clustering

Cada observación posee distintos grados de pertenencia.


$$x_i \rightarrow (P(C_1), \dots, P(C_K))$$



Intuición

K-means separa los datos en K grupos, de modo que cada observación quede cerca del centroide de su grupo.

1. Elegir K .
2. Inicializar K centroides.
3. Asignar cada punto al centroide más cercano.
4. Recalcular cada centroide como promedio del grupo.
5. Repetir hasta que las asignaciones no cambien.



Idea clave

El algoritmo alterna entre **asignar puntos** y **actualizar centroides**.

K-means: función objetivo y supuestos




Objetivo

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

- ▶ Minimiza la variabilidad dentro de cada cluster.
- ▶ Cada centroide es el promedio:


$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

- ▶ La distancia usual es euclidiana.
- ▶ La solución depende de la inicialización.



Idea clave


K-means es sensible a la escala, a outliers y a clusters no esféricos.



R: K-means



```
library(factoextra)
data(USArrests)
X <- scale(USArrests)
set.seed(123)
km_fit <- kmeans(X, centers = 3, nstart = 25)
km_fit$centers
km_fit$cluster
fviz_cluster(km_fit, data = X)
```




PAM / K-medoids: ¿por qué usar medoides?



Idea central

En lugar de representar cada cluster mediante un promedio, PAM utiliza una observación real del conjunto de datos.

- ▶ El representante siempre es un dato observado.
- ▶ Puede utilizar cualquier distancia.
- ▶ Es mucho menos sensible a outliers.
- ▶ Facilita la interpretación del cluster.



Idea clave

El outlier desplaza el **centroide**, pero el **medoide continúa siendo un punto representativo del cluster**.


Algoritmo PAM (Partition Around Medoids)




Algoritmo

1. Elegir K medoides iniciales.
2. Asignar cada observación al medoide más cercano.
3. Probar reemplazar un medoide por otra observación.
4. Calcular el nuevo costo total.
5. Aceptar el intercambio si mejora la solución.
6. Repetir hasta que ningún intercambio reduzca el costo.


Inicialización




Asignación



Swap



- ▶ A diferencia de K-means, PAM nunca calcula promedios.
- ▶ El representante del cluster siempre es una observación existente.



K-means vs. PAM / K-medoids: comparación técnica



Característica	K-means	PAM / K-medoids
Representante del cluster	Centroide (promedio)	Medoide (observación real)
¿El representante pertenece a los datos?	No necesariamente	Sí
Función objetivo	$\sum \ x_i - \mu_{c(i)}\ ^2$	$\sum d(x_i, m_{c(i)})$
Tipo de distancia	Normalmente euclidiana	Cualquier distancia
Sensibilidad a outliers	Alta	Baja
Costo computacional	Bajo	Mayor
Escalabilidad	Muy buena	Moderada
Forma de clusters favorecida	Esféricos	Más flexible
Interpretación	Centro promedio	Observación representativa

¿Cuándo usar K-means y cuándo usar PAM?



K-means es recomendable cuando

- ▶ Las variables son continuas.
- ▶ Los datos han sido estandarizados.
- ▶ Existen pocos outliers.
- ▶ Se trabaja con grandes bases de datos.
- ▶ Se prioriza rapidez computacional.

Rapidez

PAM es recomendable cuando

- ▶ Existen observaciones atípicas.
- ▶ Se requiere interpretar casos reales.
- ▶ Se utilizan otras métricas de distancia.
- ▶ El conjunto de datos es pequeño o mediano.
- ▶ La robustez es más importante que la velocidad.


Robustez



R: PAM / K-medoids



```
library(cluster)
library(factoextra)
data(USArrests)
X <- scale(USArrests)
d <- dist(X, method = "euclidean")
pam_fit <- pam(d, k = 3, diss = TRUE)
pam_fit$medoids
pam_fit$clustering
fviz_cluster(pam_fit, data = X)
```




¿Cuándo un centro representa bien a un cluster?




Cluster aproximadamente esférico

Un cluster es aproximadamente esférico cuando sus observaciones se distribuyen alrededor de un centro y la distancia al centro resume bien la pertenencia al grupo.

- ▶ Existe un centro representativo.
- ▶ La dispersión es similar en todas las direcciones.
- ▶ Puntos cercanos al centro tienden a pertenecer al mismo grupo.
- ▶ K-means y PAM suelen funcionar bien.



Un único centro resume adecuadamente el grupo.




Cuando un centro deja de representar bien al cluster



Cluster no esférico

Cuando la estructura es curva, alargada o concéntrica, un único centro deja de resumir adecuadamente el conjunto de observaciones.

- ▶ La distancia al centro puede ser engañosa.
- ▶ Puntos cercanos al centro pueden pertenecer a grupos distintos.
- ▶ K-means y PAM pueden cortar mal la estructura.
- ▶ Esto motiva algoritmos basados en densidad.



Idea clave

En clusters no esféricos, la pertenencia no se explica por cercanía a un centro, sino por continuidad, conectividad o densidad local.




Más formas no esféricas I



Idea


Los algoritmos basados en **centroides** o **medoides** (K-means y PAM) funcionan mejor cuando los clusters son aproximadamente esféricos. En las siguientes geometrías esta suposición se viola y las particiones pueden resultar incorrectas.

1. Dos lunas




Un centro no representa la forma curva.

2. Círculos concéntricos



Varios clusters pueden compartir el mismo centro.

3. Forma en U



La frontera impuesta puede ser demasiado simple.


Más formas no esféricas II



Idea


Cuando la pertenencia depende de la **conectividad**, la **densidad local** o la **geometría** de los datos, los métodos basados en centros pueden cortar artificialmente los clusters.

4. Cluster alargado




La dispersión depende fuertemente de la dirección.

5. Densidades diferentes



La densidad cambia entre regiones.

6. Forma compleja



Fronteras no convexas y estructura retorcida.

DBSCAN: dos parámetros, una idea geométrica




Idea central

DBSCAN forma clusters conectando puntos que viven en regiones de alta densidad.

$$N_{\epsilon}(x_i) = \{x_j : d(x_i, x_j) \leq \epsilon\}$$

$$|N_{\epsilon}(x_i)| \geq \text{minPts} \implies x_i \text{ es núcleo.}$$



Idea clave

DBSCAN no pregunta “¿cuál es el centro más cercano?”, sino “¿este punto vive en una zona suficientemente densa?”.



DBSCAN: parámetros principales



ϵ : radio de vecindad



Define qué tan lejos puede estar una observación para ser considerada vecina.

minPts: densidad mínima

Define cuántos vecinos se necesitan dentro de ϵ para declarar una región densa.

Idea

ϵ controla la escala espacial; minPts controla la exigencia de densidad.



DBSCAN: núcleo, borde y ruido



Punto núcleo


Tiene al menos minPts vecinos dentro de ϵ . Puede iniciar y expandir un cluster.

Punto borde

Pertenece a un cluster porque está cerca de un punto núcleo, pero no tiene suficientes vecinos para expandirlo.


Ruido

No pertenece a ninguna región suficientemente densa. Queda sin asignar a un cluster.






Idea clave

DBSCAN expande clusters desde puntos núcleo, incorpora puntos borde y deja como ruido las observaciones aisladas.




DBSCAN: qué ocurre al cambiar ϵ






Lectura del parámetro

ϵ define la escala local de vecindad. Si es muy pequeño, muchos puntos no alcanzan la densidad mínima. Si es muy grande, regiones distintas quedan conectadas artificialmente.



DBSCAN: qué ocurre al cambiar $minPts$




Lectura del parámetro

$minPts$ controla cuánta evidencia local se exige para declarar una región densa. Valores bajos aceptan cadenas débiles; valores altos eliminan clusters poco densos.



```
library(dbscan)
library(factoextra)
data(USArrests)
X <- scale(USArrests)
# Elegir eps con k-nearest neighbors distance plot
kNNdistplot(X, k = 4)
abline(h = 1.2, lty = 2)
db_fit <- dbscan(X, eps = 1.2, minPts = 4)
db_fit$cluster
fviz_cluster(db_fit, data = X, geom = "point")
```




DBSCAN: los parámetros se eligen juntos



Interacción

No existe un buen ε sin considerar minPts , ni un buen minPts sin considerar la escala de los datos.

- ▶ ε define el radio de vecindad.
- ▶ minPts define la densidad mínima.
- ▶ La estandarización cambia las distancias.
- ▶ Un solo ε puede fallar si las densidades son distintas.



Idea clave

Con densidades variables, DBSCAN puede detectar bien el cluster denso y perder el cluster disperso, o fusionar regiones que deberían permanecer separadas.

DBSCAN: ¿por qué un único ε puede fallar?



La dificultad

Supongamos que existen dos clusters:


- ▶ uno muy denso,
- ▶ otro mucho más disperso.

El mismo radio de búsqueda produce resultados muy distintos en ambos.


Problema

No existe un único valor de ε que funcione bien para todas las regiones del espacio.

ε pequeño



ε grande



pierde el cluster disperso puede fusionar regiones

Idea clave

El problema no es elegir un mal valor de ε ; el problema es asumir que toda la base de datos posee la misma densidad.



HDBSCAN: explorar múltiples escalas de densidad




La idea

En lugar de buscar un único valor adecuado de ε , HDBSCAN explora automáticamente una gran cantidad de escalas de densidad.

- ▶ No fija un único radio.
- ▶ Analiza cómo cambian los clusters.
- ▶ Conserva únicamente las estructuras más robustas.

Exploración automática de escalas

**HDBSCAN**

explora
todas
las escalas

Idea clave

HDBSCAN puede interpretarse como una generalización de DBSCAN que estudia simultáneamente múltiples niveles de densidad, en lugar de depender de un único valor de ε .



HDBSCAN: ¿qué ocurre cuando aumenta la densidad?



Observación

Al aumentar la exigencia de densidad, un cluster puede:

- ▶ mantenerse,
- ▶ dividirse,
- ▶ desaparecer.

Esto ocurre de manera gradual.

Densidad baja



Mayor densidad



Pregunta

Si aparecen muchos agrupamientos distintos, ¿cuáles representan estructuras reales?

Idea clave

Al modificar la densidad, un mismo grupo puede transformarse en varios subclusters. HDBSCAN registra toda esta evolución.



HDBSCAN: de las escalas nace una jerarquía




Construcción

Cada vez que aumentamos la exigencia de densidad, observamos cómo cambian los clusters.

- ▶ algunos permanecen,
- ▶ otros se dividen,
- ▶ otros desaparecen.

Registrando todas estas transformaciones se obtiene una **jerarquía de clusters**.



Idea clave

La jerarquía resume todas las divisiones que experimentan los clusters al modificar la densidad. HDBSCAN no analiza un único agrupamiento, sino toda esta evolución.



HDBSCAN: persistencia de un cluster



Persistencia


Un cluster nace cuando aparece por primera vez en la jerarquía y deja de existir cuando

- ▶ se divide,
- ▶ desaparece,
- ▶ o queda reducido a ruido.

Persistencia = tiempo que vive el cluster

Interpretación

Mientras mayor sea la persistencia, mayor evidencia existe de que el cluster corresponde a una estructura real.



Idea clave

La persistencia se interpreta como el intervalo de niveles de densidad durante el cual un cluster permanece existente antes de dividirse o desaparecer.



HDBSCAN: de la persistencia a la estabilidad




Estabilidad

No basta con que un cluster exista. También interesa:

- ▶ cuánto persiste,
- ▶ y cuántas observaciones contiene.

$$\text{Estabilidad} \approx \text{Persistencia} \times \text{Tamaño}$$



Resultado

HDBSCAN selecciona automáticamente los clusters con mayor estabilidad.

Idea clave

En la implementación original de HDBSCAN la estabilidad se calcula integrando la persistencia de las observaciones a lo largo de la jerarquía. Intuitivamente, los clusters grandes que sobreviven durante muchos niveles de densidad obtienen mayor estabilidad y son los que finalmente se conservan.

HDBSCAN: selección automática de clusters




Selección mediante estabilidad

HDBSCAN construye un **árbol condensado** y sigue cada grupo a medida que aumenta la exigencia de densidad.

Un cluster es más estable cuando:

- ▶ contiene suficientes observaciones;
- ▶ persiste durante un intervalo amplio de densidades;
- ▶ no desaparece inmediatamente después de formarse.

- ▶ No se necesita elegir un único corte.
- ▶ Las ramas persistentes se conservan.
- ▶ Las divisiones breves se descartan.
- ▶ Las observaciones sin pertenencia estable se etiquetan como ruido.



Resultado: 2 clusters estables + observaciones de ruido

Idea clave

La estabilidad no depende de un solo nivel de corte: mide durante cuánto tiempo sobrevive una rama al aumentar la exigencia de densidad.



HDBSCAN: parámetros principales




Parámetro	Efecto
min_cluster_size pequeño	Permite clusters pequeños
min_cluster_size grande	Conserva sólo grupos grandes
min_samples pequeño	Menos ruido
min_samples grande	Más ruido y clusters más robustos

Regla práctica

En muchas aplicaciones,

$$\text{min_samples} = \text{min_cluster_size}$$

es un buen punto de partida.




R: HDBSCAN



```
library(dbSCAN)
# Datos bidimensionales
X <- scale(datos)
# Ajuste del modelo
modelo <- hdbSCAN(
  X,
  minPts = 15
)
# Etiquetas obtenidas
modelo$cluster
```

```
# Probabilidad de pertenencia
modelo$membership_prob
# Visualización
plot(
  X,
  col = modelo$cluster + 1,
  pch = 19,
  main = "HDBSCAN"
)
```



¿Entonces por qué no usar siempre HDBSCAN?



La pregunta natural

Si HDBSCAN parece una extensión de DBSCAN,

¿por qué seguir utilizando DBSCAN?

Respuesta

Cuando los datos presentan una única escala de densidad, ambos algoritmos suelen producir prácticamente el mismo clustering. En ese caso, la simplicidad de DBSCAN puede ser una ventaja.

Característica	DBSCAN	HDBSCAN
Densidad homogénea	✓	✓
Densidades variables	△	✓
Elección de ε	Necesaria	No
Ruido	✓	✓
Interpretación	Muy simple	Más compleja
Tiempo de cómputo	Más rápido	Algo más lento

Discusión: ¿cómo decidir entre DBSCAN y HDBSCAN?



Ejercicio 1.

Un equipo de ciencia de datos desea identificar segmentos de clientes utilizando algoritmos de clustering basados en densidad. Antes de implementar un algoritmo surge la siguiente pregunta:

¿Cómo decidir si DBSCAN es suficiente o si conviene utilizar HDBSCAN?

1. ¿Es posible responder esta pregunta únicamente observando un gráfico de dispersión?
2. Si los datos tienen muchas variables, ¿cómo podría evaluarse la existencia de distintas escalas de densidad?
3. ¿Existe alguna herramienta estadística o exploratoria que permita detectar regiones con densidades diferentes?
4. ¿Qué conocimiento del problema o del dominio podría sugerir que un único valor de ϵ no será suficiente?
5. Si ambos algoritmos producen prácticamente el mismo resultado, ¿cuál elegiría? Justifique considerando simplicidad, interpretabilidad y costo computacional.

Validación interna de hard clustering



Índice	Qué evalúa	Criterio
Silhouette	Cohesión intra-cluster y separación al cluster vecino	Maximizar
Silhouette negativa	Observaciones posiblemente mal asignadas	Minimizar
Gap statistic	Mejora frente a distribución de referencia	Maximizar
Calinski-Harabasz	Separación inter vs cohesión intra	Maximizar
Davies-Bouldin	Similitud promedio entre clusters cercanos	Minimizar
G2 Gamma	Asociación entre distancias y partición	Maximizar
G3	Heterogeneidad interna estandarizada	Minimizar
C-index	Heterogeneidad interna frente a extremos posibles	Minimizar
Hartigan	Mejora marginal al pasar de K a $K + 1$	Maximizar

Idea clave

Ningún índice decide por sí solo: se comparan varios criterios y se contrasta con interpretabilidad operacional. Estas métricas suponen una partición dura, por lo que aplican directamente a K-means, PAM, DBSCAN, HDBSCAN, y también a clustering jerárquico una vez cortado el dendrograma.



Pregunta

Si cambio la distancia, el algoritmo o K : ¿obtengo una partición similar?.

Rand Index

Mide acuerdo entre pares de observaciones.

$$RI \in [0, 1]$$

Mayor es mejor.

Mutual Information

Mide información compartida entre dos particiones.

$$NMI \in [0, 1]$$

Mayor es mejor.

Variation of Information

Mide distancia informacional entre particiones.

$$VI \geq 0$$

Menor es mejor.

Idea clave

Estas métricas comparan particiones; no evalúan calidad absoluta del clustering.



¿Qué significa comparar particiones?



Idea

Dos algoritmos pueden producir particiones distintas:


$$\mathcal{C}^{(1)}, \quad \mathcal{C}^{(2)}$$

aunque trabajen sobre los mismos datos.


Queremos responder:

- ▶ ¿Las observaciones se agrupan de manera similar?
- ▶ ¿Los clusters son estables?
- ▶ ¿Cambiar la distancia altera la estructura?
- ▶ ¿El clustering es robusto?

Partición A



Partición B



Idea clave


Las métricas de consistencia permiten estudiar robustez y estabilidad.



¿Cuándo usar Rand, NMI o VI?



Métrica	Qué compara	Cuándo usar
Rand Index	Acuerdo entre pares de observaciones	Cuando interesa estabilidad de asignaciones entre clusters.
Mutual Information	Información compartida entre particiones	Cuando interesa similitud estructural global.
Variation of Information	Distancia informacional entre particiones	Cuando interesa cuantificar cuánto cambia la estructura.



Interpretación visual de consistencia entre particiones




Idea

Comparamos dos particiones del mismo conjunto de observaciones:


$$\mathcal{P}_1 \text{ vs. } \mathcal{P}_2.$$

- ▶ **Alta consistencia:** las observaciones quedan agrupadas de forma similar.
- ▶ **Baja consistencia:** muchas observaciones cambian de grupo.

Alta consistencia



Baja consistencia



Idea clave

La pregunta no es si los clusters “se ven bonitos”, sino si dos particiones cuentan la misma historia.




R: índices y consistencia entre particiones



```
library(cluster)
library(clusterSim)
library(mclust)
library(aricode)
library(clevr)
data(USArrests)
X <- scale(USArrests)
km2 <- kmeans(X, centers = 2, nstart =
  25)$cluster
km3 <- kmeans(X, centers = 3, nstart =
  25)$cluster
pam3 <- pam(dist(X), k = 3)$clustering
```

```
# Silhouette
sil <- silhouette(km3, dist(X))
mean(sil[, "sil_width"])
# Calinski-Harabasz
clusterSim::index.G1(X, km3)
# Davies-Bouldin
clusterSim::index.DB(X, km3)$DB
# Rand index / Adjusted Rand index
mclust::adjustedRandIndex(km3, pam3)
# Normalized Mutual Information
aricode::NMI(km3, pam3)
# Variation of Information
clevr::vi.dist(km3, pam3)
```




Gaussian Mixture Models: una nueva forma de ver los clusters



Cambio de perspectiva

Hasta ahora los clusters eran únicamente regiones del espacio. En un **Gaussian Mixture Model (GMM)**, cada cluster se modela mediante una distribución de probabilidad.

- ▶ Cada cluster tiene un centro.
- ▶ Posee una dispersión.
- ▶ Tiene una orientación.
- ▶ Puede generar nuevas observaciones.



Idea clave

En un GMM cada cluster deja de ser únicamente un conjunto de puntos y pasa a ser un modelo probabilístico capaz de describir cómo se generan los datos.

Gaussian Mixture Models: una mezcla de distribuciones




Modelo

La densidad observada se expresa como una combinación ponderada de distribuciones normales:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

Cada componente aporta una parte de la densidad total. Las ponderaciones cumplen

$$\sum_{k=1}^K \pi_k = 1.$$



Idea clave


La densidad total no corresponde a una única distribución, sino a la suma ponderada de varias componentes gaussianas.



Interpretación de los parámetros del modelo



Parámetro	Interpretación
μ_k	Centro de la componente gaussiana.
Σ_k	Forma, orientación y dispersión del cluster.
π_k	Probabilidad a priori de observar una muestra proveniente de esa componente.



Idea clave

Cada componente gaussiana queda completamente caracterizada por su peso π_k , su media μ_k y su matriz de covarianza Σ_k .



Gaussian Mixture Models: el problema de las etiquetas ocultas


Situación

Observamos las variables $x_1, x_2, \dots, x_n$ pero desconocemos qué componente gaussiana generó cada observación.

- ▶ Las observaciones son visibles.
- ▶ Las etiquetas de los clusters son ocultas.
- ▶ Debemos estimarlas junto con los parámetros del modelo.

Problema

¿Cómo estimar simultáneamente π , μ , Σ si ni siquiera sabemos a qué componente pertenece cada observación?



Idea clave

Las observaciones son conocidas, pero la componente que las generó es una variable latente. El algoritmo EM estima ambas de manera iterativa.



Expectation-Maximization (EM): la idea




Intuición

EM alterna entre dos preguntas muy simples:

1. ¿Qué componente probablemente generó cada observación?
2. Si esa asignación fuese correcta, ¿cómo deberían actualizarse los parámetros?

Repitiendo ambas etapas, el modelo mejora progresivamente.



Idea clave

EM mejora iterativamente las probabilidades de pertenencia y los parámetros del modelo hasta alcanzar una solución estable.



Expectation-Maximization: algoritmo




Inicialización

Elegir valores iniciales para

$$\pi_k, \quad \mu_k, \quad \Sigma_k.$$


Frecuentemente se utilizan los centroides obtenidos por K-means.

1. Inicializar parámetros.
2. E-step.
3. M-step.
4. Evaluar convergencia.
5. Repetir hasta estabilizar la log-verosimilitud.



Observación

Cada iteración de EM aumenta (o mantiene) la log-verosimilitud del modelo. Por ello, el algoritmo converge hacia un óptimo local.



E-step: estimar probabilidades de pertenencia




Expectation (E-step)

Suponiendo que las gaussianas actuales son correctas, calculamos para cada observación la probabilidad de haber sido generada por cada componente.

$$P(C_k | x_i)$$

Estas probabilidades reciben el nombre de **responsabilidades**.

- ▶ Ya no asignamos un único cluster.
- ▶ Cada punto reparte su pertenencia.
- ▶ Las probabilidades dependen de la posición respecto de todas las gaussianas.



Idea clave

Durante el E-step los parámetros permanecen fijos; únicamente cambian las probabilidades de pertenencia de cada observación.



M-step: actualizar las gaussianas




Maximization (M-step)

Ahora suponemos conocidas las probabilidades obtenidas en el E-step. Con ellas actualizamos

$$\mu_k, \quad \Sigma_k, \quad \pi_k.$$

Las gaussianas cambian de posición, orientación y tamaño para ajustarse mejor a los datos.



En el M-step se actualizan media y covarianza de cada componente usando las responsabilidades calculadas en el E-step.

Idea clave

Durante el M-step las probabilidades permanecen fijas y se recalculan los parámetros de cada componente gaussiana. El modelo se ajusta progresivamente a los datos.

Expectation-Maximization: evolución del modelo




Idea

EM mejora iterativamente el modelo alternando entre:

1. Estimar probabilidades de pertenencia (E-step).
2. Actualizar las gaussianas (M-step).

Cada iteración aumenta (o mantiene) la log-verosimilitud hasta alcanzar una solución estable.

- Cambian las responsabilidades de pertenencia.
- Se actualizan medias, covarianzas y proporciones.
- La solución puede depender de la inicialización.



Idea clave

En convergencia, la estimación actual y la anterior prácticamente coinciden.

Expectation-Maximization: ¿qué significa converger?



Durante cada iteración


EM realiza un ciclo: E-step $\rightarrow$ M-step.
Después de cada iteración, el modelo explica mejor los datos.

- ▶ La log-verosimilitud nunca disminuye.
- ▶ Las gaussianas cambian cada vez menos.
- ▶ Finalmente los parámetros prácticamente dejan de variar.

Idea clave


EM garantiza que la log-verosimilitud aumenta (o permanece constante) en cada iteración, hasta alcanzar una solución estable.

Log-verosimilitud



Convergencia

El algoritmo se detiene cuando la mejora entre dos iteraciones consecutivas es suficientemente pequeña.



Expectation-Maximization: óptimo local vs. óptimo global




Una limitación importante

EM mejora progresivamente el modelo, pero puede converger hacia distintos máximos dependiendo de la inicialización.

- ▶ No garantiza encontrar el mejor modelo posible.
- ▶ Puede terminar en un óptimo local.
- ▶ Distintas inicializaciones pueden producir soluciones diferentes.

En la práctica

Es habitual ejecutar EM varias veces con distintas inicializaciones y conservar la solución con mayor log-verosimilitud.



Idea clave

La convergencia de EM significa que el algoritmo encontró una solución estable, pero no necesariamente la mejor solución posible. Por ello, es recomendable utilizar múltiples inicializaciones y seleccionar el modelo con mayor log-verosimilitud.



Gaussian Mixture Models: ¿cómo elegir el número de componentes?



El problema

Hasta ahora seguimos necesitando decidir

K = número de componentes gaussianas.

Sin embargo, aumentar K siempre mejora el ajuste, pero también incrementa la complejidad del modelo.


Idea clave

En GMM no buscamos únicamente el mejor ajuste, sino el mejor compromiso entre ajuste y complejidad.

Pregunta

¿Cómo equilibrar calidad del ajuste y simplicidad del modelo?

Criterio relativo



Selección del modelo mediante BIC



Convención clásica


El Bayesian Information Criterion equilibra ajuste y complejidad:

$$BIC_{\text{clásico}} = -2 \log L + p \log n,$$

donde:

- ▶ L : verosimilitud maximizada;
- ▶ p : número de parámetros estimados;
- ▶ n : tamaño muestral.

Con esta definición, se prefiere el modelo con **menor BIC**.



Idea clave

En la fórmula clásica se minimiza el BIC; en la salida de `mclust`, que cambia el signo del criterio, se maximiza.



```
library(mclust)
```

```
X <- scale(datos)  
modelo <- Mclust(X)
```

```
summary(modelo)  
plot(modelo)
```

```
clusters <- modelo$classification  
probabilidades <- modelo$z
```


¿Qué hace Mclust?

- ▶ Ajusta varios GMM.
- ▶ Evalúa distintos valores de K .
- ▶ Calcula el BIC.
- ▶ Selecciona automáticamente el mejor modelo.
- ▶ Entrega probabilidades de pertenencia.

Salida

$$P(C_k | x_i)$$

para cada observación.



Validación de soft clustering I



Métrica	Qué evalúa	Criterio
Log-verosimilitud	Ajuste global del modelo a los datos	Maximizar (con cuidado de sobreajuste)
BIC / ICL	Ajuste penalizado por complejidad; ICL además penaliza solapamiento de clusters	Maximizar (mclust)
Entropía de las probabilidades	Incertidumbre promedio en la asignación	Minimizar
Probabilidad máxima promedio	Certeza promedio de pertenencia al cluster más probable	Maximizar
Partition Coefficient (PC)	Grado de "dureza" de la partición difusa (fuzzy c-means)	Maximizar
Partition Entropy (PE)	Desorden de la matriz de pertenencia difusa	Minimizar
Fuzzy Silhouette	Adaptación del Silhouette ponderando por el grado de pertenencia	Maximizar
Xie-Beni	Compacidad intra-cluster vs. separación mínima entre centros	Minimizar

Validación de soft clustering II




Por qué no basta con las métricas de hard clustering

Silhouette, Calinski-Harabasz o Davies-Bouldin asumen una asignación única por observación. En soft clustering esa asignación es difusa: primero habría que “endurecer” la partición (ej. asignar al cluster de mayor probabilidad) antes de aplicarlas, perdiendo la información de incertidumbre que el modelo sí capturó.

Idea clave

En soft clustering, validar no es sólo preguntar “¿la partición es buena?”, sino también “¿qué tan segura es esta partición?”.



Clustering jerárquico: idea general





Idea central

El clustering jerárquico construye una secuencia de fusiones hasta obtener un único cluster.

- ▶ No requiere fijar K inicialmente.
- ▶ Resume las fusiones mediante un dendrograma.
- ▶ Requiere una distancia entre puntos.
- ▶ Requiere una regla de *linkage*.

Ventaja


Podemos elegir K cortando el dendrograma a una altura deseada.



Clustering jerárquico: proceso aglomerativo I



Paso 1: cada observación comienza como su propio cluster




Al inicio hay tantos clusters como observaciones: n observaciones $\Rightarrow n$ clusters.



Clustering jerárquico: proceso aglomerativo II



Paso 2: se fusionan los clusters más cercanos



Cada fusión depende de una distancia entre clusters: por ejemplo, single, complete, average o Ward.



Clustering jerárquico: proceso aglomerativo III



Paso 3: las fusiones continúan de forma iterativa



siguiente fusión




En cada iteración disminuye el número de clusters en una unidad.



Clustering jerárquico: proceso aglomerativo IV



Paso 4: el dendrograma registra la historia de fusiones



Cortar el dendrograma a distintas alturas produce distintos números de clusters.

¿Qué es el linkage?




Pregunta central

Dados dos clusters:

C_a , C_b ,

¿cómo definimos la distancia
entre ellos?



- Single: mínima distancia
- Complete: máxima distancia
- - - Centroid: distancia entre centroides

Idea clave

Distintas reglas de linkage producen dendrogramas distintos sobre los mismos datos.



Single linkage: vecino más cercano




Definición


$$d(C_a, C_b) = \min_{x \in C_a, y \in C_b} d(x, y).$$

- ▶ Usa los puntos más cercanos.
- ▶ Puede unir grupos mediante puentes.
- ▶ Tiende a generar el efecto *chaining*.
- ▶ Útil para formas alargadas, pero sensible a ruido.

Intuición: “nearest neighbor”.



Una secuencia de puntos cercanos puede terminar fusionando grupos lejanos.



Complete linkage: vecino más lejano




Definición


$$d(C_a, C_b) = \max_{x \in C_a, y \in C_b} d(x, y).$$

- ▶ Usa los puntos más lejanos.
- ▶ Favorece clusters compactos.
- ▶ Reduce el efecto *chaining*.
- ▶ Puede separar estructuras alargadas.

Intuición: “furthest neighbor”.



La fusión solo ocurre si todo el conjunto resultante sigue siendo relativamente compacto.




Average linkage: distancia promedio




Definición

$$d(C_a, C_b) = \frac{1}{|C_a||C_b|} \sum_{x \in C_a} \sum_{y \in C_b} d(x, y).$$

- ▶ Promedia todas las distancias cruzadas.
- ▶ Balance entre single y complete.
- ▶ Suele ser estable en práctica.
- ▶ Menos sensible a un único par extremo.



La distancia entre clusters resume todas las distancias punto a punto.



Ward linkage: mínima varianza intra-cluster




Idea


Fusiona clusters minimizando el aumento de la suma de cuadrados intra-cluster:

$$\Delta RSS.$$

- ▶ Muy relacionado con K-means.
- ▶ Favorece clusters compactos.
- ▶ Favorece grupos relativamente balanceados.
- ▶ Natural con distancia euclídea.



Ward elige la fusión que menos aumenta la dispersión interna total.




Impacto del linkage



¿Lo sabías?

El mismo conjunto de datos puede producir dendrogramas diferentes según la regla de linkage.



Discusión crítica.

Cuidado No existe un linkage universalmente mejor: depende de la forma esperada de los clusters y del objetivo del análisis.

¿Cómo elegir el linkage?



Guía práctica

- ▶ Si se esperan clusters compactos: Ward o complete.
- ▶ Si se esperan formas alargadas: single puede capturarlas, con cuidado.
- ▶ Si se busca una opción robusta general: average.
- ▶ Si hay ruido o puentes: evitar single.

¿Clusters compactos y aproximadamente esféricos?

Ward
o complete

¿Riesgo de cadenas, ruido o puentes?

Evitar
single

¿Necesitas un método simple y estable?

Average

Probar varios linkages y justificar con dendrograma, coherencia e interpretación.

Discusión crítica.

Recomendación Probar más de una regla y comparar dendrogramas, estabilidad e interpretación.

Comparación conceptual de linkages



Linkage	Idea	Comportamiento	Sensibilidad
Single	Distancia mínima	Chaining, formas alargadas	Muy sensible a ruido
Complete	Distancia máxima	Clusters compactos	Menos chaining
Average Ward	Promedio de distancias Minimiza aumento de varianza	Balanceado y estable Clusters esféricos y compactos	Intermedio Sensibilidad a escala

Idea clave


En clustering jerárquico, cambiar el linkage puede producir particiones completamente distintas aun usando la misma distancia.

R: clustering jerárquico y linkages



```
library(cluster)
library(factoextra)
data(USArrests)
X <- scale(USArrests)
d <- dist(X, method = "euclidean")
hc_single <- hclust(d, method = "
  single")
hc_complete <- hclust(d, method = "
  complete")
hc_average <- hclust(d, method = "
  average")
hc_ward <- hclust(d, method = "ward.
  D2")
```

```
plot(hc_single)
plot(hc_complete)
plot(hc_average)
plot(hc_ward)
fviz_dend(hc_ward, k = 4)
```



Validación de clustering jerárquico



Correlación cofenética

Mide qué tan bien el dendrograma preserva las distancias originales:

$$c = \text{cor}(d(x_i, x_j), d_{\text{cof}}(x_i, x_j))$$

donde d_{cof} es la altura a la que dos observaciones se fusionan por primera vez.


- ▶ c cercano a 1: el dendrograma representa fielmente las distancias.
- ▶ c bajo: la estructura jerárquica distorsiona la geometría original.
- ▶ Permite comparar linkages entre sí (single vs. average vs. Ward).

Coeficiente aglomerativo (AC)

Resume qué tan marcada es la estructura de clusters detectada por el algoritmo aglomerativo, comparando las alturas de fusión de cada observación frente a la fusión final.

Después de cortar el dendrograma


Al fijar una altura de corte se obtiene una partición dura. A partir de ahí, todas las métricas de hard clustering (Silhouette, Calinski-Harabasz, Davies-Bouldin, Gap statistic) y las métricas de consistencia (Rand, NMI, VI) vuelven a ser aplicables.



R: validación de clustering jerárquico



```
library(cluster)
# Correlacion cofenetica
d <- dist(X, method = "euclidean")
hc_ward <- hclust(d, method = "ward.D2")
d_cof <- cophenetic(hc_ward)
cor(d, d_cof)
# Coeficiente aglomerativo
agnes_ward <- agnes(X, method = "ward")
agnes_ward$ac
# Particion tras cortar el dendrograma
grupos <- cutree(hc_ward, k = 3)
sil <- silhouette(grupos, d)
mean(sil[, "sil_width"])
```




Ejercicio: elección de linkage



Ejercicio 2. Interpretación geométrica

Discuta qué linkage usaría en cada situación:


1. Detección de grupos alargados en rutas logísticas.
2. Segmentación de clientes compactos y bien separados.
3. Datos con mucho ruido y outliers.
4. Clusters aproximadamente esféricos similares a K-means.
5. Exploración descriptiva donde no se conoce la geometría.



Resumen: ¿cuándo usar cada método?



Método	Representante	Distancias / datos	Complejidad
K-means	Centroide	Euclídea, continuos escalados	Baja
PAM	Medoide	Cualquier disimilitud	Alta
CLARA	Medoide en muestras	Cualquier disimilitud	Media-alta
CLARANS	Búsqueda aleatoria de medoides	Cualquier disimilitud	Media
DBSCAN	Densidad	Usualmente euclídea; depende de escala	Media
GMM	Media y covarianza	Continuos; supuesto gaussiano	Media
Fuzzy C-means	Centroide difuso	Usualmente euclídea	Media
Jerárquico	Dendrograma	Cualquier distancia + linkage	Alta





Resumen técnico de los algoritmos de clustering



Característica	K-means	PAM	DBSCAN	HDBSCAN	GMM
Tipo	Hard	Hard	Hard	Hard	Soft
Representación	Centroide	Medoide	Región densa	Persistencia	Distribución gaussiana
Forma esperada	Esférica	Flexible	Arbitraria	Arbitraria	Elíptica
Detecta ruido	No	No	Sí	Sí	Parcial
Tolera outliers	Baja	Alta	Alta	Alta	Media
Densidades variables	No	No	Limitado	Sí	Limitado
Entrega probabilidades	No	No	No	No	Sí
Parámetros	K	K	ϵ , minPts	min_cluster_size	EM + BIC
Escalabilidad	Muy alta	Media	Alta	Media	Media




¿Cómo elegir un algoritmo de clustering?



La hipótesis detrás de cada algoritmo



Algoritmo	Hipótesis	Palabra clave
K-means	Los clusters son aproximadamente esféricos.	Centro
PAM	Existe un representante real del grupo.	Representante
DBSCAN	Los clusters son regiones densas.	Vecindad
HDBSCAN	Los clusters persisten a distintas escalas de densidad.	Estabilidad
Gaussian Mixture Models	Los datos provienen de una mezcla de gaussianas.	Probabilidad
Jerárquico (linkage)	Existen relaciones de anidamiento que se revelan a distintas alturas de fusión.	Jerarquía



Ejercicio 1: selección de distancia



Ejercicio 3. Distancia y tipo de datos

Usted dispone de una base de productos con:

- ▶ precio promedio;
- ▶ rotación mensual;
- ▶ categoría del producto;
- ▶ indicador de promoción;
- ▶ margen.

Discuta:

1. ¿Tiene sentido usar K-means directamente?
2. ¿Qué distancia usaría si hay variables mixtas?
3. ¿Qué ventajas tendría PAM sobre K-means?
4. ¿Qué variables deberían escalarse antes de calcular distancias?


Ejercicio 2: interpretación de métodos



Ejercicio 4. Elegir algoritmo

Para cada situación, proponga un método:

1. Segmentación de clientes con variables continuas bien escaladas y clusters compactos.
2. Segmentación con variables mixtas y presencia de outliers.
3. Identificación de zonas anómalas en patrones de fallas.
4. Clusters elípticos con pertenencia probabilística.
5. Segmentación donde un cliente puede pertenecer parcialmente a dos perfiles.




Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Fundamentos estadísticos
3. Regularización, validación cruzada y modelos flexibles
4. Ensemble Learning
5. Clasificación supervisada
6. Clasificación no supervisada
7. Cierre del curso
8. Anexos



Del modelo a la operación: monitoreo continuo




El ciclo no termina en la decisión

Una vez implementado un modelo o una decisión basada en datos, la pregunta cambia:

¿sigue siendo válida esta decisión?

- ▶ Los datos cambian: *data drift*.
- ▶ La relación entre X y Y cambia: *concept drift*.
- ▶ El contexto operacional cambia: nuevos proveedores, nuevas políticas, nueva competencia.



Lectura ingenieril

Un modelo que funcionó ayer no garantiza funcionar mañana: el monitoreo convierte un proyecto puntual en una capacidad sostenible.

Señales de alerta y respuesta



Señal	Posible respuesta
Caída sostenida en métricas de desempeño	Revisar supuestos, reentrenar con datos recientes.
Cambio en la distribución de variables de entrada	Investigar causa operacional antes de reentrenar automáticamente.
Cambio en el comportamiento de subgrupos	Revisar equidad y desempeño diferenciado.
Nuevas categorías o valores no vistos	Actualizar preprocesamiento y validar impacto.

Discusión crítica.

Cuidado Reentrenar automáticamente sin supervisión puede propagar sesgos o errores operacionales tan rápido como corrige el desajuste original.






Los modelos no toman decisiones.

Ayudan a tomar mejores decisiones bajo incertidumbre.

Lectura ingenieril

La ventaja profesional no está en saber ejecutar un comando, sino en saber formular la pregunta, validar el resultado e interpretar sus consecuencias.





INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE




Mapa del curso



INGENIERÍA
INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

1. Bienvenida al curso
2. Fundamentos estadísticos
3. Regularización, validación cruzada y modelos flexibles
4. Ensemble Learning
5. Clasificación supervisada
6. Clasificación no supervisada
7. Cierre del curso
8. Anexos




Smooth univariado

La función suave se aproxima mediante una combinación de funciones base:

$$s(X) = \sum_{k=1}^K \beta_k b_k(X)$$

donde:

- ▶ $b_k(X)$ son funciones base locales;
- ▶ β_k son coeficientes estimados;
- ▶ la suavidad se controla penalizando curvatura.



Ejemplo:

$$Y = \beta_0 + s(X) + \varepsilon$$

Contexto de uso

Cuando una variable tiene un efecto no lineal sobre la respuesta: saturación, umbrales o cambios de pendiente.

Anexo: Construcción de $te(x,z)$


Tensor product smooth

Cuando dos variables continuas interactúan suavemente:

$$f(X, Z) = \sum_{k=1}^K \sum_{\ell=1}^L \beta_{k\ell} b_k(X) c_{\ell}(Z)$$

El modelo puede escribirse como:

$$Y = \beta_0 + te(X, Z) + \varepsilon$$



una superficie suave:

$$\mathbb{E}(Y|X, Z) = \beta_0 + f(X, Z)$$

Contexto de uso

Se usa cuando X y Z tienen distintas unidades o escalas, por ejemplo: temperatura y humedad; precio y demanda histórica; antigüedad de máquina y carga operacional.

Anexo: Construcción de $ti(x,z)$ 


Interacción suave pura

$ti()$ se usa cuando queremos separar:

$$Y = \beta_0 + s(X) + s(Z) + ti(X, Z) + \varepsilon$$

donde:

- ▶ $s(X)$: efecto principal de X ;
- ▶ $s(Z)$: efecto principal de Z ;
- ▶ $ti(X, Z)$: interacción adicional entre ambas.



Ejemplo:

$$Y = \beta_0 + s(temp) + s(humedad) + ti(temp, humedad) + \varepsilon$$

Contexto de uso

Útil cuando los efectos principales ya están incluidos y queremos modelar solo la interacción residual.

Anexo: Construcción de $t_2(x, z)$


Tensor product alternativo

$t_2()$ también modela superficies suaves:

$$f(X, Z) = \sum_{k, \ell} \beta_{k\ell} b_k(X) c_\ell(Z)$$

pero usa una parametrización distinta, conveniente para modelos más complejos o estructuras anisotrópicas.

$$Y = \beta_0 + t_2(X, Z) + \varepsilon$$



Ejemplo:

$$Y = \beta_0 + t_2(\text{carga}, \text{temperatura}) + \varepsilon$$

Contexto de uso

Se usa cuando el efecto suave multidimensional tiene distinta complejidad por dimensión o cuando se requiere mayor control numérico.

Anexo: Construcción de $bs = "..."$ 


Tipo de base para construir el smooth

La opción bs no cambia la idea del GAM, sino la familia de funciones base:

$$s(X) = \sum_{k=1}^K \beta_k b_k^{(bs)}(X)$$

Ejemplos:

- ▶ $bs = "tp"$: thin plate regression spline;
- ▶ $bs = "cr"$: cubic regression spline;
- ▶ $bs = "ps"$: P-spline;
- ▶ $bs = "cc"$: spline cíclico.



Ejemplo:

$$Y = \beta_0 + s(X, bs="cr") + \varepsilon$$

Contexto de uso

bs se elige según la estructura esperada: suavidad general; continuidad cíclica; control explícito de nodos; eficiencia computacional.


Definición

Para dos observaciones:

$$x = (x_1, \dots, x_p), \quad y = (y_1, \dots, y_p)$$

la distancia euclídea es:

$$d(x, y) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$




- ▶ Distancia geométrica usual.
- ▶ Sensible a escala.
- ▶ Base natural de K-means.
- ▶ Favorece clusters esféricos.

Ejemplo:

$$x = (1, 1),$$

$$y = (3.5, 3)$$




Anexo: Distancia Manhattan




Definición

$$d(x, y) = \sum_{j=1}^p |x_j - y_j|$$

- ▶ También llamada distancia L_1 .
- ▶ Basada en diferencias absolutas.
- ▶ Más robusta a outliers que euclídea.
- ▶ Interpretación tipo “distancia en calles”.



$$d(x, y) = 3 + 2 = 5$$





Definición

$$d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$

- ▶ Ajusta por correlaciones.
- ▶ Penaliza menos direcciones con alta variabilidad.
- ▶ Útil cuando variables están correlacionadas.

Si dos variables están altamente correlacionadas, diferencias en esa dirección son menos “sorprendentes”.



Anexo: Distancia Bray-Curtis



Definición

$$d(x, y) = \frac{\sum_{j=1}^p |x_j - y_j|}{\sum_{j=1}^p (x_j + y_j)}$$


- ▶ Muy usada en abundancias y perfiles.
- ▶ Compara composición relativa.
- ▶ Ignora magnitud absoluta total.
- ▶ Acotada entre 0 y 1.

Ejemplo:

$$x = (10, 20, 70)$$

$$y = (100, 200, 700)$$

Tienen distinta escala, pero el mismo perfil relativo.




Definición

Para variables binarias:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$


Distancia:

$$d(A, B) = 1 - J(A, B)$$



J= $\frac{\text{intersección}}{\text{unión}}$

- Muy usada en presencia/ausencia.
- Ignora coincidencias de ceros.
- Importa lo que aparece, no lo que falta.



Anexo: Distancia Gower



Idea

Permite combinar:

- ▶ variables continuas;
- ▶ binarias;
- ▶ ordinales;
- ▶ categóricas.

Variable	Obs 1	Obs 2
Edad	25	30
Región	Norte	Sur
Promo	Sí	No
Ventas	120	130

Distancia combinada
entre variables mixtas

$$d(x, y) = \frac{\sum_j w_j d_j(x_j, y_j)}{\sum_j w_j}$$

- ▶ Muy útil en datos industriales reales.
- ▶ Base natural para PAM y clustering jerárquico.

